

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



XÂY DỰNG BỘ DỮ LIỆU, HUẤN LUYỆN
MÔ HÌNH NHẬN BIẾT NGÔN NGỮ ĐỘC HẠI
VÀ PHẢN ĐỘNG TRONG TIẾNG VIỆT

MÔN HỌC: CÁC VẤN ĐỀ HIỆN ĐẠI TRONG CÔNG NGHỆ THÔNG TIN

HÀ NỘI - 2024

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



XÂY DỰNG BỘ DỮ LIỆU, HUẤN LUYỆN
MÔ HÌNH NHẬN BIẾT NGÔN NGỮ ĐỘC HẠI
VÀ PHẢN ĐỘNG TRONG TIẾNG VIỆT

MÔN HỌC: CÁC VẤN ĐỀ HIỆN ĐẠI TRONG CÔNG NGHỆ THÔNG TIN

Giảng viên : ***Nguyễn Đức Anh***

Nhóm sinh viên thực hiện: ***Nguyễn Minh Hiếu***

Ngô Văn Kiệt

Quách Lê Hải Anh

Phạm Anh Tuấn

HÀ NỘI – 2024

PHÂN CÔNG CÔNG VIỆC

Mã sinh viên	Họ và tên	Công việc	Phần trăm công việc
22022609	Nguyễn Minh Hiếu	Nhóm trưởng, crawl data, code model, làm slide thuyết trình giữa kỳ, viết báo cáo chính.	45%
22022643	Ngô Văn Kiệt	Crawl data, làm slide thuyết trình giữa kỳ, code model, đóng góp viết báo cáo	15%
21020750	Quách Lê Hải Anh	Crawl data, code web, đóng góp viết báo cáo	18%
21020397	Phạm Anh Tuấn	Crawl data, code web, đóng góp viết báo cáo	22%

LỜI CAM ĐOAN

Chúng em xin cam đoan đề tài “Xây dựng bộ dữ liệu, huấn luyện mô hình nhận biết ngôn ngữ độc hại và phản động trong Tiếng Việt” được thực hiện trực tiếp bởi nhóm, các nội dung, kết quả trong đề tài này đều là trung thực và chưa từng được công bố dưới bất kỳ hình thức nào trước đây.

Tất cả những tài liệu tham khảo phục vụ cho đề tài đều được nêu nguồn gốc rõ ràng trong mục tài liệu tham khảo và không có việc sao chép tài liệu hoặc đề tài khác mà không ghi rõ về tài liệu tham khảo, đồng thời không sử dụng ChatGPT hay AI nào để thực hiện viết báo cáo.

Nếu có bất kỳ phát hiện nào về việc sử dụng ChatGPT hay AI nào để thực hiện viết báo cáo trong đề tài này, chúng em xin hoàn toàn chịu trách nhiệm .

Sinh viên

Sinh viên

Sinh viên

Sinh viên

MỤC LỤC

PHÂN CÔNG CÔNG VIỆC.....	i
LỜI CAM ĐOAN.....	ii
MỤC LỤC	iii
DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT	v
DANH MỤC CÁC BẢNG	vi
DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ.....	vii
MỞ ĐẦU	viii
CHƯƠNG 1. BỐI CẢNH CHUNG	2
1.1 Sự phát triển của mạng xã hội và ngôn ngữ độc hại.....	2
1.1.1 Sự phát triển mạnh mẽ của mạng xã hội.....	2
1.1.2 Văn hóa ứng xử của giới trẻ trên mạng xã hội	3
1.2 Định nghĩa về ngôn ngữ độc hại.....	4
1.3 Tổng quan bài toán HSD.....	5
Chương 2: BỘ DỮ LIỆU.....	7
2.1 Thu thập dữ liệu.....	7
2.1.1 Nguồn dữ liệu	7
2.1.2 Guideline gán nhãn	7
2.2 Các bộ dữ liệu có sẵn	9
2.3 Trực quan hóa dữ liệu	12
Chương 3: PHƯƠNG PHÁP THỰC NGHIỆM	13
3.1 Cơ sở lý thuyết.....	13
3.1.1. Các phương pháp học máy (Machine Learning)	13
3.1.2 Các phương pháp học sâu (Deep Learning)	16
3.1.3 Word Embedding	20
3.1.4 PhoBERT	21

3.1.5 Chỉ số đánh giá hiệu suất.....	23
3.2 Tiền xử lý dữ liệu.....	24
3.3 Modeling	26
Chương 4. KẾT LUẬN	30
4.1 Kết quả huấn luyện.....	30
4.2 Hạn chế và hướng phát triển	31
4.3 Xây dựng website nhận biết ngôn ngữ văn bản độc hại.....	32
PHỤ LỤC.....	35
TÀI LIỆU THAM KHẢO	36

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

STT	Từ viết tắt	Từ đầy đủ	Ý nghĩa
1	HSD	Hate Speech Detection	Phát hiện lời nói thù địch
2	ML	Machine Learning	Học máy
3	RF	Random Forest	Rừng ngẫu nhiên
4	DT	Decision Tree	Cây quyết định
5	DL	Deep Learning	Học sâu

DANH MỤC CÁC BẢNG

Bảng 2.1: Guideline gán nhãn.....	9
Bảng 2.2: Ví dụ về bộ dữ liệu sau khi gán nhãn.	9
Bảng 2.3: Ví dụ về bộ dữ liệu UIT – ViCTSD	10
Bảng 2.4: Ví dụ về bộ dữ liệu ViHOS.....	11
Bảng 2.5: Ví dụ về bộ dữ liệu ViHSD.....	11
Bảng 2.6: Tổng quan về các bộ dữ liệu	12
Bảng 3.1: Ví dụ teen-code	26
Bảng 3.2: Kết quả huấn luyện.....	30

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

Hình 1.1 Tổng quan quy trình bài toán HSD	6
Hình 2.1 Biểu đồ phân bố nhãn Toxic và Non-Toxic.....	12
Hình 3.1 Minh họa về KNN.....	13
Hình 3.2 Minh họa Kernel Trick trong SVM	14
Hình 3.3 Phân nhánh 1 điểm dữ liệu tại các nút của mô hình Cây quyết định	15
Hình 3.4 Sơ đồ khối quá trình phân loại của mô hình Rừng ngẫu nhiên.....	15
Hình 3.5 Y. Kim."Convolutional Neural Networks for Sentence Classification" [2014].....	16
Hình 3.6 Đồ thị hàm kích hoạt Relu.....	17
Hình 3.7 Ví dụ kiến trúc CNN trong phân loại văn bản.....	18
Hình 3.8 Minh họa khối nhớ mô hình GRU (Nguồn: Liu et al.,2019)	20
Hình 3.9 Minh họa về PhoBert	23
Hình 3.10 Ma trận nhầm lẫn	23
Hình 3.11 Quy trình tiền xử lý dữ liệu	25
Hình 3.12 Hướng tiếp cận Transformer.....	27
Hình 4.1 Confusion Maxtric của mô hình CNN – PhoBert và GRU – PhoBert	30
Hình 4.2. Thực nghiệm kiểm tra câu mang ý nghĩa thô tục.....	30
Hình 4.3. Thực nghiệm kiểm tra câu mang ý nghĩa phân biệt vùng miền	30
Hình 4.4. Thực nghiệm kiểm tra câu có nội dung phản động (1).....	31
Hình 4.5. Thực nghiệm kiểm tra câu có nội dung phản động (2).....	31

MỞ ĐẦU

Cuộc sống, học tập và sinh hoạt hàng ngày của giới trẻ hiện nay đều bị ảnh hưởng bởi việc sử dụng mạng xã hội. Trong thời đại công nghệ số, mạng xã hội mang lại rất nhiều lợi ích nhưng không phải ai cũng sử dụng mạng xã hội một cách có văn hóa và có trách nhiệm. Mạng xã hội chính là “con dao hai lưỡi” khi nó là nơi để con người kết bạn, kết nối với nhau, thoải mái chia sẻ cảm xúc của mình nhưng chính sự “tự do ngôn luận” này cũng khiến đây là nền tảng của những phát ngôn vô văn hóa, của những bình luận xúc phạm, lăng mạ, sỉ nhục, bạo lực mạng đến các cá nhân, tổ chức, và thậm chí, đáng báo động hơn là sự tuyên truyền các thông tin sai sự thật, không chính thống, đả đảo chính quyền, cách mạng màu của các thế lực thù địch. Trước thực trạng đáng báo động, việc làm cấp thiết ngay lúc này là cần nhận biết, xóa bỏ những bình luận, bài đăng độc hại này để tránh những nội dung này lây lan nhanh chóng, ảnh hưởng tiêu cực đến mọi người, xã hội.

Trong nghiên cứu này, chúng em xây dựng, đóng góp vào bài toán Hate Speech Detection trong Tiếng Việt, với mục đích là nhận biết những bình luận độc hại hoặc nội dung phản động trên mạng xã hội. Chúng em tập trung phát triển bộ dữ liệu, thu thập dữ liệu từ Facebook và gán nhãn thủ công, xây dựng bộ dữ liệu phong phú, đa dạng, có giá trị; đồng thời sử dụng các phương pháp, hướng tiếp cận khác nhau trong lĩnh vực xử lý ngôn ngữ tự nhiên như các phương pháp học máy, học sâu, transformer,... để phân loại các bình luận độc hại, phản cảm và xúc phạm trên nền tảng mạng xã hội, tạo ra một không gian internet văn minh, lịch sự hơn. Đề tài này cũng đạt hiệu suất khả quan khi kết hợp mô hình DL với mô hình pretrained lớn trong Tiếng Việt PhoBert đạt Accuracy xấp xỉ 88% và điểm F1 87%.

Đề tài có 4 nội dung được tóm tắt như sau:

Chương 1: GIỚI THIỆU CHUNG

Chương 1 giới thiệu về sự phát triển của mạng xã hội trên thế giới nói chung và tại Việt Nam nói riêng, đồng thời giới thiệu sự phát triển của ngôn ngữ độc hại trên nền tảng này. Chương 1 cũng định nghĩa cụ thể hơn về ngôn ngữ độc hại trong Tiếng Việt, giới thiệu về bài toán HSD và các nghiên cứu liên quan đến bài toán này.

Chương 2: BỘ DỮ LIỆU

Chương này trình bày về quá trình thu thập dữ liệu từ nền tảng mạng xã hội Facebook; quá trình xây dựng guideline gán nhãn để đảm bảo dữ liệu được gán nhãn chính xác, nhất quán. Đồng thời, giới thiệu các bộ dữ liệu có sẵn; trực quan hóa dữ liệu

Chương 3: PHƯƠNG PHÁP THỰC NGHIỆM

Chương này giới thiệu các cơ sở lý thuyết của các phương pháp ML; DL; Tranformer;....được sử dụng trong đề tài này. Đồng thời, giới thiệu về các tham số, kiến trúc mô hình sử dụng.

Chương 4: KẾT LUẬN

Đưa ra kết quả của các mô hình sau khi huấn luyện; so sánh hiệu suất của các mô hình với nhau và giải thích; đồng thời giải thích những lý do khiến mô hình phân loại sai; hướng cải tiến tiếp theo cho bài toán này. Đưa ra kết luận.

CHƯƠNG 1. BỐI CẢNH CHUNG

1.1 Sự phát triển của mạng xã hội và ngôn ngữ độc hại

1.1.1 Sự phát triển mạnh mẽ của mạng xã hội

Giới trẻ hiện nay đang được bao quanh bởi công nghệ kỹ thuật số. Cuộc sống, học tập và sinh hoạt hàng ngày của giới trẻ đều có ảnh hưởng bởi việc sử dụng mạng xã hội, điện thoại thông minh, máy tính bảng và Internet. Nhiều đứa trẻ bắt đầu tương tác với công nghệ kỹ thuật số ngay từ khi còn rất bé, mới biết đi, thậm chí với không ít trường hợp còn là sớm hơn, và cuộc sống trưởng thành của chúng chắc chắn sẽ được gắn kết chặt chẽ và mật thiết với công nghệ kỹ thuật số.

Theo bài báo “Về vấn đề sử dụng mạng xã hội để phát triển nội dung báo điện tử” của tạp chí của ban tuyên giáo Trung Ương, số liệu thống kê, đầu năm 2023, Việt Nam có 77,93 triệu người dùng Internet, chiếm 79,1% tổng dân số. Ngoài ra, số lượng người dùng mạng xã hội cũng đạt con số 70 triệu, tương đương với 71% tổng dân số. Tổng số kết nối di động đang hoạt động là 161,6 triệu, tương đương với 164,0% tổng dân số. Trong thời đại công nghệ số, mạng xã hội mang lại nhiều lợi ích nhưng không phải ai cũng sử dụng mạng xã hội có văn hóa và trách nhiệm. Thực tế, tin giả, thông tin xấu, “độc” thường có xu hướng lan truyền nhanh hơn tin chính thống từ các phương tiện truyền thông, đặc biệt là các loại thông tin phản động, tuyên truyền chống phá Đảng, Nhà Nước. Bằng chứng là, hiện nay, chỉ cần xuất hiện những tin tức giật gân hay một vấn đề nóng nào đó, người dùng mạng xã hội chưa cần biết hoặc kiểm chứng đúng hay sai đã nhanh chóng quan tâm, chia sẻ khiến cho thông tin khuếch tán trên Internet và các phương tiện truyền thông.

Trong vài năm qua, mạng xã hội đã trở nên phổ biến vào cuộc sống hàng ngày của hầu hết người Việt Nam cùng với tỷ lệ sử dụng điện thoại thông minh và internet ngày càng tăng của Việt Nam. Các nền tảng mạng xã hội như Facebook, Twitter, Tiktok hay Youtube đã trở thành một phần không thể thiếu, một “xã hội thu nhỏ” – “xã hội ảo”, không chỉ phản ánh mọi khía cạnh của đời sống thực mà có thể gây ra hoặc tác động không nhỏ đến cuộc sống thực. Theo thống kê của Google cho thấy, hiện 97% người dùng Việt Nam tìm kiếm thông tin qua các thiết bị cầm tay như điện thoại thông minh, máy tính bảng. Đặc biệt là tư duy phản biện của thế hệ sinh ra trong thời kỳ “bùng nổ” rất mạnh mẽ so với bất kỳ thế hệ nào trước đây hay bất kỳ giai đoạn tuổi nào khác. Phải ghi nhận một bộ phận không nhỏ giới trẻ hiện nay quan tâm

đến những vấn đề vĩ mô như hoạt động chính trị, biến đổi khí hậu... Nhờ có dân số trẻ, hiểu biết về kỹ thuật số và có tính kết nối cao, Việt Nam nằm trong số các quốc gia có số lượng người dùng mạng xã hội cao nhất trên toàn thế giới.

Từ khi xuất hiện, internet đã tạo nên nhiều thay đổi lớn không chỉ trong đời sống kinh tế mà còn thay đổi trong mọi mặt của đời sống chính trị, xã hội. Mạng máy tính ngày càng được mở rộng, để từ đây, các hình thức giải trí trên mạng trở nên phong phú và hiện đại hơn bao giờ hết. Theo đánh giá của Hãng nghiên cứu thị trường ComScore (Mỹ), Việt Nam hiện là một trong những quốc gia có dân số trực tuyến lớn nhất tại khu vực ASEAN. Số liệu của Tổng cục Thống kê cũng cho biết số lượng người sử dụng internet mỗi năm trong nước đều tăng nhanh. Đây được đánh giá là điều kiện lý tưởng để cho các mạng xã hội xuất hiện và nhanh chóng phổ biến tại Việt Nam. Cùng với sự phát triển của internet, mạng xã hội được xem như một trong những ứng dụng của internet có ảnh hưởng lớn nhất, đặc biệt là đối với giới trẻ ở cả khu vực đô thị lẫn nông thôn hiện nay.

Có thể nói, với nhiều ứng dụng tiện ích khác nhau, các trang mạng xã hội đã đáp ứng được gần như đầy đủ các mục đích, nhu cầu của thanh, thiếu niên – bộ phận được xem là năng động nhất trong xã hội. Bên cạnh đó, việc đăng ký tham gia vào một mạng xã hội nào đó khá đơn giản và dễ dàng cho hầu hết các đối tượng người dùng như: miễn phí thành viên, có thể truy cập bất cứ khi nào và ở đâu chỉ cần có kết nối internet... đã khiến cho mạng xã hội ngày càng thu hút thanh, thiếu niên không chỉ ở các thành phố, đô thị mà ở cả những vùng nông thôn, miền núi.

1.1.2 Văn hóa ứng xử của giới trẻ trên mạng xã hội

Mỗi thời đại sẽ có những cách khác nhau để liên lạc, trao đổi thông tin. Ngày xưa, con người thường viết thư và chờ đợi những bức thư phản hồi, thời gian rất rất là lâu vì khoảng cách xa xôi, vì phương tiện vận chuyển. Nhưng ngày nay với cuộc cách mạng khoa học công nghệ 4.0 thì những bức thư đó được thay thế bằng những cú click, những dòng enter của các trang mạng xã hội. Mạng xã hội đã kết nối con người khắp nơi trên thế giới, xóa nhòa khoảng cách về không gian, thời gian nhờ tốc độ nhanh chóng đó, sự tiện lợi.

Những lợi ích, tác động tích cực mà mạng xã hội mang lại là không thể phủ nhận. Song, đi cùng với những giá trị tốt đẹp đó, những mặt trái, “vấn nạn” đến từ mạng xã hội cũng xuất hiện không ít. Trong đó, đáng báo động chính là tình trạng “xuống cấp” về đạo đức, những biểu hiện lệch chuẩn trong văn hóa ứng xử trên mạng và thậm chí

là lợi dụng mạng xã hội để thực hiện hành vi vi phạm pháp luật. Thời gian gần đây, mạng xã hội liên tục “dậy sóng” với những vụ “bóc phốt”, “đấu tố”, hiện tượng mạng xã hội được sử dụng như một kênh để giải quyết mâu thuẫn, xúc phạm, tấn công nhau gây bức xúc trong dư luận xã hội.

Đồng thời, do có tính mở, với đặc trưng tự do, đa dạng, bình đẳng, nhiều khi bị xóa nhòa ranh giới giữa thực và ảo, vì vậy không gian mạng mang đến không ít thách thức cho người dùng như mất tương tác trực tiếp giữa con người, hoạt động sống suy giảm, xâm nhập lừa đảo, bảo mật thông tin cá nhân, ảnh hưởng đến tâm lý, trầm cảm, giảm sáng tạo, đặc biệt là tăng nguy cơ tiếp cận với thông tin xấu, độc, không lành mạnh. Theo khảo sát của chương trình Nghiên cứu internet và xã hội (VPIS), các trường hợp phát ngôn gây thù ghét dẫn đến có những lỗi ứng xử vô văn hóa của người sử dụng mạng xã hội tại Việt Nam, thể hiện tập trung ở những hành vi: nói xấu, phỉ báng (61,7%); vu khống, bịa đặt thông tin (46,6%); kỳ thị dân tộc (37,01%); kỳ thị giới tính (29,03%); kỳ thị khuyết tật (21,76%); kỳ thị tôn giáo (15,09%). Đặc biệt, mạng xã hội đã và đang trở thành công cụ hàng đầu để các thế lực thù địch lợi dụng phá hoại nền tảng tư tưởng của Đảng, chuyển hóa chính trị, khủng bố.

Một thực trạng đáng buồn khi Việt Nam lọt top 5 quốc gia hành xử kém văn minh nhất trên mạng Internet (năm 2020). Đây là hồi chuông cảnh tỉnh, đáng báo động, đòi hỏi phải có những biện pháp nhằm ngăn chặn sự lây lan của ngôn ngữ độc hại, xây dựng một môi trường mạng xã hội sạch, văn hóa, văn minh.

1.2 Định nghĩa về ngôn ngữ độc hại

Ngôn ngữ độc hại trong nghiên cứu này được định nghĩa là những bình luận chứa những từ ngữ nhạy cảm hoặc xúc phạm đến cá nhân hoặc tổ chức khác. Cụ thể, chúng em định nghĩa những bình luận độc hại là:

1. Bình luận Xúc phạm: Những bình luận mang tính chất công kích, xúc phạm, sỉ nhục, chửi bới đến cá nhân, tổ chức hoặc đối tượng khác.
2. Bình luận Nhạy cảm: Những bình luận có chứa những từ ngữ nhạy cảm (đéo, vcl,...) tuy không có hàm ý xúc phạm nhưng vô văn hoá, kém văn minh.
3. Bình luận Phân Biệt: Các bình luận hàm ý phân biệt vùng miền (parky, namky, cali, Hoa Thanh Qué), phân biệt giới tính (lũ bê đê, xăng pha nhớt),....

Ngoài ra, trong nghiên cứu này, chúng em cũng định nghĩa về một loại ngôn ngữ độc hại mới trên nền tảng mạng xã hội là các **nội dung phản động**. Sau nhiều thập

kỷ thực hiện chính sách thù địch, chống phá không đạt hiệu quả, các thế lực phản động và những phần tử thù địch trong nước và nước ngoài đang dần thay đổi đi phương thức hoạt động, phổ biến hiện nay là “cách mạng màu”. Chúng sử dụng internet và truyền thông xã hội để tuyên truyền chống phá; lợi dụng những hạn chế trong quản lý nhà nước để kích động biểu tình trái phép và xuyên tạc đường lối. Đặc biệt, đối với giới trẻ, khi nhận thức và kinh nghiệm sống chưa lớn thì họ rất dễ bị lôi kéo, “thôi miên”, “thao túng tâm lý” bởi các thông tin sai sự thật này. Đặc điểm chung của những nội dung phản động này là thường vô cùng lấp ló, rất ẩn dụ, khó nhận biết. Cách làm của chúng âm thầm và lâu dài nhưng tác hại thực sự rất khó lường. Nội dung phản động có thể là các nội dung:

- Chỉ trích chính quyền hoặc chế độ chủ nghĩa xã hội. Kêu gọi thay đổi chế độ, tiến tới xóa bỏ chế độ XHCN ở Việt Nam. Bôi xấu lãnh đạo Đảng, Nhà nước, nguyên thủ quốc gia với nhiều thủ đoạn tinh vi
- Tuyên truyền sai lệch, nói ẩn dụ, hàm ý mỉa mai về đường lối lãnh đạo của Đảng Cộng sản Việt Nam, các chính sách của Nhà nước. Phủ định, xuyên tạc học thuyết Mác - Lênin, đưa ra các luận điệu cổ vũ cho bạo lực, chiến tranh; phủ định tư tưởng Hồ Chí Minh;
- Phủ nhận vai trò và thành tựu lãnh đạo của Đảng Cộng sản Việt Nam. Vu cáo Đảng chiếm quyền của dân, vi phạm dân chủ, nhân quyền, “độc đoán, đảng trị”; đối lập Đảng với Nhà nước và đối lập Đảng, Nhà nước với nhân dân...

1.3 Tổng quan bài toán HSD

Với thực trạng trên, khi nền tảng mạng xã hội là nơi giới trẻ thoải mái chia sẻ tâm tư, cảm xúc của mình, kể cả đó là tiêu cực, xúc phạm; là nơi các thế lực thù địch, phản động tuyên truyền những thông tin chống phá, sai sự thật, nhằm thực hiện “cách mạng màu” thì bài toán Hate Speech Detection (HSD) là bài toán cấp thiết hơn bao giờ hết. Việc nhận biết những nội dung độc hại này sẽ góp phần xây dựng một “xã hội ảo” văn minh hơn, “sạch” hơn.

Hiện nay, trên thế giới, bài toán HSD là một bài toán lớn và cấp thiết, đã thu hút được sự quan tâm lớn từ nhiều nhà nghiên cứu trong lĩnh vực AI hay NLP. Đã có nhiều công trình nghiên cứu về bài toán HSD và đạt được kết quả khả quan, song, hầu hết là trong Tiếng Anh, bởi trong LLM nói chung hay trong bài toán HSD nói riêng thì dữ liệu về Tiếng Anh vẫn chiếm phần lớn. Đối với Tiếng Việt, bộ dữ liệu về ngôn ngữ độc hại còn rất hạn chế, mới chỉ có vài nghiên cứu liên quan về vấn đề này

nhu: ViHOS, ViCTSD,... Các nghiên cứu này hầu như có kết quả chưa tốt, bởi lượng dữ liệu chưa phong phú và số lượng ít.

Nghiên cứu này sẽ đóng góp cho bài toán HSD trong tiếng Việt trên nền tảng mạng xã hội. Chúng em áp dụng nhiều phương pháp khác nhau, nhiều mô hình khác nhau để phân loại các bình luận độc hại, phản cảm và xúc phạm trên nền tảng mạng xã hội, góp phần tạo ra một không gian internet văn minh, lịch sự. Các đóng góp chính của nghiên cứu này đối với bài toán HSD trong tiếng Việt là:

1. Chúng em crawl dữ liệu từ Facebook và gán nhãn thủ công, góp phần xây dựng một bộ dữ liệu HSD đa dạng, phong phú, có giá trị so với các bộ dữ liệu HSD hiện tại (sử dụng các bộ dữ liệu có sẵn + thu thập dữ liệu trên Facebook).
2. Chúng em thực hiện quá trình tiền xử lý dữ liệu gồm nhiều bước kỹ lưỡng, cẩn thận để làm sạch dữ liệu trước khi đưa vào mô hình huấn luyện .
3. Chúng em áp dụng nhiều hướng tiếp cận khác nhau cũng như nhiều mô hình khác nhau để huấn luyện mô hình trên bộ dữ liệu được xây dựng nhằm có cái nhìn tổng quát và khách quan giúp so sánh hiệu suất giữa các phương pháp này: phương pháp machine learning; phương pháp deep learning; phương pháp transfer learning và phương pháp kết hợp giữa transfer learning và deep learning.



Hình 1.1 Tổng quan quy trình bài toán HSD

Chương 2: BỘ DỮ LIỆU

2.1 Thu thập dữ liệu

2.1.1 Nguồn dữ liệu

Facebook được biết đến là một mạng xã hội vô cùng nổi tiếng. Mặc dù là một trong những trang mạng xã hội của thế giới thế nhưng ở Việt Nam thì đây vẫn là trang mạng thu hút đông đảo người dùng nhất. Theo một thống kê gần nhất thì ở Việt Nam có tới hơn 58 triệu người dùng Facebook và Việt Nam cũng lọt trong danh sách những quốc gia có nhiều người dùng Facebook nhất thế giới. Người dùng trang mạng xã hội này thường có độ tuổi khá đa dạng, tuy nhiên độ tuổi nhiều nhất là từ 18 đến 30 tuổi. Facebook hiện nay được xây dựng có nhiều tính năng nổi bật và không ngừng phát triển những tính năng mới trong tương lai. Có thể nói, cho tới thời điểm hiện tại thì Facebook vẫn giữ được vị trí “độc tôn” ở Việt Nam.

Vì vậy, nhóm chúng em đã tiến hành crawl dữ liệu trên nền tảng mạng xã hội Facebook – nơi có lượng người dùng lớn và tương tác cao tại Việt Nam. Dữ liệu chủ yếu được crawl từ những bài đăng có lượng tương tác tiêu cực cao, nội dung gây tranh cãi. Đồng thời, dữ liệu cũng được thu thập từ những bài đăng trên Facebook từ các trang thù địch, phản động.

2.1.2 Guideline gán nhãn

Sau khi crawl data từ Facebook, chúng em tiến hành gán nhãn dữ liệu. Chúng em có đưa ra thống nhất cùng xây dựng, sử dụng một guideline gán nhãn để đảm bảo các thành viên trong nhóm sẽ áp dụng chung một quy trình gán nhãn một cách nhất quán, chính xác, để bộ dữ liệu chất lượng cao và ít có sai sót. Đồng thời, việc thống nhất chung một guideline gán nhãn cũng giảm đi ảnh hưởng của những “cái tôi”, “cái riêng”; của sự chủ quan hay sự thiên vị của các cá nhân thành viên trong nhóm. Quá trình gán nhãn được thể hiện cụ thể trong bảng 2.1.

Loại nhãn	Mô tả	Ví dụ
Non-toxic Nhãn 0	Bình luận không có chứa các từ ngữ nhạy cảm và cũng không mang hàm ý xúc phạm tới cá nhân, tổ chức nào.	Ví dụ: Xin tên nhạc đk fen?

	Lưu ý: Những từ ngữ nhạy cảm là những từ tục tĩu bao gồm cả những từ viết tắt như đm, đéo, vcl, vãi lồn,...	
Toxic Nhãn 1	1. Bình luận có ý nghĩa tiêu cực nhưng không mang hàm ý xúc phạm Có thể chứ các từ ngữ nhạy cảm hoặc không chứa. Có 2 trường hợp xảy ra cho bình luận phản cảm: - Trường hợp 1: Bình luận có các từ ngữ nhạy cảm, tục tĩu. Nhưng không mang hàm ý xúc phạm. - Trường hợp 2: Bình luận không có các từ ngữ nhạy cảm, tục tĩu. Không mang hàm ý xúc phạm nhưng gây ra cảm giác khó chịu cho đối phương. 2. Bình luận mang ý nghĩa xúc phạm. Có thể có chứa các từ ngữ nhạy cảm hoặc không chứa. Có 3 trường hợp sau xảy ra cho bình luận xúc phạm: • Trường hợp 1: Bình luận mang các từ ngữ tục tĩu, nhạy cảm, xúc phạm trực tiếp • Trường hợp 2: Bình luận không mang các từ ngữ tục tĩu, nhạy cảm nhưng lại có hàm ý, ý nghĩa xúc phạm • Trường hợp 3: Bình luận không mang các từ ngữ tục tĩu, nhạy cảm nhưng lại có hàm ý,	Ví dụ 1: “<i>Bố đéo xóa kênh đấy, mày làm lonz gì được tao haha.</i>” Có nội dung đề cập tới đối tượng “mày”, có các từ ngữ nhạy cảm như “đéo”, “lonz” nhưng không có ý nghĩa xúc phạm -> Gán nhãn 1 – Toxic Ví dụ 2: <i>“có một sự tồn tại của đàn bò mang tên ” cực kỳ thuyết phục ”, có sở thích là nhai đi nhai lại, mục đích của chúng trên hành tinh này vẫn chưa có lời giải đáp, theo như các nhà động vật học cho biết loài bò này có lối sống hoang dã truy lạc, có thể động dục bất cứ lúc nào, con số của loài này đang được gia tăng đáng kể.”</i> Tuy các từ ngữ, nội dung thô không đề cập tới đối tượng là cá nhân, tổ chức/ tập thể, cũng không có các từ ngữ nhạy cảm nhưng hàm ý ẩn dụ thì có và mang ý nghĩa xúc phạm tới các cá nhân, tổ chức/ tập thể. -> Gán nhãn Toxic

	ý nghĩa xúc phạm được ẩn dụ qua các hình ảnh, các từ ngữ khác. 3.Nội dung phản động	
--	--	--

Bảng 2.1 Guideline gán nhãn

Text	Label
Thương các bé quá! Các con còn nhỏ mà đã phải sớm rời xa cha mẹ!	0
Hà Nội chỉ ngồi nghĩ cách trêu dân để nghe dân chửi cho vui ?! Năm 2025 hạn chế xe máy thì dân đi bằng gì? Hàng ngàn cử nhân thạc sĩ đang chạy xe ôm sẽ kiếm thu nhập ở đâu?	1
Toàn lũ trẻ trâu óc comment	1
Haha, hài vl	1
Dân parky lúc nào chả thế:))))))	1

Bảng 1.2. Ví dụ về bộ dữ liệu sau khi gán nhãn.

2.2 Các bộ dữ liệu có sẵn

UIT-ViCTSD

Bộ dữ liệu ViCTSD được tạo ra bởi lab NLP của Trường Đại học Công nghệ Thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh. Bộ dữ liệu ViCTSD gồm 10,000 human-annotated comments khác nhau trên 10 domains của người Việt trên nền tảng mạng xã hội. Bộ dữ liệu được gán theo 2 tiêu chí: Bình luận có tính xây dựng hay không? và bình luận có toxic hay không? Bộ dữ liệu gồm:

1. Train set: 7,000 comments
2. Valid set: 2,000 comments
3. Test set: 1,000 comments

	Comment	Constructiveness	Toxicity	Title	Topic
1	Thật tuyệt vời...!!!	0	0	Những 'bước tiến diệu kỳ'	SucKhoe

				của Trúc Nhi - Diệu Nhi	
2	Cái đầm của Hà kiều anh trông nhạt nhẽo quá !	0	1	Dàn hoa hậu, á hậu Việt Nam hội ngộ	GiaiTri
3	Sĩ quan này rất thẳng thắn và mạnh mẽ. Tôi hy vọng Biden sẽ trở thành tân tổng thống của Hoa Kỳ	0	0	Cảnh sát trưởng Mỹ phản bác Trump trong tranh luận với Biden	TheGioi
4	Cũng đẹp	0	0	24 tuyến hoạt động ở Bến xe Miền Đông mới	ThoiSu
5	Lần đầu tiên quê hương Ninh Bình của mình có thí sinh vào chung kết. Chúc cháu thành công mang vinh quang về	0	0	Bốn thí sinh tranh tài tại chung kết Olympia	GiaoDuc
6	Đúng là để Messi tự do sẽ rất nguy hiểm. Đối thủ cứ lo kèm Messi. Mà quên rằng trái bóng không nhất thiết phải qua chân Messi nữa, mà nó sẽ đến vị trí của cầu thủ nào đang chiếm được khoảng trống. Bóng đá hiện đại là thế. Chúc Mừng Barca đã đi đúng hướng. Chúc Mừng Messi đã trút bỏ áp lực.	1	0	Barca thắng đậm dù Messi tịt ngòi	TheThao

Bảng 2.2 Ví dụ về bộ dữ liệu UIT – ViCTSD

ViHOS

Bộ dữ liệu ViHOS (**V**ietnamese **H**ate and **O**ffensive **S**pans) dataset bao gồm 26k spans trên 11k online comments.

1. Train set: 8,844 comments
2. Dev set: 1,106 comments
3. Test set: 1,106 comments

	Content	Index_spans
1	Dừa lắm :))	[]
2	Bấp bệnh vl thể	[9, 10]
3	Chắc cũng biết ko tồn tại đc bao lâu nữa nên cố gắng vét	[53, 54, 55]
4	Thấy chán ad page này kiến thức thì nông cạn cái gì cũng auto sửa, cái nhìn thì tiêu cực, nói chung là dốt còn nát	[5, 6, 7, 8, 36, 37, 38, 39, 40, 41, 42, 43, 62, 63, 64, 80, 81, 82, 83, 84, 85, 86, 87, 103, 104, 105, 111, 112, 113]
5	đcm 😞 sau có con cho hút cỏ chữa bệnh chứ đéo đưa đi bệnh viện 😞	[0, 1, 2, 4, 21, 22, 23, 24, 25, 26, 42, 43, 44, 63]

Bảng 2.3 Ví dụ về bộ dữ liệu ViHOS

ViHSD

Bộ dữ liệu ViHSD - Vietnamese Hate Speech Detection dataset contains 33,400 annotated comments used for hate speech detection on social network sites. Label: CLEAN (non hate) – nhãn 0 , OFFENSIVE – nhãn 1 và HATE – nhãn 2

	Free_text	Label_id
1	Em được làm fan cứng luôn rồi nè ❤️ reaction quá hay quá cute coi mấy giờ này quá hợp lí [=]]]	0
2	Đúng là bọn mắt híp lò xo thật :))) bên việt nam t cái này ra cách đây 10 năm r và bọn t gọi là cái L :)))	2
3	CÔNG ĐỒ CỤC SỨC VÔ NHÂN TÍNH ĐỀ NGHỊ VN. NHÀ NƯỚC VN BAN THƯỞNG.	2
4	Lúp lúp như chó	1
5	□□□	0

Bảng 2.4 Ví dụ về bộ dữ liệu ViHSD

Sau khi tổng hợp dữ liệu từ nguồn dữ liệu thu nhập trên Facebook và các bộ dữ liệu có sẵn đã được công bố, chúng em thống kê toàn bộ dữ liệu qua bảng sau:


Stt	Our corpus	ViHSD	ViHOS	UIT-ViCTSD
Số lượng nhãn	2	3	-	2

Số lượng sample	24148	33400	11056	10000
Lượng từ vựng	53836	29183	14182	18561
Nguồn thu nhập	Facebook	Facebook và Youtube		VnExpress

Bảng 2.5 Tổng quan về các bộ dữ liệu

2.3 Trực quan hóa dữ liệu

Sau khi tổng hợp dữ liệu, chúng em tiến hành trực quan hóa dữ liệu. Trong bộ dữ liệu đã được tổng hợp, có khoảng gần 26,2% là bình luận toxic (độc hại). Tuy chưa thực sự cân bằng về dữ liệu, song, bộ dữ liệu cũng không phải là bộ dữ liệu quá tệ, bởi dữ liệu về các nội dung độc hại, phản động thường ít hơn các dữ liệu có nội dung “sạch”. Bộ dữ liệu này cũng đã khả quan hơn các bộ dữ liệu có sẵn, vốn chỉ có khoảng xấp xỉ 10% sample là toxic.



Hình 2.1: Biểu đồ phân bố nhãn Toxic và Non-Toxic

Chương 3: PHƯƠNG PHÁP THỰC NGHIỆM


3.1 Cơ sở lý thuyết

3.1.1. Các phương pháp học máy (Machine Learning)

K-Nearest Neighbor

KNN là một trong những thuật toán học máy có giám sát cơ bản và đơn giản nhất. Trong quá trình huấn luyện, thay vì phải học từ những dữ liệu training thì KNN lại ghi nhớ một cách máy móc toàn bộ các dữ liệu đó. Ưu điểm của KNN là quá trình dự đoán rất đơn giản sau, chỉ cần xác định các láng giềng lân cận, song, KNN lại nhạy cảm với nhiễu và các giá trị outlier. Thuật toán K-NN được mô tả như sau:

1. Xác định giá trị tham số k
2. Tính khoảng cách giữa đối tượng cần phân lớp với tất cả các đối tượng trong training data
3. Sắp xếp khoảng cách theo thứ tự tăng dần; xác định k láng giềng gần nhất cho Query Point
4. Lấy tất cả các lớp của k láng giềng gần nhất đã xác định tại trên
5. Dựa vào phần lớn lớp của láng giềng gần nhất để xác định lớp cho Query Point




.Hình 3.1 Minh họa về KNN

Support Vector Machine

SVM là một thuật toán học máy được sử dụng trong các bài toán phân loại và hồi quy. Đầu vào của SVM là các điểm dữ liệu trong n chiều, sau đó nó sẽ cố tìm một đường Hyper-plane - một đường để phân chia 2 dữ liệu đầu vào thành 2 tập riêng biệt. Cụ thể, SVM xây dựng một siêu phẳng hoặc một tập hợp các siêu phẳng trong

một không gian đa chiều. Để phân loại tốt nhất thì các siêu phẳng nằm ở càng xa các điểm dữ liệu của tất cả các lớp (Margin) càng tốt, bởi Margin càng lớn thì sai số tổng quát hóa của thuật toán phân loại càng bé. Trong nhiều trường hợp, có thể sẽ không phân chia được dữ liệu một cách tuyến tính trong một không gian ban đầu. Vì vậy, trong nhiều trường hợp cần phải ánh xạ các điểm dữ liệu trong không gian ban đầu sang một không gian mới nhiều chiều hơn, để có thể phân tách dễ dàng.




Hình 3.2. Minh họa Kernel Trick trong SVM

SVM có thể tiết kiệm bộ nhớ, ngoài ra SVM có thể xử lý dữ liệu trên không gian đa chiều, đặc biệt với các bài toán phân loại văn bản. Tuy nhiên, trong trường hợp số chiều của tập dữ liệu lớn hơn rất nhiều so với số lượng dữ liệu thì SVM không hoạt động tốt.

Random Forest


Mô hình Rừng ngẫu nhiên là một phương pháp ensemble learning phổ biến, là sự kết hợp của nhiều mô hình học yếu Decision Trees

Cây quyết định: Cây quyết định là một loại mô hình học phi tham số. Trong mô hình DT, để dự đoán nhãn, mô hình bắt đầu từ root của cây, sau đó mô hình sẽ huấn luyện so sánh các giá trị của đặc trưng tại root với các đặc trưng của bản ghi. Dựa trên cơ sở của phép so sánh, mô hình sẽ phân nhánh cho mẫu tương ứng với giá trị đó và nhảy đến nút tiếp theo.



Hình 3.3. Phân nhánh 1 điểm dữ liệu tại các nút của mô hình Cây quyết định

Nguyên tắc hoạt động của RF: RF sử dụng phương pháp bagging trong quá trình dự đoán. Phương pháp bagging là việc huấn luyện các tập dữ liệu khác nhau được phân chia từ dữ liệu gốc thay vì chỉ huấn luyện training dataset 1 lần duy nhất. Các mô hình DT khác nhau sẽ tạo ra các kết quả phân loại đầu ra khác nhau, sau đó, các kết quả đầu ra này sẽ được xếp hạng, và kết quả cao nhất sẽ được chọn làm kết quả phân loại đầu ra cuối cùng (lựa chọn theo nguyên tắc đa số). Mô hình Rf đã khắc phục được vấn đề overfitting của DT.




Hình 3.4. Sơ đồ khối quá trình phân loại của mô hình Rừng ngẫu nhiên

3.1.2 Các phương pháp học sâu (Deep Learning)

CNN


Convolutional Neural Network là một loại mô hình mạng nơ-ron nhân tạo. Đặc điểm nổi bật của CNN là khả năng tự học các đặc trưng hierarchically từ dữ liệu thông qua việc sử dụng các tầng convolutional và pooling. Một kiến trúc CNN bao gồm các lớp: convolution layer, pooling layer và fully connected layer. Ở giữa các lớp convolution và pooling thường có các hàm kích hoạt phi tuyến. Dữ liệu khi đưa vào mạng sẽ được lan truyền qua tầng convolution layer, giá trị tính được từ các tầng convolution sẽ đi qua một hàm kích hoạt, sau đó giá trị này sẽ được lan truyền qua pooling layer. Cuối cùng sẽ được lan truyền đến tầng fully connected layer và đi qua hàm kích hoạt Softmax, thường thì cuối cùng sẽ thu được một vector chứa xác suất phần trăm thuộc về các lớp đối với các bài toán phân loại [15].



Hình 3.5 Y. Kim. "Convolutional Neural Networks for Sentence Classification" [2014]

- **Convolutional Layer:** Convolution layer là lớp quan trọng nhất và cũng là lớp đầu tiên của mô hình CNN. Lớp này có chức năng chính là phát hiện các đặc trưng có tính không gian hiệu quả. Trong tầng này có 4 đối tượng chính là: ma trận đầu vào, bộ filters, và receptive field, feature map. Conv layer nhận đầu vào là một ma trận và một bộ filters cần phải học. Bộ filters này sẽ trượt qua từng vị trí trên dữ liệu để tính tích chập (convolution) giữa bộ filter và phần tương ứng. Phần tương ứng này gọi là receptive field, tức là vùng mà một neuron có thể nhìn thấy để đưa ra quyết định, và ma trận cho ra bởi quá trình này được gọi là feature map..


- Hàm kích hoạt là một hàm số nhận vào một giá trị đầu vào và kết quả là một giá trị có miền giá trị nằm trên một khoảng (hay nửa khoảng) nào đó. Một số các hàm kích hoạt phổ biến có thể kể đến đó là Sigmoid, Tanh, Relu. Hàm kích hoạt rất quan trọng bởi vì nó có vai trò tăng khả năng dự đoán của mạng neural, giúp mô hình học được các quan hệ phi tuyến phức tạp tiềm ẩn trong dữ liệu. Hàm Relu có công thức toán học là $f(x) = \max(0, x)$. Hàm Relu phổ biến vì tính toán đơn giản, giúp hạn chế tình trạng vanishing gradient, và cũng cho kết quả tốt hơn. Relu cũng như những hàm kích hoạt khác, được đặt ngay sau tầng convolution, Relu sẽ gán những giá trị âm bằng 0 và giữ nguyên giá trị của đầu vào khi lớn hơn 0.



Hình 3.6. Đồ thị hàm kích hoạt Relu

- Pooling Layer: Pooling giúp cho mạng giảm số lượng tham số, từ đó giúp đơn giản hóa quá trình tính toán của CNN và qua đó góp phần giải quyết vấn đề overfitting khi huấn luyện mạng. Có nhiều toán tử pooling như Sum-pooling, Max-pooling, L2-pooling nhưng Max-pooling được sử dụng phổ biến nhất trong kiến trúc mạng CNN vì nó cho kết quả hơn so với những toán tử còn lại. Không chỉ vậy, Max-pooling còn giúp tạo ra translation invariance cho đặc trưng. Cụ thể hơn, dù đối tượng trong đầu vào có sự dịch chuyển nhỏ thì mạng vẫn có khả năng phân lớp chính xác được đối tượng. Đó là bởi vì max-pooling chọn ra neural có giá trị đầu ra tại mỗi vùng neural của lớp trước và tổng hợp thành lớp sau. Việc chọn neural có giá trị tín hiệu lớn nhất được xem như chọn ra đặc trưng tốt nhất để xử lý. Chính vì thế, khả năng phân lớp chính xác đối tượng dựa trên đặc trưng này vẫn không thay đổi và giúp cho CNN đạt được tính ổn định.

- Fully Connected Layer: Sau khi thông qua các tầng convolutional và pooling, tầng cuối cùng của mô hình CNN là tầng fully connected layer. Tầng này có chức năng chuyển ma trận đặc trưng ở tầng trước thành vector chứa xác suất của các đối tượng cần được dự đoán.



Hình 3.7. Ví dụ kiến trúc CNN trong phân loại văn bản.

Đầu vào kiến trúc CNN là câu: "I like this movie very much!". Văn bản đầu vào sẽ được mã hóa thành 1 ma trận có kích thước. Ta có region sizes (2,3,4) và chúng ta sẽ apply 2 filters cho từng vùng, sau colvolution đầu tiên ta sẽ có 6 output. Tiếp theo sử dụng lớp max-pooling để tìm đặc trưng cao nhất cho mỗi vùng, output layer 2 sẽ còn 3, chúng ta sẽ biến đổi để đưa 3 vector đơn này thành chung 1 vector cho 1 chức năng phân tích (cũng là input layer tiếp theo). Cuối cùng softmax để đưa ra 2 lớp output cuối.

GRU

Mô hình GRU (Gated Recurrent Unit) được xây dựng để xử lý và có thể nắm bắt thông tin dạng chuỗi như chuỗi văn bản. Ngoài ra, GRU khắc phục được hạn chế của kiến trúc mạng Recurrent Neural Network là vấn đề vanishing gradient, vì với các giá trị nhỏ trong ma trận, khi ta thực hiện phép nhân ma trận sẽ đạo hàm tương ứng sẽ xảy ra Vanishing gradient, tức đạo hàm bị triệt tiêu chỉ sau vài bước nhân. Như vậy, các bước ở xa sẽ không còn tác dụng với nút hiện tại nữa, làm cho RNN không thể học được các phụ thuộc xa. GRU khắc phục hạn chế đó bằng cách có cổng cập nhật và cổng cài đặt lại (update gate và reset gate). Về cơ bản, đó chính là hai vector quyết định thông tin nào sẽ được truyền cho đầu ra. Điều đặc biệt là nó có thể được đào tạo để giữ thông tin từ lâu trước đó, không hề xóa thông tin không liên quan đến dự đoán đầu ra.

Nguyên tắc hoạt động của GRU: Cổng khởi tạo r_t kiểm soát mức độ kết hợp của thông tin của trạng thái hiện tại với thông tin trạng thái đằng trước và cổng cập nhật z_t (sự kết hợp của cổng đầu vào và cổng quên) kiểm soát xem thông tin trạng thái tại thời điểm trước đó có được giữ lại hay không hay sẽ bị bỏ qua, “quên đi” và mức độ lưu giữ ở trạng thái hiện tại. Ta coi đầu ra tại thời điểm trước đó là h_{t-1} và đầu vào tại thời điểm hiện tại là x_t , quá trình tính toán đơn vị lớp ẩn h_t được viết dưới dạng phương trình đệ quy như sau:


$$r_t = \sigma(\mathcal{W}_r[h_{t-1}, x_t] + b_r)$$

$$z_t = \sigma(\mathcal{W}_z[h_{t-1}, x_t] + b_z)$$

$$\tilde{h}_t = \varphi(\mathcal{W}_{\tilde{h}}[r_t * h_{t-1}, x_t] + b_{\tilde{h}})$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

Trong đó $\mathcal{W}_r$, $\mathcal{W}_z$, $\mathcal{W}_{\tilde{h}}$ lần lượt là ma trận trọng số của r_t , z_t , $\tilde{h}_t$; b_r , b_z , $b_{\tilde{h}}$ là bias của r_t , z_t , $\tilde{h}_t$



Hình 3.8. Minh họa khối nhớ mô hình GRU (Nguồn: Liu et al., 2019)

3.1.3 Word Embedding

Word Embedding là nhúng từ vào một không gian véc tơ để có thể biểu diễn được mối liên hệ, sự tương đồng về mặt ngữ nghĩa, hay context của từ hay giữa các từ với nhau. Không gian này bao gồm nhiều chiều và các từ trong không gian đó mà có cùng văn cảnh hoặc ngữ nghĩa sẽ có vị trí gần nhau. Ví dụ như ta có hai câu : "Hôm nay ăn táo " và "Hôm nay ăn xoài ". Khi ta thực hiện Word Embedding, "táo" và "xoài" sẽ có vị trí gần nhau trong không gian véc tơ do chúng có vị trí giống nhau trong một câu. One way to define "usage": words are defined by their environments (the words around them). Zellig Harris (1954): If A and B have almost identical environments we say that they are synonyms.

TF-IDF

TF-IDF viết tắt của term frequency–inverse document frequency là một phương pháp word embedding cơ bản với ý tưởng chính của phương pháp này là đánh giá mức độ quan trọng của từ đối với 1 văn bản trong một trong bộ dữ liệu. TF - tần số xuất hiện của 1 từ trong 1 văn bản:

$$tf_{t,d} = \text{count}(t,d)$$

$$\text{hoặc: } tf_{t,d} = \log_{10}(\text{count}(t,d)+1)$$

IDF - Tần số nghịch của 1 từ trong corpus.

$$idf_t = \log_{10} \left(\frac{N}{df_t} \right)$$

Trong đó: df_t is the number of documents t occurs in; N is the total number of documents in the collection. Những từ có giá trị TF-IDF cao là những từ xuất hiện nhiều trong văn bản này, nhưng xuất hiện ít trong các văn bản khác.

Công thức TF-IDF:

$$w_{t,d} = tf_{t,d} \times idf_t$$

TF-IDF đánh giá mức độ quan trọng của một từ trong một văn bản dựa trên tần xuất xuất hiện của từ đó trong văn bản và tần suất nghịch đảo trong tập corpus. Tuy nhiên, nhược điểm của TF-IDF là TF-IDF không thể biểu diễn hay “hiểu” được mối quan hệ giữa các từ.

FastText

FastText là một bộ word embedding đa ngữ lớn, được Facebook xây dựng vào năm 2016 và pretrained trên 157 ngôn ngữ khác nhau, xử lý một nhược điểm lớn của word2vec là nó chỉ “học” được những từ xuất hiện trong dataset. Thay vì training cho đơn vị word, FastText chia text ra làm nhiều đoạn nhỏ là n-gram cho từ, ví dụ apple sẽ thành app, ppl, and ple, vector của từ apple sẽ bằng tổng của tất cả cái này. Do vậy, phương pháp này xử lý rất tốt cho những trường hợp từ hiếm gặp.

Phow2v

Phow2v - Pre-trained Word2Vec syllable and word embeddings for Vietnamese là một mô hình được huấn luyện trên nguồn dữ liệu là Tiếng Việt trên 20GB dữ liệu. Đây là một mô hình lớn, phù hợp cho tác vụ embedding trong bài toán phân loại văn bản tiếng Việt

3.1.4 PhoBERT

Trong những năm gần đây, đã xuất hiện các giải pháp SOTA (state-of-the-art) với hiệu suất đáng chú ý, cụ thể là việc phát triển các mô hình đơn ngôn ngữ và đa ngôn ngữ như BERT, RoBERTa, XLM-R.


BERT

BERT là viết tắt của Bidirectional Encoder Representations from Transformers được hiểu là một mô hình học sẵn hay còn gọi là pre-train model, học ra các vector đại diện theo ngữ cảnh 2 chiều của từ, được sử dụng để transfer sang các bài toán

khác trong lĩnh vực xử lý ngôn ngữ tự nhiên. BERT đã thành công trong việc cải thiện những công việc gần đây trong việc tìm ra đại diện của từ trong không gian số (không gian mà máy tính có thể hiểu được) thông qua ngữ cảnh của nó. Về mặt lý thuyết, các kỹ thuật khác như Word2vec, FastText hay Glove cũng tìm ra đại diện của từ thông qua ngữ cảnh chung của chúng. Tuy nhiên, những ngữ cảnh này là đa dạng trong dữ liệu tự nhiên. Trong khi các mô hình như Word2vec, fastText tìm ra 1 vector đại diện cho mỗi từ dựa trên 1 tập ngữ liệu lớn nên không thể hiện được sự đa dạng của ngữ cảnh. Việc tạo ra một biểu diễn của mỗi từ dựa trên các từ khác trong câu sẽ mang lại kết quả ý nghĩa hơn nhiều. Như trong trường hợp trên ý nghĩa của từ con chuột sẽ được biểu diễn cụ thể dựa vào phần trước hoặc sau nó trong câu. Nếu đại diện của từ "con chuột" được xây dựng dựa trên những ngữ cảnh cụ thể này thì ta sẽ có được biểu diễn tốt hơn. BERT mở rộng khả năng của các phương pháp trước đây bằng cách tạo các biểu diễn theo ngữ cảnh dựa trên các từ trước và sau đó để dẫn đến một mô hình ngôn ngữ với ngữ nghĩa phong phú hơn. [22]

PhoBert

PhoBert được lấy cảm hứng từ mô hình Bert (Pre-trained PhoBERT models are the state-of-the-art language models for Vietnamese (Pho, i.e. "Phở", is a popular food in Vietnam)). Đây là một pre-trained được huấn luyện monolingual language, tức là chỉ huấn luyện dành riêng cho tiếng Việt. Việc huấn luyện dựa trên kiến trúc và cách tiếp cận giống RoBERTa của Facebook được Facebook giới thiệu giữa năm 2019. Đây là một cái tiến so với BERT trước đây. Tương tự như BERT, PhoBERT cũng có 2 phiên bản là PhoBERTbase *PhoBERTbase* với 12 transformers block và PhoBERTlarge *PhoBERTlarge* với 24 transformers block. PhoBERT được train trên khoảng 20GB dữ liệu bao gồm khoảng 1GB Vietnamese Wikipedia corpus và 19GB còn lại lấy từ Vietnamese news corpus. Đây là một lượng dữ liệu khá ổn để train một mô hình như BERT. PhoBERT sử dụng RDRSegmenter của VnCoreNLP để tách từ cho dữ liệu đầu vào trước khi qua BPE encoder [23].



Hình 3.9. Minh họa về PhoBert

3.1.5 Chỉ số đánh giá hiệu suất

Confusion matrix là chỉ số đánh giá giúp chúng ta có cái nhìn tổng quan về việc các điểm dữ liệu được phân loại đúng/sai như thế nào.

		Predicted 0	Predicted 1
Actual 0		TN	FP
Actual 1		FN	TP

Hình 3.10. Ma trận nhầm lẫn

- True Positive (TP): số điểm dữ liệu của lớp *positive* được phân loại đúng là *positive*.
- True Negative (TN): số điểm dữ liệu của lớp *negative* được phân loại đúng là *negative*.

- False Positive (FP): số điểm dữ liệu của lớp *negative* bị phân loại sai thành *positive*.
- False Negative (FN): số điểm dữ liệu của lớp *positive* bị phân loại sai thành *negative*.

Các thông số đánh giá khác:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{Recall} = \frac{TP}{TP+FN}$$


$$\text{Precision} = \frac{TP}{TP+FP}$$

$$\text{F1 - micro} = 2 \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$

$$\text{F1-marco} = \frac{1}{N} \sum_{i=1}^N F1_i$$

3.2 Tiền xử lý dữ liệu

Preprocessing là quá trình tiền xử lý dữ liệu trước khi dữ liệu được đưa vào mô hình dự đoán. Quá trình tiền xử lý có thể bao gồm nhiều bước khác nhau như chuẩn hóa, lọc dữ liệu, loại bỏ nhiễu,..... Với ngôn ngữ tự nhiên, đặc biệt với những comment trên nền tảng xã hội, thì dữ liệu thường rất nhiễu và chưa “sạch”. Các comment này có thể chứa các đường link (link shopee, link cá độ,...); chứa các icon, hay chứa nhiều từ viết tắt,.. Trong nghiên cứu này, quá trình tiền xử lý dữ liệu được chia thành 2 phase, cụ thể được thể hiện trong hình 3.1.



Hình 3.11. Quy trình tiền xử lý dữ liệu

Lowercase Sentences: Các comment sẽ được chuyển từ viết hoa thành viết thường (Ví dụ: “Chúng ta” =>”chúng ta”). Việc thành chuyển thành chữ viết thường để mô hình hiểu rằng đây là 2 từ giống nhau .

Delete Redundant Spaces: Giới trẻ hiện nay thường có thói quen gõ nhiều khoảng trắng dư thừa, chúng em loại bỏ các những khoảng trắng thừa này.

Delete Links: Xóa các liên kết URL hoặc các đường link (link shoppe, link sản phẩm, link video đòi truy,...)

Normalize Accented Letters: Chuẩn hóa các chữ cái có dấu trong Tiếng Việt

Delete Redundant Characters: Trên mạng xã hội, giới trẻ thường gõ những ký tự lặp lại nhiều lần để thể hiện tính cách vui nhộn, bộc lộ cảm xúc (Ví dụ: "vuiiii" hoặc "hihihihihihi"). Các kí tự lặp lại này thường không mang ý nghĩa, mà lại làm nhiễu comment khi đưa vào mô hình dự đoán. Cần xóa các ký tự lặp lại không cần thiết này (ví dụ: "hihihihihihi" -> "hihi").

Normalize Unicode: Chuẩn hóa Unicode.

Word Tokenize: Tokenization là quá trình tách một cụm từ, câu, đoạn văn, một hoặc nhiều tài liệu văn bản thành các đơn vị nhỏ hơn. Trong nghiên cứu này, chúng em sử dụng VNCORENLP để tokenize các bình luận (VnCoreNLP is a fast and accurate NLP annotation pipeline for Vietnamese, providing rich linguistic annotations through key NLP components of word segmentation, POS tagging, named entity recognition (NER) and dependency parsing)

De-Teencode: Trên các nền mạng xã hội, giới trẻ thường sử dụng những từ viết tắt để gõ nhanh hơn (Ví dụ kh - không; m - mày; ntn – như thế nào,...). Ngoài ra, một số

người sử dụng những từ viết tắt này để viết tắt cho những từ xúc phạm, phản cảm. Vì vậy cần chuẩn hóa những từ viết tắt này (teen-code) về dạng từ gốc của chúng)

Teen-code	Từ gốc
Đm	Đ*t mẹ
Đcm	Đ*t cụ mày
Vl	Vãi l*n
Loz	L*n

Bảng 3.1 Ví dụ teen-code

Remove Stopwords: Loại bỏ những stopwords không mang nhiều ý nghĩa (Ví dụ như "và," "thì," "là,"...)

3.3 Modeling

Hướng tiếp cận học máy

Support Vector Machine

- $\gamma = 0.0001$ (mức độ ảnh hưởng của 1 điểm dữ liệu đến với các điểm dữ liệu khác)
- $C = 1000$ (tác động của các điểm bị phân loại sai đến quá trình học)
- kernel = “rbf” (chuyển đổi dữ liệu vào không gian cao hơn giúp quá trình phân loại các điểm dữ liệu tốt hơn)

Random Forest

- n-estimators=108 (số lượng cây quyết định)
- max-depth = 40

KNN: n_neighbors=5

Hướng tiếp cận học sâu:

Mô hình CNN: Trong nghiên cứu này, chúng em kết hợp CNN cùng hai bộ pretrained Word Embedding là fasttext và phow2v với các thông số mô hình là:


- epochs = 40
- batch-size: 256
- max-length: 100
- dropout: 0.5

- Lớp Convolution 2D với 32 filters với kích thước (2,3,5)
- optimizer: Adam - Learning rate: 1e-4
- Loss function: binary_crossentropy.

Mô hình GRU: Mô hình GRU kết hợp cùng bộ pretrained Word Embedding là fasttext với các thông số mô hình là:

- Units: 80
- max-length: 100
- Pooling Layers: GlobalAveragePooling1D và GlobalMaxPooling1D
- Dropout = 0.2
- Batch size = 256
- Epochs = 40
- Optimizer: Adam - Learning rate: 1e-4
- Loss function: binary_crossentropy.

Hướng tiếp cận Transformer



Hình 3.12. Hướng tiếp cận Transformer

PhoBERT + CNN: Trong nhiều bài toán đã combine 2 mô hình là BERT và CNN để phân loại văn bản, đặc biệt là trong các bài toán phân loại các văn bản ngắn được thu thập từ các mạng xã hội, cụ thể là bài toán phân loại bình luận toxic trên nền tảng mạng xã hội, đạt được nhiều kết quả khả quan, hiệu suất cao. Trong bài nghiên cứu này, chúng em xây dựng mô hình kết hợp giữa PhoBERT và CNN bởi cơ chế cộng hưởng của 2 mô hình này giúp làm giảm loss giữa label dự đoán và label thực tế. Trong nhiều nghiên cứu cũng về bài toán phân loại độc hại (ViHos,...) thì mô hình PhoBERT-CNN đã có kết quả tốt hơn so với những mô hình khác.

PhoBERT có nhiệm vụ embedding nhằm trích xuất thông tin từ data đầu vào. PhoBert là một pre-trained được huấn luyện monolingual language, tức là chỉ huấn luyện dành riêng cho tiếng Việt nên đạt hiệu suất cao trong các bài toán phân loại văn bản Tiếng Việt. Kiến trúc của mô hình PhoBERT là kiến trúc đa lớp gồm nhiều lớp Bidirectional Transformer encoder. PhoBERT nhận input đầu vào là một sequence có ngữ cảnh, sau đó sẽ tổng hợp các token cùng với segment vector và vị trí tương ứng của từ trong câu. Lớp Fully-connected ở phần cuối của PhoBERT được thay thế bằng kiến trúc mạng CNN. Theo paper: “Convolutional neural networks for sentence classification,” của Y. Kim (2014) CNN là mô hình hiệu quả cao cho các bài toán phân loại văn bản ngắn, CNN được dùng thay cho những mạng neural network điển hình khác như LSTM, Bi-LSTM, GRU. Cấu trúc mạng CNN trong nghiên cứu này được xây dựng:

- **INPUT:** Lớp input được sử dụng để khởi tạo đối tượng đầu vào từ ma trận các vector. Input và output của lớp này có kích thước bằng với số chiều của ma trận vector.
- **CONV1D:** Chúng em xây dựng 4 lớp để trích xuất đặc trưng từ ma trận vector. Đối với mỗi lớp CONV1D, chúng em sử dụng một filter có kích thước [1,2,3,5], khởi tạo giá trị kích thước cho kernel; sử dụng hàm kích hoạt ReLU
- **POOLING:** Tiến hành Max pooling bằng việc sử dụng hàm Max-Pool1D. Đầu ra của lớp pooling này là một ma trận các đặc trưng đã được giảm kích thước nhưng vẫn giữ lại các đặc trưng quan trọng
- **DROPOUT:** Trước khi xây dựng lớp Dropout, chúng em sử dụng hàm torch.cat() để kết nối các đặc ma trận đặc trưng đầu ra từ lớp Pooling. Tiếp theo, chúng em đặt chỉ số DROPOUT = 0.1 để loại bỏ ngẫu nhiên 10% các node trong mỗi hidden layer, tránh overfitting.
- **FC:** Trong lớp Fully Connected, chúng em xây dựng hàm loss function và một optimized function để liên kết dữ liệu đầu ra từ lớp Dropout tới các lớp phân loại. Chúng em sử dụng thuật toán tối ưu là Adam optimization và hàm mất mát Crossentropy để tối ưu hóa

Các kỹ thuật Convolution và Pooling giúp CNN đạt hiệu suất cao trong việc trích xuất lấy những thông tin quan trọng của văn bản, từ đó giúp cải thiện đáng kể hiệu suất của mô hình phân loại. Tuy nhiên, cũng theo paper: “Convolutional neural networks for sentence classification,” của Y. Kim (2014), nhược điểm của CNN đạt hiệu suất thấp trong những bài toán xử lý văn bản ở mức độ chuỗi. Để khắc phục

nhược điểm này của CNN, mô hình pretrained lớn cho Tiếng Việt: PhoBERT là một sự kết hợp hợp lý, hoàn hảo với CNN bởi PhoBERT sẽ trích xuất đặc trưng từ câu văn đầu vào, word embedding sau đó mới đưa vào mô hình CNN để huấn luyện. Với PhoBERT + CNN, chúng em huấn luyện mô hình với 10 epochs, hàm tối ưu Adam, learning rate bằng $1e-5$, epsilon là $1e-8$, batch-size là 64.

Ngoài ra chúng em cũng xây dựng kiến trúc GRU - PhoBERT với 3 phần chính: đầu tiên, chúng em cũng sử dụng mô hình PhoBERT (phiên bản `vinai/phobert-base-v2`) để embedding văn bản đầu vào embedding dim là 768 với mục đích trích xuất thông tin. Tiếp theo, chúng em xây dựng lớp bidirectional GRU với hidden size 512 có nhiệm vụ thu thập thông tin ngữ cảnh từ cả hai chiều của chuỗi văn bản. Sau đó, đầu ra được kết nối với lớp Fully Connected (Linear) sẽ giảm số chiều xuống bằng 2 bằng số nhãn cần phân loại. Cuối cùng, sẽ đi qua hàm Softmax. Trong kiến trúc này, chúng em sử dụng hàm optimizer Adam (learning rate $2e-5$)


Chương 4. KẾT LUẬN

4.1 Kết quả huấn luyện

Phương pháp	Model	Word Embedding	F1-micro	F1-macro
ML	SVM	TF-IDF	0.866	0.816
	RF	TF-IDF	0.857	0.796
	KNN	TF-IDF	0.78	0.61
DL	CNN	Fasttext	0.831	0.777
	CNN	PhoW2V	0.835	0.782
	GRU	Fasttext	0.819	0.762
Our system	CNN	PhoBERT	0.87	0.83
	GRU	PhoBERT	0.87	0.83

Bảng 4.1. Kết quả huấn luyện

Kết quả của các mô hình được hiện thị qua bảng 4.1. Nhìn chung, trong bài toán xử lý ngôn ngữ tự nhiên, cụ thể là trong bài toán HSD, các mô hình học sâu thường đạt hiệu suất cao hơn các mô hình học máy bởi học sâu sử dụng mạng nơ ron nhiều lớp nên có khả năng học các đặc trưng “sâu”, tốt hơn còn các mô hình học máy ML thường chỉ trích xuất đặc trưng thủ công. Ngoài ra, nhúng từ với TF-IDF chỉ thực hiện embedding bằng việc đếm tần suất từ, còn học sâu sử dụng các biểu diễn dense véc tơ embedding (Word2Vec, PhoBert) có thể biểu diễn từ trong không gian vec tơ, giúp mô hình hiểu được mối quan hệ ngữ nghĩa.



Hình 4.1. Confusion Maxtric của mô hình CNN – PhoBert và GRU – PhoBert

Kết quả của 2 mô hình CNN-PhoBERT và GRU-PhoBERT có kết quả F1-micro và F1-macro xấp xỉ bằng nhau. Có thể nói, 2 mô hình đều hoạt động tốt trong bài toán phân loại bình luận toxic. Tuy nhiên, chúng em trực quan hóa kết quả của 2 mô hình này qua hình 4.1. Hình bên trái là confusion maxtric của mô hình CNN-PhoBERT, hình bên phải là confusion maxtric của mô hình GRU-PhoBERT. Đối với bài toán HSD, khi mà nhiệm vụ quan trọng là nhận biết nhiều nhãn 1 nhất có thể (bình luận độc hại) thì CNN-PhoBERT đạt hiệu nhỉnh hơn so với GRU-PhoBERT. CNN-PhoBERT nhận biết đúng được 1044 sample nhãn 1 trong khi GRU-PhoBERT chỉ nhận biết đúng được 1027 sample nhãn 1. Do đó, đối với nghiên cứu này, mô hình CNN-PhoBERT là sự lựa chọn phù hợp nhất cho bài toán HSD.

Kết quả từ bảng 4.1 cho thấy rằng tuy rằng việc sử dụng các mô hình pre-trained như PhoBERT đạt hiệu suất tốt hơn, song, vẫn chưa thực sự vượt trội so với các mô hình khác, nguyên nhân có thể do sự mất cân bằng trong bộ dữ liệu. Hơn 70% bình luận là nhãn Non - toxic, gây ra một vấn đề là các mô hình có thể bị bias bởi label này.

4.2 Hạn chế và hướng phát triển

Hạn chế

Hạn chế đầu tiên đến từ bộ dữ liệu gán nhãn. Trong quá trình gán nhãn, không thể tránh khỏi việc gán nhãn sai do vội vã, nhầm lẫn hoặc do trong quá trình tiền xử lý vẫn chưa xử lý hết hay chuẩn hóa hết được các từ địa phương hay teencode của giới trẻ. Trong nghiên cứu này, chúng em đã xây dựng bộ teencode khoảng 400 từ, song, với sự hạn chế của nguồn nhân lực cũng như sự phong phú của Tiếng Việt thì có thể vẫn chưa thể chuẩn hóa hết các từ viết tắt này. Ví dụ như những bình luận bình luận "mao phắc", thì từ "phắc" ở đây ám chỉ từ "fuck" trong tiếng anh, hay từ “ sẽ gây” mang nghĩa “sex gay” trong tiếng anh. Ngoài ra, khi phân tích lỗi dự đoán, một số sample cũng bị phân loại sai do gán nhãn sai.

Về mô hình, hạn chế trong nghiên cứu này là các mô hình vẫn chưa được fine tune và vẫn chưa thử nghiệm trên nhiều model khác nhau dẫn đến cái nhìn vẫn còn chủ quan.

Hướng phát triển


Chúng em có các hướng phát triển như sau:

Về dữ liệu, tuy đã có bộ dữ liệu lớn khoảng 70k sample; và nhóm cũng đã crawl nhiều data đa dạng từ Facebook, song, vẫn cần tiếp tục phát triển, xây dựng một bộ dữ liệu chất lượng và có giá trị; chuyển hướng sang thu thập từ các nền tảng mạng xã hội khác như X, YouTube, TikTok. Ngoài ra, tiếp tục xây dựng, bổ sung, cập nhật liên tục bộ dữ liệu về teencode, tiếng lóng, từ địa phương, từ viết tắt .

Về phần mô hình, nhóm đề xuất hai hướng phát triển. Một là nhóm sẽ tiếp tục nghiên cứu việc áp dụng mô hình phoBert và cũng định hướng tự xây dựng mô hình cấu trúc RoBERTa hiệu suất cao trong tương lai xa. Hai là, hiện nay cũng có một số nghiên cứu liên quan đến khả năng nhận biết toxic của các mô hình ngôn ngữ lớn qua việc prompting, nhóm cũng sẽ triển khai nghiên cứu nội dung này để có sự so sánh so với các phương pháp truyền thống và chỉ ra các hạn chế của nó. Song song đó, tiếp tục fine-tune các mô hình.

4.3 Xây dựng website nhận biết ngôn ngữ văn bản độc hại

Nhóm chúng em đã xây dựng một website nhận biết ngôn ngữ độc hại, với mô hình CNN-PhoBERT. Người dùng sẽ nhập một nội dung và web sẽ trả về rằng câu đó có toxic hay không và với xác suất bao nhiêu.



The screenshot shows a web application for text classification. At the top, there is a document icon and the title "Text Classification". Below the title, there is a label "Enter text to classify" and a text input area with the placeholder "Paste your text here". The input area contains the text "m bị nguuuu l à". Below the input area is a red button labeled "Classify Text". Under the button, the section "Classification Results" is displayed. It shows "Top 1 Prediction" as "Toxic" with a green upward arrow and "97.77%" confidence.

Hình 4.2. Thực nghiệm kiểm tra câu mang ý nghĩa thô tục

Text Classification

Enter text to classify

Paste your text here

haaaaaaa, dân parky cần ác

Classify Text

Classification Results

Top 1 Prediction

Toxic

↑ 71.05%

Hình 4.3. Thực nghiệm kiểm tra câu phân biệt vùng miền

Text Classification

Enter text to classify

Paste your text here

Ngoài 2 vụ việc tấn công tình dục phụ nữ liên quan trực tiếp đến các viên chức tháp tùng lãnh đạo cao cấp của chế độ Cộng Sản, thì công chúng hẳn chưa quên vụ án hiếp dâm một nữ du khách chưa thành niên người Anh của 2 nghệ sỹ Việt Nam là các ông Hồ Hoài Anh và Hồng Đăng, vào khoảng 20 tháng trước đó, Tháng sáu 2022, tại Tây Ban Nha. Chỉ 2 năm sau, sợ thế giới lãng quên, các quan chức tháp tùng lãnh đạo cao cấp nhất Việt Nam đã vội tấn công tình dục phụ nữ trên trường quốc tế để nhắc nhở thế giới về bản lĩnh tình dục đảng viên Cộng Sản Việt Nam.

Sau Tây Ban Nha của Châu Âu, Chile của Châu Mỹ, giờ thì thêm New Zealand của Châu Úc được Đảng cho gởi người "đánh dấu lãnh thổ" trên thế giới. Thế nên, nếu chế độ lấy biểu tượng ngoại giao của Đảng mình bằng Linga, hỏi xem có gì là chưa đúng? Chẳng phải nó rất phù hợp với tư tưởng của ông Tô Lâm đấy sao "Kỳ nguyên mới, kỳ nguyên vườn vôi của dân tộc".

Đặng Đình Mạnh

Classify Text

Classification Results

Top 1 Prediction

Toxic

↑ 86.82%

Hình 4.4 . Thực nghiệm kiểm tra câu có nội dung phản động (1)

Text Classification

Enter text to classify

Paste your text here

Có người nói, ông Phúc bị kỷ luật cảnh cáo thì chưa ăn thua gì.
Nếu có kỷ luật khai trừ đảng thì mới chắc cũ là có án hình sự. Bây giờ nhân dân chỉ còn hy vọng vào việc bên chính quyền xử lý cách các chức vụ trong quá khứ, để đỡ tổn một, hai lần quốc tang.

Classify Text

Classification Results

Top 1 Prediction

Toxic

↑ 77.10%

Hình 4.5 Thực nghiệm kiểm tra câu có nội dung phản động (2)

PHỤ LỤC

Câu hỏi 1: Giải thích rõ công thức tính 2 điểm F1 và ý nghĩa: Đã giải thích trong chương 3, phần các chỉ số đánh giá hiệu suất

Câu hỏi 2: Tại sao các mô hình, điểm F1-macro lại luôn nhỏ hơn F1-micro?

Trong bài toán phân loại này, về dữ liệu, dữ liệu bị mất cân bằng nhãn (nhãn 1 chỉ chiếm xấp xỉ 26%), vì F1-macro tính điểm trung bình F1-score của từng lớp mà không quan tâm đến số lượng mẫu, nên các lớp 1 ảnh hưởng mạnh và kéo thấp giá trị trung bình xuống. Còn F1-micro gộp tất cả các lớp rồi mới tính F1-score, nên lớp 0 chiếm ưu thế, từ đó kéo giá F1 -micro cao hơn cao hơn.

TÀI LIỆU THAM KHẢO

- [1] P. G. Hoang, C. D. Luu, K. Q. Tran, K. V. Nguyen, and N. L. T. Nguyen, “ViHOS: Hate Speech Spans Detection for Vietnamese,” University of Information Technology, Ho Chi Minh City, Vietnam; Vietnam National University, Ho Chi Minh City, Vietnam, 2023.
- [2] R. Martins, M. Gomes, J. J. Almeida, P. Novais, and P. R. Henriques, “Hate speech classification in social media using emotional analysis,” in *7th Brazilian Conference on Intelligent Systems, BRACIS 2021*.
- [3] S. T. Luu, K. V. Nguyen, and N. L. T. Nguyen, “A large-scale dataset for hate speech detection on Vietnamese social media texts,” University of Information Technology, Ho Chi Minh City, Vietnam; Vietnam National University, Ho Chi Minh City, Vietnam, 2021
- [4] S. Mohan, A. Guha, M. Harris, F. Popowich, A. Schuster, and C. Priebe, “The impact of toxic language on the health of reddit communities,” in *Advances in Artificial Intelligence - 30th Canadian Conference on Artificial Intelligence, Canadian AI 2017*, vol. 10233, 2017, pp. 51–56.
- [5] S. Abu-Ghazaleh, Y. Hassona, and S. Hattar, “Dental trauma in social media-analysis of facebook content and public engagement,” *Dental Traumatology: Official Publication of International Association for Dental Traumatology*, pp. 394–400, 2018.
- [6] S. Malmasi and M. Zampieri, “Detecting hate speech in social media,” in *Proceedings of the International Conference Recent Advances in Natural Language Processing, RANLP 2017*, 2017, pp. 467–472.
- [7] A. Schmidt and M. Wiegand, “A survey on hate speech detection using natural language processing,” in *Proceedings of the Fifth International Workshop on Natural Language Processing for Social Media, SocialNLP@EACL 2017*, 2017, pp. 1–10.
- [8] X. Vu, T. Vu, M. Tran, T. Le-Cong, and H. T. M. Nguyen, “HSD shared task in VLSP campaign 2019: Hate speech detection for social good,” *CoRR*, 2020.
- [9] Z. Waseem and D. Hovy, “Hateful symbols or hateful people? Predictive features for hate speech detection on twitter,” in *Proceedings of the Student Research Workshop, SRW@HLT-NAACL 2016, The 2016 Conference of the North American*

Chapter of the Association for Computational Linguistics: Human Language Technologies, 2016, pp. 88–93.

[10] J. Chen, S. Yan, and K. Wong, “Verbal aggression detection on twitter comments: Convolutional neural network for short-text sentiment analysis,” *Neural Comput. Appl.*, pp. 10 809–10 818, 2020.

[11] T. Davidson, D. Warmusley, M. W. Macy, and I. Weber, “Automated hate speech detection and the problem of offensive language,” in *Proceedings of the Eleventh International Conference on Web and Social Media, ICWSM 2017, May 15–18, 2017*, 2017, pp. 512–515

[12] R. Martins, M. Gomes, J. J. Almeida, P. Novais, and P. R. Henriques, “Hate speech classification in social media using emotional analysis,” in *7th Brazilian Conference on Intelligent Systems, BRACIS 2018*, 2018, pp. 61–66.

[13] A. Conneau, K. Khandelwal, N. Goyal, et al., “Unsupervised crosslingual representation learning at scale,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, ACL 2020*, 2020, pp. 8440–8451.

[14] A. Safaya, M. Abdullatif, and D. Yuret, “KUISAIL at semeval-2020 task 12: BERT-CNN for offensive speech identification in social media,” in *Proceedings of the Fourteenth Workshop on Semantic Evaluation, SemEval@COLING 2020*, 2020, pp. 2054–2059.

[15] Võ, T. H. N. (2022). *Phân tích biểu cảm mặt người dùng mạng nơ ron tích chập* (Luận văn thạc sĩ kỹ thuật, Học viện Công nghệ Bưu chính Viễn thông). PGS.TS. Lê Hoàng Thái hướng dẫn khoa học. Thành phố Hồ Chí Minh, Việt Nam.

[16] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, pp. 37–46, 1960.

[17] T. Vu, D. Q. Nguyen, D. Q. Nguyen, M. Dras, and M. Johnson, “VnCoreNLP: A Vietnamese natural language processing toolkit,” in *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations, Jun. 2018*.

[18] B. E. Boser, I. Guyon, and V. Vapnik, “A training algorithm for optimal margin classifiers,” in *Proceedings of the Fifth Annual ACM Conference on Computational*

Learning Theory, COLT 1992, Pittsburgh, PA, USA, July 27-29, 1992, ACM, 1992, pp. 144–152.

[19] L. Breiman, “Random forests,” *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.

[20] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.

[21] Y. Kim, “Convolutional neural networks for sentence classification,” in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing, EMNLP 2014*, 2014, pp. 1746–1751.

[22] Viblo, "BERT: Bước đột phá mới trong công nghệ xử lý ngôn ngữ tự nhiên của Google," *Viblo*, [Online]. Available: <https://viblo.asia/p/bert-buoc-dot-pha-moi-trong-cong-nghe-xu-ly-ngon-ngu-tu-nhien-cua-google-RnB5pGV7IPG>. [Accessed: Dec. 17, 2024].

[23] Viblo, "BERT, RoBERTa, PhoBERT, BERTweet: Ứng dụng state-of-the-art pre-trained model cho bài toán phân loại văn bản," *Viblo*, [Online]. Available: <https://viblo.asia/p/bert-roberta-phobert-bertweet-ung-dung-state-of-the-art-pre-trained-model-cho-bai-toan-phan-loai-van-ban-4P856PEWZY3>. [Accessed: Dec. 17, 2024].