

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Nguyễn Trường Huy	–	22022509
Cần Minh Nghĩa	–	21020082
Nguyễn Trọng Khánh	–	22022603
Trần Văn Công	–	22021180

BÁO CÁO BÀI BÁO:
LOFTR: DETECTOR-FREE LOCAL FEATURE
MATCHING WITH TRANSFORMERS

BÁO CÁO MÔN HỌC: CÁC VẤN ĐỀ HIỆN ĐẠI
CỦA CÔNG NGHỆ THÔNG TIN

HÀ NỘI – 2024

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Nguyễn Trường Huy	–	22022509
Cần Minh Nghĩa	–	21020082
Nguyễn Trọng Khánh	–	22022603
Trần Văn Công	–	22021180

BÁO CÁO BÀI BÁO:
LOFTR: DETECTOR-FREE LOCAL FEATURE
MATCHING WITH TRANSFORMERS

BÁO CÁO MÔN HỌC: CÁC VẤN ĐỀ HIỆN ĐẠI
CỦA CÔNG NGHỆ THÔNG TIN

Giảng viên: TS. Nguyễn Đức Anh
(ký tên)

HÀ NỘI – 2024

PHÂN CÔNG CÔNG VIỆC

MSV	Họ và tên	Công việc	% công việc
22022509	Nguyễn Trường Huy	• Đọc bài báo • Tổng hợp nội dung • Viết báo cáo phần 1 + 2 • Làm slide	30%
21020082	Cần Minh Nghĩa	• Đọc bài báo • Viết báo cáo phần 3 • Làm slide	20%
22022603	Nguyễn Trọng Khánh	• Đọc bài báo • Viết báo cáo phần 2 + 5 • Demo sản phẩm • Làm slide	30%
22021180	Trần Văn Công	• Đọc bài báo • Viết báo cáo phần 4 + 6 • Làm slide	20%

TÓM TẮT

Tóm tắt: AI (tiếng Anh: Artificial Intelligence), còn được biết đến như Trí tuệ nhân tạo, là một công nghệ có khả năng giải quyết vấn đề như con người. Cách thức hoạt động của AI mô phỏng trí tuệ của con người và cuối cùng, mục tiêu của trí tuệ nhân tạo là làm cho phần mềm thông minh hơn để đáp ứng tương tác người dùng và giải quyết vấn đề phức tạp. Hiện nay, AI đã được áp dụng cho rất nhiều lĩnh vực trong đời sống con người, đặc biệt là các tác vụ Computer Vision(CV). Với sự phát triển ngày càng mạnh của các mô hình Deep Learning (DL) như Transformer,... các tác vụ này có thể được thực hiện và đạt được hiệu quả cao để đáp ứng được nhu cầu của con người. Do vậy, trong báo cáo này chúng em muốn giới thiệu bài báo: **“LoFTR: Detector-Free Local Feature Matching with Transformers”**; ứng dụng AI cho tác vụ CV. Đường dẫn tới bài báo: <https://arxiv.org/pdf/2104.00680>

Từ khóa: *Trí tuệ nhân tạo, Computer Vision, Deep Learning, Transformer*


Mục lục

1. GIỚI THIỆU	5
1.1. Bài toán và các vấn đề của bài toán.....	5
1.2. Phương pháp đề xuất	6
2. PHƯƠNG PHÁP.....	7
2.1. Local Feature Extraction.....	7
2.2. Local Feature Transformer (LoFTR) Module	8
2.3. Coarse-level Matches	10
2.4. Coarse-to-Fine Module	11
2.5. Supervision.....	11
2.6. Implementation Details.....	12
3. THỰC NGHIỆM CỦA TÁC GIẢ.....	13
3.1. Homography Estimation	13
3.2. Relative Pose Estimation	13
3.3. Visual Localization.....	15
3.4. Tìm hiểu về LoFTR.....	16
4. KẾT LUẬN.....	18
5. PHỤ LỤC.....	19
5.1. Giải thích LoFTR Module	19
5.2. Giải thích kích thước của ma trận ở phần Coarse-level Matches	21
5.3. Vấn đề thay đổi góc nghiêng ảnh hưởng đến số lượng match tạo ra ..	21
6. TÀI LIỆU THAM KHẢO.....	22

1. GIỚI THIỆU


1.1. Bài toán và các vấn đề của bài toán

- So khớp đặc trưng cục bộ (Local feature matching) giữa các ảnh là bài toán tìm ra các điểm đặc trưng tương ứng chính xác giữa các ảnh khác nhau.
- Local feature matching là nền tảng cho các tác vụ thị giác máy tính 3D: structure from motion (SfM), simultaneous localization and mapping (SLAM), visual localization,...
- Phần lớn các phương pháp matching trước đó được chia làm 3 giai đoạn:
 - **Feature detection:** tìm kiếm các điểm quan trọng (interest points) trong hình ảnh, như các điểm góc (corner), các cạnh (edge),...
 - **Feature description:** trích xuất các biểu diễn cục bộ xung quanh các vùng lân cận của các điểm quan trọng ở trên
 - **Feature matching:** so khớp các interest points bằng các thuật toán
- Tuy nhiên, một bộ phát hiện đặc trưng (feature detector) có thể sẽ không trích xuất đủ các interest points lặp lại giữa các ảnh do thông tin ngữ cảnh kém, các mẫu lặp lại, thay đổi góc nhìn, độ sáng, mờ do chuyển động... chủ yếu xảy ra trong môi trường trong nhà (indoor). Ví dụ như trong **Hình 1**, việc thiếu đi các interest points như cạnh ghế, góc tường... sẽ khiến cho các bộ detector gặp khó khăn trong việc tìm ra các đặc trưng tương ứng.



Hình 1.1: So sánh giữa phương pháp đề xuất LoFTR
và phương pháp dựa trên detector SuperGlue

- Một vài phương pháp loại bỏ việc sử dụng feature detector bằng cách dùng mạng tích chập CNN (Convolutional Neural Network) để trích xuất các đặc trưng dày đặc, tuy nhiên, trường tiếp nhận của CNN khá hạn chế (**Hình 1.2 (a)**), có thể sẽ không phân biệt được các vùng không rõ ràng. Trên thực tế, con người tìm các điểm tương ứng không chỉ qua các vùng lân cận cục bộ, mà còn qua một vùng toàn cảnh lớn. Như trong **Hình 1.1**, con người có thể nhận ra các đặc trưng nhờ vào vị trí tương đối giữa các cạnh bàn. Với cách nhìn nhận ấy, tác giả cho rằng trường tiếp nhận lớn như của Transformer (**Hình 1.2 (b)**) vô cùng quan trọng với việc trích xuất các đặc trưng.
- Truyền cảm hứng bởi cách nhìn nhận trên, tác giả đề xuất phương pháp: Local Feature TRansformer (LoFTR) sử dụng cách tiếp cận detector-free cho bài toán local feature matching.




Hình 1.2: Minh họa trường tiếp nhận của **(a)** Convolutions và **(b)** Transformers

1.2. Phương pháp đề xuất

- Tổng quan phương pháp:
 - Sử dụng self và cross attention layers của Transformer để biến đổi các đặc trưng cục bộ dày đặc được trích xuất từ convolutional backbone thành các transformed features (phụ thuộc về vị trí và ngữ cảnh) với kích thước $\frac{1}{8}$ so với ảnh gốc.
 - Các khớp (matches) dày đặc được trích xuất từ các transformed features, chọn ra các matches có độ tin cậy cao và tiếp tục tinh chỉnh thêm ở một sub-pixel level bằng cách tiếp cận dựa trên correlation để chọn ra các matches chính xác nhất.
- LoFTR đạt được kết quả vượt trội so với các phương pháp trước đó trong các tác vụ image matching, pose estimation, visual localization trên các tập dữ liệu indoor (trong nhà) và outdoor (ngoài trời)

2. PHƯƠNG PHÁP


- **Đầu vào:** Cho một cặp ảnh I^A và I^B
- **Đầu ra:** Các điểm đặc trưng tương ứng giữa 2 ảnh
- Tổng quan về phương pháp đề xuất LoFTR được minh họa như **Hình 2.1**



Hình 2.1: Tổng quan về phương pháp đề xuất LoFTR

2.1. Local Feature Extraction

- Sử dụng kiến trúc tích chập tiêu chuẩn Feature Pyramid Network (FPN) (**Hình 2.2**) kết hợp với Resnet-18 làm feature extractor, trích xuất các đặc trưng của hai ảnh đầu vào. Ở đây, $\tilde{F}^A$ và $\tilde{F}^B$ là đặc trưng ở coarse-level (cấp độ nổi thô) với kích thước $1/8$ so với kích thước ảnh gốc, và $\hat{F}^A$ và $\hat{F}^B$ là đặc trưng ở fine-level (cấp độ nổi mịn) với kích thước $1/2$ so với kích thước ảnh gốc.




Hình 2.2: Kiến trúc FPN

2.2. Local Feature Transformer (LoFTR) Module

- $\tilde{F}^A$ và $\tilde{F}^B$ được đưa vào LoFTR module để biến đổi thành các đặc trưng phụ thuộc về ngữ cảnh và vị trí, gọi các transformed features này là $\tilde{F}_{tr}^A$ và $\tilde{F}_{tr}^B$
- **Transformer encoder:**
 - Input vectors của Transformer encoder được biến đổi thành các query, key, và value Q, K, V thông qua các ma trận biến đổi (Hình 2.3 (a)). Query vector Q truy xuất thông tin từ value vector V theo trọng số attention tính toán bằng dot product của Q và K ứng với mỗi V :

$$Attention(Q, K, V) = softmax(QK^T)V$$


- Output vector là tổng của các value vector



Hình 2.3: (a) Transformer encoder layer. h biểu thị số đầu multiple heads attention.

(b) Vanilla dot-product attention. (c) Linear attention layer

- **Linear Transfomer:** thay vì dùng Vanilla attention (**Hình 2.3 (b)**) truyền thống, dùng Linear attention (**Hình 2.3 (c)**) để giảm tốc độ tính toán từ $O(N^2)$ thành $O(N)$ do $D \ll N$ với D là số chiều của feature, N là độ dài của Q, K (**Hình 2.4**)




Hình 2.4: Minh họa sự khác biệt giữa 2 loại attention

- **Positional Encoding:** thêm một lớp 2D extensions positional encoding vào đầu ra của backbone để học các thông tin về vị trí, khiến các vector đặc trưng trở nên phụ thuộc về vị trí. Như ở **Hình 2.5**, mặc dù có màu đồng nhất trên bức tường trắng nhưng các transformed features $\tilde{F}_{tr}^A$ và $\tilde{F}_{tr}^B$ lại là duy nhất với mỗi vị trí. Công thức 2D extensions positional encoding:

$$\mathcal{PE}_{xy}^i = f(x, y)^i := \begin{cases} \sin(\omega_k \cdot x), & i = 4k \\ \cos(\omega_k \cdot x), & i = 4k + 1 \\ \sin(\omega_k \cdot y), & i = 4k + 2 \\ \cos(\omega_k \cdot y), & i = 4k + 3 \end{cases}$$

với $\omega_k = \frac{1}{10000^{2k/d}}$, d là số chiều của features, i là chỉ số của chiều



Hình 2.5: Trực quan hóa trọng số attention và transformed dense features

- **Self-attention và Cross-attention Layers:** trong **Hình 2.3 (a)**, f_i và f_j đồng thời cùng là $\tilde{F}^A$ hoặc cùng là $\tilde{F}^B$ với Self-attention, còn với Cross-attention, f_i và f_j là $\tilde{F}^A$ và $\tilde{F}^B$ hoặc $\tilde{F}^B$ và $\tilde{F}^A$. Xen kẽ các lớp self và cross-attention N_c lần. Trọng số attention của self, cross-attention được trực quan hóa ở **Hình 2.5**.

2.3. Coarse-level Matches

- Có 2 phương pháp matching có thể được áp dụng:
 - **Optimal transport (OT):** tính inner production để tạo score matrix S biểu diễn similarity giữa $\tilde{F}_{tr}^A$ và $\tilde{F}_{tr}^B$ với D là số chiều của $\tilde{F}_{tr}$. – S có thể được dùng làm cost matrix:

$$S(i, j) = \frac{1}{D} \cdot \langle \tilde{F}_{tr}^A(i), \tilde{F}_{tr}^B(j) \rangle$$

- **Dual-softmax operator (DS):** dùng thêm softmax lên ma trận S để tạo ra ma trận xác suất matching P_c theo công thức:

$$P_c(i, j) = \text{softmax}(S(i, \cdot))_j \cdot \text{softmax}(S(\cdot, j))_i$$

- **Match Selection:** Từ ma trận P_c chọn ra các matches với điểm tin cậy cao hơn threshold θ_c và áp dụng thêm tiêu chí mutual nearest neighbor (MNN). MNN: 2 điểm $i \in A$ và $j \in B$ được coi là 1 match (i, j) khi và chỉ khi i có điểm tương đồng cao nhất với j trong tập A và đồng thời j có điểm tương đồng cao nhất với i trong tập B . Kí hiệu tập matches ở coarse-level:

$$\mathcal{M}_c = \{(\tilde{i}, \tilde{j}) \mid \forall (\tilde{i}, \tilde{j}) \in MNN(P_c), P_c((\tilde{i}, \tilde{j})) \geq \theta_c\}$$

2.4. Coarse-to-Fine Module

- Các matches thu được ở trên được tinh chỉnh về kích thước ảnh gốc bằng cách tiếp cận dựa trên correlation (**Hình 2.1**)
- Với mỗi coarse match $(\tilde{i}, \tilde{j})$, định vị vị trí tương ứng với nó $(\hat{i}, \hat{j})$ trên fine-level feature maps $\hat{F}^A$ và $\hat{F}^B$, sau đó crop 2 cửa sổ với size $w \times w$ xung quanh tâm $\hat{i}$ và $\hat{j}$
- Dùng một module LoFTR nhỏ hơn (xen kẽ self và cross-attention N_f lần) để biến đổi đặc trưng ở vùng crop được trong mỗi cửa sổ thành các transformed features $\hat{F}_{tr}^A(\hat{i})$ và $\hat{F}_{tr}^B(\hat{j})$
- Sau đó, tính tương quan bằng tích vô hướng giữa vector tâm của $\hat{F}_{tr}^A(\hat{i})$ với toàn bộ vector của $\hat{F}_{tr}^B(\hat{j})$ để tạo ra một heatmap biểu thị xác suất matching của mỗi pixel xung quanh $\hat{j}$ với $\hat{i}$ tương ứng.
- Tính kì vọng trên heatmap ta lấy được vị trí matching cuối cùng $\hat{j}^*$. Kí hiệu tất cả các matches thu được ở fine-level là kết quả matching cuối cùng:

$$\mathcal{M}_f = \{(\hat{i}, \hat{j}^*)\}$$

2.5. Supervision

- Hàm loss tổng hợp loss của 2 level coarse-level và fine-level:

$$L = L_c + L_f$$

- **Coarse-level Supervision:** $\mathcal{M}_c^{gt}$ là tập ground-truth coarse matches, được tác giả tính bằng camera poses và depth maps:

$$L_c = - \frac{1}{|\mathcal{M}_c^{gt}|} \sum_{(\tilde{i}, \tilde{j}) \in \mathcal{M}_c^{gt}} \log P_c(\tilde{i}, \tilde{j})$$

- **Fine-level Supervision:** đo độ không chắc chắn bằng tổng phương sai $\sigma^2(\hat{i})$ của heatmap tương ứng:

$$L_f = \frac{1}{|\mathcal{M}_f|} \sum_{(i,j) \in \mathcal{M}_f} \frac{1}{\sigma^2(\hat{i})} \|\hat{J} - \hat{J}_{gt}\|_2$$

2.6. Implementation Details

- Mô hình indoor được huấn luyện trên tập Scannet và mô hình outdoor được huấn luyện trên tập MegaDepth
- Trên tập Scannet, dùng Adam với learning rate 0.001, batchsize 64
- Hội tụ sau 24h huấn luyện trên 64 GTX 1080Ti GPUs.
- Backbone: Resnet18 thiết kế theo kiến trúc FPN
- Trọng số được khởi tạo ngẫu nhiên
- $N_c = 4, N_f = 1, \theta_c = 0.2, w = 5$
- $\tilde{F}_{tr}^A$ và $\tilde{F}_{tr}^B$ được upsample và and concatenate với $\hat{F}^A$ và $\hat{F}^B$ trước khi được đưa vào fine-level
- Mô hình với dual-softmax matching chạy 116ms cho một cặp ảnh 640 x 480 trên RTX 2080Ti

3. THỰC NGHIỆM CỦA TÁC GIẢ

3.1. Homography Estimation

- *Homography Estimation*: Tính toán ma trận biến đổi homography để ánh xạ một ảnh 2D sang ảnh khác
- *Tập dữ liệu*: Bộ dữ liệu HPatches chứa 52 chuỗi ảnh có sự thay đổi về độ sáng và 56 chuỗi ảnh có sự thay đổi về góc quay
- *Phương pháp đánh giá*: Với mỗi chuỗi ảnh, một ảnh gốc sẽ được ghép với năm ảnh còn lại. Với mỗi cặp ảnh, ta trích xuất tập điểm tương đồng bằng LoFTR huấn luyện trên tập MegaDepth, sau đó sử dụng RANSAC (OpenCV) để ước tính ma trận biến đổi H' . Corner error giữa ảnh biến đổi bởi H' và H (ground truth) được tính toán để đánh giá.
- *Kết quả*: LoFTR vượt trội so với các phương pháp khác

Category	Method	Homography est. AUC			#matches
		@3px	@5px	@10px	
Detector-based	D2Net [11]+NN	23.2	35.9	53.6	0.2K
	R2D2 [32]+NN	50.6	63.9	76.8	0.5K
	DISK [47]+NN	52.3	64.9	78.9	1.1K
	SP [9]+SuperGlue [37]	53.9	68.3	81.7	0.6K
Detector-free	Sparse-NCNet [33]	48.9	54.2	67.1	1.0K
	DRC-Net [19]	50.6	56.2	68.3	1.0K
	LoFTR-DS	65.9	75.6	84.6	1.0K

Hình 3.1: Homography Estimation trên tập Hpatches

3.2. Relative Pose Estimation

- *Relative Pose Estimation*: xác định sự chênh lệch về vị trí và góc quay giữa hai camera từ các cặp ảnh tương ứng
- *Tập dữ liệu*: Bộ dữ liệu ScanNet (Gồm 1613 chuỗi ảnh đơn với ground truth về pose và bản đồ độ sâu. Dữ liệu huấn luyện gồm 230 triệu cặp ảnh có độ trùng lặp từ 0.4 đến 0.8, resize về 640×480 . Tập kiểm tra gồm 1500 cặp ảnh với baseline rộng và nhiều vùng thiếu texture) và MegaDepth (Gồm 1 triệu ảnh từ 196 cảnh ngoài trời, với bản đồ độ sâu từ multi-view stereo. Tập kiểm tra lấy từ hai cảnh “Sacre Coeur” và “St. Peter’s Square” với 1500 cặp ảnh, resize với chiều dài tối đa 840 (huấn luyện) và 1200 (kiểm tra). Dữ liệu có nhiều sự thay đổi góc nhìn và các vùng họa tiết lặp lại).

- *Phương pháp đánh giá:* Đo AUC của lỗi pose tại các ngưỡng (5° , 10° , 20°), với lỗi pose là giá trị lớn nhất giữa lỗi góc quay và lỗi dịch chuyển. Ma trận pose được khôi phục từ các điểm matching bằng RANSAC để tính essential matrix.
- *Kết quả:*
 - Scannet:
 - LoFTR đạt hiệu suất vượt trội so với các phương pháp khác, với AUC cao nhất ở mọi ngưỡng.
 - Hai biến thể LoFTR-OT và LoFTR-DS đạt kết quả tương đương, thể hiện sự hiệu quả của các lớp matching dựa trên optimal transport và dual-softmax.
 - LoFTR huấn luyện trên MegaDepth (LoFTR[†]) cũng vượt trội so với DRC-Net[†] trên ScanNet, thể hiện tính tổng quát hóa cao giữa các tập dữ liệu.

Category	Method	Pose estimation AUC		
		@ 5°	@ 10°	@ 20°
Detector-based	ORB [35]+GMS [2]	5.21	13.65	25.36
	D2-Net [11]+NN	5.25	14.53	27.96
	ContextDesc [27]+Ratio Test [26]	6.64	15.01	25.75
	SP [9]+NN	9.43	21.53	36.40
	SP [9]+PointCN [52]	11.40	25.47	41.41
	SP [9]+OANet [53]	11.76	26.90	43.85
	SP [9]+SuperGlue [37]	16.16	33.81	51.84
Detector-free	DRC-Net [†] [19]	7.69	17.93	30.49
	LoFTR-OT [†]	16.88	33.62	50.62
	LoFTR-OT	21.51	40.39	57.96
	LoFTR-DS	22.06	40.8	57.62

Hình 3.2: Indoor Pose Estimation trên tập ScanNet

- MegaDepth:
 - LoFTR vượt DRC-Net với mức tăng 61% ở AUC@ 10° và vượt SuperGlue với mức tăng 13% ở AUC@ 10°
 - LoFTR-DS thể hiện hiệu suất tốt hơn LoFTR-OT trên MegaDepth, đặc biệt trong điều kiện thay đổi góc nhìn lớn và họa tiết lặp lại.

Category	Method	Pose estimation AUC		
		@5°	@10°	@20°
Detector-based	SP [9]+SuperGlue [37]	42.18	61.16	75.96
Detector-free	DRC-Net [19]	27.01	42.96	58.31
	LoFTR-OT	50.31	67.14	79.93
	LoFTR-DS	52.8	69.19	81.18

Hình 3.3: Outdoor Pose Estimation trên tập MegaDepth

⇒ Kết quả cho thấy thiết kế detector-free của LoFTR dựa trên Transformer giúp cải thiện đáng kể độ chính xác trong bài toán pose estimation cả ở môi trường trong nhà lẫn ngoài trời.

3.3. Visual Localization

- *Visual Localization*: Ước tính 6-DoF poses (vị trí và góc quay) của ảnh đầu vào với mô hình 3D của cảnh tương ứng. Nhiệm vụ này rất thách thức do sự thay đổi về ánh sáng (ngày/đêm), hình học cảnh, hoặc các vùng thiếu texture (indoor scenes). Hiệu suất của bài toán phụ thuộc vào khả năng matching ảnh chính xác và bền vững.
- *Tập dữ liệu*: Aachen Day-Night Dataset: Ngoài trời, chứa các ảnh ngày/đêm. InLoc Dataset: Trong nhà, với nhiều thay đổi về appearance, texture thiếu hụt, và các yếu tố đối xứng/lặp lại.
- *Kết quả*: LoFTR vượt trội so với các phương pháp khác:
 - Local Feature Challenge Track: LoFTR-DS đạt hiệu suất vượt trội so với tất cả baseline, thể hiện tính robust dưới điều kiện ngày-đêm thay đổi.

Method	Day	Night
	(0.25m,2°) / (0.5m,5°) / (1.0m,10°)	
Local Feature Evaluation on Night-time Queries		
R2D2 [32]+NN	-	71.2 / 86.9 / 98.9
LISRD [31]+SP [9]+AdaLam [4]	-	73.3 / 86.9 / 97.9
ISRF [29]+NN	-	69.1 / 87.4 / 98.4
SP [9]+SuperGlue [37]	-	73.3 / 88.0 / 98.4
LoFTR-DS	-	72.8 / 88.5 / 99.0
Full Visual Localization with HLoc		
SP [9]+SuperGlue [37]	89.8 / 96.1 / 99.4	77.0 / 90.6 / 100.0
LoFTR-OT	88.7 / 95.6 / 99.0	78.5 / 90.6 / 99.0

Hình 3.4: Visual Localization trên tập Aachen-Daylight

- Handheld Devices Track: LoFTR-OT vượt trội so với các phương pháp đã công bố trên InLoc dataset, nhờ khả năng xử lý tốt các vùng thiếu texture, yếu tố đối xứng/lặp lại và thay đổi appearance. Trên Aachen v1.1 dataset, LoFTR-OT có hiệu suất tương đương với SuperPoint + SuperGlue trên các ảnh đêm và chỉ kém một chút trên các ảnh ngày.

Method	DUC1	DUC2
	(0.25m, 10°) / (0.5m, 10°) / (1.0m, 10°)	
ISRF [29]	39.4 / 58.1 / 70.2	41.2 / 61.1 / 69.5
KAPTURE [14]+R2D2 [32]	41.4 / 60.1 / 73.7	47.3 / 67.2 / 73.3
HLoc [36]+SP [9]+SuperGlue [37]	49.0 / 68.7 / 80.8	53.4 / 77.1 / 82.4
HLoc [36]+LoFTR-OT	47.5 / 72.2 / 84.8	54.2 / 74.8 / 85.5

Hình 3.5: Visual Localization trên tập InLoc


3.4. Tìm hiểu về LoFTR

- Ablation Study: Đánh giá vai trò của các thành phần trong LoFTR bằng cách thử nghiệm với các biến thể khác nhau.
 - Thay thế LoFTR bằng Convolution: Sử dụng convolution với số lượng tham số tương đương dẫn đến giảm đáng kể AUC, như dự đoán.
 - Giảm kích thước Feature Maps: Sử dụng bản nhỏ hơn của LoFTR với feature maps có độ phân giải 1/16 (coarse) và 1/4 (fine) làm giảm độ chính xác của pose estimation, mặc dù thời gian chạy giảm còn 104ms.
 - Kiến trúc Transformer theo phong cách DETR: Thay thế bằng Transformer kiểu DETR với positional encoding ở mỗi layer dẫn đến giảm hiệu suất đáng kể.
 - Tăng số Layer trong LoFTR: Tăng số layer của LoFTR lên $N_c = 8$ và $N_f = 2$ hầu như không cải thiện kết quả.

Method	Pose estimation AUC		
	@5°	@10°	@20°
1) replace LoFTR with convolution	14.98	32.04	49.92
2) 1/16 coarse-resolution + 1/4 fine-resolution	16.75	34.82	54.0
3) positional encoding per layer	18.02	35.64	52.77
4) larger model with $N_c = 8$, $N_f = 2$	20.87	40.23	57.56
Full ($N_c = 4$, $N_f = 1$)	20.06	40.8	57.62

Hình 3.6: Ablation Study

- Visualization: Hình ảnh trực quan về attention weights được minh họa, giúp hiểu rõ hơn về cách LoFTR học và sử dụng thông tin toàn cục.



Hình 3.7: Trực quan hóa attention weights

4. KẾT LUẬN

- Phương pháp LoFTR mang lại cách tiếp cận tiên tiến trong việc giải quyết bài toán khớp đặc trưng cục bộ, vốn là một trong những thách thức lớn trong thị giác máy tính.
- Việc loại bỏ nhu cầu sử dụng các bộ phát hiện truyền thống (detector-free) giúp LoFTR không bị giới hạn bởi các đặc điểm được trích xuất từ các thuật toán cũ như SIFT hay ORB, vốn có thể không hiệu quả trên các vùng low-texture hoặc có repetitive patterns. Cách tiếp cận coarse-to-fine của LoFTR đảm bảo rằng quá trình tìm kiếm đặc trưng diễn ra mượt mà, từ việc xác định các đặc trưng cơ bản đến tinh chỉnh chính xác các điểm khớp.
- Điểm nổi bật của LoFTR chính là khả năng sử dụng các lớp self-attention và cross-attention trong Transformer. Những cơ chế này không chỉ giúp các đặc trưng cục bộ trở nên phụ thuộc vào context và position, mà còn cho phép mô hình học được các tương quan phức tạp giữa các điểm trên hình ảnh. Điều này là một bước tiến lớn, đặc biệt trong các ứng dụng thực tế đòi hỏi độ chính xác cao, chẳng hạn như relative pose estimation hay visual localization.
- Hiệu quả của LoFTR đã được kiểm chứng trên nhiều bộ dữ liệu tiêu chuẩn, chứng minh khả năng vượt trội của nó so với các phương pháp hiện có. Không chỉ đạt hiệu suất hàng đầu, LoFTR còn mở ra tiềm năng ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau, từ robot tự hành, dựng lại môi trường 3D, cho đến thực tế tăng cường (AR).

5. PHỤ LỤC

5.1. Giải thích LoFTR Module

- Ảnh đầu vào với độ phân giải 640×480 đưa vào mô hình từ giai đoạn một sẽ tạo ra vector ở mức thô với kích thước $80 \times 60 \times C$ chiều để chuyển sang giai đoạn 2
- Mô tả vector :
 - mỗi vector mô tả đặc trưng về một vùng có độ rộng 8×8 trên ảnh gốc
 - $C = 256$ ở lớp thô và 128 ở lớp tinh
 - 256 giá trị này được CNN trích xuất để học được các thông tin như màu sắc, góc, cạnh, mẫu hoa văn,
- Flatten:
 - Với đầu vào là một vector 3 chiều $H' \times W' \times C$, dùng flatten để thu được một vector 2 chiều $(H' \times W') \times C$
 - Quá trình toán học
 - Duyệt qua từng điểm ảnh (i, j) trong $H' \times W'$.
 - Tạo ra một vector 1D $f_{\{i,j\}} \in \mathbb{R}^C$ cho mỗi vị trí (i, j) .
 - Ghép nối tất cả các vector $f_{\{i,j\}}$ thành một ma trận 2D:

$$\tilde{F}_A^{flat} = [f_{\{1,1\}}, f_{\{1,2\}}, \dots, f_{\{H',W'\}}]^T.$$
- Positional Encoder:

$$p_{\{i,j\}}[k] = \begin{cases} \sin\left(\frac{(i * W' + j) * k}{10000^{\frac{C}{2}}}\right), & \text{nếu } k \text{ lẻ} \\ \cos\left(\frac{(i * W' + j) * k}{10000^{\frac{C}{2}}}\right), & \text{nếu } k \text{ chẵn} \end{cases}$$

- k là chỉ số của chiều trong vector C
- i, W', j là các chỉ số liên quan đến vị trí của điểm ảnh
- Sau khi tính toán ta thu được position encoding P, cộng trực tiếp vào ma trận đặc trưng để sử dụng trong Attention

$$\tilde{F}_A^{enc} = \tilde{F}_A^{flat} + P$$

$$\tilde{F}_A^{enc} \in \mathbb{R}^{(H'W') \times C}$$

- Sau khi đã hoàn thành quá trình flatten và position encoding thì output ta thu được sẽ được sử dụng cho self và cross attention
- Trong quá trình này sẽ sử dụng 3 ma trận tham số đã học được từ quá trình train là

$$W_Q, W_K, W_V \in \mathbb{R}^{d \times d_k} \text{ là các trọng số học được}$$

các ma trận Q, K, V được tính như sau :

$$Q = FW_Q, K = FW_K, V = FW_V$$

- Từ các ma trận đó ta áp vào công thức sau để thu được các ma trận đầu ra từ self và cross attention :

- Self :

$$A_{self} = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)$$

$$F'_{self} = A_{self}V$$

- Cross:

$$A_{cross} = softmax\left(\frac{Q_A K_B^T}{\sqrt{d_k}}\right)$$

$$F'_{cross} = A_{cross}V_B$$

- Nếu áp dụng linear tranformer thì sẽ áp dụng thêm hàm kích hoạt cho mỗi vector Q, K, V để giảm số lượng phép tính cần thực hiện

```
for layer, name in zip(self.layers, self.layer_names):
    if name == 'self':
        # Self-attention
        feat0 = layer(feat0, feat0, mask0, mask0)
        feat1 = layer(feat1, feat1, mask1, mask1)
    elif name == 'cross':
        # Cross-attention
        feat0 = layer(feat0, feat1, mask0, mask1)
        feat1 = layer(feat1, feat0, mask1, mask0)
    else:
        raise KeyError
```

- Quá trình self và cross attention sẽ được thực hiện dựa trên thiết lập sẵn trong `layer_names`
- Quá trình trên sẽ lần lượt biến đổi các vector đặc trưng của ảnh để có thể học được các đặc trưng từ cả ảnh A (self) và B(cross)
- Vector đầu ra thu được có kích thước $(H' \times W') \times C$ (với C ở lớp thô là 256)

5.2. Giải thích kích thước của ma trận ở phần Coarse-level Matches

- Phần này hai vector đầu vào là kết quả của quá trình trước đó nên sẽ có kích thước tương tự với vector đầu ra của giai đoạn attention $(H' \times W') \times C$
- Lưu ý : Ở đây đang xét batch size với batch size bằng một nếu thay đổi giá trị lớn hơn thì kích thước vector sẽ trở thành $batch_size \times (H' \times W') \times C$ do tính chất xử lý song song được áp dụng

5.3. Vấn đề thay đổi góc nghiêng ảnh hưởng đến số lượng match tạo ra

- LoFTR hoạt động dựa trên đặc trưng **dense features** và sử dụng self-attention và cross-attention để tìm các điểm phù hợp giữa hai ảnh. Tuy nhiên:
 - Self-Attention: Chỉ xử lý thông tin nội tại của một ảnh, không giúp bù đắp sự thay đổi góc nghiêng.
 - Cross-Attention: Phụ thuộc vào mức độ tương đồng giữa đặc trưng của hai ảnh. Nếu góc nghiêng thay đổi mạnh, các đặc trưng tương đồng khó được tìm thấy.
- LoFTR không tự động khắc phục sự thay đổi hình học lớn, vì nó không sử dụng thông tin về phối cảnh hay các mô hình hình học.

6. TÀI LIỆU THAM KHẢO

- Amazon Web Services (AWS). (n.d.). *What is Artificial Intelligence?*. [<https://aws.amazon.com/vi/what-is/artificial-intelligence/>]
- Sun, Z., Shen, T., Wang, Y., Bao, H., & Zhou, X. (2021). *LoFTR: Detector-Free Local Feature Matching with Transformers*. arXiv preprint arXiv:2104.00680. [<https://arxiv.org/pdf/2104.00680>]
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention is All You Need*. arXiv preprint arXiv:1612.03144v2. [<https://arxiv.org/pdf/1612.03144v2>]
- Liu, J., et al. (2023). *Transformers in Vision: A Survey*. arXiv preprint arXiv:2308.00442v2. [<https://arxiv.org/pdf/2308.00442v2>]
- Sun, Z., Shen, T., Wang, Y., Bao, H., & Zhou, X. (2021). *Supplementary Material for LoFTR: Detector-Free Local Feature Matching with Transformers*. [<https://zju3dv.github.io/loftr/files/LoFTR-suppmat.pdf>]
- Sarlin, P.-E., et al. (2020). *SuperGlue: Learning Feature Matching with Graph Neural Networks*. arXiv preprint arXiv:1911.11763. [<https://arxiv.org/abs/1911.11763>]
- Dusmanu, M., et al. (2019). *D2-Net: A Trainable CNN for Joint Detection and Description of Local Features*. arXiv preprint arXiv:1905.03561. [<https://arxiv.org/abs/1905.03561>]