

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO

CÁC VẤN ĐỀ HIỆN ĐẠI CỦA CÔNG NGHỆ THÔNG TIN

**LIGHTRAG: SIMPLE AND FAST
RETRIEVAL-AUGMENTED GENERATION**

Giảng viên:	TS. Nguyễn Đức Anh	
Mã môn học:	INT3507_1	
Sinh viên thực hiện:	Nguyễn Anh Tú	23020147
	Lê Trọng Thực	23020165
	Trương Văn Hải	23020058
	Nguyễn Hoàng Vũ	23020177

HÀ NỘI – 2025

TÓM TẮT

Báo cáo này tập trung phân tích kiến trúc LightRAG, một hệ thống truy xuất hiệu suất tốt dựa trên đồ thị tri thức, nhằm giải quyết vấn đề chi phí vận hành và cập nhật dữ liệu, hiện đang là một trong những điểm yếu chính của các hệ thống RAG khác. Trong báo cáo, nhóm lần lượt trình bày vấn đề của các hệ thống RAG hiện tại, giải thích tổng quan về bài toán tra cứu thông tin và chỉ ra cơ sở lý thuyết của hệ thống RAG. Sau đó nhóm đi sâu vào phân tích kiến trúc LightRAG và chỉ ra điểm mạnh của nó so với hệ thống khác. Cuối cùng là thực nghiệm đánh giá và đề xuất ý tưởng cải tiến của nhóm.

LỜI CAM ĐOAN

Cam kết của các thành viên nhóm: Chúng em, các thành viên của nhóm này, không sao chép bất kỳ nội dung nào từ các nhóm khác hoặc sử dụng bất kỳ nội dung nào có nguồn gốc từ các công cụ AI như Chat GPT hoặc bất kỳ phần mềm hỗ trợ nào khác. Toàn bộ báo cáo dựa trên nỗ lực, nghiên cứu và sự sáng tạo của nhóm em. Chúng em chấp nhận hình phạt 0 điểm trong trường hợp vi phạm dù chỉ một đoạn văn hoặc câu trong báo cáo này, như đã nêu trong nội quy và quy định của trường. Chúng em hoàn toàn chịu trách nhiệm nếu cam kết trên không được chúng em thực hiện nghiêm túc.

Mục lục

Mục lục	iv
Danh sách hình vẽ	vi
Danh sách bảng	vii
Chương 1. Mở đầu	1
1.1. Đặt vấn đề	1
1.2. Mục tiêu của báo cáo	1
1.3. Phạm vi nghiên cứu	2
Chương 2. Tổng quan về bài toán tra cứu thông tin	3
2.1. Bài toán truy xuất thông tin	3
2.1.1. Phương pháp truyền thống	3
a) Tìm kiếm dựa trên từ khóa	3
b) BM25	3
c) Hạn chế của các phương pháp trên	4
2.1.2. Phương pháp hiện đại	4
a) Embedding	4
b) Vector Search	5
2.2. Đồ thị tri thức	5
Chương 3. Cơ sở lý thuyết	7
3.1. Large Language Model	7
3.2. Retrieval-Augmented Generation	7
3.2.1. Công nghệ RAG	8
3.2.2. Thách thức	8
Chương 4. Phân tích kiến trúc LightRAG	10
4.1. Tổng quan hệ thống	10
4.2. Cơ chế đánh chỉ mục dựa trên đồ thị	11
4.2.1. Trích xuất	11
4.2.2. LLM Profiling	12

4.2.3. Deduplication.....	13
4.2.4. Cập nhật dữ liệu mới	13
4.3. Cơ chế truy xuất hai cấp độ	14
4.3.1. Truy xuất cấp thấp.....	14
4.3.2. Truy xuất cấp cao.....	15
4.3.3. Ví dụ minh họa.....	16
4.4. Phân tích Độ phức tạp và Chi phí.....	16
4.4.1. API.....	16
4.4.2. Chi phí Tái cấu trúc	18
Chương 5. Thực nghiệm và Đánh giá	19
5.1. Thiết lập thực nghiệm	19
5.1.1. Bộ dữ liệu đánh giá	19
5.1.2. Sinh câu hỏi.....	20
5.1.3. Các mô hình cơ sở để so sánh	20
5.1.4. Chi tiết về triển khai đánh giá	21
5.2. So sánh LightRAG với các mô hình cơ sở (RQ1)	22
5.3. Ablation studies (RQ2).....	24
5.4. Nghiên cứu tình huống (RQ3).....	26
5.5. Chi phí mô hình và phân tích khả năng thích ứng (RQ4).....	30
Chương 6. Đề xuất cải tiến hệ thống	33
6.1. Hạn chế hiện tại của LightRAG.....	33
6.2. Đề xuất ý tưởng cải tiến.....	33
Chương 7. Kết luận	35
7.1. Về các phương pháp cải thiện đề xuất.....	35
7.2. Kết luận	35

Danh sách hình vẽ

4.1. Kiến trúc tổng thể của hệ thống LightRAG đề xuất	10
4.2. Prompt cho việc sinh đồ thị.....	12
4.3. Prompt cho việc trích xuất từ khóa	15
4.4. Ví dụ minh họa quy trình truy xuất và sinh câu trả lời	17

Danh sách bảng

5.1. So sánh LightRAG với các mô hình cơ sở	23
5.2. So sánh giữa các phiên bản lược bỏ của LightRAG và NaiveRAG.....	24
5.3. So sánh GraphRAG và LightRAG trong tình huống cụ thể.....	27
5.4. Token và chi phí giữa GraphRAG và LightRAG	32

Chương 1.

Mở đầu

1.1. Đặt vấn đề

Trong những năm gần đây, các mô hình ngôn ngữ lớn đã dần trở nên hiệu quả hơn trong việc giải quyết nhiều loại nhiệm vụ khác nhau. Tuy nhiên, chúng vẫn còn một số hạn chế về độ tin cậy và độ chính xác do các lỗi phát sinh từ việc mô hình thiếu kiến thức mới sau quá trình huấn luyện. Để giải quyết vấn đề này, RAG đã được áp dụng như một kỹ thuật thiết yếu để bổ sung thông tin bên ngoài khi các mô hình cần câu trả lời yêu cầu nguồn dữ liệu được cập nhật liên tục. Có rất nhiều kỹ thuật RAG khác nhau, và mỗi kỹ thuật đều có vấn đề riêng. Đặc biệt, trong những trường hợp cần tổng hợp thông tin từ nhiều nguồn khác nhau, các phương pháp RAG truyền thống thường hoạt động kém hiệu quả do thiếu sự liên kết giữa các nguồn thông tin. Cách tiếp cận mới để giải quyết những vấn đề này, như GraphRAG, khắc phục được điểm yếu này nhưng cũng bao gồm nhược điểm chính là chi phí vận hành và tài nguyên tính toán rất cao. Vì vậy, nhóm nghiên cứu của chúng tôi đã quyết định nghiên cứu sâu hơn về LightRAG. Đây là một kiến trúc mới nhằm mô hình hóa cấu trúc dữ liệu toàn cục thông qua đồ thị đồng thời đảm bảo truy xuất dữ liệu nhanh chóng và tiết kiệm chi phí.

1.2. Mục tiêu của báo cáo

Mục tiêu chính của báo cáo này là giải thích cách thức hoạt động của LightRAG. Phần giải thích này đi từ lý thuyết đến kiến trúc. Vì lý do đó, báo cáo này bao gồm các thông tin sau:

- Phân tích tổng quan về bài toán tra cứu thông tin, phân tích cơ sở lý thuyết và kiến trúc của hệ thống LightRAG.
- Phân tích về hạn chế của hệ thống LightRAG hiện tại, thực nghiệm và đánh giá, đề xuất hướng cải tiến phù hợp.

1.3. Phạm vi nghiên cứu

Nghiên cứu của chúng tôi trong báo cáo này được giới hạn trong bài toán xử lý dữ liệu văn bản. Toàn bộ quá trình phân tích nhóm chúng tôi trình bày sẽ bám sát vào nội dung bài báo gốc **LightRAG: Simple and Fast Retrieval-Augmented Generation**.

Đây là liên kết tới bài báo: <https://arxiv.org/pdf/2410.05779>

Chương 2.

Tổng quan về bài toán tra cứu thông tin

2.1. Bài toán truy xuất thông tin

2.1.1. Phương pháp truyền thống

a) Tìm kiếm dựa trên từ khóa

Phương pháp này đã tồn tại khá lâu và dựa vào sự liên quan giữa truy vấn và tài liệu để truy xuất. Sự liên quan này được tính dựa trên sự xuất hiện và tần suất của các từ khóa. Người dùng thực hiện tìm kiếm bằng cách sử dụng câu lệnh truy vấn dạng văn bản. Các tài liệu phù hợp sẽ được truy xuất dựa trên mức độ liên quan, thường được đánh giá theo xếp hạng mức độ liên quan. Tuy nhiên, vấn đề của phương pháp tìm kiếm này nằm ở chỗ nó không hiểu được ngữ nghĩa của truy vấn mà chỉ dựa vào cấp độ từ vựng. Điều này khiến nó phụ thuộc rất nhiều vào mức độ trùng khớp giữa các từ trong truy vấn với các từ trong tài liệu.

b) BM25

BM25 là một trong những hàm xếp hạng được sử dụng phổ biến trong ngữ cảnh tìm kiếm từ khóa. Mục tiêu của việc xếp hạng là mức độ liên quan của truy vấn đến tài liệu dựa trên ba tham số chính:

- Tần suất xuất hiện của từ trong tài liệu.
- Tần suất nghịch đảo của tài liệu. Các từ hiếm gặp trong tài liệu có khả năng phân biệt cao hơn.

- Độ dài tài liệu: BM25 tích hợp một kỹ thuật ngăn các tài liệu quá dài nhận được ưu tiên cao nhất.

Nhờ khả năng cân bằng tốt giữa các yếu tố này, BM25 đã được sử dụng rộng rãi trong nhiều hệ thống tìm kiếm thực tế như công cụ tìm kiếm văn bản, truy vấn cơ sở dữ liệu, tài liệu hoặc các hệ thống hỏi đáp truyền thống.

c) Hạn chế của các phương pháp trên

Tuy khá hiệu quả và đơn giản, việc tìm kiếm dựa trên từ khóa như BM25 tồn tại nhiều hạn chế trong việc hiểu ngữ nghĩa. Một số nguyên nhân là:

- Không xử lý được từ đồng nghĩa: Ví dụ nếu truy vấn có từ **sinh viên**, tài liệu chỉ có từ **học viên** sẽ không được trả về mặc dù nó có nghĩa tương đương.
- Không hiểu ngữ cảnh: Các từ đa nghĩa không được hiểu theo ngữ cảnh sử dụng.
- Không nắm bắt được mối quan hệ ngữ nghĩa: BM25 không mô hình hóa được mối quan hệ giữa các khái niệm, do nó chỉ dựa trên sự trùng khớp về từ vựng.

Do đó, các cách tiếp cận này thường kém hiệu quả hơn so với các phương pháp hiện đại như Vector Search dựa trên embedding.

2.1.2. Phương pháp hiện đại

a) Embedding

Embedding là một dạng biểu diễn dữ liệu bằng số, trong đó các đơn vị ngôn ngữ có thể là từ, câu hoặc đoạn văn sẽ được ánh xạ thành các vector trong không gian đa chiều. Không giống như các biểu diễn rời rạc truyền thống như one-hot, embedding có khả năng biểu diễn thông tin ngữ nghĩa của văn bản. Các mô hình embedding được huấn luyện sao cho:

- Các văn bản truyền tải thông tin hoặc ý nghĩa tương tự có các vector gần nhau.

- Các liên kết ngữ nghĩa (tương đương, tương phản,...) được biểu diễn gián tiếp bằng khoảng cách giữa các vector.

Trong hệ thống vector search, embedding trở thành một cầu nối kết nối truy vấn của người dùng với tập tài liệu, tạo điều kiện thuận lợi cho việc tìm kiếm các tài liệu liên quan mà không cần khớp từ khóa chính xác.

b) Vector Search

Trong tìm kiếm vector, cả truy vấn và tài liệu đều được ánh xạ vào cùng một không gian vector liên tục với số chiều cố định. Trong không gian này, các văn bản có ý nghĩa tương tự được đặt gần nhau, bất kể có sử dụng cùng một từ vựng hay không. Việc truy xuất dựa trên sự tương đồng hình học giữa các vector (thường được đo bằng độ tương đồng cosin hoặc tích vô hướng) chứ không phải dựa trên việc khớp từ khóa. Do đó, tìm kiếm vector cho phép các truy vấn tự nhiên, các cách diễn đạt khác nhau và các trường hợp liên quan đến từ đồng nghĩa hoặc cách diễn đạt gián tiếp. Tìm kiếm vector thường được coi là nền tảng của các hệ thống tìm kiếm ngữ nghĩa, một phần quan trọng của các kiến trúc RAG hiện đại.

2.2. Đồ thị tri thức

Đồ thị tri thức là cách biểu diễn tri thức dưới dạng đồ thị, trong đó mỗi thực thể trong thế giới thực được biểu diễn như một nút, và mỗi mối quan hệ giữa các thực thể đó được biểu diễn như một cạnh kết nối các nút này. Điều này cho phép hệ thống lưu trữ các dữ liệu riêng lẻ và đặc biệt là mối quan hệ giữa các dữ liệu đó trong một bối cảnh cụ thể. Đồ thị tri thức rất hữu ích cho các hệ thống để hiểu rõ hơn về cấu trúc dữ liệu bằng cách làm nổi bật các mối liên hệ giữa các thực thể dữ liệu, khác với cơ sở dữ liệu quan hệ nơi dữ liệu chỉ được lưu trữ dưới dạng bảng. Đồ thị tri thức không chỉ cho phép đặt

câu hỏi dựa trên các sự kiện đã biết mà còn có khả năng suy luận với sự trợ giúp của các mối liên hệ giữa dữ liệu để tạo ra tri thức ngầm dựa trên các sự kiện và mối liên hệ giữa chúng. Đồ thị tri thức đã trở nên rất quan trọng đối với các hệ thống dựa trên trí tuệ nhân tạo để biểu diễn ngữ nghĩa của dữ liệu bằng cách cung cấp kiến thức về các mối liên hệ giữa các mẫu thông tin khác nhau.

Chương 3.

Cơ sở lý thuyết

3.1. Large Language Model

Large Language Model (LLM) hay mô hình ngôn ngữ lớn, là những mô hình học sâu được thiết kế dựa trên kiến trúc transformer. Những mô hình này được huấn luyện trên một lượng lớn dữ liệu, thường là dữ liệu internet, có số lượng tham số cực lớn, thường là chục tỷ, trăm tỷ tham số. Do đó, LLM thường có khả năng hiểu, phân tích, sinh ngôn ngữ tự nhiên rất mạnh mẽ.

Dù có khả năng xử lý ngôn ngữ rất tốt, LLM vẫn đối mặt với những hạn chế cố định như:

- Ảo giác (Hallucination): tạo ra thông tin nghe có vẻ chính xác nhưng thực ra là không đúng.
- Giới hạn về kiến thức (Knowledge Cutoff): việc mô hình không có thông tin về các kiến thức mới sau thời điểm huấn luyện.

Đây chính là những lý do dẫn đến sự ra đời của kỹ thuật RAG (Retrieval-Augmented Generation) nhằm kết hợp sức mạnh của LLM với các nguồn dữ liệu tri thức bên ngoài.

3.2. Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG) là phương pháp hay kỹ thuật tận dụng sức mạnh của LLM bằng cách tích hợp các nguồn tri thức bên ngoài, tri thức của một miền nghiệp vụ nào đó vào quá trình sinh văn bản. Thay vì chỉ dựa vào các mô hình ngôn ngữ

lớn nền tảng, RAG là một phương pháp cung cấp cho những mô hình này những tri thức từ nguồn được cung cấp.

3.2.1. Công nghệ RAG

Một hệ thống RAG tổng quát, được biểu diễn bởi M , có hai phần chính: phần truy xuất và phần tạo sinh. Kỹ thuật này được mô tả như sau:

$$M = \{G, R = (\phi, \psi)\}$$

$$M(q; D) = G(q, \psi(q; \hat{D})), \quad \hat{D} = \phi(D)$$

Trong đó:

- G : Đây là mô-đun tạo sinh, có mục đích tạo ra văn bản.
- q : Truy vấn do người dùng nhập.
- D : Cơ sở dữ liệu tri thức bên ngoài
- R : Đây là thành phần truy xuất và bao gồm hai hàm con:
 - + $\phi(\cdot)$: Đây là hàm lập chỉ mục dữ liệu. Nó lấy cơ sở dữ liệu D và tạo ra một cấu trúc $\hat{D}$ cụ thể để lưu trữ.
 - + $\psi(\cdot)$: Hàm truy xuất dữ liệu, so sánh sự tương đồng giữa truy vấn q và dữ liệu $\hat{D}$ được lập chỉ mục, tìm kiếm các đoạn tài liệu phù hợp nhất với q trong $\hat{D}$.

3.2.2. Thách thức


Để xây dựng một hệ thống RAG tối ưu, cần xác định ba thách thức cần phải giải quyết:

- Truy xuất thông tin toàn diện (Comprehensive Information Retrieval): Hàm lập chỉ mục $\phi(\cdot)$ phải có khả năng trích xuất dữ liệu toàn diện, chính xác, vì điều này rất quan trọng trong việc nâng cao khả năng mô hình trả lời truy vấn hiệu quả.
- Truy xuất hiệu quả với chi phí thấp (Efficient and Low-Cost Retrieval): Cấu trúc dữ liệu sau khi lập chỉ mục $\hat{D}$ phải có khả năng cho phép việc truy vấn nhanh và rẻ để xử lý lượng lớn truy vấn.
- Khả năng thích ứng nhanh với sự thay đổi dữ liệu (Fast Adaptation to Data Changes): Hệ thống cần có khả năng điều chỉnh cấu trúc dữ liệu một cách linh hoạt để cập nhật dữ liệu mới từ tri thức bên ngoài, việc này rất quan trọng cho việc đảm bảo hệ thống duy trì sự cập nhật trong một bối cảnh mà kiến thức rất nhanh lỗi thời và luôn được cập nhật mới hằng ngày.

Chương 4.

Phân tích kiến trúc LightRAG

4.1. Tổng quan hệ thống



Hình 4.1. Kiến trúc tổng thể của hệ thống LightRAG đề xuất

Hệ thống LightRAG được thiết kế để khắc phục những hạn chế của các quy trình truy xuất truyền thống bằng cách tích hợp cấu trúc đồ thị vào quy trình xử lý văn bản. Quy trình làm việc của hệ thống LightRAG được phân loại thành hai bước xử lý văn bản: Lập chỉ mục văn bản dựa trên đồ thị và Truy xuất hai cấp độ. Ví dụ, trong bước đầu tiên của quy trình, được bắt đầu ở phía bên trái của đồ thị, từ dữ liệu văn bản thô, thay vì chỉ đơn thuần phân đoạn và lưu trữ dữ liệu, hệ thống LightRAG sử dụng một mô hình ngôn ngữ lớn để phân tích kỹ lưỡng dữ liệu được trích xuất. Hệ thống cố gắng xác định các thực thể và mối quan hệ giữa chúng để thiết lập các cặp khóa-giá trị. Một giai đoạn quan trọng trong quy trình này là "Loại bỏ trùng lặp", trong đó hệ thống tự động kết hợp các thực thể giống hệt nhau để đảm bảo rằng đồ thị tri thức được hình thành vừa mang tính thông tin cao vừa được cô đọng.

Khi người dùng nhập một truy vấn, hệ thống không chỉ tìm kiếm bằng một từ khóa duy nhất. Đây là chỗ LightRAG sử dụng quy trình tìm kiếm kép, như minh họa ở phía bên phải của sơ đồ trên. Truy vấn được chia nhỏ để tìm kiếm đồng thời ở hai cấp độ:

- Cấp độ thấp: Tập trung vào các thực thể và mối quan hệ có liên quan trực tiếp đến câu hỏi.
- Cấp độ cao: Bao gồm việc nắm bắt các chủ đề rộng hơn và các khái niệm tổng quát.

Cuối cùng, thông tin thu được được tập hợp lại, sau đó chúng cung cấp cho LLM một cái nhìn toàn diện để đưa ra câu trả lời cho truy vấn. Điều này rất quan trọng vì nó tránh được những sai sót trong các chi tiết nhỏ trong khi vẫn đảm bảo tính nhất quán trong các câu trả lời đòi hỏi tư duy toàn diện.

4.2. Cơ chế đánh chỉ mục dựa trên đồ thị

Hệ thống LightRAG nâng cao khả năng truy xuất bằng cách phân đoạn tài liệu và xây dựng một đồ thị tri thức toàn diện. Quá trình này được biểu diễn qua công thức sinh đồ thị sau:

$$\hat{D} = (\hat{V}, \hat{E}) = Dedupe \circ Prof(V, E)$$

trong đó V, E là tập hợp các thực thể và quan hệ được trích xuất từ các đoạn văn bản D_i . Quá trình này bao gồm ba bước xử lý chính sử dụng LLM: Trích xuất thực thể và quan hệ, LLM Profiling và Deduplication, trong đó bước trích xuất và profiling được hướng dẫn bởi một prompt chuyên biệt ở hình 4.2

4.2.1. Trích xuất

1. **Thực thể:** Hệ thống chọn ra tên của các thực thể như bác sĩ tim mạch, bệnh tim rồi nhóm chúng theo thể loại, sẽ là tổ chức, cá nhân, địa điểm hoặc sự kiện.

– **Đối với Quan hệ:**

- + *Khóa*: Có thể chứa một số từ khóa chỉ mục, được LLM tạo ra để bao quát các chủ đề rộng của các thực thể được kết nối.
- + *Giá trị*: Văn bản mô tả chi tiết quan hệ giữa hai thực thể.

Việc sử dụng cấu trúc khóa-giá trị này mang lại hiệu suất vượt trội so với các phương pháp khớp vector thiếu chính xác hoặc duyệt đồ thị tốn kém tài nguyên.

4.2.3. Deduplication

Vì có nhiều đoạn văn bản khác nhau do việc phân mảnh dữ liệu thô ban đầu, nên sẽ có nhiều thực thể và mối quan hệ có thể cùng xuất hiện trong nhiều đoạn. Vì lý do đó, để tối ưu hóa đồ thị tri thức, một hàm khử trùng lặp sẽ được sử dụng trong hệ thống để loại bỏ các thực thể hoặc quan hệ giống nhau. Cụ thể thì hàm trên phải thực hiện các bước sau:

1. Tìm các thực thể và mối quan hệ tương đương giữa các đoạn văn bản khác nhau.
2. Hợp nhất chúng thành một nút/cạnh duy nhất trong đồ thị toàn cục.

Điều này giúp giảm kích thước đồ thị, tiết kiệm chi phí tính toán khi thực hiện các thao tác trên đồ thị trong tương lai, đồng thời đảm bảo tính nhất quán của thông tin.

4.2.4. Cập nhật dữ liệu mới

Ưu điểm chính của thiết kế này là khả năng cập nhật dữ liệu mới mà không cần phải tạo lại toàn bộ chỉ mục. Khi có tài liệu mới, LightRAG chỉ cần thực hiện hai thao tác đơn giản: Ưu điểm của phương pháp này là các thay đổi đối với dữ liệu mới có thể được thực hiện mà không cần phải xây dựng lại toàn bộ đồ thị tri thức. Khi có một tài liệu mới, hệ thống chỉ cần thực hiện hai bước đơn giản sau:

1. **Xử lý dữ liệu mới riêng biệt:** Ở đây, hệ thống áp dụng quy trình trích xuất và profiling dữ liệu như trong mô tả ở các phần trên nhưng lần này là cho tài liệu mới; do đó, một tập hợp thực thể và mối quan hệ mới được hình thành, còn được gọi là đồ thị con.
2. **Hợp nhất vào kho dữ liệu:** Hệ thống hợp nhất tất cả các thực thể và mối quan hệ đã được xác định vào một đồ thị tri thức hiện có. Quá trình này hoạt động giống như việc thêm một danh sách mới vào một danh sách cũ. Các thực thể mới được thêm vào một tập hợp thực thể cũ, và các mối quan hệ mới được thêm vào một tập hợp mối quan hệ cũ.

Phương pháp này giúp tiết kiệm đáng kể công sức tính toán và cũng đảm bảo rằng tất cả thông tin được cung cấp cho người dùng đều được cập nhật.

4.3. Cơ chế truy xuất hai cấp độ

Để đảm bảo khả năng trả lời chính xác cho cả các câu hỏi chi tiết và các câu hỏi mang tính khái quát, LightRAG giới thiệu chiến lược truy xuất kép. Thay vì dựa vào việc embedding toàn bộ văn bản như trong các mô hình RAG truyền thống, chiến lược này sử dụng cấu trúc dữ liệu khóa-giá trị được tích hợp sẵn trong mô hình để truy xuất dữ liệu theo hai chiều riêng biệt. Để phương pháp này hoạt động trong hệ thống, điều đầu tiên cần làm là xác định ý định của người dùng. Vì mục đích này, một prompt cụ thể (Hình 4.3) được sử dụng để chia câu hỏi đầu vào thành hai tập hợp từ khóa: từ khóa cụ thể và từ khóa chủ đề.

4.3.1. Truy xuất cấp thấp

Cơ chế truy xuất cấp thấp tham gia vào việc trả lời các truy vấn cụ thể, trong đó người dùng phải tìm kiếm thông tin về một đối tượng, sự kiện hoặc một định danh nhất

---Role---
 You are a helpful assistant tasked with identifying both high-level and low-level keywords in the user's query.

---Goal---
 Given the query, list both **high-level** and **low-level** keywords. High-level keywords focus on overarching concepts or themes, while low-level keywords focus on specific entities, details, or concrete terms.

Keywords Generate Instruction Prompt

- Output the keywords in **JSON format**.
 - The JSON should have two keys:
 - **"high_level_keywords"** for overarching concepts or themes.
 - **"low_level_keywords"** for specific entities or details.

-Examples-

Example 1:
 Query: "How does international trade influence global economic stability?"
 Output: {{ "high_level_keywords": ["International trade", "Global economic stability", "Economic impact"], "low_level_keywords": ["Trade agreements", "Tariffs", "Currency exchange", "Imports", "Exports"] }}

Example 2:
 Query: "What are the environmental consequences of deforestation on biodiversity?"
 Output: {{ "high_level_keywords": ["Environmental consequences", "Deforestation", "Biodiversity loss"], "low_level_keywords": ["Species extinction", "Habitat destruction", "Carbon emissions", "Rainforest", "Ecosystem"] }}

Example 3:
 Query: "What is the role of education in reducing poverty?"
 Output: {{ "high_level_keywords": ["Education", "Poverty reduction", "Socioeconomic development"], "low_level_keywords": ["School access", "Literacy rates", "Job training", "Income inequality"] }}

-Real Data-
Query: {query}
Output:

Keywords Generate Input Prompt

Hình 4.3. Prompt cho việc trích xuất từ khóa

định. Điều này được thực hiện bằng cách lấy đầu vào là một danh sách các từ khóa cụ thể đã được tạo ra từ bước xử lý truy vấn trước đó. Trong trường hợp này, thay vì tìm kiếm trong toàn bộ văn bản gốc, như được thực hiện trong tìm kiếm vector, hệ thống thực hiện tra cứu trực tiếp trong chỉ mục khóa-giá trị của các thực thể, còn được gọi là nút thực thể. Tại đây, tên của thực thể được sử dụng làm khóa để định vị, và khi tìm thấy kết quả phù hợp, nó sẽ truy xuất giá trị cụ thể liên quan đến thực thể, trong trường hợp này là tóm tắt ngữ nghĩa liên quan đến các thuộc tính hoặc hoạt động của thực thể đó. Hệ thống sử dụng các thông tin cụ thể từ biểu đồ tri thức để đảm bảo rằng nó thu thập được thông tin không bị làm nhiễu bởi các ngữ cảnh liên quan khác.

4.3.2. Truy xuất cấp cao

Trái ngược với xử lý truy vấn cấp thấp, xử lý truy vấn cấp cao nhằm mục đích giải quyết các truy vấn rất tổng quát, trong đó người dùng tìm kiếm các chủ đề, xu hướng và mối quan hệ chung. Truy vấn sử dụng các từ khóa chủ đề đã được tạo ra từ bước xử lý

truy vấn trước đó. Điểm nổi bật của hệ thống LightRAG là cách tiếp cận xử lý truy vấn của nó, cụ thể là ở đối tượng tìm kiếm: thay vì tra cứu thực thể, hệ thống thực hiện so khớp các từ khóa này trong kho chỉ mục khóa-giá trị của các mối quan hệ. Trong giai đoạn lập chỉ mục, LLM đã phát triển thêm các từ khóa liên quan đến chủ đề tổng thể dựa trên các khóa quan hệ. Điều này có nghĩa là, trong trường hợp tìm thấy sự trùng khớp, hệ thống có khả năng trích xuất các cụm từ mô tả làm rõ bản chất của mối quan hệ cũng như bản chất của sự tương tác giữa các thực thể. Điều này rất quan trọng vì nó cho phép hệ thống nắm bắt được bức tranh tổng thể mà không cần phải sàng lọc qua vô số đoạn văn bản.


4.3.3. Ví dụ minh họa

Để giải thích rõ hơn cách hai cấp độ truy xuất này hoạt động song song, một ví dụ thực tế liên quan đến câu hỏi về tiêu chí đánh giá cho hệ thống đề xuất phim được minh họa trong Hình 4.4. Như có thể thấy khi xem xét ví dụ này, cả hai cơ chế đã được kích hoạt đồng thời thành công, trong đó, tầng truy xuất cấp thấp chỉ tập trung vào việc trích xuất các tiêu chí kỹ thuật như "Accuracy", "Precision" và "Recall", còn tầng truy xuất cấp cao lại trích xuất được các khái niệm tổng quát như "Evaluation methods" hay "Movie recommendation systems". Chính nhờ sự kết hợp truy xuất hai cấp độ này mà LLM có tất cả thông tin cần thiết về ngữ cảnh mà nó phải tổng hợp câu trả lời.

4.4. Phân tích Độ phức tạp và Chi phí

4.4.1. API

1. Giai đoạn lập chỉ mục:



Hình 4.4. Ví dụ minh họa quy trình truy xuất và sinh câu trả lời

- *GraphRAG*: Vì mô hình này được cung cấp nhiều token trong quá trình phân cụm phân cấp các thực thể và sau đó phải tóm tắt nội dung của các cụm kết quả, nên chi phí tính toán tăng không tuyến tính với khối lượng dữ liệu.
- *LightRAG*: Mô hình này giảm số lượng token bằng cách loại bỏ hoàn toàn việc tóm tắt các cụm phức tạp của các thực thể chồng chéo. Nó có một cách tiếp cận mới liên quan đến việc trích xuất và tối ưu hóa cho từng đoạn văn bản, từ đó tối ưu hóa chi phí API.

2. Giai đoạn truy xuất:

- LightRAG yêu cầu ít token hơn khi tạo prompt cho LLM để cuối cùng tạo ra câu trả lời vì mô hình này ngăn chặn việc trích xuất các cặp khóa-giá trị vô ích trong khi GraphRAG phải ép buộc các cụm thông tin toàn diện.

4.4.2. Chi phí Tái cấu trúc

Đây là ưu điểm lớn nhất của LightRAG về mặt vận hành lâu dài:

- **GraphRAG:** Có chi phí cập nhật rất cao. Khi có dữ liệu mới, cấu trúc phân cụm của đồ thị bị thay đổi, đòi hỏi hệ thống phải tính toán và tóm tắt lại toàn bộ các cụm thông tin từ đầu hoặc thực hiện các bước cập nhật rất phức tạp.
- **LightRAG:** Khi thêm dữ liệu mới, LightRAG chỉ đơn giản là trích xuất các node/edge mới và thực hiện khử trùng lặp (deduplication) với dữ liệu cũ mà không làm phá vỡ cấu trúc hiện có. Điều này giúp LightRAG cực kỳ phù hợp cho các ứng dụng thực tế cần cập nhật kiến thức liên tục với chi phí thấp nhất.

Chương 5.

Thực nghiệm và Đánh giá

Đánh giá thực nghiệm được dựa trên bộ dữ liệu tiêu chuẩn để đánh giá hiệu quả của lightRAG bằng các trả lời các câu hỏi nghiên cứu (research questions: RQ) sau:

- **RQ1:** LightRAG so với các phương pháp RAG khác có hiệu quả như nào trên phương diện tạo sinh.
- **RQ2:** Truy xuất hai cấp và chỉ mục dựa trên đồ thị nâng cao chất lượng tạo sinh cho lightRAG như thế nào.
- **RQ3:** Lợi thế cụ thể của lightRAG nào được thể hiện ở các ví dụ qua nhiều trường hợp
- **RQ4:** LightRAG có những chi phí nào và khả năng thích ứng của lightRAG với sự thay đổi dữ liệu

5.1. Thiết lập thực nghiệm

5.1.1. Bộ dữ liệu đánh giá

Để có một đánh giá toàn diện và chuyên sâu, bốn bộ dữ liệu được chọn từ dữ liệu UltraDomain. Dữ liệu UltraDomain được lấy từ nguồn là 428 quyển sách giáo khoa từ các trường cao đẳng, bao gồm 18 miền nghiệp vụ khác nhau như: nông nghiệp, khoa học xã hội, nhân văn học. Bốn bộ dữ liệu trong UltraDomain về nông nghiệp, khoa học máy tính, luật pháp và trộn các miền được chọn. Mỗi bộ gồm khoảng 600000 đến 5000000 token. Dưới đây là mô tả kĩ càng về 4 miền nghiệp vụ trên:

- **Nông nghiệp:** Miền nghiệp vụ này tập trung vào các hoạt động nông nghiệp, bao gồm nhiều chủ đề nông nghiệp như: nuôi ong, quản lý tổ ong, sản xuất cây trồng và phòng chống dịch bệnh
- **Khoa học máy tính:** Miền nghiệp vụ này tập trung vào lĩnh vực khoa học máy tính và bao gồm những lĩnh vực con chính là khoa học dữ liệu và công nghệ phần mềm. Đặc biệt nhấn mạnh vào học máy, xử lý dữ liệu lớn, cụ thể về các hệ thống đề xuất, thuật toán phân loại và phân tích thời gian thực bằng Spark
- **Luật pháp:** Miền nghiệp vụ này xoay quanh các hoạt động pháp lý doanh nghiệp, gồm tái cấu trúc doanh nghiệp, thỏa thuận pháp lý, tuân thủ quy định và quản trị, tập trung vào các lĩnh vực pháp lý và tài chính.
- **Trộn lẫn:** Miền này bao quát lượng văn bản từ văn học, sinh học hay triết học, các nghiên cứu về văn hóa, lịch sử, triết học.

5.1.2. Sinh câu hỏi

Để đánh giá hiệu quả của lightRAG cho những tác vụ cần kiến thức hiểu biết sâu, nội dung từ các bộ dữ liệu được hợp nhất như ngữ cảnh. LLM được hướng dẫn để tạo ra 5 người dùng, cùng 5 tác vụ cho. Mỗi người dùng được tạo ra sẽ gắn liền với một mô tả kỹ càng về chuyên môn và đặc điểm kèm theo hoạt động đặt ra câu hỏi của họ. Tổng cộng, LLM tạo ra 125 câu hỏi cho mỗi bộ dữ liệu.

5.1.3. Các mô hình cơ sở để so sánh

LighRAG được so sánh với các mô hình sau qua các bộ dữ liệu:

- **NaiveRAG** (Gao et al., 2023): Mô hình này có vai trò như một cơ sở tiêu chuẩn cho các hệ thống RAG hiện nay. Nó phân đoạn văn bản thô thành chunks và lưu trữ trong cơ sở dữ liệu vector dùng text embeddings. Với mỗi truy vấn, NaiveRAG

sinh biểu diễn vector cho chúng và lấy những chunks văn bản có độ tương đồng cao nhất, việc này đảm bảo hiệu quả và đơn giản.

- **RQ-RAG** (Chan et al., 2024): Cách tiếp cận này tận dụng LLM để chia nhỏ truy vấn đầu vào thành nhiều truy vấn con. Những truy vấn con này được thiết kế để nâng cao độ chính xác khi tìm kiếm bằng cách tận dụng những kỹ thuật như viết lại, phân tích và làm rõ nghĩa.
- **HyDE** (Gao et al., 2022): Phương pháp này dùng LLM để sinh một tài liệu giả thuyết dựa trên truy vấn đầu vào. Sau đó tài liệu này được sử dụng để trích xuất những chunks văn bản liên quan, sau đó được dùng để tạo ra câu trả lời cuối cùng.
- **GraphRAG** (Edge et al., 2024): Hệ thống này dùng LLM để trích xuất thực thể và quan hệ từ văn bản, biểu diễn chúng như nút và cạnh của đồ thị. Sau đó sinh mô tả cho các thành phần. GraphRAG tổng hợp nhiều nút thành các cộng đồng, tạo ra các báo cáo cộng đồng để thu thập các thông tin toàn diện. Khi xử lý những truy vấn cấp cao, GraphRAG truy xuất nhiều thông tin toàn diện hơn bằng cách duyệt qua các cộng đồng.

5.1.4. Chi tiết về triển khai đánh giá

Cơ sở dữ liệu vector nano được dùng để quản lý truy nhập dữ liệu. Cho các tác vụ cần dùng LLM để sinh, mặc định dùng GPT-4o-mini. Độ dài chunk được cố định là 1200 cho mọi bộ dữ liệu. Tham số gleaning được cố định là 1 cho cả GraphRAG và LightRAG.

Bốn tiêu chí được sử dụng để đánh giá đã được miêu tả trong prompt đánh giá, bao gồm:

- **Tính toàn diện:** Câu trả lời có giải quyết được đầy đủ tất cả các khía cạnh và chi tiết của câu hỏi như thế nào?

- **Tính đa dạng:** Câu trả lời phong phú và đa dạng đến mức nào trong việc đưa ra các quan điểm và hiểu biết khác nhau liên quan đến câu hỏi?
- **Tính hữu ích:** Câu trả lời giúp người đọc hiểu chủ đề và đưa ra phán đoán có căn cứ một cách hiệu quả như thế nào?
- **Tính tổng thể:** Tiêu chí này đánh giá hiệu quả tổng hợp trên ba tiêu chí trước đó để xác định câu trả lời tổng thể tốt nhất.

LLM so sánh trực tiếp hai câu trả lời cho mỗi tiêu chí và chọn câu trả lời tốt hơn cho mỗi tiêu chí. Sau khi xác định câu trả lời tốt hơn cho ba tiêu chí, LLM kết hợp các kết quả để xác định câu trả lời tốt hơn về tổng thể. Để đảm bảo đánh giá công bằng và giảm thiểu khả năng thiên vị có thể phát sinh từ thứ tự các câu trả lời trong câu hỏi, vị trí của mỗi câu trả lời được luân phiên. Cuối cùng tính toán tỷ lệ thắng tương ứng để ra kết quả cuối cùng.

5.2. So sánh LightRAG với các mô hình cơ sở (RQ1)

Sự vượt trội của các hệ thống RAG dựa trên đồ thị trong các tập dữ liệu quy mô lớn: Khi xử lý số lượng token lớn và các truy vấn phức tạp đòi hỏi sự hiểu biết sâu sắc về ngữ cảnh của tập dữ liệu, các hệ thống RAG dựa trên đồ thị như LightRAG và GraphRAG luôn vượt trội hơn các phương pháp truy xuất dựa trên chunk văn bản thuần túy như NaiveRAG, HyDE và RQRAG. Khoảng cách hiệu suất này càng trở nên rõ rệt hơn khi kích thước tập dữ liệu tăng lên. Ví dụ, trong tập dữ liệu lớn nhất (Luật pháp), sự chênh lệch tăng lên đáng kể, với các phương pháp cơ bản chỉ đạt tỷ lệ thắng khoảng 20% so với sự vượt trội của LightRAG. Xu hướng này nhấn mạnh những lợi thế của các hệ thống RAG được dựa trên đồ thị trong việc nắm bắt các sự phụ thuộc ngữ nghĩa phức tạp trong các tập dữ liệu quy mô lớn, tạo cho sự hiểu biết toàn diện hơn về kiến thức và dẫn đến hiệu quả khái quát hóa được cải thiện.

Bảng 5.1. So sánh LightRAG với các mô hình cơ sở

	Agriculture		CS		Legal		Mix	
	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG
Comprehensiveness	32.4%	<u>67.6%</u>	38.4%	<u>61.6%</u>	16.4%	<u>83.6%</u>	38.8%	<u>61.2%</u>
Diversity	23.6%	<u>76.4%</u>	38.0%	<u>62.0%</u>	13.6%	<u>86.4%</u>	32.4%	<u>67.6%</u>
Empowerment	32.4%	<u>67.6%</u>	38.8%	<u>61.2%</u>	16.4%	<u>83.6%</u>	42.8%	<u>57.2%</u>
Overall	32.4%	<u>67.6%</u>	38.8%	<u>61.2%</u>	15.2%	<u>84.8%</u>	40.0%	<u>60.0%</u>
	RQ-RAG	LightRAG	RQ-RAG	LightRAG	RQ-RAG	LightRAG	RQ-RAG	LightRAG
Comprehensiveness	31.6%	<u>68.4%</u>	38.8%	<u>61.2%</u>	15.2%	<u>84.8%</u>	39.2%	<u>60.8%</u>
Diversity	29.2%	<u>70.8%</u>	39.2%	<u>60.8%</u>	11.6%	<u>88.4%</u>	30.8%	<u>69.2%</u>
Empowerment	31.6%	<u>68.4%</u>	36.4%	<u>63.6%</u>	15.2%	<u>84.8%</u>	42.4%	<u>57.6%</u>
Overall	32.4%	<u>67.6%</u>	38.0%	<u>62.0%</u>	14.4%	<u>85.6%</u>	40.0%	<u>60.0%</u>
	HyDE	LightRAG	HyDE	LightRAG	HyDE	LightRAG	HyDE	LightRAG
Comprehensiveness	26.0%	<u>74.0%</u>	41.6%	<u>58.4%</u>	26.8%	<u>73.2%</u>	40.4%	<u>59.6%</u>
Diversity	24.0%	<u>76.0%</u>	38.8%	<u>61.2%</u>	20.0%	<u>80.0%</u>	32.4%	<u>67.6%</u>
Empowerment	25.2%	<u>74.8%</u>	40.8%	<u>59.2%</u>	26.0%	<u>74.0%</u>	46.0%	<u>54.0%</u>
Overall	24.8%	<u>75.2%</u>	41.6%	<u>58.4%</u>	26.4%	<u>73.6%</u>	42.4%	<u>57.6%</u>
	GraphRAG	LightRAG	GraphRAG	LightRAG	GraphRAG	LightRAG	GraphRAG	LightRAG
Comprehensiveness	45.6%	<u>54.4%</u>	48.4%	<u>51.6%</u>	48.4%	<u>51.6%</u>	50.4%	<u>49.6%</u>
Diversity	22.8%	<u>77.2%</u>	40.8%	<u>59.2%</u>	26.4%	<u>73.6%</u>	36.0%	<u>64.0%</u>
Empowerment	41.2%	<u>58.8%</u>	45.2%	<u>54.8%</u>	43.6%	<u>56.4%</u>	50.8%	<u>49.2%</u>
Overall	45.2%	<u>54.8%</u>	48.0%	<u>52.0%</u>	47.2%	<u>52.8%</u>	50.4%	<u>49.6%</u>

Nâng cao tính đa dạng với LightRAG: LightRAG vượt trội hơn các phương pháp tiêu chuẩn về tính đa dạng, đặc biệt là trên tập dữ liệu luật pháp, vốn là tập dữ liệu lớn nhất. Tỷ lệ thắng chung trên toàn bộ tập dữ liệu thử nghiệm phản ánh thế mạnh của LightRAG trong việc tạo ra các phản hồi đa dạng hơn, đặc biệt là trong các tình huống yêu cầu nội dung đa dạng. Điều này có thể được giải thích bằng mô hình truy xuất hai cấp của nó, thu thập thông tin toàn diện từ cả nguồn cấp thấp (độ sâu) và cấp cao (độ toàn diện) bằng cách sử dụng chỉ mục văn bản dựa trên đồ thị.

Ưu điểm của LightRAG so với GraphRAG: Mặc dù cả LightRAG và GraphRAG đều được dựa trên các phương pháp truy xuất đồ thị, LightRAG luôn hoạt động tốt hơn GraphRAG, đặc biệt là với các tập dữ liệu lớn có cấu trúc ngôn ngữ phức tạp. Trong các tập dữ liệu nông nghiệp, khoa học máy tính và luật pháp, nơi có hàng triệu token trong mỗi tập, LightRAG cho thấy sự cải thiện đáng kể, hoạt động tốt hơn đáng kể so với GraphRAG và nổi bật trong khả năng nắm bắt dữ liệu một cách toàn diện trong các bối cảnh khác nhau. LightRAG tăng cường sự đa dạng phản hồi bằng cách kết hợp truy

xuất đồ thị cấp thấp cho các thực thể cụ thể và truy xuất đồ thị cấp cao cho các lĩnh vực chung. Với chiến lược hai chiều này, dữ liệu phức tạp cũng như dữ liệu tổng quát được bao phủ hiệu quả, mang lại lợi thế trong các tình huống thực tế cần có nhiều góc nhìn đồng thời, bằng cách bao phủ các sự kiện cụ thể cũng như các lĩnh vực rộng hơn, LightRAG phản hồi dữ liệu phức tạp liên quan đến các lĩnh vực tương quan một cách phù hợp.

5.3. Ablation studies (RQ2)

Để đánh giá sự hiệu quả của mô hình truy xuất hai cấp và lập chỉ mục văn bản theo đồ thị, nghiên cứu cắt bỏ từng phần được xây dựng.

Hiệu quả của mô hình truy xuất hai cấp: Hai mô hình, mỗi mô hình lược bỏ một cấp và LightRAG hoàn chỉnh được thực hiện đánh giá trên bốn bộ dữ liệu. Kết quả quan sát được được biểu hiện qua bảng sau:

Bảng 5.2. So sánh giữa các phiên bản lược bỏ của LightRAG và NaiveRAG

	Agriculture		CS		Legal		Mix	
	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG
Comprehensiveness	32.4%	67.6%	38.4%	61.6%	16.4%	83.6%	38.8%	61.2%
Diversity	23.6%	76.4%	38.0%	62.0%	13.6%	86.4%	32.4%	67.6%
Empowerment	32.4%	67.6%	38.8%	61.2%	16.4%	83.6%	42.8%	57.2%
Overall	32.4%	67.6%	38.8%	61.2%	15.2%	84.8%	40.0%	60.0%
	NaiveRAG	-High	NaiveRAG	-High	NaiveRAG	-High	NaiveRAG	-High
Comprehensiveness	34.8%	65.2%	42.8%	57.2%	23.6%	76.4%	40.4%	59.6%
Diversity	27.2%	72.8%	36.8%	63.2%	16.8%	83.2%	36.0%	64.0%
Empowerment	36.0%	64.0%	42.4%	57.6%	22.8%	77.2%	47.6%	52.4%
Overall	35.2%	64.8%	44.0%	56.0%	22.0%	78.0%	42.4%	57.6%
	NaiveRAG	-Low	NaiveRAG	-Low	NaiveRAG	-Low	NaiveRAG	-Low
Comprehensiveness	36.0%	64.0%	43.2%	56.8%	19.2%	80.8%	36.0%	64.0%
Diversity	28.0%	72.0%	39.6%	60.4%	13.6%	86.4%	33.2%	66.8%
Empowerment	34.8%	65.2%	42.8%	57.2%	16.4%	83.6%	35.2%	64.8%
Overall	34.8%	65.2%	43.6%	56.4%	18.8%	81.2%	35.2%	64.8%
	NaiveRAG	-Origin	NaiveRAG	-Origin	NaiveRAG	-Origin	NaiveRAG	-Origin
Comprehensiveness	24.8%	75.2%	39.2%	60.8%	16.4%	83.6%	44.4%	55.6%
Diversity	26.4%	73.6%	44.8%	55.2%	14.4%	85.6%	25.6%	74.4%
Empowerment	32.0%	68.0%	43.2%	56.8%	17.2%	82.8%	45.2%	54.8%
Overall	25.6%	74.4%	39.2%	60.8%	15.6%	84.4%	44.4%	55.6%

- **Truy xuất chỉ ở cấp độ thấp:** Biến thể -High loại bỏ truy xuất cấp cao, dẫn đến sự suy giảm hiệu suất đáng kể trên hầu hết các tập dữ liệu và các tiêu chí. Sự suy giảm này chủ yếu là do nó nhấn mạnh quá vào thông tin cụ thể, tập trung quá mức vào các thực thể và các thực thể lân cận trực tiếp gần nhất của chúng. Mặc dù phương pháp này cho phép khám phá sâu hơn các thực thể liên quan trực tiếp, nhưng nó gặp khó khăn trong việc thu thập thông tin cho các truy vấn phức tạp đòi hỏi những hiểu biết toàn diện.
- **Truy xuất chỉ ở cấp độ cao:** Biến thể -Low thu thập một tập hợp thông tin rộng hơn bằng cách sử dụng các liên kết giữa các thực thể thay vì tập trung vào từng thực thể riêng lẻ. Phương pháp này có một lợi thế lớn về phạm vi bao phủ vì nó có thể thu thập thông tin rộng hơn và đa dạng hơn nhiều. Nhược điểm là phạm vi điều tra các thực thể không sâu, và nó có thể không phải lúc nào cũng cung cấp được câu trả lời rất cụ thể và đầy đủ thông tin cho các câu hỏi.
- **Chế độ hoàn chỉnh:** Phiên bản đầy đủ của LightRAG, kết hợp những ưu điểm của cả phương pháp truy xuất cấp thấp và cấp cao. Nó truy xuất một tập hợp các mối quan hệ rộng hơn trong khi đồng thời đi sâu khám phá chuyên sâu các thực thể cụ thể. Cách tiếp cận hai cấp độ này đảm bảo cả chiều rộng trong quá trình truy xuất và chiều sâu trong phân tích, cung cấp một cái nhìn toàn diện về kiến thức. Kết quả là LightRAG đạt được hiệu suất cân bằng trên nhiều tiêu chí.

Hiệu quả của đồ thị ngữ nghĩa trong RAG: Việc sử dụng văn bản gốc trong quy trình truy xuất được loại bỏ. Điều đáng ngạc nhiên là biến thể thu được, -Origin, không cho thấy sự suy giảm hiệu suất đáng kể trên cả bốn tập dữ liệu. Trong một số trường hợp, biến thể này thậm chí còn cho thấy sự cải thiện (ví dụ: trong bộ dữ liệu nông nghiệp và bộ dữ liệu trộn lẫn). Việc này có thể giải thích là do sự hiệu quả của việc trích xuất thông tin chính trong quá trình lập chỉ mục dựa trên đồ thị, cung cấp đủ ngữ cảnh để trả

lời các truy vấn. Ngoài ra, văn bản gốc thường chứa thông tin không liên quan lại có thể gây nhiễu trong phân hồi.

5.4. Nghiên cứu tình huống (RQ3)

Để so sánh rõ ràng giữa các phương pháp tiêu chuẩn và LightRAG, các ví dụ cụ thể được trình bày trong bảng 5.3, bao gồm các câu trả lời cho một câu hỏi về học máy từ cả phương pháp tiêu chuẩn, GraphRAG và LightRAG. Trong trường hợp này, LightRAG vượt trội hơn ở tất cả các khía cạnh đánh giá được LLM đánh giá, bao gồm tính toàn diện, tính đa dạng, tính hữu ích và chất lượng tổng thể. Các quan sát chính của như sau:

- **Tính toàn diện.** Đáng chú ý, LightRAG bao quát được phạm vi rộng hơn về các metrics học máy, thể hiện tính toàn diện và khả năng khám phá thông tin liên quan một cách hiệu quả. Điều này làm nổi bật sức mạnh của mô hình lập chỉ mục dựa trên đồ thị, vượt trội trong việc trích xuất thực thể và mối quan hệ chính xác.
- **Tính đa dạng và tính hữu ích.** LightRAG không chỉ cung cấp nhiều thông tin đa dạng hơn mà còn cung cấp nội dung hữu ích hơn. Hiệu quả này là nhờ vào mô hình truy xuất hai cấp của LightRAG, kết hợp việc khám phá sâu các thực thể liên quan thông qua truy xuất cấp thấp để tăng cường khả năng tìm kiếm sâu với việc khám phá rộng hơn thông qua truy xuất cấp cao nhằm cải thiện tính đa dạng của câu trả lời. Kết hợp cùng nhau, những phương pháp này nắm bắt được một cái nhìn toàn diện về miền lĩnh vực kiến thức, góp phần cải thiện hiệu suất RAG.

Bảng 5.3. So sánh GraphRAG và LightRAG trong tình huống cụ thể (Trích nguyên văn, không chỉnh sửa, từ bài báo gốc)

Query	Which methods can normalize the feature values for effective machine learning?
GraphRAG	Key Metrics for Evaluating Movie Recommendation Systems: Evaluating the effectiveness of movie recommendation systems is crucial for ensuring user satisfaction and improving the overall performance of these systems. Several metrics are widely recognized for their ability to provide insights into how well a recommendation system performs. Below are the most informative metrics: 1. Precision [...] 2. Recall [...] 3. F1 Score [...] 4. Mean Average Precision (MAP) [...] 5. Root Mean Squared Error (RMSE) [...] 6. User Satisfaction Metrics [...] Conclusion: In summary, metrics such as precision, recall, F1 score, MAP, RMSE, and user satisfaction are critical for evaluating the performance of movie recommendation systems. Each metric provides unique insights that can help developers and researchers refine their algorithms and enhance user experiences. By focusing on these metrics, stakeholders can ensure that their recommendation systems effectively meet user preferences and expectations.
<i>Tiếp tục ở trang sau...</i>	

Query	(Như trên)
LightRAG	Key Metrics for Evaluating Movie Recommendation Systems: Evaluating movie recommendation systems involves multiple metrics that assess the effectiveness and accuracy of the recommendations provided to users. Below are some of the most informative metrics commonly used in this context, derived from the data and concepts surrounding recommendation systems. 1. Mean Average Precision at K (MAPK) [...] 2. Precision and Recall [...] 3. Root Mean Squared Error (RMSE) and Mean Squared Error (MSE) [...] 4. Area Under the Curve (AUC) [...] 5. F-Measure [...] 6. User Engagement Metrics [...] Conclusion: A comprehensive evaluation of movie recommendation systems employs a range of metrics that capture both the accuracy of the recommendations and user satisfaction. By effectively leveraging these metrics, system designers can optimize recommendation engines to deliver more personalized and relevant experiences.
Tiếp tục ở trang sau...	

Query	(Như trên)
LLM Decision	Comprehensiveness: "Winner": "Answer 2 (LightRAG)", "Explanation": "Answer 2 provides a broader array of metrics including MAPK, AUC, and user engagement metrics alongside precision, recall, RMSE, and F-Measure. This gives a fuller view of how recommendation systems can be evaluated. Answer 1, while detailed, is more focused on traditional metrics and lacks the inclusion of engagement metrics which are crucial for understanding user interaction." Diversity: "Winner": "Answer 2 (LightRAG)", "Explanation": "Answer 2 not only covers a wide variety of metrics but also includes nuanced explanations of how some metrics interrelate and differ from one another, like the inclusion of both RMSE and MSE, as well as the details behind AUC. In contrast, Answer 1 sticks primarily to standard metrics without much exploration of potential nuances."
Tiếp tục ở trang sau...	

Query	<i>(Như trên)</i>
LLM Decision	Empowerment: "Winner": "Answer 2 (LightRAG)", "Explanation": "Answer 2 empowers the reader more effectively by detailing how each metric functions and its importance in evaluating recommendation systems. By providing context such as the trade-offs between precision and recall and emphasizing user engagement metrics, it enables readers to make more informed judgments and understand the implications of different metrics. Answer 1 is more straightforward but lacks the depth of insight regarding why these metrics matter." Overall Winner: "Winner": "Answer 2 (LightRAG)", "Explanation": "While Answer 1 is more direct and systematic, Answer 2 excels in comprehensiveness, diversity, and empowerment. It provides a richer exploration of the topic, including insights into user engagement and nuanced differences between metrics. This depth and breadth make it more informative for readers seeking to thoroughly understand the evaluation of movie recommendation systems."

5.5. Chi phí mô hình và phân tích khả năng thích ứng (RQ4)

Chi phí của LightRAG được so sánh với GraphRAG (phương pháp tiêu chuẩn có hiệu suất cao nhất) từ hai khía cạnh chính.

- Xem xét số lượng token và số lần gọi API trong quá trình lập chỉ mục và truy xuất.
- Phân tích các chỉ số này liên quan đến việc xử lý các thay đổi dữ liệu trong môi trường thay đổi.

Kết quả đánh giá này trên tập dữ liệu luật pháp được trình bày trong bảng 5.4. Trong đó, T_{extract} đại diện cho chi phí token cho việc trích xuất thực thể và mối quan hệ, C_{max} biểu thị số lượng token tối đa được phép cho mỗi lần gọi API, và C_{extract} cho biết số lần gọi API cần thiết để trích xuất.

Trong quá trình truy xuất, GraphRAG đã tạo ra 1399 cộng đồng, trong đó có 610 cộng đồng cấp 2 được sử dụng để truy xuất thường xuyên trong thử nghiệm này. Số lượng token trung bình trong một báo cáo cộng đồng là 1000 token, dẫn đến tổng cộng 610000 token ($610 \text{ cộng đồng} \times 1000 \text{ token/cộng đồng}$). Thêm vào đó, GraphRAG đã gọi các API để duyệt qua từng cộng đồng riêng lẻ, gây ra hàng trăm lần gọi API và làm tăng chi phí truy xuất. LightRAG đã tối ưu hóa quy trình này bằng cách tiêu thụ ít hơn 100 token cho việc tạo và truy xuất tiếp theo của mỗi từ khóa được tạo ra chỉ với một cuộc gọi API cho toàn bộ quy trình so với GraphRAG. Chiến lược được tối ưu hóa là kết quả của cách tiếp cận thông minh và tối ưu của LightRAG, kết hợp cấu trúc đồ thị và vector một cách hợp lý để truy xuất thông tin mà không nhất thiết phải xử lý khối lượng thông tin lớn.

Trong giai đoạn cập nhật dữ liệu tăng dần, nhằm xử lý các tình huống thực tế khi dữ liệu thay đổi, cả hai mô hình đều có chi phí tương đương trong việc trích xuất các thực thể cũng như các mối quan hệ từ dữ liệu. Tuy nhiên, GraphRAG tỏ ra cực kỳ kém hiệu quả khi xử lý dữ liệu lúc dữ liệu mới được thêm vào hệ thống. Khi một tập dữ liệu

mới có kích thước bằng với tập dữ liệu hợp lệ được thêm vào hệ thống, GraphRAG cần phải giải tái cấu trúc cộng đồng của nó để tích hợp tập dữ liệu mới về mặt các thực thể và mối quan hệ được trích xuất vào đồ thị, sau đó là việc tạo lại hoàn toàn toàn bộ cấu trúc cộng đồng thành một báo cáo cộng đồng mới, điều này gây ra chi phí khổng lồ khoảng 5000 token cho mỗi báo cáo cộng đồng. Vì có 1399 cộng đồng trong GraphRAG, nên sẽ cần một lượng token khổng lồ là $1399 \times 2 \times 5000$ token để tạo lại cả báo cáo cộng đồng cũ và báo cáo cộng đồng mới, điều này cực kỳ tốn kém và do đó, không hiệu quả đối với GraphRAG. LightRAG, với hiệu quả cực kỳ cao về chi phí trong giai đoạn cập nhật dữ liệu tăng dần, LightRAG tích hợp liền mạch các thực thể và quan hệ mới được trích xuất vào đồ thị hiện có mà không cần tái tạo hoàn toàn. Cách tiếp cận này giúp giảm đáng kể chi phí overhead trong quá trình cập nhật gia tăng.

Bảng 5.4. Token và chi phí giữa GraphRAG và LightRAG

Phase	Retrieval Phase		Incremental Text Update	
Model	GraphRAG	LightRAG	GraphRAG	LightRAG
Tokens	$610 \times 1,000$	< 100	$1,399 \times 2 \times 5,000$ $+ T_{\text{extract}}$	T_{extract}
API Calls	$\frac{610 \times 1,000}{C_{\text{max}}}$	1	$1,399 \times 2 + C_{\text{extract}}$	C_{extract}

Chương 6.

Đề xuất cải tiến hệ thống

6.1. Hạn chế hiện tại của LightRAG

- **Phụ thuộc nặng vào chất lượng LLM mà người dùng sử dụng:** mặc dù giảm đáng kể chi phí so với GraphRAG, LightRAG vẫn phải phụ thuộc hoàn toàn vào LLM cho bước trích xuất thực thể và quan hệ, dẫn đến việc không giải quyết được vấn đề ảo giác đã bàn phân trên và đồ thị tri thức sinh ra sẽ có khả năng sai lệch, thiếu chính xác.
- **Khả năng đa ngôn ngữ:** Mặc dù LightRAG hỗ trợ đa ngôn ngữ nhưng tất cả prompt của LightRAG vẫn được tối ưu để hỗ trợ cho tiếng Anh, do đó việc sử dụng với các ngôn ngữ khác tiếng Anh mà muốn câu trả lời chất lượng nhất đôi khi đòi hỏi phải tinh chỉnh lại các prompt.
- **Các chế độ:** LightRAG có khả năng suy luận rất tốt do có nhiều chế độ truy xuất và sinh câu hỏi như local, global, naive. Nhưng điều này cũng đòi hỏi người dùng tự chọn giữa nhiều chế độ, đòi hỏi người dùng tự đánh giá mức độ trừu tượng câu hỏi để chọn chế độ hợp lý để có thể có được câu trả lời chất lượng nhất.

6.2. Đề xuất ý tưởng cải tiến

- **Giảm sự phụ thuộc vào LLM trong bước trích xuất thực thể và quan hệ:**

- + Fine-tune một mô hình LLM nhỏ chuyên biệt cho tác vụ trích xuất thực thể, quan hệ và gán key-value: Input Text -> Output JSON. Lợi ích mong muốn là tốc độ trích xuất nhanh hơn, giảm chi phí.
- + Vẫn phụ thuộc vào LLM trong tác vụ gán key-value nhưng dùng các mô hình nhận diện thực thể (NER) và trích xuất quan hệ (RE) chuyên biệt. Lợi ích mong muốn cũng là tốc độ trích xuất nhanh hơn, giảm chi phí.
- **Đa ngôn ngữ**: Viết lại toàn bộ prompt bằng ngôn ngữ đích.
- **Các chế độ**: Tạo thêm một chế độ là auto dựa trên một agent tự động đánh giá câu hỏi và chọn chế độ phù hợp để đạt được câu hỏi có chất lượng tốt nhất.

Chương 7.

Kết luận

7.1. Về các phương pháp cải thiện đề xuất

- **Fine-tune một mô hình nhỏ:** Khả thi nhưng cần xây dựng một bộ dữ liệu có nhãn là các thực thể quan hệ và phân mô tả cho việc trích key-value.
- **Dùng mô hình chuyên biệt NER, RE:** Không quá khả thi do phân trích key-value vẫn phải phụ thuộc vào LLM và có thể phải cung cấp cả chunk cho phần này. Do đó chi phí tiết kiệm được có thể không quá nhiều.
- **Viết thêm prompt cho ngôn ngữ mới:** Khả thi nhưng có thể phải thiết kế và viết rất nhiều prompt cho nhiều ngôn ngữ và không đảm bảo chất lượng câu trả lời được cải thiện.
- **Thêm chế độ auto:** Khả thi nhưng sẽ tốn thêm chi phí gọi LLM để đánh giá độ phức tạp cho từng truy vấn người dùng để chọn chế độ phù hợp.

7.2. Kết luận

Nghiên cứu này đề xuất một cải tiến trong việc tích hợp các giải pháp lập chỉ mục dựa trên đồ thị vào khuôn khổ mô hình RAG, cải thiện cả hiệu quả và tính dễ hiểu trong việc truy xuất dữ liệu. LightRAG tận dụng một đồ thị tri thức mở rộng cho phép tra cứu nhanh các tài liệu liên quan đến truy vấn hiện tại. Đây là một bước tiến trong xử lý và hiểu dữ liệu tìm kiếm. LightRAG cũng được trang bị mô hình tìm kiếm hai cấp hỗ trợ tìm kiếm cả dữ liệu thực tế và trừu tượng. Hơn nữa, tính năng cập nhật gia tăng của nó

cho phép nó luôn được cập nhật hiệu quả khi dữ liệu mới được cho vào, nâng cao hiệu quả chi phí và thời gian.

Tài liệu tham khảo

Tiếng Anh

- [1] Z. Guo, L. Xia, Y. Yu, T. Ao, and C. Huang, “LightRAG: Simple and Fast Retrieval-Augmented Generation” *arXiv preprint arXiv:2410.05779*, 2024.