

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO MÔN HỌC
Các vấn đề hiện đại của Công nghệ thông tin

**MINIRAG: TOWARDS EXTREMELY SIMPLE
RETRIEVAL-AUGMENTED GENERATION**

Giảng viên hướng dẫn : TS. Nguyễn Đức Anh
Mã học phần : INT3507 1
Sinh viên thực hiện : Lê Quốc Anh - 23020005
Nguyễn Ngọc Tuấn Anh - 23020008
Nguyễn Bảo Long - 23020103
Nguyễn Hoài Nam - 23020121

Lời cam đoan

Chúng em xin cam đoan không sử dụng AI trong quá trình viết báo cáo. Các kết quả thực nghiệm là trung thực và chính xác, không sao chép từ các tài liệu khác. Trong báo cáo đã trích dẫn và chú thích đầy đủ các tài liệu bên ngoài được đề cập. Chúng em xin chịu mọi trách nhiệm về bản báo cáo và lời cam kết này.

Nhóm sinh viên

Lê Quốc Anh

Nguyễn Ngọc Tuấn Anh

Nguyễn Bảo Long

Nguyễn Hoài Nam

Mục lục

Lời cam đoan	1
Mục lục	2
Lời cảm ơn	3
Tóm tắt	5
1 Tổng quan	6
1.1 Giới thiệu về mô hình ngôn ngữ (Language Models)	6
1.1.1 Khái quát về Language Models (LM, LLM, SLM)	6
1.1.2 Lợi ích và hạn chế của Large Language Models (LLM)	6
1.1.3 Động lực sử dụng SLM	7
1.2 Tạo tăng cường truy xuất (Retrieval-Augmented Generation - RAG)	8
1.3 Các hệ RAG hiện nay	8
1.4 Khó khăn khi áp dụng RAG với SLM	9
1.5 Giới thiệu bài báo MiniRAG	9
2 Mô hình MiniRAG - Ý tưởng và kiến trúc	11
2.1 Lập chỉ mục đồ thị không đồng nhất với các mô hình ngôn ngữ nhỏ	11
2.2 Truy xuất tri thức dựa trên đồ thị nhẹ	14
2.2.1 Ánh xạ ngữ nghĩa truy vấn (Query Semantic Mapping)	15
2.2.2 Truy xuất tăng cường topo trên đồ thị (Topology-Enhanced Graph Retrieval)	15

3	Thực nghiệm và kết quả trong bài báo	18
3.1	Mục tiêu thực nghiệm của tác giả	18
3.2	Dữ liệu đánh giá	18
3.3	Môi trường và cấu hình thực nghiệm	19
3.4	Đánh giá hiệu suất	19
3.5	Phân tích thành phần	21
3.6	Case study	21
3.7	Nhận xét của tác giả	22
4	Thực nghiệm mô phỏng của nhóm	24
4.1	Mục tiêu thực nghiệm của nhóm	24
4.2	Môi trường thực nghiệm	24
4.3	Bộ dữ liệu sử dụng	25
4.4	Kết quả thực nghiệm	29
4.5	Nhận xét và đánh giá	33
5	ĐÁNH GIÁ CHUNG VÀ HƯỚNG PHÁT TRIỂN	34
5.1	Đánh giá tổng quan về bài báo MiniRAG	34
5.2	Đánh giá kết quả thực nghiệm của nhóm	35
5.3	Hướng nghiên cứu và cải tiến tiếp theo	36
	Tài liệu tham khảo	40

Lời cảm ơn

Trước tiên, nhóm chúng em xin gửi lời cảm ơn sâu sắc đến thầy TS. Nguyễn Đức Anh đã cung cấp các đề tài cấp thiết, mới mẻ và phù hợp với môn học là các vấn đề hiện đại của công nghệ thông tin giúp chúng em có thể định hướng cho khóa luận tốt nghiệp sau này. Bên cạnh đó, chúng em cũng cảm ơn thầy đã hướng dẫn, thảo luận và đánh giá bài thuyết trình cũng như bài báo cáo của nhóm chúng em.

Tóm tắt

Trong bài báo cáo này, nhóm chúng em xin phép trình bày về một hệ thống Retrieval-Augmented Generation (RAG) triển khai trên các mô hình ngôn ngữ nhỏ (Small Language Models – SLMs). Với các phương pháp hiện có đang phải đối mặt với sự suy giảm hiệu năng nghiêm trọng do khả năng hiểu ngữ nghĩa và xử lý văn bản còn hạn chế của SLMs, từ đó gây khó khăn trong việc triển khai các mô hình RAG trong môi trường bị hạn chế tài nguyên, đặc biệt là trên thiết bị cá nhân. Để giải quyết hạn chế ấy của các RAG hiện có, nhóm tác giả đã đề xuất MiniRAG - một hệ thống được thiết kế nhằm đạt được sự đơn giản và hiệu quả ở mức cao nhất. MiniRAG được thiết kế dựa vào hai cải tiến cốt lõi: cơ chế lập chỉ mục dựa trên đồ thị dị thể có nhận thức ngữ nghĩa (Emantic-aware heterogeneous graph indexing), trong đó các đoạn văn bản và thực thể được đặt tên được tích hợp trong một cấu trúc thống nhất, giúp giảm sự phụ thuộc vào khả năng hiểu ngữ nghĩa phức tạp của mô hình; và phương pháp truy xuất nhẹ được tăng cường bởi thông tin tô-pô của đồ thị (Lightweight topology-enhanced retrieval), cho phép mô hình truy xuất và khai phá thông tin từ đồ thị mà không yêu cầu khả năng ngôn ngữ nâng cao. Kết quả đánh giá của nhóm tác giả đã cho thấy được MiniRAG đạt được hiệu năng tương đương với các phương pháp RAG sử dụng LLMs trong khi chỉ sử dụng 25% dung lượng lưu trữ. Bên cạnh đó trong bài báo, nhóm tác giả cũng giới thiệu một bộ benchmark mới, toàn diện nhằm đánh giá các hệ thống RAG gọn nhẹ trong các kịch bản on-device thực tế với các truy vấn phức tạp.

Chương 1

Tổng quan

1.1 Giới thiệu về mô hình ngôn ngữ (Language Models)

1.1.1 Khái quát về Language Models (LM, LLM, SLM)

Mô hình ngôn ngữ (Language Model - LM) là một mô hình toán học, thống kê hoặc một mô hình học sâu được thiết kế để đoán từ tiếp theo trong một chuỗi các văn bản hoặc xác định xác suất xuất hiện của chuỗi các từ. Nói cách khác, công dụng của LM là học các quy tắc ngữ pháp, ngữ nghĩa và ngữ cảnh trên một tập dữ liệu lớn, qua đó mô hình có thể hiểu và sinh ra ngôn ngữ giống với con người. Do đó, LM là nền tảng của hầu hết các hệ thống NLP và các AI tạo sinh hiện nay.

Dựa trên quy mô và hiệu năng, các mô hình ngôn ngữ hiện nay thường được chia thành hai nhóm chính:

- **LLM (Large Language Model):** là một loại mô hình ngôn ngữ được đào tạo bằng cách sử dụng các kỹ thuật học sâu trên tập dữ liệu văn bản khổng lồ. Các mô hình này có khả năng tạo văn bản tương tự như con người và thực hiện các tác vụ xử lý ngôn ngữ tự nhiên khác nhau (ví dụ: GPT, PaLM, LLaMA).
- **SLM (Small Language Model):** là một loại mô hình ngôn ngữ có số lượng tham số nhỏ hơn rất nhiều so với LLM nhưng vẫn có thể thực hiện các tác vụ ngôn ngữ cơ bản một cách hiệu quả. Các mô hình này được thiết kế để giảm tải nguyên tính toán, chi phí và có thể dễ dàng triển khai trên các thiết bị có phần cứng hạn chế, đặc biệt là thiết bị cá nhân (ví dụ: Llama 3.1 8B, Gemma2, Qwen 2)

1.1.2 Lợi ích và hạn chế của Large Language Models (LLM)

Một số các lợi ích nổi bật của LLM như:

- **Hiểu được ngữ cảnh phức tạp:** LLM có khả năng xử lý văn bản dài và nắm bắt

quan hệ ngữ nghĩa phức tạp.

- **Khả năng tổng quát hóa cao:** LLM được huấn luyện trên tập dữ liệu lớn và đa dạng nên có thể áp dụng được cho nhiều bài toán khác nhau mà không cần phải huấn luyện lại.
- **Suy luận đa bước:** LLM giải quyết tốt các bài toán reasoning, multi-hop question answering và tổng hợp thông tin từ nhiều đoạn văn bản.

Bên cạnh những lợi ích trên, LLM cũng tồn tại những hạn chế:

- **Chi phí tính toán lớn:** LLM với số lượng tham số lớn (từ 10 - 100+ tỷ tham số) nên việc huấn luyện và suy luận cần lượng tài nguyên phần cứng rất lớn, đặc biệt là GPU và TPU.
- **Độ trễ cao:** Do LLM thường phải gửi dữ liệu lên máy chủ và chờ thời gian phản hồi của LLM nên có thể không thích hợp cho các ứng dụng thời gian thực.
- **Vấn đề bảo mật và riêng tư:** LLM thường phải gửi dữ liệu đến máy chủ để thực hiện suy luận có thể gây rò rỉ dữ liệu và các vấn đề về quyền riêng tư.
- **Hiện tượng Hallucination:** LLM có thể "bịa" hay tạo ra những thông tin không chính xác nhưng lại trông khá hợp lý nếu người đọc không có kiến thức nền đủ tốt.

1.1.3 Động lực sử dụng SLM

Các mô hình LLM đạt được hiệu năng rất tốt trong các bài toán NLP nhưng lại gặp các khó khăn như đã trình bày ở phần trên. SLM sinh ra nhằm giải quyết một phần các hạn chế ấy nhưng vẫn có thể giải quyết được các bài toán tương tự. Một số động lực cho việc sử dụng SLM như:

- **Triển khai on-device:** SLM có thể triển khai được trên các thiết bị cá nhân như laptop, điện thoại.
- **Tiết kiệm tài nguyên:** SLM được thiết kế với số lượng tham số nhỏ hơn rất nhiều so với LLM nên yêu cầu về tài nguyên tính toán cũng như bộ nhớ cũng ít hơn, làm giảm chi phí vận hành.
- **Bảo mật và riêng tư:** SLM giúp tăng cường tính bảo mật do hệ thống không cần phải gửi dữ liệu lên máy chủ ngoài.

1.2 Tạo tăng cường truy xuất (Retrieval-Augmented Generation - RAG)

là một kiến trúc kết hợp giữa hai công đoạn chính: truy xuất thông tin (retrieval) và sinh văn bản (generation). RAG cho phép mô hình có thể truy xuất với các tài liệu bên ngoài và sử dụng chúng để sinh ra câu trả lời. Với cách hoạt động này mô hình có thể đưa ra câu trả lời chính xác hơn, đặc biệt trong các bài toán yêu cầu các kiến thức chuyên biệt hoặc kiến thức cập nhật.

Một hệ thống RAG thường bao gồm 3 công đoạn chính:

- **Bước chuẩn bị (Indexing):** Chuẩn bị dữ liệu để có thể tìm kiếm hiệu quả. Trước tiên, tài liệu đưa vào được chia thành các đoạn nhỏ (chunks) để dễ dàng tìm kiếm. Sau đó, RAG chuyển đổi văn bản thành dạng số (vector) để máy tính có thể hiểu được ý nghĩa của văn bản. Văn bản đã chuyển đổi được đưa vào một cơ sở dữ liệu đặc biệt - tối ưu cho việc tìm kiếm vector.
- **Quá trình truy xuất (Retrival):** Thực hiện khi người hỏi. Trước tiên, RAG cũng chuyển câu hỏi thành vector, tương tự bước trên. Sau đó, RAG so sánh vector câu hỏi với các vector trong cơ sở dữ liệu để tìm ra được nội dung tương đồng nhất.
- **Quá trình sinh câu trả lời (Generation):** RAG kết hợp thông tin vừa tìm được và nội dung câu hỏi đưa vào LLM để sinh ra câu trả lời.

Nhờ việc sử dụng tài liệu để truy xuất, RAG làm giảm đáng kể hiện tượng Hallucination - vấn đề của LLM. Bên cạnh đó, RAG cũng giúp cho mô hình cập nhật được tri thức mới mà không cần huấn luyện lại và giải thích được nguồn gốc của tri thức sinh ra dựa trên tài liệu truy xuất.

1.3 Các hệ RAG hiện nay

- **NaiveRAG:** là dạng RAG đơn giản nhất, mã hóa các chunk thành các vector embedding và truy vấn theo độ tương đồng embedding. Sau đó, ghép trực tiếp vào prompt để LLM sinh câu trả lời. Ưu điểm: đơn giản, dễ triển khai. Nhược điểm: Hiệu năng giảm mạnh khi sử dụng với SLM, không triển khai được on-device, không giải quyết được các câu hỏi phức tạp.

- **GraphRAG:** là một cách cải tiến RAG, thay vì sử dụng vector embedding, GraphRAG sử dụng knowledge graph. Bên cạnh đó, nó sử dụng truy vấn trên đồ thị thay vì truy vấn ánh xạ. Các nút và quan hệ tìm được trong quá trình truy vấn được đẩy vào LLM để sinh câu trả lời. Ưu điểm: trả lời tốt các câu hỏi phức tạp, hiểu tốt các văn bản có cấu trúc, giảm hallucination. Nhược điểm: Kiến trúc phức tạp, chi phí tính toán lớn, không phù hợp sử dụng với SLM, không triển khai được on-device.
- **LightRAG:** là một loại RAG đơn giản hóa của GraphRAG, tối ưu đồ thị và thuật toán truy xuất để cân bằng giữa hiệu năng và chi phí tính toán. Ưu điểm: phù hợp sử dụng với SLM, triển khai on-device. Nhược điểm: trả lời câu hỏi phức tạp kém hơn so với GraphRAG.

1.4 Khó khăn khi áp dụng RAG với SLM

Khi thay thế từ LLM sang SLM trong hệ thống RAG, mô hình gặp hạn chế về năng lực hiểu ngữ nghĩa và suy luận do hạn chế số lượng tham số của SLM - biểu diễn ngữ nghĩa kém hơn so với LLM, khiến cho việc truy xuất thông tin từ nhiều đoạn trong văn bản kém hiệu quả. Bên cạnh đó, SLM nhạy cảm với nhiễu các đoạn không liên quan đến truy xuất. SLM giới hạn context window và tài nguyên tính toán làm giảm đi lượng thông tin có thể sinh ra. Cuối cùng, RAG với SLM phụ thuộc mạnh vào thiết kế hệ thống nhưng các hệ thống RAG hiện nay thường được thiết kế không phù hợp với môi trường hạn chế tài nguyên. Qua các hạn chế trên, thấy được như cần cấp thiết về một cấu trúc RAG đơn giản hơn nhưng vẫn có thể tận dụng được đồ thị tri thức phù hợp với SLM.

1.5 Giới thiệu bài báo MiniRAG


Bài báo MiniRAG: Extremely Simple Retrieval-Augmented Generation for Small Language Models, công bố vào năm 2025 trên arXiv bởi nhóm nghiên cứu HKUDS, nhóm tác giả đã đề xuất MiniRAG - một hệ thống được thiết kế nhằm đạt được sự đơn giản và hiệu quả ở mức cao nhất. MiniRAG được thiết kế dựa vào hai cải tiến cốt lõi: cơ chế lập chỉ mục dựa trên đồ thị dị thể có nhận thức ngữ nghĩa (Emantic-aware heterogeneous graph indexing) và phương pháp truy xuất nhẹ được tăng cường bởi thông tin tô-pô của đồ thị (Lightweight topology-enhanced retrieval). Qua 2 cải tiến này, MiniRAG có thể đạt được hiệu năng tương đương với các mô hình RAG sử dụng LLM trong khi sử dụng

một lượng tài nguyên và bộ nhớ thấp hơn đáng kể. Chi tiết về ý tưởng và kiến trúc của MiniRAG sẽ được trình bày ở chương 2.

Chương 2

Mô hình MiniRAG - Ý tưởng và kiến trúc

Trong phạm vi của chương này, chúng tôi sẽ mô tả chi tiết kiến trúc của mô hình MiniRAG được đề xuất. Như trong Hình 2.1, MiniRAG có hai thành phần chính: (1) Chỉ mục đồ thị không đồng nhất (Mục 2.1), tạo ra một biểu diễn tri thức có nhận thức ngữ nghĩa, và (2) Truy xuất tri thức dựa trên đồ thị nhẹ (Mục 2.2), cho phép truy xuất thông tin một cách chính xác và đồng thời hiệu quả.



Hình 2.1: Chênh lệch về khả năng giữa SLM và LLM. (Trái) SLM tạo đầu ra mô tả những điểm sai lệch. (Phải) SLM tỏ ra đuối sức trong việc trích lập thông tin trong ngữ cảnh dài, LLM thực hiện việc này với tốc độ nhanh và trơn tru.

2.1 Lập chỉ mục đồ thị không đồng nhất với các mô hình ngôn ngữ nhỏ


Liên hệ đến hệ thống RAG với nguồn lực hạn chế, SLMs mô hình ngôn ngữ nhỏ cũng gặp phải một số khó khăn đáng kể, cản trở khả năng hoạt động hiệu quả. Những khó khăn này đã được thể hiện với 2 vấn đề cốt yếu:

- SLMs gặp phải rất nhiều khó khăn trong việc trích xuất và nhận thức các thực thể

và các mối quan hệ thực thể phức tạp với các mối liên hệ ngữ cảnh tinh vi, với một kho văn bản thô.

- Khả năng tóm lược văn bản với các dữ liệu đã được quy trình xử lý, văn bản được trích xuất một cách ngẫu nhiên và có sự không liên quan đến yếu tố gây nhiễu.

Kết quả đối chiếu giữa SLM (Phi-3.5-mini) và LLM (gpt-4o-mini) tại Hình 2.2 đã làm sáng tỏ những hạn chế này trong điều kiện thực tế. Mặc dù cả hai mô hình đều nhận diện chính xác thực thể "HOUSE RULES", nhưng phần mô tả của SLM lại khá rời rạc, thiếu chi tiết cụ thể và bỏ sót các quy định cũng như mục đích cốt lõi từ văn bản gốc (Hạn chế 1). Đặc biệt, trong giai đoạn truy vấn, SLM tỏ ra lúng túng khi phải trích lọc thông tin từ các ngữ cảnh dài, dẫn đến tình trạng bị xao nhãng bởi các nội dung nhiễu không liên quan — một nhược điểm mà các dòng LLM hoàn toàn có thể khắc phục (Hạn chế 2).



Hình 2.2: Quy trình vận hành tổng quát của hệ thống MiniRAG.

Nhằm hỗ trợ các hệ thống RAG có nguồn lực hạn chế, MiniRAG hướng tới 2 mục tiêu:

- **Cơ chế lập chỉ mục:** Nhằm bóc tách và phân tích những liên hệ và ngữ cảnh trọng yếu, nhằm bù đắp điểm yếu về khả năng trừu tượng, nhận diện thực thể, tóm tắt văn bản do các mô hình nhỏ cung cấp.

- **Tinh gọn nội dung:** Chỉ giữ những thông tin có liên quan, sát sao với câu hỏi nhằm loại bỏ "nhiều". Nhằm giúp cho mô hình nhỏ, không bị rối thông tin, quá tải thông tin, từ đó các thông tin quan trọng được xử lý và chọn lọc chính xác hơn.

Để đạt được các mục tiêu đã nêu, bài báo này đề xuất một cơ chế để lập chỉ mục dữ liệu thông qua việc xây dựng một Đồ thị Kết hợp của Chữ ký Ngữ nghĩa. Cấu trúc đồ thị này kết hợp có hệ thống các đoạn văn bản và các trích xuất thực thể tên (NE) để tạo thành một cấu trúc phong phú và có mạng lưới ngữ nghĩa, giúp việc truy xuất thông tin chính xác. Trong đồ thị hỗn hợp này, các nút bao gồm hai loại chính:

- **Nút Đoạn văn bản V_c :** Trích xuất các đoạn văn bản như một phần của việc bảo tồn ngữ cảnh liên quan đến các đoạn văn bản một cách hợp lý.
- **Nút Thực thể V_e :** đây là những yếu tố ngữ nghĩa chính được trích xuất từ các đoạn văn bản, bao gồm các sự kiện, địa điểm, thời gian và các khái niệm chuyên ngành mà phục vụ như các điểm 'neo' của sự hiểu biết ngữ nghĩa sâu sắc.

Việc sử dụng cấu trúc nút kép này nhằm mục đích các phân đoạn dữ liệu (data chunks) có thể tham gia quét trong thời gian truy xuất nhằm giúp nhận diện các nội dung có liên kết trong ngữ cảnh theo mục đích đề xuất (context porpoising) cao nhất. Phương pháp này cải thiện tình trạng mất thông tin – vấn đề hết sức thông dụng trong các mô hình tóm tắt với ngữ cảnh (SLM). Trong mạng lưới đồ thị hỗn hợp này, các cạnh liên kết giữa các nút được chia thành hai nhóm chính:

- **Mối liên kết Thực thể - Thực thể E_α :** Nắm bắt sự tương tác ngữ nghĩa, cấu trúc phân cấp, cũng như các ràng buộc tạm thời và không gian giữa các thực thể có tên.
- **Mối liên kết Thực thể - Đoạn văn E_β :** Hoạt động như một cầu nối giữa các thực thể và ngữ cảnh gốc mà chúng được trích xuất, do đó đảm bảo sự gắn kết chặt chẽ và tính thống nhất ngữ nghĩa trong toàn bộ hệ thống.

Có sự dự đoán tương tác nhờ sự thấu hiểu ngữ nghĩa và các mô hình ngôn ngữ. Ví dụ: với tài liệu hướng dẫn du lịch và thông tin về thể vận hội Paris 2024, mô hình tự động xác lập được các kết nối thực thể - thực thể (E_α) giữa các địa điểm (Stade de France) và các thực thể như lịch trình của sự kiện (chung kết bơi lội), phương án di chuyển (Tuyến Metro 13) và các điểm tham quan khác (Tháp Eiffel). Đồng thời, các liên kết thực thể -

đoạn văn (E_β) này cũng giúp gắn các địa điểm với những văn bản tương ứng, nơi đề cập đến trạng thái vé, lưu trú, đánh giá các điểm du lịch hay di chuyển. Để tăng cường khả năng phân tích ngữ nghĩa quan hệ, chúng tôi bổ sung mỗi cạnh trong biểu đồ tri thức với thông tin mô tả ngữ nghĩa được tạo ra bởi một mô hình ngôn ngữ. Những mô tả này cung cấp các mối quan hệ ngữ cảnh rõ ràng giữa các nút kết nối. Cụ thể, đối với mỗi cạnh $e_\beta \in E_\beta$ kết nối một thực thể với văn bản tương ứng của nó, chúng tôi sử dụng mô hình ngôn ngữ để tạo ra một mô tả một đoạn văn d_{e_β} về thực thể như một thông tin hỗ trợ cho cạnh. Mô tả này không chỉ cung cấp chi tiết về thực thể, mà còn phản ánh mối quan hệ sâu sắc mang ý nghĩa giữa thực thể đã được trích xuất và văn bản liên quan. Nhờ vào mô tả bằng văn bản của phần này, cạnh thực thể - đoạn văn trở thành một 'cạnh liên kết văn bản' (text-attributed edge) $(e_{\beta}, d_{e_{\beta}}) \in E_{\beta}$. Cuối cùng, quá trình lập chỉ mục trong khung MiniRAG sẽ tạo ra một đồ thị hỗn hợp G , bao gồm cả các nút thực thể và các nút tài liệu với các kết nối nhận thức ngữ nghĩa như sau:

$$D = G = (\{V_c, V_e\}, \{E_\alpha, (e_\beta, d_{e_\beta}) \in E_\beta\}) \quad (2.1)$$

2.2 Truy xuất tri thức dựa trên đồ thị nhẹ

Trong bối cảnh RAG chạy trên thiết bị (on-device), ta nhận thấy có hai điểm bất lợi lớn nhất là tài nguyên tính toán bị hạn chế và thiếu sự bảo mật về quyền riêng tư dữ liệu. Điều này khiến việc dùng mô hình LLM mạnh hoặc các mô hình embedding lớn trở nên khó khăn hơn trong thực tiễn. Tuy nhiên, nhiều mô hình RAG truyền thống lại tập trung vào việc ghép khớp ngữ nghĩa bằng embedding và dùng mô hình LLM để hiểu các đoạn văn bản ngữ cảnh dài. Khi thay thế mô hình LLM bằng mô hình SLM có thể giảm chất lượng truy xuất vì mô hình SLM khó có thể giữ được các sắc thái nghĩa trong văn bản dài và dễ bị gây nhiễu bởi những đoạn văn bản khác không liên quan.

Do vậy, MiniRag đã đặt ra hai mục tiêu sau cho việc truy xuất:

- Giảm sự phức tạp của nội dung cho vào sinh, ưu tiên hơn cho các nội dung cô đọng và có cấu trúc
- Rút ngắn các đầu vào cho SLM, làm giảm sự nhiễu và tăng chất lượng câu trả lời

Thay vì để SLM ghép khớp ngữ nghĩa như LLM thì MiniRAG sử dụng cấu trúc đồ thị có được từ bước lập chỉ mục để truy xuất. Nhờ đó mà hệ thống vẫn có thể có được lượng thông tin đầy đủ nhất có thể chỉ với chi phí tính toán thấp.

2.2.1 Ánh xạ ngữ nghĩa truy vấn (Query Semantic Mapping)

Trong MiniRag, Query Semantic Mapping là bước đầu tiên trong việc truy xuất, giúp chuyển từ truy vấn q (truy vấn ngôn ngữ tự nhiên) sang các thông tin có cấu trúc để giúp cho các bước sau, bằng cách xác định các thành phần nào trong đồ thị chủ mục có liên quan trực tiếp đến câu trả lời. Các hệ thống RAG dùng mô hình LLM thường dựa vào khả năng trích xuất thông tin chất lượng cao từ truy vấn và hiểu được truy vấn theo nhiều khía cạnh, nhưng đối với mô hình SLM sẽ rất dễ gây ra nhiễu và sai lệch khiến phương án trên sẽ không khả thi và câu trả lời sẽ không có chất lượng tốt.

Do vậy, MiniRAG chọn cách khác khả thi hơn đối với mô hình SLM, đó là tập trung vào các thực thể để xử lý truy vấn. MiniRag sẽ trích xuất các thực thể có trong truy vấn q , rồi dùng chúng để có thể liên kết truy vấn q với đồ thị chủ mục $G = \{V_c, V_e\}$, trong đó V_e là các nút thực thể và V_c là các nút chunk.

Ở giai đoạn đầu tiên, Query Semantic Mapping sử dụng mô hình SLM để có thể trích xuất ra tập thực thể V_q từ truy vấn q và dự đoán các kiểu đáp án có thể là câu trả lời. Ví dụ với câu hỏi ai, ở đâu thì các kiểu đáp án có thể sẽ là tên người, địa điểm, nhờ vậy giảm nhiễu trong việc truy xuất câu trả lời.

Sau đó, trong giai đoạn thứ hai, MiniRag dùng một mô hình embedding nhẹ để so sánh sự giống nhau giữa các thực thể có trong truy vấn q và các nút thực thể V_e có trong đồ thị, rồi chọn được các nút thực thể trong V_e phù hợp nhất để tạo thành tập các điểm xuất phát đáng tin để suy luận. MiniRag sử dụng cả embedding và cấu trúc của đồ thị để tìm kiếm cho đường suy luận có ý nghĩa hơn nhiều so với việc không sử dụng cấu trúc đồ thị.

Quá trình tìm đường suy luận gồm có ba phần, lần lượt là chọn các seed nodes hay $\hat{V}_s$ để bắt đầu đường đi, chọn các ứng cử viên đáp án $\hat{V}_a$ đã xác định ở bước trên để định hướng đường đi, và cuối cùng là thu thập các chunk có liên quan để giúp tăng cường ngữ cảnh.

2.2.2 Truy xuất tăng cường topo trên đồ thị (Topology-Enhanced Graph Retrieval)

Thực chất, bước Topology-Enhanced Graph Retrieval dùng để giảm nhiễu khi truy xuất bằng mô hình SLM, bởi vì như đã đề cập ở trên mô hình SLM rất dễ tạo nhiễu nếu chỉ dùng embedding và tính toán chi phí thấp. Đầu tiên, MiniRag sẽ dùng các điểm khởi điểm khởi đầu là các seed nodes và các ứng cử viên đáp án (ký hiệu là $\hat{V}_s$ và $\hat{V}_a$) mà đã xác định từ embedding trên. Sau đó là bước khai thác cấu trúc, được gọi là Key Relationship

Identification, để xác định các cạnh thực thể - thực thể (hay E_α) quan trọng nhất cho truy vấn q . MiniRag coi một cạnh E_α là quan trọng nếu cạnh đó nằm trên hoặc gần đường đi ngắn nhất từ một nút khởi đầu $\hat{v}_s \in \hat{V}_s$ đến một nút đáp án $\hat{v}_a \in \hat{V}_a$.

Để tính toán được mức độ quan trọng của mỗi cạnh $e \in E_\alpha$, MiniRAG gán cho cạnh một lượng điểm $\omega_e(e)$ được tính toán bằng cách đếm xem trong vùng đồ thị k -hop quanh cạnh đó có xuất hiện bao nhiêu nút khởi đầu và nút đáp án. Công thức để tính điểm như sau:

$$\omega_e(e) = \sum_{\hat{v}_s \in \hat{V}_s} \text{count}(\hat{v}_s, \hat{G}_{e,k}) + \sum_{\hat{v}_a \in \hat{V}_a} \text{count}(\hat{v}_a, \hat{G}_{e,k}), \quad (2.2)$$

trong đó $\hat{G}_{e,k}$ là đồ thị con k -hop quanh cạnh e , gồm các nút và cạnh có thể đi tới trong k bước từ hai đầu nút của e . Các cạnh có $\omega_e(e)$ lớn nhất được chọn để tạo thành tập $\hat{E}_\alpha$.

Bước tiếp theo gọi là Query-Guided Path Discovery, MiniRag tìm các đường đi trên đồ thị được coi là chuỗi suy luận cho truy vấn, được mở rộng thêm từ một seed node, qua các nút liên quan để đến gần hơn với các nút có khả năng là đáp án. Trong quá trình mở rộng này, MiniRag sẽ ưu tiên cho các đường đi đi qua những cạnh quan trọng có trong tập $\hat{E}_\alpha$ bởi vì chúng có khả năng có liên quan cao nhất tới câu trả lời. Với mỗi seed node $\hat{v}_s \in \hat{V}_s$, MiniRag sẽ tạo các tập đường đi ứng viên, là các đường đi không có chu trình có độ dài n xuất phát từ $\hat{v}_s$, và ký hiệu tập đó là $P_{\hat{v}_s}$.

Để chấm điểm một đường đi p , MiniRAG sử dụng hàm $\omega_p(p | v_q)$ có công thức như sau:

$$\omega_p(p | v_q) = \omega_v(\hat{v}_s | v_q) \cdot \left(1 + \sum_{v \in (p \wedge \hat{V}_\alpha)} \text{count}(v, p) + \sum_{e \in (p \wedge \hat{E}_\alpha)} \omega_e(e)\right), \quad (2.3)$$

trong đó $\omega_v(\hat{v}_s | v_q)$ là độ tương đồng cosine giữa embedding của seed node $\hat{v}_s$ và thực thể truy vấn v_q , còn $\text{count}(v, p)$ là hàm bằng 1 nếu nút v xuất hiện trong đường đi p hoặc bằng 0 nếu ngược lại. Với mỗi cặp $(v_q, \hat{v}_s)$, các đường đi sẽ được xếp hạng theo điểm đánh giá ω_p và chọn top- k để tạo thành tập P_q .

Khi đã có P_q , MiniRag sẽ tiếp tục tìm các đoạn văn bản có liên quan để có thể cung cấp ngữ cảnh cho việc sinh câu trả lời. Bởi vì mỗi nút thực thể có liên kết với các nút đoạn văn bản nên chỉ cần duyệt qua các liên kết này để lấy được tập chunk ứng viên (ký hiệu V_c^q) tương ứng với các $p \in P_q$. Đồng thời, để giảm nhiễu và giữ các đoạn quan trọng nhất, MiniRag sẽ lại lọc các đoạn văn bản trên qua ba bước sau. Đầu tiên là lọc ứng viên bằng cách lấy giao của tập chunk trên đường suy luận và tập chunk ứng viên, tức là lấy $\hat{V}_c \wedge V_c^q$. Sau đó là tính độ tương đồng bằng cách dùng embedding giữa truy vấn và nội

dung có được sau khi ghép các văn bản chunk và các mô tả cạnh liên quan. Cuối cùng là xếp hạng điểm và chọn top để thu được tập chunk cuối cùng $\hat{V}_c^q$.

Sau khi thực hiện xong Topology-Enhanced Graph Retrieval, ta sẽ có được hai thành phần quan trọng là tập quan hệ $\hat{E}_\alpha$ và tập chunk $\hat{V}_c^q$. Cùng với các nút ứng viên đáp án $\hat{V}_a$, MiniRag sẽ tạo ra đầu vào có cấu trúc và ngắn gọn cho mô hình sinh tăng cường, giúp mô hình có thể tập trung từ các nội dung liên quan hơn thay vì các thông tin nhiễu.

Chương 3

Thực nghiệm và kết quả trong bài báo

3.1 Mục tiêu thực nghiệm của tác giả

Qua chương 2 ta thấy được thiết kế mới của MiniRAG, xây dựng mô hình RAG tối ưu cho on-device một cách hiệu quả mà không cần phụ thuộc vào mô hình ngôn ngữ lớn. Trong chương 3 thực nghiệm của tác giả tập trung trả lời 3 câu hỏi nghiên cứu chính:

- **RQ1:** So sánh hiệu suất: So sánh giữa mô hình MiniRAG với các mô hình SOTA khác trên tiêu chí truy cứu thông tin và hiệu quả của việc truy cứu
- **RQ2:** Phân tích thành phần: Đánh giá đóng góp của các key components cho sự hiệu quả của MiniRAG
- **RQ3:** Case studies: Hiệu quả của MiniRAG trong việc xử lý các bài toán phức tạp, cần nhiều bước suy luận với các mô hình ngôn ngữ nhỏ

3.2 Dữ liệu đánh giá

Sử dụng các bộ dữ liệu on-device (các dữ liệu bảo đảm được thông tin các nhân, có thể xử lý theo thời gian thực, và hiệu quả trong việc quản lý dữ liệu cá nhân) như Tin nhắn (thu thập theo thời gian thực từ lịch sử chat, thông tin liên lạc cá nhân, emails), dữ liệu cá nhân (notes, ghi nhớ, lịch trình), các đoạn thông tin ngắn trên thiết bị (các tệp text nhẹ). Hai bộ dữ liệu sử dụng để đánh giá trong bài báo bao gồm:

- **LihuaWorld:** Tạo sinh dữ liệu giao tiếp cá nhân, sử dụng GPT-4 để tạo bộ dataset tương đương với việc giao tiếp trong một năm. Bộ dữ liệu đa dạng về chủ đề, như đời sống hằng ngày (đồ ăn, quần áo, sinh hoạt, đi lại), hoạt động xã hội và giải trí, công việc và học tập,.... Sử dụng bộ dữ liệu để đánh giá use case Tin nhắn và Dữ liệu cá nhân.

- **MultiHop-RAG** Các đoạn văn bản ngắn, sử dụng bộ dữ liệu multi-hop RAG trên các bài báo hiện thời. Việc này giúp đánh giá khả năng điều phối và thu thập thông tin của hệ thống giữa nhiều văn bản ngắn khác nhau. Bộ dữ liệu mô phỏng được ngữ cảnh thực tế, khi người dùng muốn truy vấn thông tin liên quan từ nhiều bộ dữ liệu khác nhau ở trên hệ thống.

3.3 Môi trường và cấu hình thực nghiệm

Chi tiết cài đặt: Với xử lý văn bản: Chia thành các chunk gồm 1200 tokens với số overlapped token=100, và sử dụng nano vector base để lưu trữ vector. Khi cài đặt MiniRAG, lấy 5 văn bản trên cùng và cài đặt số token là 6000.

Các model sử dụng để so sánh trong thực nghiệm của bài báo:

- LLM: Sử dụng gpt-4o-mini làm mô hình ngôn ngữ và text-embedding-3-small làm mô hình embedding.
- SLM: Sử dụng mô hình tối ưu all-MiniLM-L6-v2 làm mô hình embedding kết hợp với các mô hình gồm Phi-3.5-mini-instruct, GLM-Edge-1.5B-Chat, Qwen2.5-3B-Instruct, MiniCPM3-4B

Thước đo sử dụng để đánh giá trong thực nghiệm:

- **Accuracy (acc):** Đánh giá độ chính xác giữa câu trả lời của hệ thống và câu trả lời được kỳ vọng.
- **Error rate (err):** Lưu các trường hợp hệ thống RAG trả về thông tin sai NHƯNG không nhận ra lỗi sai đó.

3.4 Đánh giá hiệu suất

Hiệu suất giảm khi triển khai hệ thống RAG với các mô hình SLM.

- **LightRAG:** Mô hình RAG xây dựng dựa trên kiến trúc LLM có sự suy giảm hiệu suất rõ rệt, từ 56.9% -> 35.42% khi chuyển từ LLM sang SLM
- **GraphRAG:** Hệ thống không thể hoạt động cho không thể tạo ra dữ liệu chất lượng


LiHuaWorld	NaiveRAG		GraphRAG		LightRAG		MiniRAG	
	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓
Phi-3.5-mini-instruct	41.22%	23.20%	/	/	39.81%	25.39%	53.29%	23.35%
GLM-Edge-1.5B-Chat	42.79%	24.76%	/	/	35.74%	25.86%	52.51%	25.71%
Qwen2.5-3B-Instruct	43.73%	24.14%	/	/	39.18%	28.68%	48.75%	26.02%
MiniCPM3-4B	43.42%	17.08%	/	/	35.42%	21.94%	51.25%	21.79%
gpt-4o-mini	46.55%	19.12%	35.27%	37.77%	56.90%	20.85%	54.08%	19.44%

MultiHop-RAG	NaiveRAG		GraphRAG		LightRAG		MiniRAG	
	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓	<i>acc</i> ↑	<i>err</i> ↓
Phi-3.5-mini-instruct	42.72%	31.34%	/	/	27.03%	11.78%	49.96%	28.44%
GLM-Edge-1.5B-Chat	44.44%	24.26%	/	/	/	/	51.41%	23.44%
Qwen2.5-3B-Instruct	39.48%	31.69%	/	/	21.91%	13.73%	48.55%	33.10%
MiniCPM3-4B	39.24%	31.42%	/	/	19.48%	10.41%	47.77%	26.88%
gpt-4o-mini	53.60%	27.19%	60.92%	16.86%	64.91%	19.37%	68.43%	19.41%

Hình 3.1: Bảng đánh giá hiệu năng

- **NaiveRAG:** Kết quả ổn định, nhưng còn nhiều giới hạn
- **MiniRAG:** Kết quả ổn định ngay cả khi sử dụng các mô hình ngôn ngữ đơn giản hơn nhờ các cải tiến của mô hình: Semantic-aware Graph Indexing và Topology-enhanced retrieval

Mô hình cũng cho thấy hiệu quả lưu trữ tốt khi tiết kiệm tới 25% bộ nhớ so với mô hình LightRAG, nhưng độ chính xác trả về có thể sánh với LightRALightRAG



Hình 3.2: Phân tích so sánh ba hệ thống RAG — MiniRAG, LightRAG và GraphRAG.

3.5 Phân tích thành phần

Biến I: Thay thế heterogeneous graph indexing bằng description-based indexing - mô hình cần sự thông hiểu ngữ nghĩa tốt nếu muốn trả về kết quả chính xác

Biến Ri: Chọn ngắt các module cụ thể khi truy vấn đồ thị => Kết quả: Khẳng định suy luận của nhóm tác giả: Các mô hình SLM tồn tại những giới hạn vốn có, đặc biệt là khả năng thông hiểu ngữ nghĩa toàn diện.

LiHuaWorld	MiniRAG		$\mathcal{I}$		$\mathcal{R}_{chunk}$		$\mathcal{R}_{edge}$	
	$acc \uparrow$	$err \downarrow$	$acc \uparrow$	$err \downarrow$	$acc \uparrow$	$err \downarrow$	$acc \uparrow$	$err \downarrow$
Phi-3.5-mini-instruct	53.29%	23.35%	26.02%	19.12%	48.90%	17.40%	50.47%	15.36%
GLM-Edge-1.5B-Chat	52.51%	25.71%	25.08%	31.50%	46.24%	16.77%	47.81%	20.53%
Qwen2.5-3B-Instruct	48.75%	26.02%	24.14%	15.67%	40.91%	16.14%	48.43%	18.65%
MiniCPM3-4B	51.25%	21.79%	26.18%	15.52%	46.39%	15.83%	48.59%	19.44%

Hình 3.3: Phân tích so sánh ba hệ thống RAG — MiniRAG, LightRAG và GraphRAG.

3.6 Case study

Tình huống nghiên cứu để đánh giá khả năng suy luận đa bước, phức tạp của MiniRAG khi sử dụng SLM. Bối cảnh và truy vấn minh họa: “*What is the name of the Italian restaurant where Wolfgang and Li Hua are having dinner to celebrate Wolfgang’s promotion?*”

Đây là câu hỏi yêu cầu truy vấn đa bước (multi-hop) yêu cầu mô hình cần phải:

- Xác định được mối quan hệ giữa 2 thực thể "Li Hua" và "Wolfgang"
- Xác định sự kiện trong câu hỏi "having dinner to celebrate Wolfgang’s promotion"
- Từ đó, liên kết các thông tin tìm được để đưa ra thông tin "the name of the Italian restaurant"

Qua thực nghiệm của nhóm tác giả, cho thấy:

- **LightRAG:**
 - Cách hoạt động: tách câu truy vấn thành 2 phần Low-level information (Wolfgang, Li Hua, restaurant name) và High-level information (Italian restaurant, dinner celebration, promotion). Từ đó, LightRAG trích xuất các entities và các relations từ các văn bản liên quan.

- Vấn đề gặp phải: LightRAG đã tìm ra các thông tin về "Wolfgang", "Li Hua", "promotion", "restaurant". Tuy nhiên, khi đến bước Generation mô hình lại không thể liên kết các thông tin này thành một quan hệ thống nhất.
- Kết quả: Trả về câu trả lời mơ hồ, không trả lời được đúng trọng tâm là tên nhà hàng. *"Wolfgang and Li Hua are planning to have dinner at a pasta joint celebrate Wolfgang's promotion...The specific name of the restaurant wasn't listed in the provided information..."*

- **MiniRAG:**

- Cách hoạt động: MiniRAG xác định loại câu hỏi - xác định loại câu trả lời. Sau đó, MiniRAG truy xuất các thông tin về "Wolfgang", "Li Hua", "promotion", "restaurant" trong đồ thị dị thể. Cuối cùng, MiniRAG liên kết các thông tin đã tìm được bằng đường dẫn suy luận có định hướng truy vấn (query-guided reasoning path).
- Kết quả: MiniRAG xác định được entity "Venedia Grancaffè" từ quan hệ giữa các nút "Wolfgang" → "dinner party" → "Italian place" và đưa ra câu trả lời chính xác *"The name of the Italian restaurant where Wolfgang and Li Hua are having dinner to celebrate Wolfgang's promotion is Venedia Grancaffè..."*

3.7 Nhận xét của tác giả

Qua việc đi vào trả lời 3 câu hỏi nghiên cứu trên, nhóm tác giả nhận thấy MiniRAG thể hiện hiệu năng ổn định và nhất quán trên hai bối cảnh đánh giá truy vấn on-device và câu hỏi suy luận phức tạp. MiniRAG cải thiện độ chính xác trong truy xuất khi sử dụng SLM và duy trì được hiệu năng trong môi trường tài nguyên hạn chế. MiniRAG đặc biệt tốt khi thực nghiệm trên bộ dữ liệu LihuaWorld - bộ dữ liệu phân mảnh, thiếu cấu trúc và thay đổi theo thời gian. Với bộ dữ liệu Multi-HopRAG, trong case study, có thể thấy MiniRAG có khả năng suy luận đa bước và tổng hợp thông tin từ nhiều nguồn khác nhau. Từ đó, nhóm tác giả nhấn mạnh hiệu quả mà MiniRAG đạt được không phụ thuộc vào các LLM và các suy luận phức tạp. Bên cạnh đó, đồ thị dị thể có nhận thức ngữ nghĩa có thể bù đắp hạn chế về khả năng hiểu ngữ nghĩa của SLM. Từ các kết quả của thực nghiệm, nhóm tác giả kết luận MiniRAG là một mô hình phù hợp và khả thi cho việc triển khai các mô hình RAG gọn nhẹ, đặc biệt trong các kịch bản on-device - một nơi yêu cầu cao về bảo mật, tối ưu bộ nhớ và chi phí tính toán.

Table 3: Case study comparing LightRAG and MiniRAG on a complex restaurant identification query, demonstrating how query-guided reasoning path discovery effectively addresses small language model (SLM) limitations in multi-constraint information retrieval tasks.

Query: What is the name of the Italian restaurant where Wolfgang and Li Hua are having dinner to celebrate Wolfgang's promotion?
Ground-Truth: Venedia Grancaffè
LightRAG Source: Given the query, I decomse it to low-level information: <"Wolfgang"><"LiHua"><"Restaurant name"> and high-level information: <"Italian restaurant"><"Dinner celebration"><"Promotion">. Using these information, I find these elements: Entities:<"FRIES"><"COLLABORATION"><"WOLFGANGSCHULZ"><"HAILEY'S BAK-ERY"><"LIHUA"><"JAM SESSION">... Relations:<"ORGANIZATION", "PIZZA ORDER"><"LIHUA", "WOLFGANGSCHULZ"> <"FAR-RAH", "PIZZA"><"LUNCH", "THANECHAMBERS">... Texts:<Time: 20260318_15:30><Time: 20260508_08:00><Time: 20260514_14:00><Time: 20261103_13:00><Time: 20260326_16:00>... LightRAG Response: Wolfgang and Li Hua are planning to have dinner at a pasta joint to celebrate Wolfgang's promotion...The specific name of the restaurant wasn't listed in the provided information...
MiniRAG Source: Given the query, I guess the answer type could be: <"SOCIAL INTERACTION"><"LOCATION"> and I found the entities from query are: <"Italian restaurant"><"Wolfgang"><"LiHua"><"dinner"><"promotion">. Using these information, I find these elements: Entities from query: <"ITALIAN PLACE"><"RESTAURANT"><"WOLFGANG"><"WOLFGANG SCHULZ"><"LIHUA"><"DINNER PARTY">... Candidate answer entity: ...<"ITALIAN PLACE"><"GRATITUDE EXPRESSION"><"NEW PIZZA PLACE DOWNTOWN">... Texts: <Time: 20260908_21:00><Time: 20260529_17:00><Time: 20260523_14:00><Time: 20260430_17:00><Time: 20260419_21:00> MiniRAG Response: The name of the Italian restaurant where Wolfgang and Li Hua are having dinner to celebrate Wolfgang's promotion is Venedia Grancaffè. Wolfgang mentioned it in a reminder about the dinner planned for 6 PM. They were excited to celebrate his promotion with a feast, with both looking forward to enjoying some delicious food together....

Hình 3.4: Case study - So sánh MiniRAG và LightRAG

Chương 4

Thực nghiệm mô phỏng của nhóm

4.1 Mục tiêu thực nghiệm của nhóm

Nhóm em tiến hành các thực nghiệm, đánh giá với những mục tiêu sau:

- **Mục tiêu 1:** Cài đặt và chạy lại code của bài báo MiniRAG với một phần dataset của bài báo (LiHua-World). Nhóm chúng em tiến hành clone project từ bài báo và chạy code trên nền tảng kaggle. Tuy nhiên, quá trình indexing của các mô hình ngôn ngữ nhỏ tương đối lâu. Vì vậy, nhóm chúng em chỉ tiến hành chạy code với một phần nhỏ dataset gốc trong bài báo.
- **Mục tiêu 2:** Kiểm tra tính hiệu quả và khả thi của MiniRAG khi chạy trên máy tính cá nhân. Vì mục đích của bài báo là sử dụng SLM nhằm giúp cho quá trình RAG có thể được tiến hành trong môi trường có nguồn tài nguyên hạn chế. Do đó, chúng em tiến hành chạy MiniRAG trên máy tính cá nhân để kiểm tra tính hiệu quả và khả thi của phương pháp.

4.2 Môi trường thực nghiệm

Phần mềm, thư viện: Nhóm em tiến hành thực nghiệm trên hai môi trường: Kaggle và Máy tính cá nhân. Project sử dụng ngôn ngữ Python và các thư viện:

- **Các thư viện cơ bản:** accelerate, aiofiles, aiohttp, configparser, graspologic, json-repair, httpx.
- **Database packages:** networkx, nltk.
- **Basic modules:** numpy, pipmaster, pydantic.
- **File manipulation libraries:** PyPDF2, python-docx, python-dotenv, python-pptx, rouge.

- **Setuptools:** tenacity.
- **LLM packages:** tiktoken, tqdm, xxhash.

Mô hình SLM sử dụng

- **Đối với môi trường Kaggle:** Nhóm em sử dụng SLM Phi-3.5-mini-instruct của Microsoft
- **Đối với môi trường trên máy tính cá nhân:** Nhóm em sử dụng SLM phi3:mini thông qua Ollama.

4.3 Bộ dữ liệu sử dụng

Do tập dữ liệu gốc của bài báo quá lớn và tốc độ indexing của các mô hình SLM là tương đối chậm. Vì vậy, nhóm em chỉ tiến hành thực nghiệm trên một phần của dataset gốc (LiHua-World). Cụ thể, phần dataset nhóm em tiến hành thực nghiệm được chia thành 2 phần:

- **Phần 1 (Các câu hỏi loại single):** 28 đoạn hội thoại trải dài qua 13 tuần (từ 05/01/2026-17/04/2026) và 45 câu hỏi liên quan đến các chủ đề của 28 đoạn hội thoại phía trên. Trong đó, có 25 câu hỏi có thể tìm được câu trả lời trong các đoạn hội thoại và 20 câu hỏi không có câu trả lời trong các đoạn hội thoại (câu hỏi loại null). Các câu hỏi trong phần này có dẫn chứng nằm trọn vẹn trong một đoạn hội thoại. Vì vậy, để trả lời câu hỏi, mô hình không cần truy xuất thông tin giữa nhiều đoạn hội thoại khác nhau.
- **Phần 2 (Các câu hỏi loại multi):** 21 đoạn hội thoại trải dài từ 21/01/2026-09/10/2026 và 32 câu hỏi liên quan đến các chủ đề của 21 đoạn hội thoại phía trên. Trong đó, có 22 câu hỏi có thể tìm được câu trả lời trong các đoạn hội thoại và 10 câu hỏi không có câu trả lời trong các đoạn hội thoại (câu hỏi loại null). Các câu hỏi loại multi là các câu hỏi có dẫn chứng nằm trong nhiều đoạn hội thoại khác nhau. Do đó, để đưa ra được câu trả lời chính xác, mô hình phải liên kết được thông tin từ nhiều đoạn hội thoại khác nhau, đòi hỏi phải suy luận nhiều và phức tạp hơn.

Question	Gold Answer	Evidence	Type
What time does Li Hua check in with Adam about moving in?	5:30 PM	20260105_14:00	Single
When was the first time Li Hua had dinner with Wolfgang this year?	20260108	20260108_11:00	Single
Where was the first time Li Hua had dinner with Wolfgang this year?	the cozy caf� downtown	20260108_11:00	Single
What time is Li Hua's lunch with Wolfgang Schulz at the cozy caf� downtown?	20260108	20260108_11:00	Single
What is the Wi-Fi password at Li Hua's house?	Family123	20260106_09:00	Single
What does Adam say about having friends over?	having friends over occasionally is fine	20260106_09:00	Single
What house rule does Adam mention?	keep noise to a minimum during late hours	20260106_09:00	Single
What does Li Hua report to Adam on January 6th?	the water tap in the apartment is broken	20260106_13:00	Single

Hình 4.1: Một số câu hỏi loại single

Question	Gold Answer	Evidence	Type
What time will Li Hua and Wolfgang meet for breakfast on the morning of the 9th?	Insufficient information	N/A	Null
What type of equipment does Wolfgang Schulz use when he works out at the gym?	Insufficient information	N/A	Null
What type of exercise does Li Hua prefer to do at the gym, and what time does Wolfgang usually go to the gym?	Insufficient information	N/A	Null
What type of traditional games did Wolfgang Schulz play with Li Hua during the Lunar New Year celebration?	Insufficient information	N/A	Null
What did Li Hua eat for dinner on January 20, 2026?	Insufficient information	N/A	Null
What specific suggestions did Li Hua have regarding the construction schedule during the last community meeting?	Insufficient information	N/A	Null
What movie did Li Hua and Wolfgang decide to watch together on New Year's Eve 2026?	Insufficient information	N/A	Null
What dish did Li Hua order for dessert after having Sichuan hot pot with Wolfgang Schulz?	Insufficient information	N/A	Null

Hình 4.2: Một số câu hỏi loại null

Question	Gold Answer	Evidence	Type
Did Adam Smith send a message to Li Hua about the upcoming building maintenance schedule before the administrators announced a temporary change in the construction schedule due to weather conditions?	Yes	20260121_10:00<and>20260701_10:00	Multi
Did Wolfgang ask Li Hua about watching "Star Wars: A New Hope" after he asked Li Hua about going to see "Overwatch 3"?	Yes	20260121_13:00<and>20261009_17:00	Multi
Did Li Hua agree to go out for dinner after Wolfgang first asked him if he wanted to go out for dinner?	Yes	20260123_17:00<and>20260930_16:00	Multi
Did Yuriko ask Li Hua for help with her studio's homepage before she booked a seat at the "Central Perk" cafe?	Yes	20260223_15:00<and>20260225_15:00	Multi
Did Li Hua ask Yuriko to play music together before Wolfgang proposed to pause playing musical instruments?	Yes	20260318_15:10<and>20260416_21:00	Multi
Did Wolfgang Schulz recommend the band learns "Viva la Vida" by Coldplay after he and Li Hua discussed what song to play this Sunday?	Yes	20260318_15:30<and>20260625_19:00	Multi

Hình 4.3: Một số câu hỏi loại multi

4.4 Kết quả thực nghiệm

Khi thực nghiệm trên nền tảng kaggle

- Với tập câu hỏi loại single:
 - Số câu trả lời đúng: 20/45 câu tương đương 44.4%
 - Số câu trả lời sai: 6/45 câu tương đương 13.3%
 - Số câu không tìm được thông tin: 19/45 câu tương đương 42.3%
- Với tập câu hỏi loại multi:
 - Số câu trả lời đúng: 14/32 câu tương đương 43.8%
 - Số câu trả lời sai: 5/32 câu tương đương 15.6%
 - Số câu không tìm được thông tin: 13/32 câu tương đương 40.6%

Khi thực nghiệm trên máy tính cá nhân (Chỉ thực nghiệm trên tập câu hỏi loại single)

- Số câu trả lời đúng: 19/45 câu tương đương 42.2%
- Số câu trả lời sai: 7/45 câu tương đương 15.6%
- Số câu không tìm được thông tin: 19/45 câu tương đương 42.2%

Question	Gold Answer	minirag
When was the first time Li Hua had dinner with Wolfgang this year?	20260306	According to the provided data tables, Li Hua and Wolfgang had their first dinner meeting on March 6th, 2026, at 2:00 PM to discuss homepage updates for Wolfgang's studio. This information is derived from the interaction between Li Hua and Yuriko Yamamoto, where Li Hua confirms the meeting and Wolfgang expresses his anticipation for the discussion.`` `markdown### First Dinner Meeting: March 6th, 2026- **Time:** 2:00 PM- **Location:**
What house rule does Adam mention?	keep noise to a minimum during late hours	In the provided data tables, Adam mentions a specific house rule during the conversation with LiHua on February 23, 2026. The house rule discussed is: **Keep noise to a minimum during late hours**: Adam advises LiHua to be mindful of the noise level, especially during the night, to maintain a peaceful environment within the household.This rule is crucial for ensuring that all residents can enjoy a quiet and respectful living space, particularly during times when others might be sleeping or seeking tranquility.Here is the relevant excer
What is the name of the gym that Wolfgang recommended LiHua to go to?	FitZone	Wolfgang recommended LiHua to visit a gym named **FitZone**. This establishment is noted for providing a variety of facilities for physical exercise, including numerous classes and equipment necessary for workouts. Wolfgang also highlighted the welcoming atmosphere at FitZone, which he described as "pretty chill," and mentioned the helpfulness of the staff, suggesting it as a good place for LiHua to maintain an active lifestyle.`` `markdown## Gym Recommendation**FitZone**- **Description**: A gym that offers a range of classes and
What type of ambiance does YurikoYamamoto want for her studio's homepage?	more welcoming and engaging	YurikoYamamoto expresses a desire for her studio's homepage to have an ambiance that is both inviting and user-friendly. This is inferred from her positive reactions to the new features, such as the "Automatically schedule available time" feature, which she believes will make scheduling more convenient for her clients. She appreciates the seamless interaction between the user and the homepage, which aligns with the concept of User Experience (UX) as described in the provided data.Yuriko's enthusiasm for the new feature and her e

Hình 4.4: Một số câu trả lời đúng

Question	Gold Answer	minirag
Where was the first time Li Hua had dinner with Wolfgang this year?	the cozy caf� downtown	Li Hua and Wolfgang had their first dinner together this year at "central Perk" caf�, as mentioned in the conversation on February 25, 2026. The meeting was scheduled for 3 PM on that day, with the purpose of discussing ideas for Wolfgang's studio's homepage. The caf� was chosen for its cozy atmosphere, which was conducive to their brainstorming session. ### First Dinner at central Perk Caf�- **Date:** February 25, 2026-
What time is Li Hua's lunch with Wolfgang Schulz at the cozy caf� downtown?	20260411	Li Hua and Wolfgang Schulz have planned to meet for lunch at the cozy caf� downtown on February 25th, 2026. The specific time for their lunch is not mentioned in the provided data tables. However, they express enthusiasm for the meal and discuss their preferences, with Li Hua suggesting a burger and Wolfgang indicating a preference for something warm and hearty, like soup or a sandwich. They agree on the plan and look forward to the gathering. ## Lunch Meeting with Wolfgang SchulzLi H
Who is Li Hua meeting with to discuss homepage design updates?	Yuriko Yamamoto	Li Hua is collaborating with the Design Team to discuss updates to the homepage design. The Design Team, led by "Design Team," is responsible for the visual and interactive aspects of the homepage updates. This collaboration is crucial for ensuring that the homepage design aligns with the company's vision and meets user expectations. ## Homepage Design Updates CollaborationLi Hua is working closely with the **Design Team** to discuss and implement updates to the homepage design. The Design Team, consisting of creative professionals, is tasked with en
Who invites Li Hua to join the community bake sale?	Adam Smith	HaileyJohnson invites Li Hua to join the community bake sale. This invitation is mentioned in the data table with the following entry: csvid,content9,"Hey Li Hua! It was great meeting you at the bake sale today! I just wanted to share that I offer a doorstep delivery service for fresh milk and bread. It's super convenient, especially for busy days! Would you be interested in trying it out?" LiHua: Hey Hailey! It was nice meeting you too!

Hình 4.5: Một số câu trả lời sai

Question	Gold Answer	minirag
What is the Wi-Fi password at Li Hua's house?	Family123	Sorry, I'm not able to provide an answer to that question.
What does Adam say about having friends over?	having friends over occasionally is fine	Sorry, I'm not able to provide an answer to that question.
Li Hua accidentally broke a light fixture once. What did Adam say about the light fixture?	I'll arrange for a professional to take a look	Sorry, I'm not able to provide an answer to that question.
When did Li Hua invite Adam Smith to check the basement renovation progress?	20260223_19:00	Sorry, I'm not able to provide an answer to that question.
What new song does the Jolly band decide to work on for the jam session according to their discussion on 20260410?	Stand By Me	Sorry, I'm not able to provide an answer to that question.
What is Li Hua's feedback on Chae Song-hwa's medical knowledge lecture?	It is insightful and makes complex topics easy to understand	Sorry, I'm not able to provide an answer to that question.
When is the anniversary event of Hailey Johnson's bakery shop?	April 15 to 17	Sorry, I'm not able to provide an answer to that question.
What does Li Hua want to have on Hailey's bakery shop anniversary event?	Sourdough and sweet pastries	Sorry, I'm not able to provide an answer to that question.
Why does Li Hua ask ChaeSong-hwa about whether neurosurgeons actually use test tubes in their work?	Li Hua is trying to get some insights for a website design	Sorry, I'm not able to provide an answer to that question.
Who proposes that the band takes a break from jamming this week?	Wolfgang Schulz	Sorry, I'm not able to provide an answer to that question.
What suggestions does Li Hua propose to Adam Smith about the upcoming community garden renovation?	Add more seating areas for people to relax and enjoy the space and some flower beds with native plants	Sorry, I'm not able to provide an answer to that question.
What kinds of flowers does Li Hua recommend to Adam Smith for the	Lavender and coneflowers and fresh	Sorry, I'm not able to provide an answer to that question.

Hình 4.6: Một số câu mô hình không tìm được thông tin

4.5 Nhận xét và đánh giá

- Về kết quả: Thực nghiệm của nhóm chỉ tiến hành trên tập dataset nhỏ tuy nhiên đã đạt được kết quả khá tốt. Mặc dù không đạt được tỉ lệ trả lời đúng cao như trong paper do mô hình SLM nhóm em sử dụng không tốt như của tác giả. Tuy nhiên, tỉ lệ các câu hỏi mô hình trả lời sai cũng giảm đi.
 - **Đối với hai tập dataset:** Tập các câu hỏi loại single cho kết quả tốt hơn tập các câu hỏi loại multi. Qua đó, ta thấy được miniRAG chưa thực sự tối ưu cho quá trình truy xuất thông tin từ nhiều nguồn khác nhau.
 - **Đối với hai môi trường thực nghiệm:** Trên máy tính cá nhân, mô hình miniRAG vẫn thực hiện được tuy nhiên thời gian chạy lâu hơn và kết quả nhận được cũng không tốt như trên môi trường kaggle. Do các tài nguyên trên máy cá nhân không đầy đủ như trên môi trường kaggle dẫn đến nhóm em phải thay đổi mô hình SLM về mô hình nhỏ hơn. Vì vậy, thời gian chạy lâu hơn và kết quả chạy không tốt bằng trên kaggle. Qua đó, ta thấy được mặc dù miniRAG được đề xuất để thích hợp với môi trường có tài nguyên hạn chế tuy nhiên vẫn yêu cầu mức cấu hình tương đối cao và chưa thực sự tối ưu cho môi trường trên laptop cá nhân.
- Về các hạn chế trong quá trình thực nghiệm của nhóm:
 - Thực nghiệm chỉ được tiến hành trên tập dataset nhỏ. Do tài nguyên có giới hạn nên nhóm em chỉ tiến hành thực nghiệm trên một phần tập dataset gốc trong bài báo. Vì vậy, kết quả thực nghiệm có thể chưa được chính xác tuyệt đối như trong paper. Tuy nhiên, qua thực nghiệm, nhóm em cũng đã làm rõ và đánh giá được quá trình truy xuất thông tin của mô hình miniRAG.
 - Kết quả thực nghiệm của nhóm được đánh giá thủ công mà chưa có một công cụ tính toán và đánh giá tự động. Vì vậy, nếu thực nghiệm trên một tập dữ liệu quá lớn có thể dẫn đến sai sót trong quá trình tính toán, đánh giá kết quả.

Chương 5

ĐÁNH GIÁ CHUNG VÀ HƯỞNG PHÁT TRIỂN

5.1 Đánh giá tổng quan về bài báo MiniRAG

- **Điểm mạnh:**

- MiniRAG được đề xuất để hoạt động được trên môi trường có tài nguyên hạn chế. Giải pháp chính được paper đưa ra là thay thế các mô hình LLM bằng các mô hình SLM. Mô hình SLM có ít tham số hơn rất nhiều, vì vậy yêu cầu về tài nguyên của mô hình cũng giảm đi rất nhiều và phù hợp với các môi trường có tài nguyên hạn chế. Mô hình miniRAG đã sử dụng các kỹ thuật graph structure và heuristic search để khắc phục các điểm yếu của SLM so với LLM. Từ đó, miniRAG vẫn đảm bảo được hiệu năng dù đã thay thế hoàn toàn LLM bằng SLM.
- MiniRAG cũng giúp tăng hiệu quả tính toán và tiết kiệm tài nguyên. Mặc dù thay thế LLM bằng SLM nhưng miniRAG vẫn đảm bảo được hiệu năng ổn và thậm chí cao hơn một số phương pháp RAG trước đó nhờ vào việc tận dụng tốt các kỹ thuật lập đồ thị và truy xuất thông tin. Ngoài ra, nhờ sử dụng SLM, miniRAG cần ít tham số, không gian lưu trữ hơn. Qua đó giúp tiết kiệm đáng kể tài nguyên cho người dùng.
- Các tác giả sử dụng heterogeneous graph giúp khắc phục điểm yếu hiểu ngữ cảnh kém của SLM. Việc xây dựng đồ thị thông minh với nhiều loại cạnh và nút hợp lý giúp giữ nguyên được ngữ cảnh gốc và giảm đáng kể tình trạng hiểu sai ngữ cảnh của SLM.
- MiniRAG có một cấu trúc rõ ràng, pipeline dễ hiểu giúp cho quá trình tìm hiểu, triển khai và debug dễ hơn nhiều so với các phương pháp RAG khác.

- **Điểm yếu:**

- Kết quả của miniRAG phụ thuộc rất mạnh vào quá trình indexing cụ thể là quá trình entity extraction. Mọi quá trình truy xuất thông tin và trả lời câu hỏi của miniRAG đều bắt nguồn từ các entity. Từ các entity sẽ tìm đến các chunk và suy ra được ngữ cảnh, câu trả lời. Vì vậy, nếu quá trình trích xuất entity không đạt được hiệu suất tốt thì kết quả cuối cùng cũng sẽ kém đi rất nhiều.
- MiniRAG không thực tối ưu cho các câu hỏi loại multi-hop. Quá trình truy xuất với các câu hỏi multi-hop yêu cầu mô hình phải tìm kiếm câu trả lời qua nhiều bước tìm kiếm trên đồ thị. Do đó, quá trình truy xuất thông tin cho các câu hỏi multi-hop cần thời gian lâu hơn và có thể đạt kết quả không cao.
- MiniRAG không phù hợp để mở rộng cho dataset rất lớn. Do sử dụng SLM nên vốn dĩ quá trình hoạt động của miniRAG rất tốn thời gian. Vì vậy nếu sử dụng SLM cho tập dataset quá lớn sẽ không phù hợp và rất tốn thời gian. Ngoài ra, khi dùng cho tập dataset lớn, entity được trích xuất sẽ rất nhiều, graph sẽ mở rộng rất nhanh dẫn đến quá trình truy xuất thông tin sẽ không hiệu quả, thiếu chính xác.

5.2 Đánh giá kết quả thực nghiệm của nhóm

Sau đây là một số đánh giá về quá trình thực nghiệm của nhóm em:

- **Những điều nhóm đã kiểm chứng được qua quá trình thực nghiệm:**
 - Quá trình thực nghiệm giúp nhóm hiểu rõ hơn pipeline hoạt động của mô hình miniRAG từ quá trình indexing đến QA.
 - Quá trình thực nghiệm của nhóm đã kiểm chứng được khả năng truy xuất dữ liệu của mô hình miniRAG khi chỉ sử dụng SLM.
 - Thực nghiệm giúp kiểm tra khả năng hạn chế hiện tượng hallucination (mô hình đưa ra câu trả lời dù không có bằng chứng trong các đoạn hội thoại). Kết quả thực nghiệm cho thấy tỉ lệ xảy ra hiện tượng hallucination là rất thấp. Khi không tìm được thông tin phù hợp, mô hình sẽ trả về trạng thái không trả lời được ("Sorry, I'm not able to provide an answer to that question.") chứ không tự bịa ra câu trả lời.
 - Thực nghiệm của nhóm giúp kiểm chứng khả năng trả lời các câu hỏi single và multi-hop. Kết quả thực nghiệm cho thấy miniRAG có thể trả lời được cả hai

loại câu hỏi. Tuy nhiên mô hình làm tốt hơn với các câu hỏi loại single. Qua đó, ta thấy được miniRAG chưa thực sự tối ưu với các câu hỏi đòi hỏi suy luận nhiều bước.

- Quá trình thực nghiệm cũng giúp kiểm tra tính tương thích của miniRAG khi triển khai trên môi trường có tài nguyên hạn chế (máy tính cá nhân). Mặc dù miniRAG vẫn hoạt động được trên môi trường máy cá nhân tuy nhiên thời gian indexing, retrieval mất nhiều thời gian và hiệu suất tổng thể không cao.

- **Những điều nhóm chưa làm được:**

- Nhóm chưa chạy được thực nghiệm trên toàn bộ tập dataset gốc trong bài báo. Do các hạn chế về tài nguyên và tập dataset của bài báo quá to, vì vậy, quá trình thực nghiệm của nhóm không thể tiến hành trên toàn bộ tập dataset LiHua-World mà chỉ chọn ra những đoạn hội thoại và câu hỏi đặc trưng để tiến hành thực nghiệm. Do đó, kết quả thực nghiệm có thể chưa sát với thực tế và có độ tin cậy không cao.
- Nhóm chỉ tiến hành thực nghiệm trên 2 SLM. Trong paper, nhóm tác giả đã tiến hành thực nghiệm mô hình miniRAG trên nhiều SLM khác nhau để cho ra đánh giá khách quan, thực tế nhất. Tuy nhiên, nhóm em chỉ tiến hành thực nghiệm trên 2 SLM là: Phi-3.5-mini-instruct và phi3:mini.
- Trong quá trình thực nghiệm, nhóm chưa có một công cụ để đánh giá kết quả một cách tự động và chính xác. Vì vậy, nhóm em phải tiến hành đánh giá thủ công nên kết quả có thể chưa thực sự chính xác khi đánh giá với tập dataset lớn.

5.3 Hướng nghiên cứu và cải tiến tiếp theo

Dựa vào các kết quả đã có ở trong phần thực nghiệm và các hạn chế đã nêu, ta dễ dàng nhận thấy rằng MiniRag là phương pháp rất phù hợp cho các mô hình RAG chạy trên các thiết bị hay còn gọi là on-device, nhất là trong các trường hợp cần sự cân bằng giữa chi phí tính toán và chất lượng kết quả truy xuất được. Tuy vậy, để hệ thống có thể đạt được hiệu năng tốt như trong bài báo gốc đã công bố và cải thiện khả năng ứng dụng thực tế thì nhóm đã đề xuất ra các hướng nghiên cứu và các cải tiến phù hợp cho tương lai. Các hướng cải tiến sẽ được sắp xếp theo các mức độ ưu tiên và phù hợp với quá trình triển khai hiện tại.

(1) Mở rộng và chuẩn hóa bộ dữ liệu đánh giá

Hướng cải tiến này là để tăng độ tin cậy của các kết quả thực nghiệm, cùng với đó là kiểm tra MiniRag có thể cho ra kết quả như thế nào trong các tình huống khó khăn và thực tế hơn. Đầu tiên là mở rộng quy mô dữ liệu và số lượng câu truy vấn bằng cách tăng số lượng hội thoại, tăng số lượng tài liệu và số lượng truy vấn để xem kết quả khi số lượng nhiều, trùng lặp tăng. Sau đó, nhóm sẽ cải tiến để đa dạng hóa các câu hỏi thay vì chỉ dùng các truy vấn single-hop, các câu hỏi sẽ ưu tiên về multi-hop (kết hợp thông tin từ nhiều đoạn tài liệu khác nhau), các câu hỏi so sánh, các câu hỏi tổng hợp theo thời gian, các câu hỏi phủ định hay thậm chí là các câu hỏi không hề có đáp án để đánh giá liệu MiniRag có tự tạo ra câu trả lời hay không, liệu cơ chế đã đủ tốt để khắc phục điều này chưa. Hơn nữa, việc thêm vào những bộ dữ liệu bằng Tiếng Việt và các dữ liệu có tính ứng dụng (ví dụ như ghi chú cá nhân, nội dung học tập, văn bản hành chính,...) sẽ đánh giá hệ thống trong môi trường dữ liệu hỗn loạn như trên các thiết bị on-device thực tế. Cuối cùng, nhóm sẽ chuẩn hóa quy trình chấm điểm đúng sai, mức chấp nhận được và các tiêu chí cho kết quả không có đáp án.

(2) Thử nghiệm thêm mô hình SLM và embedding khác và đánh giá sự ảnh hưởng.

Hướng cải tiến quan trọng tiếp theo là thử nhiều các mô hình ngôn ngữ nhỏ SLM và các mô hình embedding nhẹ khác để đánh giá xem MiniRag hoạt động tốt như thế nào khi thay đổi các mô hình. Đối với thay đổi về mô hình ngôn ngữ nhỏ SLM, nhóm sẽ kiểm tra sự ảnh hưởng của mô hình tại các bước trích xuất thực thể từ truy vấn, dự đoán kiểu đáp án và tạo câu trả lời cuối cùng. Về mô hình embedding, nhóm sẽ đánh giá về việc mô hình nào có thể giúp chọn được seed nodes và các ứng cử viên đáp án tốt nhất, cải thiện khả năng cho việc suy luận trên đồ thị. Ngoài ra, vì mục tiêu của MiniRag là thực hiện được trên thiết bị on-device, nhóm sẽ bổ sung các tiêu chí đánh giá chi phí như thời gian lập chỉ mục, thời gian truy xuất theo từng truy vấn, mức sử dụng bộ nhớ và dung lượng lưu trữ của đồ thị, qua đó đánh giá được các đánh đổi cần thiết khi chọn các mô hình.

(3) Hoàn thiện triển khai MiniRAG gần với bài báo gốc hơn về thuật toán, tham số và pipeline.

Để có thể giảm sự khác biệt giữa kết quả mà nhóm đã thực nghiệm được với kết quả thực nghiệm của bài báo gốc, nhóm cần cải thiện các thành phần của mô hình theo đúng thiết kế, nhất là các phần lập chỉ mục đồ thị, các loại nút, cạnh và mô tả của các cạnh và các

bước trong truy xuất tăng cường theo cấu trúc (đánh giá chấm điểm). Đồng thời, nhóm sẽ chuẩn hóa và tìm kiếm các tham số tối ưu hơn cho MiniRag hoạt động, các tham số như độ lớn của một đoạn văn bản (chunk), top k, độ dài đường đi n hoặc đồ thị k-hop. Quan trọng hơn, nhóm sẽ thực hiện việc thay đổi từng bộ phận trong mô hình để xem phần nào thật sự giúp tối ưu cho mô hình, chẳng hạn có thể chỉ dùng embedding retrieval và bỏ key relationship identification, hoặc bỏ bước lọc các đoạn chunk, hoặc là chỉ dùng mỗi chunk retrieval,... Điều này giúp nhóm có thể xác định chính xác thành phần nào quan trọng trong MiniRag.

(4) Mở rộng ra dữ liệu đa phương thức và phức tạp.

Một lĩnh vực triển khai tự động của MiniRAG là khả năng để nó mở cho các nhiệm vụ để có thể thực hiện được đa phương tiện lúc dữ liệu không chỉ là văn bản mà còn gồm thêm các hình thức như là hình ảnh, bảng biểu, biểu đồ (như là các tài liệu PDF, slide, ảnh tài liệu). Tại thời điểm đó, đồ thị có thể thêm một loại nút mới và các cạnh mới kết nối giữa các phương tiện để có thể kết hợp với việc nhúng đa phương thức cho sự định vị và truy xuất. Sự mở rộng đó đặc biệt hữu ích cho các tài liệu học thuật và kỹ thuật, nơi thông tin quan trọng thường được chứa trong bảng hay đồ thị và nơi các câu hỏi như “Bảng nào chứng minh kết quả này?” hoặc “Hình nào mô tả kiến trúc?” là phổ biến nhưng khó giải quyết với RAG chỉ có văn bản.

(5) Mở rộng ra các lĩnh vực khác và kiểm tra tính tổng quát.

Để có thể thể hiện giá trị của ứng dụng, hệ thống nên được thử nghiệm trong nhiều lĩnh vực tri thức khác nhau như y tế, luật, giáo dục và kỹ thuật. Những lĩnh vực này có đặc điểm chung là có nhiều thuật ngữ với các thực thể dày đặc và các mối quan hệ phức tạp và là nơi mà các câu hỏi thường yêu cầu suy luận nhiều bước. Thêm vào đó thì hệ thống nên được thử nghiệm để duy trì tiếng ồn đối kháng (sai chính tả, viết tắt, tham chiếu thực thể, trùng lặp tài liệu) để có thể đánh giá khả năng chịu đựng của cơ chế truy xuất được cải tiến topo và khả năng duy trì chất lượng trong sự hiện diện của dữ liệu bẩn.

(6) Các hướng phát triển bổ sung.

Nếu muốn nghiên cứu để nâng báo cáo lên mức có hệ thống thì nhóm có thể nghiên cứu điều kiện cho phép cập nhật đồ họa ở trong thời gian thực hay tăng nhẹ nhằm tránh việc phải chỉ số lại tất cả mọi thứ khi có dữ liệu mới. MiniRAG có thể làm rất tốt về việc giải thích nhờ có lộ trình và các chứng cứ. Vì vậy có thể xây dựng mộtocasi công đầu ra rõ

nét bằng việc (i) chọn lộ trình nào, (ii) các chứng cứ hay mối quan hệ nào quan trọng, và (iii) block nào là chứng cứ. Nhóm có thể cung cấp thêm độ tin cậy về tiến trình RAG bằng việc cung cấp một chứng minh về một cơ chế phân định ngưỡng từ chối khi không có chứng cứ hoặc chỉ tái xếp nhẹ để làm giảm nhiễu cho các dữ liệu đầu vào của mô hình sinh. Các biện pháp bảo mật và quyền riêng tư để triển khai trên thiết bị người dùng bao gồm có: Mã hóa dữ liệu được lập chỉ mục, giảm nhật ký truy vấn, xóa dữ liệu theo yêu cầu,...

Tổng kết tất cả mọi thứ, hướng phát triển này là: dữ liệu và đánh giá (đủ rộng và đúng độ khó), mô hình và tối ưu tài nguyên (nhẹ, chạy và giữ lại chất lượng), triển khai bám sát bài báo (đúng thuật toán, đúng thiết lập) và mở rộng ứng dụng (đa phương thức, đa ngành). Nếu lần lượt thực hiện các hướng này thì hệ thống MiniRAG của nhóm sẽ có thể tiệm cận tính năng của bài báo gốc và phát triển thành một giải pháp RAG khả dụng cho cá nhân.

Tài liệu tham khảo

- [1] Amazon Web Services. *What is RAG (Retrieval-Augmented Generation)?* <https://aws.amazon.com/what-is/retrieval-augmented-generation/>. Accessed: 2025-01. 2024.
- [2] Zirui Guo et al. *LightRAG: Simple and Fast Retrieval-Augmented Generation*. 2024. arXiv: 2410.05779 [cs.CL]. URL: <https://arxiv.org/abs/2410.05779>.
- [3] Haoyu Han et al. *Retrieval-Augmented Generation with Graphs (GraphRAG)*. 2025. arXiv: 2501.00309 [cs.IR]. URL: <https://arxiv.org/abs/2501.00309>.
- [4] HKUD Research Group. *MiniRAG: Towards Extremely Simple Retrieval-Augmented Generation*. 2025. arXiv: 2501.06713 [cs.CL]. URL: <https://arxiv.org/abs/2501.06713>.