

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



Giảng viên hướng dẫn: TS. Nguyễn Đức Anh

Sinh viên thực hiện:
Phí Đình Mạnh – 23020108
Hoàng Ngọc Hưng – 22021170
Đặng Việt Thành – 22021213
Bùi Đức Đăng – 22021155

**TỰ ĐỘNG TRÍCH XUẤT LUỒNG CÔNG VIỆC DỰA
TRÊN SOFT CONTRASTIVE ACTION DRIVEN
EMBEDDING**

BÁO CÁO BÀI TẬP NHÓM

Ngành: Công nghệ thông tin

HÀ NỘI – 2025

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Giảng viên hướng dẫn: TS. Nguyễn Đức Anh

Sinh viên thực hiện: **Phí Đình Mạnh** – 23020108
Hoàng Ngọc Hưng – 22021170
Đặng Việt Thành – 22021213
Bùi Đức Đăng – 22021155

TỰ ĐỘNG TRÍCH XUẤT LUỒNG CÔNG VIỆC DỰA
TRÊN SOFT CONTRASTIVE ACTION DRIVEN
EMBEDDING

BÁO CÁO BÀI TẬP NHÓM

Ngành: Công nghệ thông tin

HÀ NỘI – 2025

TÓM TẮT

Việc trích xuất hiệu quả các quy trình làm việc có cấu trúc từ các đoạn hội thoại chưa được chú thích vẫn là một thách thức lớn và chưa được khám phá đầy đủ trong ngôn ngữ học tính toán. Tự động hóa quy trình này có thể đẩy nhanh đáng kể việc thiết kế thủ công các quy trình làm việc trong các lĩnh vực mới và cho phép xây dựng các mô hình ngôn ngữ lớn dựa trên các sơ đồ quy trình chuyên biệt theo lĩnh vực, tăng cường tính minh bạch và khả năng kiểm soát. Trong bài báo này, chúng tôi trình bày lại phương pháp embedding Dialog2Flow (D2F) của Sergio Burdisso¹ Srikanth Madikeri and Petr Motlicek. Khác với các embedding câu thông thường bằng cách ánh xạ các phát ngôn vào một không gian tiềm ẩn, nơi chúng được nhóm lại theo chức năng giao tiếp và thông tin của chúng (tức là các hành động mà chúng đại diện). D2F cho phép mô hình hóa các đoạn hội thoại như các quỹ đạo liên tục trong một không gian tiềm ẩn với các vùng liên quan đến hành động riêng biệt. Bằng cách phân cụm các embedding D2F, không gian tiềm ẩn được lượng tử hóa, và các đoạn hội thoại có thể được chuyển đổi thành các chuỗi ID vùng/hành động, tạo điều kiện thuận lợi cho việc trích xuất quy trình làm việc cơ bản. Để huấn luyện trước D2F, cần phải xây dựng một tập dữ liệu toàn diện bằng cách hợp nhất hai mươi tập dữ liệu hội thoại hướng nhiệm vụ với các chú thích hành động được chuẩn hóa trên mỗi lượt. Họ giới thiệu một hàm mất mát tương phản mềm mới tận dụng thông tin ngữ nghĩa của các hành động này để hướng dẫn quá trình học biểu diễn, cho thấy hiệu suất vượt trội so với hàm mất mát tương phản có giám sát tiêu chuẩn. Đánh giá với nhiều nhúng câu khác nhau, bao gồm cả các nhúng dành riêng cho hội thoại, cho thấy rằng D2F mang lại kết quả định tính và định lượng vượt trội trên nhiều lĩnh vực khác nhau.

LỜI CAM ĐOAN

Nhóm 12 chúng em cam kết: Các thành viên nhóm không sử dụng nội dung có nguồn gốc từ AI hay sao chép của người khác. Bài báo cáo hoàn toàn do các thành viên nhóm nghiên cứu và hoàn thành. Chúng em xin chịu trách nhiệm và chấp nhận hình phạt 0 điểm nếu có vi phạm.

Hà Nội, ngày ... tháng ... năm 2025

Sinh viên

Nhóm 12

Mục lục

TÓM TẮT	1
LỜI CAM ĐOAN	2
1 CƠ SỞ LÝ THUYẾT	6
1.1 Tổng quan	6
1.2 Vấn đề	7
1.3 Định nghĩa bài toán	8
1.3.1 Định nghĩa Action trong task oriented dialog (TOD)	8
1.3.2 Công thức xác định Action	8
1.3.3 Vai trò của action trong việc tránh xuất luồng công việc:	8
1.4 Nghiên cứu liên quan	8
1.5 Sự khác biệt giữa ngữ nghĩa và hành động	9
1.6 Đóng góp	10
2 PHƯƠNG PHÁP	11
2.1 Khung học biểu diễn	11
2.1.1 Encoder	11
2.1.2 Contrastive Head	11
2.1.3 Phép đo độ tương đồng	11
2.2 Supervised Contrastive Loss	11
2.3 Supervised Soft Contrastive Loss	12
2.4 Mục tiêu huấn luyện	13
3 DỮ LIỆU VÀ THIẾT LẬP HUẤN LUYỆN	14

3.1	Bộ dữ liệu huấn luyện	14
3.2	Chuẩn hóa dữ liệu	15
3.2.1	Chuẩn hóa dialog act	15
3.2.2	Chuẩn hóa domain và slot	17
3.2.3	Chuẩn hóa action label	17
3.3	Thiết lập huấn luyện	17
3.3.1	Kiến trúc mô hình	17
3.3.2	Hàm độ tương đồng giữa các nhãn	18
3.4	Các mô hình baseline	18
3.4.1	Baseline tổng quát	18
3.4.2	Baseline chuyên hội thoại	18
3.5	Dữ liệu đánh giá	19
3.5.1	Unified TOD Evaluation Set	19
3.5.2	SpokenWOZ	19
3.6	Các metric đánh giá	19
3.6.1	Anisotropy	19
3.6.2	Few-shot	19
3.6.3	Xếp hạng với nDCG@10	20
4	KẾT QUẢ VÀ TRÍCH XUẤT LUỒNG CÔNG VIỆC	21
4.1	Kết quả đánh giá tương đồng	21
4.1.1	Anisotropy	22
4.1.2	NDCG	22
4.2	Đánh giá kết quả trích xuất workflow	22
4.2.1	Chi tiết về cách đánh giá	22
4.2.2	Kết quả	22
4.3	Nghiên cứu ablation	23
	KẾT LUẬN	25
4.4	Các kết quả chính của bài báo	25

4.5	Hạn chế của nghiên cứu	25
4.6	Các mối quan tâm về đạo đức	26
4.7	Hướng phát triển trong tương lai	26
TÀI LIỆU THAM KHẢO		27

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

1.1. Tổng quan

- **Trí tuệ nhân tạo đàm thoại (Conversational AI):** Trí tuệ nhân tạo đàm thoại (Conversational AI) sử dụng xử lý ngôn ngữ tự nhiên (NLP), các quy trình học máy (ML) và các công nghệ khác để dạy máy tính cách hiểu, xử lý và mô phỏng các cuộc hội thoại của con người. NLP diễn giải ý nghĩa của câu hỏi của người dùng, và ML thu thập thông tin mới để giúp các tương tác trong tương lai với người dùng dễ dàng hơn. Trí tuệ nhân tạo đàm thoại cũng kết hợp các kỹ thuật như gắn thẻ từ loại, một phương pháp được thực hiện tự động bởi thuật toán để đối sánh các từ với các từ loại, chẳng hạn như danh từ, động từ và tính từ, nhằm đảm bảo rằng ý nghĩa của đầu vào của người dùng được hiểu đúng. Doanh nghiệp có thể xây dựng và sử dụng các loại trí tuệ nhân tạo đàm thoại khác nhau để đáp ứng nhu cầu của mình. Phần mềm trí tuệ nhân tạo đàm thoại cần được đào tạo từ hàng tỷ tương tác của khách hàng để xác định những gì cần thiết nhằm cung cấp hỗ trợ khách hàng chính xác và cá nhân hóa [2].
- **Hệ thống đối thoại hướng nhiệm vụ (Task Oriented Dialog System):** Hệ thống đối thoại hướng nhiệm vụ được thiết kế để giúp người dùng đạt được một mục tiêu cụ thể hoặc hoàn thành một nhiệm vụ cụ thể, chẳng hạn như đặt vé máy bay, gọi món ăn hoặc lên lịch cuộc họp. Các hệ thống này khác với hệ thống đối thoại mở, được thiết kế để trò chuyện với người dùng về nhiều chủ đề khác nhau. Về bản chất, hệ thống đối thoại hướng nhiệm vụ là về việc thu hẹp khoảng cách giữa ngôn ngữ và hành động. Ngôn ngữ liên quan đến khả năng truyền đạt ý nghĩa thông qua từ ngữ và câu, trong khi hành động liên quan đến khả năng thực hiện các nhiệm vụ vật lý dựa trên sự truyền đạt đó. Bằng cách kết hợp hai phương thức này, hệ thống đối thoại hướng nhiệm vụ có thể cho phép máy móc hiểu ngôn ngữ của con người và hướng dẫn người dùng thực hiện các nhiệm vụ dựa trên sự hiểu biết đó. Các hệ thống hướng nhiệm vụ ngày càng được sử dụng trong nhiều ứng dụng khác nhau, chẳng hạn như dịch vụ khách hàng, thương mại điện tử, hướng dẫn điều hướng, v.v. Việc sử dụng rộng rãi các hệ thống này đạt được là do chúng cung cấp một cách thức tự nhiên và trực quan hơn để người dùng tương tác với công nghệ cũng như dễ dàng hoàn thành các nhiệm vụ cụ thể [4].
- **Quy trình trong việc tự động hóa:** Quy trình công việc là một hệ thống quản lý các quy trình và nhiệm vụ lặp đi lặp lại diễn ra theo một trình tự cụ thể. Chúng là cơ chế mà con người và doanh nghiệp sử dụng để hoàn thành công việc của mình, cho dù đó là sản xuất sản phẩm, cung cấp dịch vụ, xử lý thông tin hay bất kỳ hoạt động tạo ra giá trị nào khác. Nếu không có quy trình thì chatbot

chỉ có thể trả lời các câu hỏi đơn giản và không làm được nhiệm vụ gì.

1.2. Vấn đề

- **Hạn chế của việc gán nhãn thủ công:**

- **Tốn kém thời gian:** Khi nói đến việc phát triển một dự án học máy, việc gán nhãn dữ liệu không phải là một bước nhanh chóng có thể thực hiện dễ dàng. Nhiều người ngạc nhiên rằng việc chuẩn bị dữ liệu, bao gồm cả việc gán nhãn, chiếm gần 80 % toàn bộ thời gian của dự án. Cho dù đang làm việc về nhận dạng hình ảnh hay xử lý ngôn ngữ tự nhiên, mỗi điểm dữ liệu thường cần được các chuyên gia con người dán nhãn tỉ mỉ để đảm bảo độ chính xác. Và nếu dự án có hàng triệu điểm dữ liệu này thì yếu tố thời gian sẽ trở thành gánh nặng ngày càng nặng nề [3].
- **Sự dụng nhiều nhân lực:** Bên cạnh việc tiêu tốn thời gian, việc gán nhãn dữ liệu còn tốn nhiều công sức. Lý do rất đơn giản: việc gán nhãn chất lượng đòi hỏi sự đánh giá của con người. Mặc dù có những công cụ và phần mềm có thể hỗ trợ quá trình gán nhãn nhưng bước kiểm tra cuối cùng thường cần có sự can thiệp của con người. Điều này càng trở nên rõ ràng hơn trong các lĩnh vực chuyên biệt như chăm sóc sức khỏe, nơi người dán nhãn cần phải có trình độ chuyên môn nhất định để dán nhãn chính xác cho dữ liệu như hình ảnh y tế hoặc hồ sơ bệnh nhân. Nhu cầu về các kỹ năng chuyên môn làm tăng thêm độ phức tạp và chi phí cho quy trình [3].
- **Chi phí tốn kém:** Nói về chi phí, khía cạnh tiền tệ của việc gán nhãn dữ liệu là điều không thể bỏ qua. Chi phí sẽ tăng lên nhanh chóng khi tính đến nguồn nhân lực cần thiết cho một dự án gán nhãn quy mô lớn. Cho dù đang thuê chuyên gia nội bộ hay thuê ngoài các dịch vụ gán nhãn chuyên dụng, mỗi dịch vụ đều có mức giá riêng. Đối với các tổ chức hoặc dự án nhỏ hơn với ngân sách hạn chế, những chi phí này có thể là rào cản đáng kể, hạn chế khả năng tận dụng AI của họ ở mức tối đa. Mặc dù gán nhãn dữ liệu là một bước quan trọng trong quá trình phát triển học máy nhưng những thách thức của nó thường bị đánh giá thấp. Quá trình này không hề đơn giản, đòi hỏi phải đầu tư đáng kể về thời gian, nguồn nhân lực và tiền bạc [3].

- **Hạn chế của các phương pháp cũ khi miền phân phối thay đổi:**

- Các phương pháp sentence embedding thường thất bại khi thử nghiệm trên các domain mới vì chúng chỉ được nắm bắt được ngữ nghĩa trong tập huấn luyện và không có tính tổng quát vì được pre-train trên wikipedia, webs trong khi các domain thực tế có phân phối từ vựng và cấu trúc rất khác.

1.3. Định nghĩa bài toán

1.3.1. Định nghĩa Action trong task oriented dialog (TOD)

Trong các hệ thống đối thoại hướng tác vụ. Một câu nói không chỉ mang ý nghĩa đơn thuần mà nó còn mang một mục đích cụ thể. Action là sự kết hợp giữa ý định giao tiếp của người nói và thực thể họ đang đề cập đến. Điều này giúp chuyển đổi hội thoại tự nhiên thành một chuỗi các logic có thể biểu diễn trên sơ đồ luồng.

1.3.2. Công thức xác định Action

Để chuẩn hóa các hành động, bài báo kết hợp hai thành phần chính:

$$Action = Act \oplus Slots$$

- **Dialog act:** Đây là thành phần đại diện cho ý định giao tiếp của người nói. Nó cho biết người nói đang có ý định làm gì
- **Slots:** Đây là thành phần đại diện cho nội dung hoặc thực thể chi tiết liên quan đến tác vụ đó. Nó cho biết người hỏi đang đề cập đến thông tin gì

1.3.3. Vai trò của action trong việc trích xuất luồng công việc:

Khác với các mô hình cũ chỉ tập trung vào ngữ nghĩa thì việc tập trung vào action mang lại 3 lợi ích:

- **Trừu tượng hóa hội thoại:** Biến câu nói phức tạp, đa dạng từ vựng thành các định dạng chuẩn.
- **Xây dựng được Trajectory:** Khi các câu nói được chuyển thành action, một của hội thoại sẽ trở thành chuỗi các action liên tiếp còn được gọi là quỹ đạo liên tục (continuous trajectories) như bài báo đề cập nơi mà cách hành động được nhóm lại gần nhau trong latent space.
- **Lượng tử hóa không gian để trích xuất luồng công việc :** Bằng cách phân cụm các action, latent space được lượng tử hóa thành các vùng hành động riêng biệt. Khi đó các của hội thoại sẽ được chuyển đổi thành chuỗi hành động cho phép xây dựng một đồ thị luồng công việc từ dữ liệu thô.

1.4. Nghiên cứu liên quan


Các mô hình như Sentence-BERT và Universal Sentence Encoder đã tạo ra bước tiến lớn trong việc biểu diễn ngôn ngữ nhưng khi áp dụng vào trích xuất luồng công việc chúng gặp 2 điểm yếu chí mạng.

- **Nhầm lẫn giữa ngữ nghĩa và hành động:** Các mô hình này được huấn luyện để tìm sự tương đồng từ nội dung. Ví dụ nếu ta có một công khác ngữ nghĩa nhưng cùng một mục đích thì các mô hình này sẽ thất bại ngay lập tức.
- **Vấn đề về dữ liệu huấn luyện:** Do được huấn luyện trên các văn bản tĩnh như Wikipedia hay các trang web. Cho nên các mô hình này không thể nhận biết được các cách diễn đạt trong hội thoại.

Các mô hình TOD-BERT và Dialog Sentence ra đời để khắc phụ điểm yếu của các mô hình trên. Tuy nhiên chúng vẫn gặp các hạn chế:

- **Phụ thuộc vào domain cụ thể** Các mô hình đó thường được huấn luyện trên dữ liệu hội thoại cố định. Khi mang vào một miền hoàn toàn mới chúng gặp phải hiện tượng dịch chuyển miền và không còn duy trì được khả năng biểu diễn chính xác.
- **Thiếu tính tổng quát hóa:** Mặc dù sự dụng học tương phản để kéo các câu trong một cuộc hội thoại lại gần nhau xong do thiếu chuẩn hóa các hành động nên không gian vector mà chúng tạo ra thường bị nhiễu và không minh bạch để tạo ra đồ thị luồng công việc.

1.5. Sự khác biệt giữa ngữ nghĩa và hành động



Hình 1.1: So sánh không gian ngữ nghĩa và không gian hành động

- **Tương đồng về ngữ nghĩa:** Là đo lường độ tương đồng dựa trên các từ khóa, cấu trúc ngữ pháp và từ vựng. Do đó các câu nói bị phân tán hỗn loạn như ta có thể thấy tại hình 1.1.
- **Tương đồng hành động:** Bỏ qua lớp vỏ ngôn ngữ để tập trung vào mục tiêu của người nói.

1.6. Đóng góp

Bài báo đã đạt được một bước tiến mới trong việc chuyển đổi dữ liệu hội thoại không cấu trúc thành các luồng công việc thông qua 3 khía cạnh sau:

- **Phương pháp dialog2flow:** thay vì nhóm các câu theo nghĩa thông thường thì phương pháp ánh xạ vào latent space nơi mà các câu nói được phân loại dựa trên mục tiêu cho phép mô hình hóa và chuyển đổi hội thoại thành chuỗi hàng động đây là yếu tố quan trọng để xây được đồ thị luồng công việc mà không cần can thiệp thủ công.
- **Bộ dữ liệu hợp nhất quy mô lớn:** Bài báo đã giải quyết vấn đề về giao cản dữ liệu của mô hình TOD trước đây do sự thiếu hụt dữ liệu nhãn hành động chuẩn hóa trên miền khác nhau bằng cách hợp nhất 20 bộ dữ liệu hội thoại hướng tác vụ và chuẩn hóa bộ dữ liệu này với các nhãn hành động theo quy chuẩn đồng nhất.
- **Học tương phản mềm:** Để dialog2flow đạt kết quả tốt thì bài báo đã giới thiệu một phương pháp mới là học tương phản mềm, khác với học tương phản truyền thống thì học tương phản mềm tận dụng tốt thông tin ngữ nghĩa của các hành động hơn ví dụ (INFROM_PHONE và INFORM_ADDRESS) nên nằm gần nhau hơn so với THANK_YOU. Kết quả thực nghiệm cho thấy mô hình có khả năng tổng quát hóa vượt trội đặc biệt là khi đối mặt với các miền dữ liệu mới.

CHƯƠNG 2. PHƯƠNG PHÁP

2.1. Khung học biểu diễn

Framework của phương pháp D2F gồm các thành phần chính là:

2.1.1. Encoder

Thành phần đầu tiên Encoder $f(\cdot) \in \mathbb{R}^n$ dùng để ánh xạ x thành một vector biểu diễn $x = f(x)$. $f(\cdot)$ là một encoder dựa trên BERT kết hợp với mean pooling và được huấn luyện như một bi-encoder với các weight được chia sẻ.

2.1.2. Contrastive Head

Thành phần tiếp theo là Contrastive head $g(\cdot) \in \mathbb{R}^d$ dùng khi huấn luyện để ánh xạ vector biểu diễn x đến không gian được áp dụng contrastive loss. $g(\cdot)$ được thiết kế là một mạng perceptron đa lớp với một lớp ẩn $z = g(x) = \text{ReLU}(x \cdot W_1)W_2$, trong đó $W_1 \in \mathbb{R}^{n \times n}$ và $W_2 \in \mathbb{R}^{n \times d}$

2.1.3. Phép đo độ tương đồng

Phương pháp sử dụng cosine similarity. Vì thế $\text{sim}(u, v)$ được tính bằng góc giữa hai vector u và v trong không gian biểu diễn. Trong bài báo, tác giả coi similarity và alignment có thể thay thế cho nhau và coi như các vector $f(\cdot)$ và $g(\cdot)$ sau khi qua encoder và contrastive head đều đã được chuẩn hóa L2 nên có thể tính độ tương đồng bằng tích vô hướng:

$$\text{sim}(u, v) = \cos(u, v) = u \cdot v \quad (2.1)$$

2.2. Supervised Contrastive Loss

Với một batch gồm N mẫu anchor, mẫu positive và nhãn được lấy mẫu ngẫu nhiên, ký hiệu là $B = \{(x_i, x_i^+, y_i)\}_{i=1}^N$, hàm Supervised Contrastive Loss cho mỗi bộ ba (x_i, x_i^+, y_i) thứ i được định nghĩa như sau:

$$\ell_i^{sup} = - \sum_{j \in \mathcal{P}_i} \frac{1}{|\mathcal{P}_i|} \log \frac{e^{\mathbf{z}_i \cdot \mathbf{z}_j^+ / \tau}}{\sum_k e^{\mathbf{z}_i \cdot \mathbf{z}_k^+ / \tau}} \quad (2.2)$$

Trong đó:

- $\mathcal{P}_i = \{j \mid y_i = y_j\}$ là tập hợp các chỉ số của tất cả các mẫu có cùng nhãn với mẫu thứ i trong batch.
- τ là tham số nhiệt độ softmax, đóng vai trò kiểm soát mức độ mạnh hay yếu khi kéo các cặp positive lại gần nhau và đẩy các cặp negative ra xa nhau trong embedding space.

Hàm loss cuối cùng được tính toán trung bình trên tất cả N cặp trong một mini-batch theo công thức $\mathcal{L}^{sup} = \frac{1}{N} \sum_{i=1}^N \ell_i^{sup}$.

Ví dụ câu thoại đặt mua máy tính: ”Tôi muốn mua chiếc laptop Dell mới” có nhãn ”inform-laptop-dell” sẽ là Anchor. Câu thoại ”Tôi cần một chiếc máy tính xách tay hiệu Dell” do cùng nhãn sẽ là Positive, trong khi câu thoại ”Thời tiết hôm nay thế nào?” có ý định hội thoại khác sẽ là Negative.

2.3. Supervised Soft Contrastive Loss

Điểm mới trong phương pháp D2F nằm ở việc chuyển từ supervised contrastive loss sang supervised soft contrastive loss. Trong các hàm supervised contrastive loss truyền thống, tất cả các mẫu có nhãn khác với mẫu anchor đều bị coi là các mẫu negative ngang hàng nhau và bị đẩy ra xa với cùng một cường độ. Tuy nhiên trong những cuộc hội thoại thực tế, hai nhãn khác nhau vẫn có thể mang những đặc điểm chức năng gần giống nhau (ví dụ: nhãn Reject ”Tôi không ăn được hải sản” có thể gần với nhãn Request_Alternative ”Còn món nào khác không?” vì dù khác nhãn nhưng vẫn cùng biểu thị sự không đồng ý với phương án ban đầu). Vì vậy nên thay vì tư duy mọi nhãn khác nhau đều là mẫu negative như nhau thì các mẫu có nhãn khác nhau nhưng gần gũi về mặt ngữ nghĩa thì nên bị đẩy đi ít hơn.

Vẫn với ví dụ mua máy tính, nếu câu thoại là ”Tôi muốn mua một laptop Lenovo” có nhãn ”inform-laptop-lenovo” thì trong hàm soft contrastive loss, câu thoại này sẽ bị đẩy ra xa khỏi câu thoại anchor ”Tôi muốn mua chiếc laptop Dell mới” với cường độ thấp hơn so với câu thoại ”Thời tiết hôm nay thế nào?” có nhãn hoàn toàn khác biệt thay vì đều bị đẩy ra cùng một cường độ như trong hàm loss truyền thống.

Đặt $\delta(y_i, y_j)$ là thước đo độ tương đồng ngữ nghĩa giữa các nhãn y_i và y_j , hàm soft contrastive loss như sau:

$$\ell_i^{soft} = - \sum_{j=1}^N \frac{e^{\delta(y_i, y_j) / \tau'}}{\sum_{k=1}^N e^{\delta(y_i, y_k) / \tau'}} \log \frac{e^{\mathbf{z}_i \cdot \mathbf{z}_j^+ / \tau}}{\sum_k e^{\mathbf{z}_i \cdot \mathbf{z}_k^+ / \tau}} \quad (2.3)$$

Trong đó τ' là tham số nhiệt độ điều khiển độ softness của các nhãn negative.

Khác với hàm loss truyền thống, hàm loss này khuyến khích encoder phân tách mẫu anchor và các mẫu negative theo tỉ lệ thuận với độ tương đồng ngữ nghĩa các nhãn. Cụ thể, các mẫu negative có nhãn càng tương đồng về mặt ngữ nghĩa với nhãn của mẫu anchor thì sẽ bị đẩy ra xa với cường độ thấp hơn và ngược lại.

Cuối cùng, hàm loss cho mini-batch $\mathcal{L}^{soft}$ được tính toán tương tự như cách tính $\mathcal{L}^{sup}$.

2.4. Mục tiêu huấn luyện

Tác giả đã tiến hành thực nghiệm với bốn mục tiêu huấn luyện khác nhau. Các mục tiêu này được phân biệt dựa trên việc nhãn dialogue action được sử dụng trực tiếp hay được phân rã thành các nhãn act và nhãn slot riêng biệt. Ngoài ra các mục tiêu còn được phân biệt dựa trên loại hàm contrastive loss được áp dụng. Cụ thể thì hai mục tiêu sử dụng soft contrastive loss là:

- **D2F_{single}**: $\mathcal{L} = \mathcal{L}_{act+slots}^{soft}$
- **D2F_{joint}**: $\mathcal{L} = \mathcal{L}_{act}^{soft} + \mathcal{L}_{slots}^{soft}$

Hai mục tiêu tương ứng sử dụng hàm supervised contrastive loss để làm cơ sở so sánh:

- **D2F-Hard_{single}**: $\mathcal{L} = \mathcal{L}_{act+slots}^{sup}$
- **D2F-Hard_{joint}**: $\mathcal{L} = \mathcal{L}_{act}^{sup} + \mathcal{L}_{slots}^{sup}$

Trong trường hợp sử dụng hàm joint loss, các contrastive head $g(\cdot)$ riêng biệt sẽ được áp dụng cho từng loại nhãn tương ứng nhằm tối ưu hóa các không gian đặc trưng chuyên biệt.

CHƯƠNG 3. DỮ LIỆU VÀ THIẾT LẬP HUẤN LUYỆN

3.1. Bộ dữ liệu huấn luyện

Bài báo sử dụng bộ dữ liệu hội thoại định hướng nhiệm vụ được hợp nhất từ 20 bộ dữ liệu TOD phổ biến.

Bảng 3.1: Các bộ dữ liệu hội thoại TOD

Dataset	#U	#D	#DA	#S
ABCD (Chen et al., 2021)	20.4K	10	0	10
BiTOD (Lin et al., 2021)	72.5K	6	13	33
Disambiguation (Qian et al., 2022)	114.3K	8	9	28
DSTC2-Clean (Mrkšić et al., 2017)	25K	1	2	8
FRAMES (El Asri et al., 2017)	20K	1	21	46
GEORGE (Quan et al., 2019)	25K	1	2	10
HDSA-Dialog (Chen et al., 2019)	91.9K	8	6	24
KETOD (Chen et al., 2022)	107.7K	20	15	182
MS-DC (Li et al., 2018)	71.9K	3	11	56
MulDoGO (Peskov et al., 2019)	74.8K	6	0	63
MultiWOZ2.1 (Eric et al., 2020)	108.3K	8	9	27
MultiWOZ2.2 (Zang et al., 2020)	55.9K	8	2	26
SGD (Rastogi et al., 2020)	479.5K	20	15	184
Taskmaster1 (Byrne et al., 2019)	30.7K	6	1	59
Taskmaster2 (Byrne et al., 2019)	147K	11	1	117
WOZ2.0 (Mrkšić et al., 2017)	4.4K	1	2	10
SimJointMovie (Shah et al., 2018)	7.2K	1	14	5
SimJointRestaurant (Shah et al., 2018)	20K	1	15	9
SimJointGEN (Zhang et al., 2024)	1.3M	16	16	5
Total	3.4M	52	44	524

Sau khi hợp nhất và chuẩn hóa, bộ dữ liệu đạt quy mô lớn với:

- 3.4 triệu lượt lời (utterances)
- 52 domain
- 18 dialog acts
- 524 slot
- 3982 action labels

3.2. Chuẩn hóa dữ liệu

Các bộ dữ liệu TOD ban đầu được xây dựng độc lập, không có sự thống nhất về cách đặt tên dialog act, domain và slot. Vì vậy tác giả đã chuẩn hóa dữ liệu bằng quy trình gồm các bước:

3.2.1. Chuẩn hóa dialog act

Để chuẩn hóa nhãn, tác giả đã ánh xạ 44 nhãn xuống 18 nhãn hành động được chuẩn hóa, quá trình này dựa trên ý nghĩa ngữ nghĩa được mô tả trong các bài báo của bộ dữ liệu gốc.

Bảng 3.2: Ánh xạ dialog act gốc sang dialog act chuẩn

Original	Standardized	Parent
inform	inform(slots)	inform
notify_fail	inform_failure	inform
notify_failure		
no_result		
nobook		
nooffer		
sorry		
cant_understand		
canthelp		
reject		
book	inform_success	inform
offerbooked		
notify_success		

Original	Standardized	Parent
request	request(slots)	request
request_alt		
request_compare		
request_update		
req_more	request_more	request
request_more		
moreinfo		
hearmore		
confirm	confirm(slots)	confirmation
confirm_answer	confirm_answer	/ confirmation
confirm_question	confirm_question	
affirm	agreement	agreement
affirm_intent		
negate	disagreement	disagreement
negate_intent		
deny		
offer	offer	offer
select		
multiple_choice		
offerbook		
suggest	recommendation	recommendation
recommend		
greeting	greeting	greeting
welcome		
thank_you	thank_you	thank_you
thanks		

Original	Standardized	Parent
good_bye	good_bye	good_bye
goodbye		
closing		

Việc giảm số lượng dialog act giúp hạn chế phân mảnh nhãn và tăng khả năng học ngữ nghĩa cốt lõi của hành động hội thoại.

3.2.2. Chuẩn hóa domain và slot

Các domain có cùng ý nghĩa nhưng khác cách đặt tên được gộp lại thành một domain thống nhất. Slot được biểu diễn cùng domain nên có thể cùng tên slot nhưng lại là hai slot khác nhau. Định dạng của slot:

$$\langle \text{domain} \rangle . \langle \text{slot} \rangle \quad (3.1)$$

Ví dụ: *restaurant.price_range*, *hotel.check_in_date*.

3.2.3. Chuẩn hóa action label

Mỗi action được định nghĩa là một bộ ba:

$$(\text{dialog act}, \text{domain}, \text{slot}) \quad (3.2)$$

Ví dụ: *REQUEST.restaurant.price_range*

Cuối cùng tác giả cho ra được 3982 action labels, được sử dụng để huấn luyện mô hình embedding.

3.3. Thiết lập huấn luyện

3.3.1. Kiến trúc mô hình

Mô hình sử dụng BERT-base làm backbone encoder với các tham số:

- Embedding size: 768.
- Độ dài chuỗi tối đa: 64 token.
- Batch size: 64.

- Số epoch huấn luyện: 15.
- learning rate: 3×10^{-6} .

Đầu ra của mô hình là các vector 768 chiều. Trước khi tính loss, vector được đưa qua một đầu MLP riêng biệt để thành vector 128 chiều.

3.3.2. Hàm độ tương đồng giữa các nhãn

Bài báo không coi các action label là các nhãn rời rạc mà biểu diễn mỗi nhãn bằng một vector embedding. Độ tương đồng giữa hai nhãn y_i và y_j được tính bằng cosine similarity:

$$\delta(y_i, y_j) = \cos(\mathbf{e}_{y_i}, \mathbf{e}_{y_j}) \quad (3.3)$$

Cách định nghĩa này cho phép mô hình học được mối quan hệ ngữ nghĩa mềm giữa các hành động hội thoại khác nhau.

3.4. Các mô hình baseline

3.4.1. Baseline tổng quát

Nhóm baseline tổng quát bao gồm các mô hình embedding ngôn ngữ phổ biến:

- GloVe.
- BERT.
- Sentence-BERT (SBERT).
- GTR-T5.
- OpenAI Embedding models.

3.4.2. Baseline chuyên hội thoại

Ngoài ra, bài báo so sánh với các mô hình được thiết kế riêng cho hội thoại và bài toán TOD:

- TOD-BERT.
- DSE.
- SPACE-2.

- DialoGPT.
- SBD-BERT.

3.5. Dữ liệu đánh giá

3.5.1. Unified TOD Evaluation Set

Tập đánh giá Unified TOD có 26910 câu nói với 1794 nhãn được trích xuất từ dữ liệu huấn luyện. Những câu nói này được lấy mẫu và loại bỏ 15 câu nói cho mỗi nhãn.

3.5.2. SpokenWOZ

SpokenWOZ là bộ dữ liệu hội thoại nói, gồm 31303 câu nói với 427 nhãn tương ứng với 1710 cuộc trò chuyện đơn lĩnh vực. Bài báo chỉ sử dụng các cuộc trò chuyện đơn lĩnh vực để có thể trích xuất quy trình làm việc cho 7 lĩnh vực trong SpokenWOZ. Câu nói được chuyển thành văn bản qua hệ thống ASR nên sẽ xảy ra trường hợp sai từ, thiếu từ dẫn đến nhận diện hành động và slot bị khó khăn. Ngoài ra vẫn nói còn tồn tại nhiều trường hợp như ngập ngừng, câu cụt, ngữ điệu từng người khác nhau. Tất cả đều gây ra những sự khó khăn nhưng cũng là thách thức cho nhóm tác giả.

3.6. Các metric đánh giá

3.6.1. Anisotropy

Bài báo sử dụng các chỉ số anisotropy nội lớp (intra-class), liên lớp (inter-class) và hiệu số Δ để đánh giá cấu trúc không gian embedding.

- Intra-class: Đo độ tương đồng trung bình giữa các embedding cùng nhãn. Nếu chỉ số cao, cho thấy cùng hành động được gom tốt.
- Inter-class: Đo độ tương đồng trung bình giữa các embedding khác nhãn. Nếu chỉ số thấp, cho thấy các hành động khác nhau được tách tốt.
- hiệu số Δ : Intra - Inter. Đây là chỉ số chính được nhóm tác giả dùng để so sánh chất lượng.

3.6.2. Few-shot

Bài báo sử dụng Prototypical Networks với thiết lập 1-shot và 5-shot. Với mỗi hành động, một embedding mẫu bằng trung bình k embedding của hành động đó. Các embedding còn lại được đánh giá dựa trên độ tương đồng với embedding mẫu.

3.6.3. Xếp hạng với nDCG@10

Đối với mỗi hành động, bài báo chọn ngẫu nhiên một câu làm truy vấn và truy xuất top k embedding gần nhất, từ đó tạo ra danh sách xếp hạng các hành động. Các embedding ở top k chủ yếu có cùng hành động với câu truy vấn và được xếp hạng cao nhất.

CHƯƠNG 4. KẾT QUẢ VÀ TRÍCH XUẤT LUỒNG CÔNG VIỆC

4.1. Kết quả đánh giá tương đồng

Tất cả các phiên bản D2F đều cho kết quả vượt trội so với baseline trên tất cả các độ đo. Các mô hình được chọn làm baseline để đánh giá sự phù hợp cho các câu hỏi thoại hướng tác vụ. Ví dụ, với DSE, mô hình embedding cho kết quả tốt hơn hẳn các mô hình embedding tổng quát, do mô hình này sẽ gom nhóm dựa trên mức độ xuất hiện liên tiếp nhau của hai lượt nói trong một đoạn hội thoại hướng tác vụ. So sánh giữa các phiên bản D2F, phiên bản huấn luyện dùng hàm mất mát tương phản mềm cho kết quả nhất, vượt trội so với phiên bản sử dụng hàm mất mát tương phản thường. Trên bộ SpokenWOZ, khoảng cách về kết quả của các mô hình thu hẹp lại, và độ lệch chuẩn tăng đáng kể. Một lý do giải thích đó là các lượt của SpokenWOZ được thu thập bằng mô hình nhận dạng tiếng nói dựa trên các đoạn hội thoại người với người trong thực tế, do đó đặc trưng của bộ dữ liệu này bị ảnh hưởng bởi cả mô hình nhận dạng tiếng nói và các hiện tượng ngôn ngữ.

Embeddings	F ₁ score		Accuracy		Anisotropy		
	1-shot	5-shot	1-shot	5-shot	intra(↑)	inter(↓)	Δ (↑)
GloVe	19.47 ± 2.47	24.54 ± 2.45	26.07 ± 4.52	33.30 ± 4.19	0.653	0.642	0.010
BERT	21.93 ± 2.40	31.11 ± 2.56	28.33 ± 3.76	39.98 ± 3.56	0.711	0.761	-0.049
Sentence-BERT	23.48 ± 2.62	35.71 ± 2.94	33.03 ± 4.70	47.47 ± 3.60	0.440	0.404	0.036
GTR-T5	26.53 ± 2.29	41.10 ± 2.37	35.76 ± 4.00	52.73 ± 3.16	0.681	0.714	-0.033
OpenAI	28.67 ± 2.33	42.49 ± 2.54	39.98 ± 3.77	55.37 ± 3.24	0.496	0.468	0.029
DSE	27.53 ± 2.70	39.90 ± 3.08	35.93 ± 4.54	51.73 ± 3.41	0.633	0.608	0.026
SPACE-2	25.07 ± 2.06	38.31 ± 2.38	34.00 ± 3.91	48.45 ± 3.21	0.653	0.650	0.003
TOD-BERT	21.23 ± 2.03	32.28 ± 2.33	29.26 ± 3.99	41.71 ± 3.68	0.848	0.885	-0.038
DialoGPT	21.74 ± 2.10	32.01 ± 2.38	27.65 ± 3.47	41.05 ± 3.64	0.700	0.726	-0.026
SBD-BERT	19.09 ± 2.10	23.83 ± 2.22	25.80 ± 3.56	32.14 ± 3.62	0.651	0.596	0.055
D2F-Hard _{single}	34.64 ± 2.90	49.63 ± 2.87	42.77 ± 4.61	58.63 ± 3.27	0.526	0.424	0.103
D2F-Hard _{joint}	31.46 ± 2.61	46.89 ± 2.50	39.45 ± 4.22	56.43 ± 2.98	0.514	0.481	0.033
D2F _{single}	35.55 ± 3.51	49.75 ± 2.48	43.15 ± 5.24	59.93 ± 3.06	0.516	0.321	0.195
D2F _{joint}	33.19 ± 2.95	46.90 ± 2.66	41.22 ± 4.40	57.07 ± 2.92	0.545	0.429	0.116

Bảng 4.1: Đánh giá độ tương đồng trên tập SpokenWOZ.

4.1.1. Anisotropy

Các mô hình embedding D2F cho kết quả anisotropy tốt nhất cả trên cùng nhãn và giữa các nhãn, với kết quả gấp đôi so với phiên bản D2F-Hard. Giả thuyết các tác giả đưa ra là việc sử dụng hàm mất mát tương phản mềm, với nhiều thông tin ngữ nghĩa hơn về sự sắp xếp trong không gian biểu diễn của các embedding. Việc dựa vào ngữ nghĩa của action hướng mô hình tạo ra embedding được sắp xếp lại có ý nghĩa hơn.

4.1.2. NDCG

Kết quả trong bảng gồm trung bình và độ lệch chuẩn của 10 lần lấy lượt hội thoại ngẫu nhiên trên mỗi action. Các mô hình D2F đều cho kết quả vượt trội so với các mô hình baseline và D2F-Hard. Tuy nhiên, cũng trên SpokenWOZ, kết quả của tất cả embedding đều suy giảm so với bộ đánh giá hợp nhất.

4.2. Đánh giá kết quả trích xuất workflow

4.2.1. Chi tiết về cách đánh giá

Đặt $\mathcal{U}, \mathcal{A}$ lần lượt là tập các câu hội thoại và hành động tương ứng

Đặt $\alpha : \mathcal{U} \mapsto \mathcal{A}$ là ánh xạ (chưa biết) từ lượt hội thoại tới action tương ứng.

Đặt $d_i = (u_1, \dots, u_k)$ là một cuộc hội thoại với $u_j \in \mathcal{U}$, and $t_i = (\alpha(u_1), \dots, \alpha(u_k)) = (a_1, \dots, a_k)$ là sự chuyển đổi thành chuỗi hành động, hay còn gọi là quỹ đạo.

Với tập gồm m dialogs, $D = \{d_1, \dots, d_m\}$, và tập các quỹ đạo tương ứng $D^t = \{t_1, \dots, t_m\}$, bài toán ở đây là trích xuất các luồng hội thoại thường thấy bằng việc kết hợp tất cả quỹ đạo của D^t . Các luồng hội thoại phổ biến được biểu diễn bởi đồ thị chuyển trạng thái. $G_D = \langle A, E, w_A, w_E \rangle$ với A tập các hành động, E là cạnh một chiều biểu diễn hành động nào đến hành động nào. Trọng số cạnh $w_E(a_i, a_j) \in [0, 1]$ thể hiện mức độ thường a_i được nối tiếp bởi a_j , và trọng số $w_A(a_i) \in [0, 1]$ là tần suất xuất hiện của hành động A_j trong mỗi lĩnh vực.

4.2.2. Kết quả

Với mỗi miền của bộ SpokenWOZ, đồ thị tham chiếu từ dữ liệu G_D được xây dựng từ các đường đi D^t bằng nhãn hành động đúng, và đồ thị suy ra từ mô hình embedding $\hat{G}_D$. Mặc dù có trạng thái là các action cụ thể khiến đây không phải một quá trình markovian, đồ thị này có thể dễ dàng giải thích được. Đồng thời, đồ thị này liên kết chất lượng của từng cụm action tới chất lượng tổng thể của luồng.

Các mô hình tạo embedding cho câu đều có xu hướng đánh giá thấp độ phức tạp trên mỗi miền, với việc gom được ít cụm, dẫn đến workflow trích xuất được không mang ý nghĩa như workflow tham chiếu. Giả thuyết được đưa ra là các mô hình embedding hiện có thường gom cụm dựa trên ngữ nghĩa hoặc giữa hội thoại - ngữ cảnh của hội thoại. Trong các mô hình embedding được chọn làm baseline, DSE cho kết

Embeddings	Taxi (31)	Police (23)	Hospital (18)	Train (49)	Restaurant (59)	Attraction (45)	AVG.
D2F _{single}	9.68% (+3)	4.35% (-1)	11.11% (-2)	2.04% (+1)	5.08% (-3)	8.89% (+4)	6.86%
D2F _{joint}	3.23% (+1)	8.70% (-2)	5.56% (-1)	10.20% (-5)	23.73% (-14)	0.00% (0)	8.57%
D2F-Hard _{single}	12.90% (-4)	26.09% (-6)	16.67% (-3)	10.20% (-5)	10.17% (-6)	15.56% (+7)	15.26%
D2F-Hard _{joint}	0.00% (0)	8.70% (-2)	33.33% (-6)	20.41% (-10)	25.42% (-15)	13.33% (-6)	16.87%
DSE	32.26% (-10)	17.39% (-4)	33.33% (-6)	30.61% (-15)	27.12% (-16)	26.67% (-12)	27.90%
SPACE-2	32.26% (-10)	30.43% (-7)	38.89% (-7)	18.37% (-9)	32.20% (-19)	33.33% (-15)	30.91%
DialoGPT	32.26% (-10)	34.78% (-8)	22.22% (-4)	44.90% (-22)	64.41% (-38)	51.11% (-23)	41.61%
BERT	54.84% (-17)	30.43% (-7)	22.22% (-4)	46.94% (-23)	59.32% (-35)	42.22% (-19)	42.66%
OpenAI	54.84% (-17)	52.17% (-12)	55.56% (-10)	42.86% (-21)	49.15% (-29)	44.44% (-20)	49.84%
Sentence-BERT	48.39% (-15)	43.48% (-10)	55.56% (-10)	57.14% (-28)	50.85% (-30)	55.56% (-25)	51.83%
GTR-T5	41.94% (-13)	43.48% (-10)	66.67% (-12)	51.02% (-25)	61.02% (-36)	53.33% (-24)	52.91%
SBD-BERT	77.42% (-24)	43.48% (-10)	38.89% (-7)	71.43% (-35)	86.44% (-51)	86.67% (-39)	67.39%
TOD-BERT	74.19% (-23)	78.26% (-18)	55.56% (-10)	85.71% (-42)	83.05% (-49)	82.22% (-37)	76.50%

Bảng 4.2: So sánh kích thước của đồ thị tham chiếu và đồ thị suy ra được trên mỗi lĩnh vực của tập SpokenWOZ

quả tốt hơn rõ rệt so với các mô hình embedding (27,90% khác biệt trên tất cả các lĩnh vực) gợi ý mô hình embedding ngữ cảnh - hội thoại, nắm bắt tốt hơn chức năng của các lượt hội thoại. so với các mô hình embedding khác dựa trên sự tương đồng ngữ nghĩa. Các mô hình D2F cho những kết quả tốt nhất về độ phức tạp của đồ thị workflow trên tất cả các lĩnh vực, so với cả các mô hình D2F-Hard được huấn luyện với hàm mất mát tương phản thông thường và các mô hình embedding khác, với kết quả chênh lệch rõ rệt. (, lần lượt so với ... lần lượt của D2F-Hard single, D2F-Hard Joint và DSE)

Đồ thị sinh từ D2F đều cho kết quả tương đối ổn định trên các lĩnh vực khác nhau, mặc dù một số lĩnh vực có lượng dữ liệu rất nhỏ cùng lĩnh vực trong dữ liệu huấn luyện, như các lĩnh vực hospital và police. chỉ lần lượt chiếm 0,11% và 0,07%.

4.3. Nghiên cứu ablation

Bốn sự thay thế sau đã được và được đánh giá dựa trên các độ đo về độ tương đồng vector, bao gồm điểm F1 và anisotropy trên bộ dữ liệu

Thay thế ở phần encoder sử dụng BERT ban đầu bằng mô hình DSE - đã được tiền huấn luyện trên dữ liệu hội thoại hướng tác vụ. Kết quả cho thấy việc sử dụng kết quả cải thiện trên tất cả các phiên bản mô hình khác nhau.

Thay thế ở mô hình tạo nhãn, sử dụng all-mpnet-base-v2 là phiên bản mới hơn, thay cho all-mpnet-base-dot-v1. Sự thay thế này cho kết quả không tốt bằng, nhưng chênh lệch là chưa quá nhiều

Việc bỏ đầu tương phản khi đào tạo mô hình cũng cho kết quả kém hơn.

c		
DF2 Variation	F ₁ score	Δ Anisotropy ($\uparrow$)
D2F-Hard _{single}	67.82	0.332
* DSE Backbone	+2.66	+0.011
+ Self-Supervision	-7.41	-0.002
D2F-Hard _{joint}	66.22	0.230
* DSE Backbone	+1.97	+0.010
+ Self-Supervision	-6.01	-0.064
D2F _{single}	70.89	0.597
* DSE Backbone	+0.97	+0.012
* all-mpnet-base-v2 Label	-0.60	-0.038
+ Self-Supervision	-6.65	-0.189
– Contrastive Head	-1.13	-0.047
D2F _{joint}	70.94	0.451
* DSE Backbone	+0.65	+0.011
* all-mpnet-base-v2 Label	-0.34	-0.038
+ Self-Supervision	-8.06	-0.126
– Contrastive Head	-3.78	-0.073

Kết hợp hàm mất mát của phương pháp học tự giám sát như trong DSE cho kết quả suy giảm nhiều nhất (giảm 8,06% và 6,65% so với mô hình ban đầu về điểm F1)

KẾT LUẬN

Trình bày các kết quả chính đạt được, hạn chế và hướng phát triển trong tương lai.

4.4. Các kết quả chính của bài báo

Về phương pháp, nghiên cứu đã lần đầu tiên đưa ra phương pháp trong việc trích luồng công việc tự động dựa trên các đoạn hội thoại có sẵn mà không cần phải gán nhãn thủ công. Luồng trích xuất được bằng phương pháp này cho kết quả khá tốt về độ phức tạp của luồng công việc và chất lượng.

Về dữ liệu, bộ dữ liệu về hội thoại hướng tác vụ đã được tổng hợp và chuẩn hoá về đánh nhãn từ 20 bộ dữ liệu thành phần. Với hơn 300000 đoạn hội thoại và hơn 3 triệu lời hội thoại, đây là bộ dữ liệu lớn nhất về hội thoại hướng tác vụ.

Về phương pháp huấn luyện, bài báo đã ứng dụng học tương phản mềm dựa trên sự tương đồng về ngữ nghĩa giữa các nhãn về act hoặc slot, cho kết quả tốt hơn cho phương pháp học tương phản thông thường. Đồng thời, phương pháp này cũng cho kết quả vượt trội khi so với các mô hình embedding tổng quát được đào tạo trên bộ dữ liệu trên.

4.5. Hạn chế của nghiên cứu

Nghiên cứu này chỉ tập trung vào khám phá luồng công việc các đoạn hội thoại hướng tác vụ. Vì vậy, trong với các kiểu loại hội thoại khác, các phương pháp được đề cập về hàm mất mát mềm và trích xuất luồng có thể không cho kết quả như với hội thoại hướng tác vụ.

Về mô hình, mô hình BERT là sự lựa chọn còn đơn giản. Các kết quả mà đưa ra trong bài báo còn có thể được cải thiện tốt hơn khi sử dụng các mô hình nhiều tham số hơn. Đồng thời, việc sử dụng học có giám sát cũng khiến việc thích nghi trên các nhãn act và slots nằm ngoài dữ liệu huấn luyện.

Về dữ liệu, đây là bộ dữ liệu lớn nhất hiện có về hội thoại hướng tác vụ, tuy nhiên kích thước của bộ dữ liệu này còn khá nhỏ cho khâu tiền huấn luyện. Việc tạo ra những bộ dữ liệu hoàn toàn mới chỉ dành riêng cho hội thoại hướng tác vụ cũng đòi hỏi chi phí và thời gian rất lớn, đồng thời thiếu tính tổng quát hoá.

Các đánh giá trong bài báo về chất lượng của mô hình nhúng được thực hiện theo các tiêu chí thường thấy. Còn phần đánh giá trích xuất workflow, sử dụng độ đo là số nút của workflow trích xuất

được đã thể hiện sự phân biệt về kết quả giữa các mô hình nhúng, tuy nhiên chưa phản ánh hết thực tế. Một trường hợp có thể đặt ra là workflow trích xuất được có độ lớn tương đồng với, tuy nhiên các lượt hội thoại được gom vào cùng một cụm lại rất khác nhau. giữa kết quả thực sự. Và hiện tại, cũng chưa có một độ đo tiêu chuẩn nào cho việc đánh giá tương đồng giữa hai luồng công việc được trích xuất.

4.6. Các mối quan tâm về đạo đức

Bộ dữ liệu được ra trong nghiên cứu bao gồm nhiều bộ dữ liệu với giấy phép khác nhau và không tương thích với nhau. Bài báo đã đưa ra mã để tùy chỉnh các bộ dữ liệu thành phần để tạo bộ dữ liệu cuối. Tuy nhiên, một vấn đề đặt ra là có trường hợp bộ dữ liệu này không được sử dụng toàn bộ do sự xung đột giữa giấy phép của một số bộ dữ liệu thành phần và điều kiện người sử dụng. Việc đó khiến đóng góp của bộ dữ liệu sẽ bị giảm bớt.

Bộ dữ liệu này cũng tồn tại thiên kiến về giới tính, dẫn đến sự thiên kiến của mô hình khi đào tạo trên bộ dữ liệu này, thể hiện ở việc embedding có giả sử về việc người trao đổi trong hội thoại là nam hoặc nữ.

4.7. Hướng phát triển trong tương lai

Các kĩ thuật trích xuất workflow phức tạp hơn có thể được thử nghiệm trên những đoạn hội thoại phức tạp hơn.

Về phần encoder, có thể thay thế mô hình BERT bằng mô hình nhiều tham số hơn, như các biến thể của BERT với khả năng tốt hơn (RoBERTa, DeBERTa) hoặc cho hiệu năng tốt hơn như DistilBERT [1], ModernBERT [5].

Các mô hình embedding được đào tạo bằng phương pháp đề xuất và bộ dữ liệu có thể được áp dụng các bài toán khác trong hội thoại hướng tác vụ như truy vết trạng thái hội thoại (dialog state tracking), học chính sách (policy learning).

Về khâu đánh giá, đánh giá trên các đoạn hội thoại hướng tác vụ trên nhiều lĩnh vực cần được mở rộng để kiểm chứng sự hiệu quả của phương pháp được đề xuất. Về phương pháp đánh giá, các phương pháp đánh giá sự tương đồng giữa đồ thị hoặc sử dụng mô hình ngôn ngữ lớn có thể được thử nghiệm để đưa ra phương pháp đánh giá đồ thị luồng công việc sát với con người hơn.

Tài liệu tham khảo

- [1] Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter, 2020.
- [2] Coursera Staff. Chatbot vs. conversational ai: What’s the difference? *Coursera Articles*, 2024.
- [3] Sapien Editorial Team. The hidden costs of data labeling: Time, money, and effort. *Sapien AI Blog*, 2024.
- [4] VoxReality. Task-oriented dialogue systems: Bridging the gap between language and action. *VoxReality Blog*, 2023.
- [5] Benjamin Warner, Antoine Chaffin, Benjamin Clavié, Orion Weller, Oskar Hallström, Said Taghadouini, Alexis Gallagher, Raja Biswas, Faisal Ladhak, Tom Aarsen, Griffin Thomas Adams, Jeremy Howard, and Iacopo Poli. Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference. In Wanxiang Che, Joyce Nabende, Ekaterina Shutova, and Mohammad Taher Pilehvar, editors, *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2526–2547, Vienna, Austria, July 2025. Association for Computational Linguistics.