



BÁO CÁO CUỐI KÌ
MÔN HỌC: CÁC VẤN ĐỀ HIỆN ĐẠI CỦA
CÔNG NGHỆ THÔNG TIN

PAPERQA: TÁC NHÂN TRUY XUẤT TĂNG CƯỜNG TẠO SINH
CHO NGHIÊN CỨU KHOA HỌC

Giảng viên: TS. Nguyễn Đức Anh

Mã học phần: INT3507 7

Nhóm sinh viên: Bùi Đặng Đức Phong - 21020781
Trần Tuấn Nghĩa - 21020549
Đinh Văn Ninh - 21020362
Nguyễn Hải Long - 21020349

Phân chia công việc

STT	Họ và tên	Mã sinh viên	Đóng góp	Nhóm trưởng
1	Bùi Đăng Đức Phong	21020781	23.75%	
2	Trần Tuấn Nghĩa	21020549	23.75%	x
3	Đinh Văn Ninh	21020362	23.75%	
4	Nguyễn Hải Long	21020349	28.75%	

Chi tiết phân chia công việc:

- **Bùi Đăng Đức Phong:** nghiên cứu phần abstract, các điểm hạn chế của hệ thống paper-qa, đưa ra kết luận và làm slide.
- **Trần Tuấn Nghĩa:** chịu trách nhiệm phân chia công việc cho các thành viên, nghiên cứu phương pháp cốt lõi được sử dụng trong hệ thống paper-qa và nghiên cứu tập dữ liệu LitQA được sử dụng để đánh giá hệ thống.
- **Đinh Văn Ninh:** nghiên cứu về cách demo công cụ, chuẩn bị các bài báo liên quan và phù hợp để thực hiện các câu truy vấn thuận tiện nhất.
- **Nguyễn Hải Long:** nghiên cứu phần giới thiệu tổng quan về paper-qa, hoàn cảnh dẫn đến việc sử dụng paper-qa và nghiên cứu phần thực nghiệm.

Mục lục

1	GIỚI THIỆU BÀI BÁO VÀ BỐI CẢNH	3
1.1	Thông tin về bài báo	3
1.2	Bối cảnh	4
1.2.1	Thách thức	4
1.2.2	Đề xuất giải pháp	6
1.2.3	Giới thiệu PaperQA	6
2	PHÂN TÍCH BÀI BÁO	9
2.1	Phương pháp	9
2.1.1	PaperQA	9
2.1.2	Các công cụ	10
2.2	Tập dữ liệu LitQA	11
2.3	Thực nghiệm của tác giả	13
2.3.1	Chi tiết cài đặt	13
2.3.2	Kết quả	14
3	DEMO CÔNG CỤ	18
3.1	Các điều kiện môi trường cần chuẩn bị	18
3.2	Chạy code	19
4	KẾT LUẬN	21
5	PHỤ LỤC	22
5.1	Các thắc mắc được giải đáp bởi tác giả	22
5.2	Các câu hỏi phản biện trên lớp	24

Lời nói đầu

Báo cáo này cung cấp một cái nhìn tổng quan về bài báo **”PaperQA: Retrieval-Augmented Generative Agent for Scientific Research”**. Bài báo giới thiệu PaperQA, một hệ thống tạo ra tăng cường truy xuất (**Retrieval-Augmented Generation - RAG**) chuyên biệt được thiết kế để giải quyết những hạn chế của các Mô hình ngôn ngữ lớn (**Large Language Models - LLM**) truyền thống trong việc trả lời câu hỏi khoa học. Các mô hình LLMs mặc dù mạnh mẽ nhưng thường bị tình trạng ảo giác trong câu trả lời và thiếu khả năng diễn giải một cách rõ ràng. Điều này đã trở thành một hạn chế, cản trở việc áp dụng chúng trong các lĩnh vực yêu cầu có tính chính xác cao như học thuật, chăm sóc sức khỏe và nghiên cứu khoa học.

Để vượt qua những thách thức này, PaperQA tích hợp các cơ chế **truy xuất** với các khả năng **tạo sinh câu trả lời** để cung cấp các phản hồi chính xác, dựa trên bằng chứng và có thể truy xuất cho các truy vấn khoa học phức tạp. Bài báo cũng giới thiệu **LitQA** là một chuẩn mực (**benchmark**) để đánh giá các hệ thống trả lời câu hỏi trên các bài báo khoa học. Dựa trên LitQA, bài báo đánh giá được chất lượng vượt trội của PaperQA so với các mô hình QA khác hiện có.

Những đóng góp chính của bài báo bao gồm:

- PaperQA có thể giải quyết được những vấn đề lớn đối với các mô hình LLMs hiện tại là Hallucination - Ảo giác thông tin và Uninterpretability - Khó diễn giải
- Minh chứng về khả năng của PaperQA trong việc đạt được độ chính xác ở cấp độ con người khi xử lý các câu hỏi khoa học.
- Tỷ lệ **ảo giác 0%** đối với các trích dẫn.

- Tính linh hoạt của PaperQA khi hoạt động độc lập với các LLM cụ thể như GPT-3.5, GPT-4 và Claude-2.

Bằng cách cung cấp mã nguồn mở cho cộng đồng, PaperQA mở đường cho những tiến bộ trong tương lai của các hệ thống **Retrieval-Augmented Generation**, đặc biệt là đối với các ứng dụng đòi hỏi **độ tin cậy** và **tính minh bạch cao**.

Bài báo nghiên cứu đóng góp đáng kể vào sự phát triển của các hệ thống AI có thể hỗ trợ các nhà nghiên cứu bằng cách giảm thời gian tìm kiếm và tổng hợp thông tin trong khi tăng độ chính xác của các phát hiện của họ. Báo cáo này nhằm mục đích khám phá **Bối cảnh bài báo**, **Giải pháp của nhóm tác giả**, **Quá trình thực hiện** và **Kết quả quá trình thực hiện** của PaperQA, cùng với việc so sánh với các hệ thống dựa trên RAG hiện có.

Chương 1

GIỚI THIỆU BÀI BÁO VÀ BỐI CẢNH

1.1 Thông tin về bài báo

Bài báo “*PaperQA: Retrieval-Augmented Generative Agent for Scientific Research*” được đăng tải lần đầu vào ngày 08 tháng 12 năm 2023 với version 1 và được chỉnh sửa vào ngày 14 tháng 12 năm 2023 với version 2 trên tạp chí *Arxiv* tại địa chỉ <https://arxiv.org/abs/2312.07559>.

Trong bài báo này, nhóm tác giả giới thiệu PaperQA là một *Framework Question & Answer* được phát triển cho mục đích chính là trích xuất các thông tin liên quan đến câu hỏi (*Question*) để đưa vào câu trả lời (*Answer*) từ các tài liệu khoa học. PaperQA được phát triển nhằm giải quyết một số vấn đề quan trọng trong việc đọc hiểu các tài liệu khoa học, ví dụ như khối lượng văn bản lớn, tính chuyên môn hoá về mặt kỹ thuật và nhu cầu cần xác định, trích xuất được các thông tin một cách chính xác từ bài báo. Thông qua việc sử dụng các mô hình ngôn ngữ lớn (*Large Language Model – LLM*) và các hệ thống dựa trên truy xuất (*Retrieval-Based System*), PaperQA trực tiếp giúp giải quyết các vấn đề trên bằng cách thực hiện truy vấn trực tiếp thông tin từ bài báo, nâng cao tính chính xác của câu trả lời đồng thời bổ sung ngữ cảnh vào câu trả lời.

1.2 Bối cảnh

1.2.1 Thách thức

Trong bài báo, các tác giả đã mô tả chi tiết các thách thức chính của các mô hình ngôn ngữ lớn (LLMs), đặc biệt liên quan đến hai vấn đề lớn: *hallucination* (ảo tưởng thông tin) và *uninterpretability* (khó diễn giải).

Hallucination (Ảo tưởng thông tin)

Vấn đề ảo tưởng thông tin xảy ra khi một mô hình LLM sinh ra câu trả lời chứa thông tin không chính xác, không tồn tại, hoặc thậm chí là bịa đặt thông tin. Trong lĩnh vực nghiên cứu khoa học, hallucination có thể tạo ra các trích dẫn cho các bài báo học thuật không tồn tại, hoặc bịa ra các lý thuyết, kết luận mà không đưa ra được nguồn gốc thông tin lấy từ đâu.

Nguyên nhân của Hallucination:

- Tính xác suất của các mô hình LLM: Do LLM được huấn luyện để dự đoán từ/chuỗi từ tiếp theo dựa trên các mẫu trong dữ liệu mà nó được huấn luyện. Do đó, trong trường hợp không có/có nhưng thiếu ngữ cảnh và thông tin cần thiết, các mô hình LLM vẫn có thể dự đoán câu trả lời. Điều này dẫn tới câu trả lời có vẻ hợp lý nhưng thực tế thì không chính xác hoặc không tồn tại thông tin mà câu trả lời đưa ra.
- Dữ liệu huấn luyện mô hình không đầy đủ: LLM dựa trên dữ liệu được huấn luyện để đưa ra câu trả lời. Do đó, nếu dữ liệu huấn luyện không phù hợp hoặc không bao phủ đến lĩnh vực cụ thể, các mô hình LLM có thể tạo ra thông tin không chính xác hoặc bịa đặt do chưa từng được huấn luyện.
- Thiếu cơ chế truy xuất thông tin: Nhiều mô hình LLM cần phải được truy cập vào cơ sở dữ liệu hoặc tài liệu bên ngoài theo thời gian thực để có thể đưa ra câu trả lời chính xác nhất. Do đó, trong trường hợp không có các quyền này, LLM chỉ có thể dựa vào thông tin được huấn luyện trước đó dẫn tới vấn đề ảo giác thông tin khi trả lời các câu hỏi với các topic mới nổi hoặc quá chuyên sâu.

Tác động của Hallucination

- Mất lòng tin từ phía người dùng: Trong trường hợp LLM đưa ra quá nhiều thông tin không đúng, đủ, chính xác để khiến người dùng không còn tin tưởng sử dụng các mô hình LLM khác.
- Rủi ro trong các lĩnh vực khoa học: Trong các lĩnh vực yêu cầu tính chính xác cao, gần như tuyệt đối như y học, câu trả lời sai từ LLM có thể gây ra hậu quả nghiêm trọng như gây ra sự sai sót trong các quyết định y tế.

Ví dụ: Một nhà nghiên cứu y sinh hỏi LLM, "Những phát hiện mới nhất về điều trị ung thư là gì?" LLM tạo ra phản hồi trích dẫn một bài báo không tồn tại từ "Tạp chí Ung thư", trong đó bao gồm các kết luận không được chứng minh về một phương pháp điều trị.

Uninterpretability (Khó diễn giải)

Đối với người dùng, các mô hình LLM thường được coi là "black-boxes" – hộp đen bởi quá trình suy luận để đưa ra câu trả lời thường không rõ ràng. Người dùng khó có thể hiểu được cách thức, nguyên nhân tại sao lại nhận được câu trả lời như thế từ LLM.

Nguyên nhân của Uninterpretability:

- Thiếu cơ chế giải thích: Phần lớn các mô hình LLM không cung cấp, không đưa ra được nguyên nhân câu trả lời được hình thành hay cách suy luận để đưa ra câu trả lời đó. Điều này dẫn tới khó xác minh tính chính xác hoặc logic phía sau các câu trả lời.
- Không có minh chứng rõ ràng: Câu trả lời từ LLM thường không có trích dẫn nguồn hoặc giải thích quá trình tạo ra câu trả lời.
- Mơ hồ trong các truy vấn phức tạp: Khi đối mặt với các câu hỏi nhiều mặt hoặc cụ thể về lĩnh vực, các LLM có thể đơn giản hóa quá mức hoặc đưa ra các câu trả lời mơ hồ, thiếu chiều sâu cần thiết.

Tác động của Uninterpretability:

- Người dùng dễ nhầm lẫn: Do không thể hoặc khó có thể xác nhận tính chính xác của câu trả lời do không hiểu được logic của mô hình, người dùng không thể phân biệt được câu trả lời là chính xác hay bịa đặt.

- Khó áp dụng trong các lĩnh vực có tính rủi ro cao: Các mô hình không thể diễn giải ít có khả năng được áp dụng trong các lĩnh vực quan trọng như chăm sóc sức khỏe, luật pháp hoặc nghiên cứu học thuật, bởi tính minh bạch là điều cần thiết trong các lĩnh vực này.

1.2.2 Đề xuất giải pháp

Tác nhân tăng cường truy xuất (Retrieval Augmented Generation - RAG) được sử dụng để giải quyết một số hạn chế chính của Mô hình ngôn ngữ lớn (LLM) bằng cách tích hợp truy xuất kiến thức bên ngoài vào quy trình tạo câu trả lời.

Những hạn chế được xử lý bởi RAG

Giảm thiểu Hallucination: LLM tạo ra câu trả lời dựa trên các mẫu trong dữ liệu huấn luyện. Khi mô hình gặp phải các câu hỏi về chủ đề ngách hoặc ngoài phạm vi, nó có thể “ảo tưởng” (bịa đặt) thông tin vì nó không có quyền truy cập thời gian thực vào dữ liệu cập nhật hoặc cụ thể.

→ RAG lấy thông tin từ các nguồn bên ngoài đáng tin cậy (ví dụ: các bài báo khoa học, cơ sở dữ liệu hoặc cơ sở kiến thức) và sử dụng bằng chứng này để tạo ra câu trả lời. Điều này làm giảm đáng kể khả năng xảy ra phản ứng ảo giác bằng cách dựa đầu ra vào dữ liệu có thể xác minh được.

Cung cấp câu trả lời với thông tin mới nhất: LLM được đào tạo trên các tập dữ liệu tĩnh trở nên lỗi thời khi có nghiên cứu hoặc thông tin mới.

→ RAG truy cập các nguồn dữ liệu động bên ngoài (ví dụ: PubMed, ArXiv hoặc cơ sở kiến thức tùy chỉnh). Điều này cho phép mô hình truy xuất thông tin mới nhất và cung cấp câu trả lời dựa trên nội dung cập nhật theo thời gian thực.

1.2.3 Giới thiệu PaperQA

PaperQA được giới thiệu là một mô hình RAG được chuyên môn hoá đặc biệt trong việc truy vấn các tài liệu nghiên cứu, khoa học. Bằng việc kết hợp giữa việc truy xuất thông tin và tổng hợp thông tin, câu trả lời từ mô hình này đảm bảo việc thông tin đã được đánh giá và chọn lọc những phần phù hợp nhất.

Feature	Standard LLMs	RAG Systems
Source Reliability	Phụ thuộc vào dữ liệu được huấn luyện	Phụ thuộc vào dữ liệu từ các nguồn linh hoạt
Hallucination Rate	Cao (40-60% trong trích dẫn thông tin)	Thấp (0% với PaperQA)
Transparency	Không hỗ trợ trích dẫn	Cung cấp tài liệu tham khảo và truy xuất nguồn gốc
Knowledge Updates	Yêu cầu phải huấn luyện lại mô hình	Tự động cập nhật với các nguồn mới
Context Awareness	Có giới hạn	Truy xuất ngữ cảnh từ tài liệu

Bảng 1.1: So sánh RAG và Standard LLMs

Core Functions:

- *Truy xuất thông tin:* PaperQA quét qua toàn bộ bài báo khoa học thay vì chỉ qua phần tóm tắt hay tổng kết của bài báo. Điều này giúp truy cập vào toàn bộ các thông tin trong bài báo, từ đó giúp nâng cao chất lượng câu trả lời.
- *Đánh giá mức độ liên quan:* PaperQA đánh giá mức độ liên quan của từng nguồn và đoạn văn để lọc ra những thông tin không cần thiết hoặc sai lệch. Điều này làm giảm ảo giác và đảm bảo rằng chỉ những dữ liệu có liên quan cao mới hỗ trợ cho câu trả lời cuối cùng.
- *Tổng hợp câu trả lời:* Bằng cách sử dụng mô hình RAG, PaperQA tổng hợp câu trả lời bằng cách tích hợp thông tin có liên quan, được chọn lọc, giúp tạo ra các phản hồi vừa chính xác vừa có thể theo dõi được.

Tính năng	PaperQA	Các hệ thống RAG khác
Chuyên môn hóa	Được thiết kế để xử lý toàn văn các bài báo khoa học, đảm bảo độ sâu và chính xác.	Ứng dụng đa mục đích, thường không được tối ưu hóa cho các lĩnh vực kỹ thuật hoặc khoa học.
Độ chính xác trong trích dẫn	Đạt tỷ lệ ảo tưởng trích dẫn 0% trong các bài kiểm tra.	Tỷ lệ lỗi trích dẫn 40-60%, dẫn đến thông tin không được xác minh hoặc trích dẫn giả mạo.
Độc lập với LLMs	Hoạt động linh hoạt với nhiều LLMs (ví dụ: Claude-2, GPT-3.5, GPT-4).	Thường tích hợp chặt chẽ với các LLM cụ thể, hạn chế khả năng thích nghi.
Khả năng truy xuất toàn văn	Có thể truy xuất và xử lý toàn văn các bài báo để cung cấp câu trả lời toàn diện.	Chủ yếu hoạt động trên dữ liệu metadata, tóm tắt hoặc văn bản ngắn, hạn chế độ chi tiết.
Hiệu suất trên benchmark	Vượt trội trên LitQA (một benchmark cho QA dựa trên tài liệu khoa học toàn văn).	Thiếu các bài kiểm tra nghiêm ngặt, tập trung vào các bộ dữ liệu hoặc nhiệm vụ đơn giản hơn.
Ra quyết định động	Tích hợp cơ chế lặp lại để cải thiện độ chính xác và độ rõ ràng của câu trả lời.	Không có cơ chế lặp lại, cung cấp các phản hồi tĩnh.
Minh bạch và độ tin cậy	Cung cấp câu trả lời có thể truy vết với liên kết rõ ràng đến nguồn tài liệu gốc.	Minh bạch thấp hơn, khó truy vết nguồn gốc dữ liệu.
Cập nhật lĩnh vực kiến thức	Dễ dàng cập nhật bằng cách thêm các bài báo khoa học mới vào kho tài liệu.	Hạn chế mở rộng; cập nhật yêu cầu đào tạo lại mô hình.
Mã nguồn mở	Mã nguồn mở cho mục đích học thuật và nghiên cứu, khuyến khích phát triển thêm.	Mã nguồn đóng và độc quyền, hạn chế khả năng tùy chỉnh.
Trường hợp sử dụng	Được thiết kế đặc biệt cho nghiên cứu khoa học và ứng dụng học thuật.	Được sử dụng trong các ngành như hỗ trợ khách hàng, marketing.

Bảng 1.2: So sánh PaperQA và các hệ thống RAG khác

Chương 2

PHÂN TÍCH BÀI BÁO

2.1 Phương pháp

2.1.1 PaperQA


PaperQA là một hệ thống, có khả năng tìm kiếm các bài báo khoa học liên quan từ các cơ sở dữ liệu trực tuyến như Arxiv¹ hay Pubmed², sau đó tiến hành thu thập từ những bài báo đó các đoạn văn liên quan và cuối cùng tổng hợp lại để sinh ra câu trả lời đầy đủ, tin cậy và có khả năng đúng cao nhất.

So với các hệ thống RAG truyền thống thì PaperQA có 4 điểm mới quan trọng

- **Thứ nhất:** Các thành phần của một hệ thống RAG được tách biệt thành các công cụ và hoạt động một cách độc lập với nhau, điều này cho phép PaperQA có thể sử dụng một công cụ nhiều lần nếu cảm thấy chưa hài lòng với kết quả của công cụ ấy mà không cần chạy qua toàn bộ các công cụ khác, điều này giúp giảm tải chi phí và thời gian.
- **Thứ hai:** Hệ thống PaperQA sử dụng cơ chế *map - reduce*, *map* có vai trò tập trung các đoạn văn mà hệ thống tìm được, *reduce* thì sẽ đảm nhiệm việc làm rõ cụ thể trong các đoạn văn đó thì những thông tin nào sẽ giúp ích cho việc trả lời câu hỏi. Cơ chế này sẽ giúp tăng cường số lượng thông tin truy xuất được từ các cơ sở dữ liệu online, đồng thời tổng hợp lại được các thông tin quan trọng nhất.

¹<https://arxiv.org/>

²<https://pubmed.ncbi.nlm.nih.gov/>



Hình 2.1: Sơ đồ luồng hoạt động

- **Thứ ba:** PaperQA có khả năng tính toán độ liên quan và cung cấp một số điểm thể hiện độ liên quan giữa câu hỏi đầu vào với từng đoạn văn tìm được, sau đó các đoạn văn được sắp xếp theo thứ tự giảm dần độ liên quan với câu hỏi, từ đó sẽ chọn ra các đoạn văn mà khả năng cao sẽ phục vụ tốt cho việc trả lời câu hỏi.
- **Thứ tư:** Cuối cùng, PaperQA có thể tìm ra các kiến thức tiềm ẩn của một mô hình ngôn ngữ lớn để kiểm tra xem mô hình đó vốn đã biết những gì về câu hỏi, sau đó hệ thống sẽ tổng hợp các thông tin này đưa vào thư viện prompt của mô hình ngôn ngữ lớn để tổng hợp và đưa ra câu trả lời đúng nhất.

2.1.2 Các công cụ

PaperQA sử dụng 3 công cụ **Search**, **Gather Evidence** và **Answer Question**; cùng với 3 thực thể của một mô hình ngôn ngữ lớn là **summary LLM**, **ask LLM** và **answer LLM**.

Search: Công cụ này sẽ nhận thông tin về câu hỏi và các từ khóa quan trọng trong câu hỏi, sau đó sẽ tiến hành tìm kiếm các bài báo khoa học có chứa các từ khóa ấy hoặc có mốc thời gian liên quan đến mốc thời gian được nhắc tới trong câu hỏi, tiếp theo công cụ sẽ chọn ra K bài báo để chuyển sang công cụ tiếp theo.

Gather Evidence: Từ các bài báo tìm được ở công cụ trước, *gather evidence* sẽ phân tích nội dung của các bài báo, chia nhỏ nội dung thành các đoạn văn nhỏ với độ dài khoảng 4000 ký tự và mã hóa tất cả các đoạn văn đó dưới dạng véc-tơ sử dụng mô hình

text-embedding-ada-002 [1]. Công cụ này cũng sẽ mã hóa chính câu hỏi đầu vào thành một véc-tơ, sau đó tính toán độ liên quan giữa câu hỏi với từng đoạn văn một bằng công thức *Maximal Marginal Relevance* [2], công thức này sẽ cân bằng giữa 2 yếu tố là độ liên quan và độ đa dạng, nó sẽ cố gắng chọn ra các đoạn văn liên quan tới câu hỏi nhưng sẽ loại đi các đoạn văn có nội dung trùng lặp với các đoạn văn đã được chọn để đảm bảo sự đa dạng về nội dung trong các đoạn văn được chọn. Các đoạn văn sau đó được xử lý bởi thực thể *summary LLM* để tóm tắt đoạn văn, lọc ra các ý chính. Sau đó công cụ sẽ sắp xếp các đoạn văn theo thứ tự giảm dần số điểm liên quan và chọn ra K đoạn văn có số điểm cao nhất.

Answer question: Sau khi có được các đoạn văn từ công cụ *gather evidence*, công cụ này sẽ đưa chúng vào *context library* để làm cơ sở cho việc trả lời câu hỏi. Ngoài ra, công cụ này sẽ nhận vào câu hỏi của người dùng và sử dụng một mô hình ngôn ngữ lớn đã được huấn luyện để tìm hiểu xem trước khi tiếp cận với các kiến thức mới từ các đoạn văn tìm được từ công cụ trước thì mô hình đó đã biết những gì về câu hỏi này, đây sẽ là các kiến thức nền tảng có sẵn để trả lời câu hỏi và được tổng hợp vào *context library* để phục vụ cho việc trả lời câu hỏi. Sau đó, công cụ này sẽ sinh ra một câu trả lời và đưa cho tác nhân kiểm duyệt, nếu câu trả lời được cho là phù hợp thì sẽ trả về cho người dùng, còn không thì quá trình thu thập bằng chứng và trả lời câu hỏi sẽ được tiếp tục.

2.2 Tập dữ liệu LitQA

Các tiêu chuẩn đánh giá hiện tại cho việc trả lời câu hỏi khoa học chủ yếu đánh giá khả năng của AI trong việc trình bày thông tin đã được biết đến hoặc trả lời câu hỏi trong một ngữ cảnh cụ thể. Chúng chưa đủ để đánh giá khả năng trả lời câu hỏi của AI dựa trên những thông tin được truy xuất. Nhóm tác giả giới thiệu bộ dữ liệu LitQA cho việc đánh giá PaperQA. Các câu hỏi trong LitQA có nguồn gốc từ các tài liệu gần đây (sau tháng 9 năm 2021) nhằm đảm bảo chúng không nằm trong dữ liệu huấn luyện của các mô hình ngôn ngữ. LitQA được thiết kế để khó hoặc không thể trả lời nếu không truy xuất bài báo có liên quan. Do đó, LitQA có thể đánh giá được khả năng thu thập thông tin cần thiết và khả năng đưa ra câu trả lời chính xác dựa trên những thông tin đó.

Mô tả tập dữ liệu: Tập dữ liệu LitQA gồm 50 câu hỏi trắc nghiệm, được các chuyên

ID	Question	Answers	Difficulty
7	Has anyone performed a base editing screen against splice sites in CD33 before?	Yes No	Easy
32	How diffuse are the laminar patterns of the axonal terminations of lower Layer 5/Layer 6 intratelencephalic neurons compared to Layer 2-4 intratelencephalic neurons in mouse cortex?	More diffuse About the same Less diffuse	Medium
21	Which of these glycoRNAs does NOT show an increase in M0 macrophages upon stimulation with LPS: U1, U35a, Y5 or U8?	U8 U1 U35a Y5	Hard

Bảng 2.1: Ví dụ về bộ dữ liệu LitQA

gia tập hợp. Tất cả các câu hỏi đều thuộc lĩnh vực y sinh học. Có 5 câu hỏi trả lời Có hoặc Không, 6 câu hỏi với 3 đáp án, 23 câu hỏi với 4 đáp án, 10 câu hỏi có 5 đáp án, 4 câu hỏi có 6 đáp án và 2 câu hỏi có 7 đáp án. Bảng 1 trình bày một số ví dụ về câu hỏi với câu trả lời đúng được in đậm.

Thu thập dữ liệu: Tất cả các câu hỏi được viết và xem xét bởi các nhà nghiên cứu thuộc lĩnh vực khoa học tự nhiên và y sinh học. Các câu hỏi được tổng hợp bằng cách: chọn một bài báo được xuất bản sau tháng 9 năm 2021 rồi thiết kế một câu hỏi đề cập đến một phát hiện mới của bài báo nhưng không được trình bày trong phần tóm tắt của bài báo đó. Mọi câu hỏi đều được tạo ra các câu trả lời gây nhiễu bởi chính người viết câu hỏi hoặc sử dụng LLM để cung cấp câu trả lời cho câu hỏi đã cho. Nhóm tác giả chỉ thu thập câu hỏi từ các bài báo được xuất bản sau thời điểm cắt dữ liệu của GPT-3.5/4 vào tháng 9 năm 2021 để đảm bảo rằng các câu hỏi không thể được trả lời một cách đáng tin cậy nhờ việc sử dụng kiến thức tiềm ẩn của GPT-4. Mỗi câu hỏi sau đó được ít nhất một đồng tác giả khác xem xét độc lập.

Hiệu suất của con người: Nhóm tác giả đã sử dụng 5 nhà nghiên cứu y sinh học có bằng đại học trở lên cho việc giải quyết LitQA. Các nhà nghiên cứu được tham gia trả lời 50 câu hỏi với ba phút cho mỗi câu hỏi (tổng cộng 2,5 giờ để trả lời tất cả các câu hỏi). Họ được cung cấp quyền truy cập internet và cần chỉ rõ bài báo sử dụng để chọn câu trả lời tương ứng. Ngoài ra, họ được hướng dẫn trả lời không chắc chắn nếu không tìm thấy câu trả lời cho một câu hỏi nhất định.

2.3 Thực nghiệm của tác giả

Thực nghiệm được tiến hành trên tập dữ liệu LitQA đã được giới thiệu ở phần trên. Mục tiêu của tác giả là:

- So sánh PaperQA với các sản phẩm thương mại hiện có.
- Chứng minh từng thành phần trong PaperQA đều có vai trò quan trọng.
- Kiểm tra độ ảo giác của mô hình.

2.3.1 Chi tiết cài đặt

Trong thực nghiệm, 4 mô hình ngôn ngữ lớn (LLM) trong paperQA được sử dụng với các cài đặt:

- Agent LLM: GPT-4 (OpenAIFunctions Agent) với nhiệt độ 0,5.
- Summary LLM: GPT-3.5 với temperature 0,2.
- Answer LLM: GPT-4 với temperature 0,5.
- Ask LLM: GPT-4 với temperature 0,5.

Trong đó: Temperature là một tham số điều chỉnh mức độ ngẫu nhiên trong câu trả lời mà mô hình tạo ra. Nó ảnh hưởng đến cách mô hình lựa chọn các từ tiếp theo trong một câu, từ đó ảnh hưởng đến sự sáng tạo hoặc tính nhất quán của câu trả lời.³

Các bước để thực nghiệm trên PaperQA được tiến hành như sau:

- Nhận câu hỏi từ người dùng (Input Query)
 - Hệ thống bắt đầu bằng việc nhận câu hỏi từ người dùng và truyền vào **Agent LLM** (GPT-4), là mô hình trung tâm điều phối toàn bộ quy trình.
- Tìm kiếm tài liệu (Search)
 - Hệ thống sử dụng các từ khóa và mốc thời gian từ câu hỏi để tìm kiếm tài liệu liên quan.

³<https://www.hopsworke.ai/dictionary/llm-temperature>

- Sử dụng Google Scholar và các API công khai (Arxiv, PMC, OpenAccess, PubMed) để thu thập tối đa **top 5 bài báo** có thể truy cập.
- Kết quả của bước này là một tập hợp các tài liệu liên quan chứa thông tin có khả năng trả lời câu hỏi.
- Thu thập bằng chứng (Gather Evidence)
 - **Embedding**: Câu hỏi và từng đoạn văn trong các tài liệu được chuyển đổi thành vector, giúp tính toán độ tương đồng giữa câu hỏi và nội dung tài liệu.
 - **MMR (Maximal Marginal Relevance)**: Áp dụng thuật toán này để lọc và chọn các đoạn văn bản có mức độ liên quan cao nhất từ các tài liệu, đồng thời đảm bảo tính đa dạng của thông tin.
 - **Summary LLM (GPT-3.5)** đánh giá và gán điểm mức độ liên quan cho từng đoạn văn bản, sau đó chọn ra **20 đoạn** có độ liên quan cao nhất để xem xét ở mỗi vòng thu thập bằng chứng.
- Trả lời câu hỏi (Answer Question)
 - **Ask LLM (GPT-4)** kiểm tra xem hệ thống có thông tin nội bộ nào liên quan đến câu hỏi không.
 - **Answer LLM (GPT-4)** dựa vào các đoạn bằng chứng từ bước *Gather Evidence* để đề xuất một câu trả lời cho câu hỏi.
 - **Agent LLM** sẽ kiểm tra số lượng ngữ cảnh có liên quan (tối đa **8 đoạn ngữ cảnh**) và quyết định xem có đủ bằng chứng để đưa ra câu trả lời cuối cùng hay cần tiếp tục thu thập thêm.

2.3.2 Kết quả

Các mô hình được đánh giá trên 50 câu trong bộ LitQA và dựa trên ba tiêu chí chính: số lượng câu trả lời chính xác (Correct), không chính xác (Incorrect), và không chắc chắn (Unsure). Ngoài ra, bảng còn đưa ra hai chỉ số là: Độ chính xác tổng thể (*Accuracy*) và Độ chính xác khi chắc chắn (*Precision*). Ở đây nhóm em đã liên hệ với tác giả để hỏi về các chỉ số. Đầu tiên là sample. Thì sample chính là số lần mà tác giả thực hiện đánh giá

Model	Samples	Response			Score	
		Correct	Incorrect	Unsure	Accuracy ($\frac{\text{Correct}}{\text{All}}$)	Precision ($\frac{\text{Correct}}{\text{Sure}}$)
Random	100	10.2	29.5	10.3	20.4%	25.7%
Human	5	33.4	4.6	12.0	66.8%	87.9%
Claude-2	3	20.3	26.3	3.3	40.6%	43.6%
GPT-4	3	16.7	16.3	17.0	33.4%	50.6%
AutoGPT	3	20.7	7.3	22.0	41.4%	73.9%
Elicit	1	12.0	16.0	22.0	24.0%	42.9%
Scite	1	12.0	21.0	17.0	24.0%	36.4%
Perplexity	1	9.0	10.0	31.0	18.0%	47.4%
Perplexity (Co-pilot)	1	29.0	10.0	12.0	58.0%	74.4%
PaperQA	4	34.8	4.8	10.5	69.5%	87.9%

Bảng 2.2: So sánh PaperQA với các phương pháp hiện có

trên các mô hình. Nhóm cũng có thắc mắc là số lần thực hiện không bằng nhau như vậy thì liệu có đánh giá công bằng trên các mô hình thì tác giả có lý giải là các kết quả qua các lần đánh giá của các mô hình đều khá tương đồng nhau nên cũng không ảnh hưởng quá nhiều đến độ công bằng và tác giả cũng lý giải là do chi phí thực hiện đánh giá cũng khá đắt đỏ nên mới thực hiện số lần đánh giá khác nhau như vậy.

Nhận xét của nhóm là nhìn vào bảng có thể thấy chỉ số về accuracy và precision đều vượt trội so với các mô hình hiện có. Và đặc biệt là PaperQA có độ chính xác ngang con người (Human). Tuy nhiên do số lần thực hiện không giống nhau và cũng không đảm bảo là các mô hình được so sánh liệu nó có chuyên về các vấn đề học thuật như PaperQA đang giải quyết không nên là các con số mà tác giả đưa giả có thể không được khách quan nhất.

Tiếp theo tác giả đánh giá mô hình qua khả năng thích ứng bằng các lọc bỏ một số thành phần của PaperQA.

Model		Correct	Incorrect	Unsure
Answer	Summary			
Claude-2	GPT-3.5	32.5	7.0	10.5
Claude-2	GPT-4	26.5	9.0	14.5
GPT-4	GPT-3.5	33.5	5.0	11.5
GPT-4	GPT-4	31.5	7.0	11.5

Bảng 2.3: Thay thế các phần answer và summary bởi các mô hình khác nhau

Nhìn vào bảng 2.2 ta có thể thấy sử dụng GPT-4 làm mô hình trả lời (answer LLM) cho kết quả nhìn hơn Claude-2 một chút.

Bảng 2.3 là kết quả khi bỏ đi từng bộ phận của PaperQA, ta có thể thấy độ chính xác

Ablation	Correct	Incorrect	Unsure
PaperQA	33.5	5.0	11.5
No summary LLM	29.0	10.0	11.0
Single citation	27.0	10.0	13.0
No ask LLM	23.0	14.0	13.0
No search	23.0	7.0	20.0
Vanilla RAG	22.0	6.0	22.0
Semantic Scholar	21.0	4.0	25.0
No MC options	18.0	6.0	26.0

Bảng 2.4: Bỏ đi từng bộ phận của PaperQA

giảm dần, đặc biệt là khi bỏ các câu hỏi trắc nghiệm có nhiều lựa chọn. Ở đây tác giả có lý giải rằng khi loại bỏ tùy chọn câu hỏi trắc nghiệm (MC options) và sử dụng Semantic Scholar thay vì Google Scholar, hiệu suất giảm mạnh. Điều này là do các câu hỏi dạng trắc nghiệm dễ hơn và mô hình có thể tìm từ khóa từ các đáp án có sẵn. Loại bỏ kiến thức tiềm ẩn của LLM (no ask LLM) cũng làm giảm hiệu suất, mặc dù các câu hỏi đều có dữ liệu sau ngày cắt đào tạo. Điều này cho thấy kiến thức tiềm ẩn của LLM giúp mô hình chọn lựa dẫn chứng tốt nhất.

Tiếp theo tác giả thực nghiệm độ ảo giác của PaperQA.

LLM	Valid (%)	Hallucinated (%)			N
		Full Hallucination	Citation Inaccuracy	Context Irrelevance	
GPT-3.5	52.50%	33.75%	12.50%	1.25%	80
GPT-4	60.78%	29.41%	3.92%	5.88%	51
Claude-2	39.71%	42.65%	4.41%	13.24%	68
PaperQA	100%	0%	0%	0%*	237

Bảng 2.5: So sánh độ ảo giác PaperQA với các mô hình

Ở đây N là iếm của mỗi LLM được tính dựa trên số lượng và độ chính xác của các trích dẫn mà mô hình tạo ra (ký hiệu là "N citations"). Có 3 tiêu chí để đánh giá là ảo giác hoàn toàn, trích dẫn không chính xác, ngữ cảnh không chính xác. Nhìn vào ta có thể thấy PaperQA đặt độ chính xác tuyệt đối, không hề xảy ra ảo giác.

Tiếp theo tác giả đánh giá PaperQA trên tiêu chuẩn QA Benchmarks

Các bộ dữ liệu đánh giá:

- PubMedQblind: Phiên bản của PubMedQA với ngữ cảnh bị ẩn đi, chỉ bao gồm các câu hỏi có/không (loại bỏ câu trả lời "có thể").

Method	MedQA-USMLE	BioASQ	PubMedQA _{blind}
GPT-4	67.0	84.0	57.9
GPT-4 + PaperQA	63.0	87.0	86.3
AutoGPT	54.0	73.0	56.8
AutoGPT + Post reasoning	56.0	75.0	61.3
PaperQA	68.0	89.0	86.3
PaperQA + Post reasoning	69.0	91.0	85.0

Bảng 2.6: So sánh hiệu suất của PaperQA qua các bộ dữ liệu MedQA-USMLE, BioASQ, and PubMedQA_{blind}.

- MedQA: Bộ câu hỏi nhiều lựa chọn từ kỳ thi y khoa của Hoa Kỳ, thường dựa trên kiến thức trong sách giáo khoa.
- BioASQ: Bộ dữ liệu QA y sinh học, chỉ dùng các câu hỏi có/không.

PaperQA có hiệu suất tốt hơn GPT-4 trong tất cả các bộ dữ liệu, đặc biệt là trên PubMedQblind (với ngữ cảnh bị ẩn). PaperQA có khả năng truy xuất thông tin ngữ cảnh gần như chính xác như khi cung cấp ngữ cảnh gốc. Trên MedQA, Tác giả lý giải khoảng cách hiệu suất giữa PaperQA và GPT-4 nhỏ hơn, vì MedQA yêu cầu kiến thức từ sách giáo khoa nhiều hơn là từ các bài báo học thuật. GPT-4 hoạt động tốt hơn khi sử dụng PaperQA hỗ trợ cho suy luận, đặc biệt là khi dùng cách suy luận hậu suy luận (posteriori reasoning).

Chú thích:

- PubMedQAblind: Đây là một phiên bản của PubMedQA, trong đó ngữ cảnh bị ẩn đi để tăng độ khó cho mô hình khi trả lời.
- GPT-4 + PaperQA: GPT-4 có thể tự trả lời hoặc tham khảo PaperQA như một ”nguồn thông tin hỗ trợ” để giúp đưa ra câu trả lời.
- PaperQA/AutoGPT + Hậu suy luận (Post reasoning): Đầu tiên, PaperQA hoặc AutoGPT trả lời câu hỏi. Sau đó, đầu ra từ một trong hai công cụ này sẽ được chuyển cho GPT-4 để GPT-4 có thể sử dụng thông tin đó, nếu thấy hữu ích, nhằm đưa ra câu trả lời cuối cùng.

Chương 3

DEMO CÔNG CỤ

3.1 Các điều kiện môi trường cần chuẩn bị

Để có thể thực hiện được việc demo công cụ, nhóm em đã chuẩn bị như sau:

- Tải thư viện *paperqa* bằng câu lệnh sau:

```
pip install paper-qa
```

- Chuỗi *OPENAI_API_KEY* lấy từ tài khoản ChatGPT để sinh ra câu trả lời và lưu chuỗi này trong *.env* để đảm bảo tính bảo mật. Có thể tìm hiểu và lấy key từ đây <https://platform.openai.com/settings/organization/api-keys>
- Tải về máy tính cá nhân 3 bài báo tiêu biểu cho lĩnh vực hóa học và môi trường và lưu chúng tại folder *papers*. Chú ý đổi lại tên file bài báo sau khi tải về để dễ đọc và dễ nhận biết, phục vụ việc kiểm chứng tính đúng đắn của các tham chiếu.
 - Large-scale production of single-walled carbon nanotubes by the electric-arc technique [3]
 - Chemically assisted directed assembly of carbon nanotubes for the fabrication of large-scale device arrays. [4]
 - Large-scale complementary macroelectronics using hybrid integration of carbon nanotubes and IGZO thin-film transistors [5]

- Để chạy được công cụ, ta cần tạo môi trường ảo *venv* bằng câu lệnh sau:

```
python3 -m venv .venv
source .venv/bin/activate
```

Câu lệnh thứ nhất sẽ tạo một môi trường ảo độc lập, ta có thể thoải mái cài đặt các thư viện mà không ảnh hưởng tới các nơi khác. Câu lệnh thứ hai sẽ kích hoạt môi trường ảo này để sử dụng.

3.2 Chạy code

Tạo môi trường ảo *venv* và chạy đoạn code dưới đây

```
import os
import glob
from paperqa import Docs
from dotenv import load_dotenv

load_dotenv()

os.getenv("OPENAI_API_KEY")

docs = Docs()

folder_path = 'papers'
pdf_files = glob.glob(os.path.join(folder_path, '*.pdf'))
for d in pdf_files:
    docs.add(d)

question = "How can carbon nanotubes be manufactured at a large scale?"
answer = docs.query(question)
print(answer.formatted_answer)
```

Đầu ra cho đoạn mã trên:

Question: How can carbon nanotubes be manufactured at a large scale?

Carbon nanotubes (CNTs) can be manufactured at a large scale through two primary methods: the electric-arc technique and chemically assisted directed assembly. The electric-arc technique involves an arc discharge between two graphite electrodes in a helium atmosphere, optimized with a catalyst mixture of 1 at.% Y and 4.2 at.% Ni, to produce single-walled carbon nanotubes (SWNTs) with yields of 70–90% (Journet6644 pages 2-2). Alternatively, the chemically assisted directed assembly method chemically functionalizes single-walled carbon nanotubes (SWCNTs) for water solubility and selective binding to surfaces, enabling the fabrication of large-scale arrays of SWCNT devices with high yield (Tulevski2007 pages 1-1; Tulevski2007 pages 4-5).

References

1. (Tulevski2007 pages 1-1): Tulevski, George S., et al. "Chemically Assisted Directed Assembly of Carbon Nanotubes for the Fabrication of Large-Scale Device Arrays."*Contribution from the IBM T. J. Watson Research Center*, vol. 2007, no. 09/07, 2007, pp. 1-5.
2. (Journet6644 pages 2-2): Journet, C., et al. "Large-Scale Production of Single-Walled Carbon Nanotubes by the Electric-Arc Technique."Nature, vol. 388, no. 6644, Aug. 1997, pp. 756–758. Nature Publishing Group, doi:10.1038/41972. Accessed 24 Mar. 2024.
3. (Tulevski2007 pages 4-5): Tulevski, George S., et al. "Chemically Assisted Directed Assembly of Carbon Nanotubes for the Fabrication of Large-Scale Device Arrays."*Contribution from the IBM T. J. Watson Research Center*, vol. 2007, no. 09/07, 2007, pp. 1-5.

Chương 4

KẾT LUẬN

PaperQA thực sự là một mô hình có thể đóng góp giá trị lớn trong lĩnh vực trả lời câu hỏi khoa học bằng cách giải quyết những hạn chế chính của Mô hình ngôn ngữ lớn (LLM) truyền thống. Thông qua việc sử dụng **Retrieval-Augmented Generation (RAG)**, PaperQA không chỉ cải thiện độ chính xác của câu trả lời mà còn giảm hiện tượng ảo giác thông tin và vấn đề khó diễn giải ở các mô hình ngôn ngữ lớn nói chung. Bằng cách tích hợp các cơ chế **truy xuất động** từ tài liệu khoa học, PaperQA đảm bảo rằng các câu trả lời không chỉ chính xác mà còn có thể theo dõi và được chứng minh bằng bằng chứng, một tính năng quan trọng cho các ứng dụng nghiên cứu và học thuật.

Bài báo chứng minh rằng PaperQA có thể đạt được độ chính xác ở cấp độ con người trong khi tiết kiệm chi phí hơn so với các nhà nghiên cứu con người, mang lại những cải tiến đáng kể về cả hiệu quả và độ tin cậy. Với tỷ lệ ảo giác 0% đối với các trích dẫn trong thử nghiệm, bài báo cho thấy PaperQA là một công cụ cực kỳ đáng tin cậy để trích xuất và tổng hợp kiến thức khoa học phức tạp.

Báo cáo này đã chỉ ra các hướng phát triển tương lai, đặc biệt trong việc xử lý sự thay đổi liên tục của kiến thức khoa học. Trong bối cảnh rộng hơn, PaperQA có thể cách mạng hóa cách các nhà nghiên cứu tương tác với tài liệu, giảm thời gian đánh giá và truy vấn thông tin từ tài liệu. Khi mô hình tiếp tục hoàn thiện, nó hứa hẹn sẽ đóng vai trò quan trọng trong tương lai của nghiên cứu khoa học tự động.

Chương 5

PHỤC LỤC

5.1 Các thắc mắc được giải đáp bởi tác giả

Trong quá trình nghiên cứu một bài báo khoa học, việc gặp phải những kiến thức mới, những chi tiết khó hiểu là không tránh khỏi. Do đó, nhóm em đã liên hệ với tác giả - thầy Aleksandar Shtedritski (<https://scholar.google.com/citations?user=cGnonsQAAAAJ&hl=en>) qua nền tảng LinkedIn và rất may mắn được thầy giải đáp.

Câu hỏi 1: Tại sao khi chạy công cụ paper-qa thì con tác nhân không tự đi tìm các bài báo mà mình lại phải tự tìm và tải về máy?

Câu trả lời: Do các vấn đề liên quan tới pháp lý và vì Future House - tổ chức của nhóm tác giả không chỉ là một tổ chức nghiên cứu mà còn làm kinh doanh, nên bản mã nguồn mà tác nhân tự đi tìm tài liệu sẽ không thể là mã nguồn mở. Do đó nhóm em chỉ có thể sử dụng bản miễn phí và phải tự tìm kiếm và tải các bài báo về máy cá nhân.

Câu hỏi 2: Ở phần kết quả đánh giá hệ thống - evaluation, nhóm tác giả có dùng các chỉ số của sample, vậy sample là gì và tại sao với mỗi hệ thống, mô hình ta lại có số sample khác nhau?


Câu trả lời:

Sample là số lần nhóm tác giả sử dụng hệ thống, mô hình để đánh giá trên tập dữ liệu LitQA, kết quả trong hình là kết quả chia trung bình trên số sample mà mỗi hệ thống, mô hình dùng để đánh giá.

Model	Samples	Response			Score	
		Correct	Incorrect	Unsure	Accuracy ($\frac{\text{Correct}}{\text{All}}$)	Precision ($\frac{\text{Correct}}{\text{Sure}}$)
Random	100	10.2	29.5	10.3	20.4%	25.7%
Human	5	33.4	4.6	12.0	66.8%	87.9%
Claude-2	3	20.3	26.3	3.3	40.6%	43.6%
GPT-4	3	16.7	16.3	17.0	33.4%	50.6%
AutoGPT	3	20.7	7.3	22.0	41.4%	73.9%
Elicit	1	12.0	16.0	22.0	24.0%	42.9%
Scite_	1	12.0	21.0	17.0	24.0%	36.4%
Perplexity	1	9.0	10.0	31.0	18.0%	47.4%
Perplexity (Co-pilot)	1	29.0	10.0	12.0	58.0%	74.4%
PaperQA	4	34.8	4.8	10.5	69.5%	87.9%

Hình 5.1: Kết quả quá trình đánh giá

Lý do sử dụng số lượng sample khác nhau cho các hệ thống, mô hình khác nhau là do chi phí sử dụng của các hệ thống, mô hình đó là khác nhau, ví dụ như một vài mô hình như GPT-4, Elicit có chi phí không rẻ do đó chỉ phù hợp để chạy một lần. Điều này là hoàn toàn phù hợp với thực tế, chứ không gây ra sự ”thiên vị” hay ”bất công nào”.



Hình 5.2: Đoạn tin nhắn với tác giả

5.2 Các câu hỏi phản biện trên lớp

Câu hỏi 1: Mình thấy trong paper thì con agent này có khả năng tự tìm kiếm các bài báo có liên quan, nhưng phần demo thì tại sao các bạn lại tải sẵn hết báo về mà không để nó tự tìm?

Câu trả lời: Ban đầu nhóm cũng thắc mắc như vậy, bọn mình đã hỏi tác giả, thì được biết rằng với thư viện paperqa miễn phí thì sẽ không có chức năng này mà phải dùng bản có trả phí.

Câu hỏi 2: Ở kiến trúc của con agent, bạn có nói về cơ chế MMR để tính độ tương đồng giữa 2 vector, vậy MMR có gì đặc biệt, khác gì với các công thức tính độ tương đồng bình thường?

Câu trả lời: Các công thức bình thường: chỉ đơn giản là tính độ tương đồng giữa 2 vector, thường là các công thức như cosine_similarity hay euclid_distance. Công thức MMR: công thức này đảm bảo cân bằng giữa 2 yếu tố là độ liên quan và độ đa dạng.

Câu hỏi 3: Trong bài các bạn có nhắc đến chunk, vậy chunk cụ thể hơn là gì?

Câu trả lời: Chunk thường là các đoạn văn, câu chủ đề.

Câu hỏi 4: Trong paper, trang số 5, dòng thứ 2 từ trên xuống có nói rằng công cụ "gather information" chỉ trả về top-1 chunk cho agent, vậy các chunk còn lại thì được xử lý thế nào?

Câu trả lời: Sau khi có được M đoạn chunks từ bước gather_evidence, tác nhân sẽ trả từng đoạn 1 về cho context thay vì trả tất cả đoạn cùng lúc, bước answer_question sẽ đưa ra câu trả lời dựa trên đoạn này, và tác nhân sẽ đánh giá câu trả lời đó, nếu thiếu hoặc chưa đủ chính xác thì sẽ trả tiếp các đoạn còn lại -> Tăng tốc độ trả lời.

Câu hỏi 5: Ở phần search, tại sao các paper tìm kiếm được lại phải được chuyển thành các chunk xếp chồng nhau? Nếu không chồng lên nhau thì có sao không?

Câu trả lời: Để đảm bảo các chunk có nội dung liên quan, liên kết với nhau thay vì là các đoạn văn có nội dung rời rạc.

Câu hỏi 6: Mình thấy trong bài báo có nhắc tới map - reduce, bạn giải thích kỹ hơn được không?

Câu trả lời: Map-reduce diễn ra ở công cụ ggather_evidence. Map: tập trung thu thập nhiều nguồn thông tin nhất có thể. Reduce: tóm tắt lại các ý chính từ bước map, để thuận lợi nhất

để trả lời.

Câu hỏi 7: Làm sao để xác định câu trả lời đã đầy đủ chưa hay vẫn thiếu?

Câu trả lời: Tác nhân sẽ kiểm tra xem từng vế trong câu hỏi đã được trả lời hay chưa.

Câu hỏi 8: PaperQA thực sự là gì? Nó có phải là 1 mô hình như GPT không?

Câu trả lời: PaperQA không phải 1 mô hình như GPT, nó là 1 hệ thống sử dụng các mô hình LLM khác để thực hiện các tác vụ của nó.

Câu hỏi 9: PaperQA khác gì với các mô hình RAG bình thường?

Câu trả lời: PaperQA được thiết kế để hỗ trợ nghiên cứu khoa học, trong khi các mô hình RAG bình thường thường được sử dụng cho nhiều mục đích khác nhau. PaperQA cung cấp nguồn tham khảo chi tiết còn các mô hình RAG bình thường thì không.

Câu hỏi 10: Nhiệm vụ của bước ask LLM là gì?

Câu trả lời: Bước ask hoạt động như 1 bước tiền đề, cơ sở, để xem hệ thống đã hiểu biết những gì về câu hỏi trước khi tiếp cận các đoạn văn bằng chứng.

Câu hỏi 11: Lợi ích cụ thể của quy trình map-reduce trong PaperQA là gì khi xử lý nhiều nguồn tài liệu và làm thế nào quy trình này tối ưu việc tổng hợp thông tin?

Câu trả lời: Trong PaperQA, quy trình map-reduce được sử dụng để cải thiện quá trình tổng hợp thông tin từ nhiều tài liệu. Ở bước "map," hệ thống truy xuất và tóm tắt các đoạn văn bản liên quan từ các bài báo khác nhau, tạo ra một tập hợp các bằng chứng. Sau đó, ở bước "reduce," các bằng chứng này được tổng hợp thành câu trả lời cuối cùng. Quy trình này giúp PaperQA tận dụng nhiều nguồn tài liệu để xây dựng câu trả lời đầy đủ và chính xác hơn, thay vì chỉ dựa vào một tài liệu duy nhất. Đồng thời, nó cũng cung cấp một "scratchpad" để lưu các bằng chứng trung gian trước khi đi đến câu trả lời cuối cùng, cho phép hệ thống lọc bỏ thông tin không phù hợp và tối ưu hóa chất lượng tổng hợp.

Câu hỏi 12: PaperQA đã được đánh giá bằng các phương pháp nào để đảm bảo rằng nó giảm thiểu "hallucinations" trong trích dẫn và câu trả lời? Các phương pháp này có thể mở rộng để kiểm tra các mô hình RAG khác không?

Câu trả lời: PaperQA được đánh giá thông qua việc kiểm tra tỷ lệ trích dẫn chính xác và các lỗi ảo giác trong câu trả lời. Cụ thể, PaperQA được so sánh với các mô hình LLM khác như GPT-4 và Claude-2 trên khả năng giảm thiểu trích dẫn ảo và đảm bảo trích dẫn đúng nguồn. PaperQA đã giảm thiểu hoàn toàn hiện tượng ảo giác trong trích dẫn nhờ khả năng truy xuất và đánh giá mức độ liên quan của các đoạn văn bản trước khi tổng hợp.

Các phương pháp này có thể mở rộng để kiểm tra các mô hình RAG khác, vì tính chính xác của trích dẫn là vấn đề quan trọng đối với bất kỳ hệ thống nào sử dụng tài liệu để trả lời câu hỏi.

Câu hỏi 13: Với mục tiêu tối ưu hóa chi phí, tại sao PaperQA lại sử dụng các LLM instance khác nhau cho từng bước (search, gather evidence, answer question), và lợi ích của cách tiếp cận này là gì?

Câu trả lời: PaperQA sử dụng các LLM instance khác nhau cho từng bước như tìm kiếm, thu thập bằng chứng và trả lời câu hỏi để tối ưu hóa hiệu suất và chi phí. Bằng cách sử dụng các LLM khác nhau cho các nhiệm vụ khác nhau, PaperQA có thể giảm chi phí xử lý khi các tác vụ đòi hỏi độ phức tạp khác nhau. Ví dụ, bước "summary LLM" có thể dùng mô hình GPT-3.5 rẻ hơn để tóm tắt các đoạn văn, trong khi bước "answer LLM" có thể dùng GPT-4 để đảm bảo độ chính xác cao nhất trong câu trả lời cuối cùng. Cách tiếp cận này không chỉ giúp tiết kiệm chi phí mà còn tận dụng đúng năng lực của từng mô hình cho từng nhiệm vụ.

Câu hỏi 14: PaperQA có lợi thế gì so với các hệ thống RAG tĩnh khi có thể thực hiện các truy vấn tìm kiếm lặp lại, và điều này có giúp cải thiện hiệu suất trong các nhiệm vụ trả lời câu hỏi mở không?

Câu trả lời: PaperQA có thể thực hiện các truy vấn tìm kiếm lặp lại khi cần, giúp nó có thể cải thiện hiệu suất trong các nhiệm vụ trả lời câu hỏi mở. Khả năng này cho phép PaperQA điều chỉnh các truy vấn tìm kiếm khi bằng chứng chưa đủ rõ ràng, bằng cách tìm thêm các đoạn văn từ nhiều nguồn hoặc thay đổi từ khóa tìm kiếm để làm rõ câu trả lời. Hệ thống RAG tĩnh thường có quy trình cố định và không thể linh hoạt tìm kiếm bổ sung khi cần thiết, do đó có thể bỏ qua các thông tin quan trọng nếu chúng không nằm trong các đoạn văn được truy xuất ban đầu.

Câu hỏi 15: PaperQA sử dụng vector-embedding retrieval và maximal marginal relevance search trong quá trình tìm kiếm bằng chứng như thế nào? Hai kỹ thuật này có giúp giảm bớt độ phức tạp của truy vấn không?

Câu trả lời: PaperQA sử dụng vector-embedding retrieval để tìm kiếm các đoạn văn bản liên quan bằng cách so sánh các điểm nhúng (embedding) của truy vấn với các đoạn văn trong cơ sở dữ liệu. Điều này cho phép hệ thống xác định các đoạn văn có ngữ nghĩa tương tự, thay vì chỉ dựa vào từ khóa trực tiếp. Kỹ thuật maximal marginal relevance

search (MMR) giúp tăng cường độ đa dạng của các kết quả bằng cách chọn các đoạn văn có ngữ nghĩa khác nhau nhưng vẫn liên quan đến truy vấn. Kết hợp hai kỹ thuật này giúp PaperQA giảm độ phức tạp của truy vấn bằng cách loại bỏ các thông tin không cần thiết và đảm bảo rằng các đoạn văn được chọn bao quát toàn diện chủ đề, hỗ trợ quá trình tổng hợp thông tin chính xác hơn.

Câu hỏi 16: Tại sao PaperQA chỉ sử dụng hai nguồn dữ liệu là Arxiv và PubMed để truy xuất thông tin? Những hạn chế nào có thể phát sinh từ việc chỉ dựa vào hai nguồn này?

Câu trả lời: PaperQA lựa chọn Arxiv và PubMed vì đây là hai cơ sở dữ liệu lớn, phổ biến trong giới khoa học với độ phủ rộng về các lĩnh vực nghiên cứu như khoa học máy tính, sinh học và y học. Tuy nhiên, việc chỉ dựa vào hai nguồn này có thể tạo ra hạn chế về tính đầy đủ khi xử lý các câu hỏi đa lĩnh vực hoặc những câu hỏi yêu cầu kiến thức từ các tài liệu nghiên cứu ngoài khoa học kỹ thuật và y học. Để nâng cao độ bao phủ, PaperQA có thể cần tích hợp thêm các nguồn khác, chẳng hạn như IEEE Xplore cho tài liệu kỹ thuật hoặc các cơ sở dữ liệu đa ngành như SpringerLink và Wiley Online Library.

Câu hỏi 17: Khi gặp phải các tài liệu mâu thuẫn, PaperQA có thể đưa ra cách giải quyết nào? Liệu có khả năng phát hiện và báo cáo mâu thuẫn đó cho người dùng không?

Câu trả lời: PaperQA hiện chưa có cơ chế tự động phát hiện mâu thuẫn giữa các tài liệu. Tuy nhiên, nhóm phát triển có thể tích hợp một công cụ kiểm tra sự nhất quán của các tài liệu hoặc tạo ra một hệ thống thông báo cho người dùng khi có nhiều nguồn với nội dung mâu thuẫn.

Câu hỏi 18: Tại sao PaperQA lại rẻ hơn so với con người

Sau khi tìm hiểu đọc kỹ lại bài báo và có tham khảo câu trả lời của tác giả thì nhóm em có câu trả lời sau : Thời gian trung bình để PaperQA trả lời tất cả các câu hỏi là khoảng 2,4 giờ, tương đương với thời gian 2,5 giờ mà con người được cho để hoàn thành công việc này. Chi phí cho một phiên PaperQA là 3,75 USD mỗi giờ, thấp hơn nhiều so với mức lương trung bình hàng giờ của một nhà nghiên cứu

Cam đoan

Chúng em xin cam đoan không sử dụng bất kì một công cụ hay mô hình trí tuệ nhân tạo nào trong quá trình viết báo cáo.

Xác nhận của từng thành viên:

Bùi Đặng Đức Phong

Trần Tuấn Nghĩa

Đinh Văn Ninh

Nguyễn Hải Long

Tài liệu tham khảo

- [1] A. Neelakantan, T. Xu, R. Puri, A. Radford, J. M. Han, J. Tworek, Q. Yuan, N. Tezak, J. W. Kim, C. Hallacy, and et al., “Text and code embeddings by contrastive pre-training,” *arXiv preprint arXiv:2201.10005*, 2022. [Online]. Available: <https://arxiv.org/abs/2201.10005>
- [2] J. Carbonell and J. Goldstein, “The use of mmr, diversity-based reranking for reordering documents and producing summaries.” *In Proceedings of the 21st annual international ACM SIGIR conference on Research and development in information retrieval*, pages 335–336, 1998.
- [3] C. Journet, “Large-scale production of single-walled carbon nanotubes by the electric-arc technique.” *nature* 388.6644, 1997. [Online]. Available: <https://www.nature.com/articles/41972>
- [4] G. S. Tulevski, “Chemically assisted directed assembly of carbon nanotubes for the fabrication of large-scale device arrays.” *Journal of the American Chemical Society* 129.39, 2007. [Online]. Available: <https://pubs.acs.org/doi/10.1021/ja073647t>
- [5] H. Chen, “Large-scale complementary macroelectronics using hybrid integration of carbon nanotubes and igzo thin-film transistors.” *Nature communications* 5.1, 2014. [Online]. Available: <https://www.nature.com/articles/ncomms5097>