

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO CUỐI KÌ

**CHỦ ĐỀ: PHÁT HIỆN VÀ PHÒNG CHỐNG CÁC MẪU ĐỐI
KHÁNG TRONG HỌC SÂU SỬ DỤNG THỐNG KÊ CẢNH TỰ
NHIÊN VÀ KHỦ NHIỀU THÍCH ỨNG**

Lớp môn học: Các vấn đề hiện đại trong công nghệ thông tin

Mã môn học: INT3507 7

Giảng viên: TS. Nguyễn Đức Anh

Nhóm 5:

Lý Trường Thành 21020790

Dương Bình Minh 21020778

Ngô Bình Dương 21020756

HÀ NỘI - 2024

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO CUỐI KÌ

**CHỦ ĐỀ: PHÁT HIỆN VÀ PHÒNG CHỐNG CÁC MẪU ĐỐI
KHÁNG TRONG HỌC SÂU SỬ DỤNG THỐNG KÊ CẢNH TỰ
NHIÊN VÀ KHỦ NHIỀU THÍCH ỨNG**

Lớp môn học: Các vấn đề hiện đại trong công nghệ thông tin

Mã môn học: INT3507 7

Giảng viên: TS. Nguyễn Đức Anh

Nhóm 5:

Lý Trường Thành 21020790

Dương Bình Minh 21020778

Ngô Bình Dương 21020756

HÀ NỘI - 2024

LỜI CAM ĐOAN

Chúng em, nhóm thực hiện bài báo cáo với đề tài *Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng*, xin cam đoan rằng đây là công trình nghiên cứu thực sự của nhóm dựa trên quá trình tự tìm hiểu và vận dụng kiến thức chuyên ngành đã học.

Chúng em xin cam đoan rằng những nội dung và công việc được trình bày trong báo cáo này là kết quả của việc nghiên cứu, phân tích, và tóm tắt từ bài báo gốc. Chúng em không phải là tác giả của bài báo gốc và những công trình nghiên cứu này đã được công bố từ trước. Tuy nhiên, chúng em đảm bảo rằng các số liệu, kết quả và thông tin được trích dẫn trong báo cáo là trung thực và không làm giả số liệu.

Nếu có điều gì sai sót, nhóm chúng em xin hoàn toàn chịu trách nhiệm.

Hà Nội, ngày ... tháng ... năm 2024

Trưởng nhóm

Lý Trường Thành

Thành viên 1

Thành viên 2

Dương Bình Minh

Ngô Bình Dương

LỜI CẢM ƠN

Nhóm chúng em xin chân thành cảm ơn thầy Nguyễn Đức Anh, người đã trực tiếp giảng dạy bộ môn Các vấn đề hiện đại trong công nghệ thông tin trong học kỳ I năm học 2024 - 2025. Những lời góp ý của thầy trong suốt quá trình học tập và nghiên cứu đã tạo điều kiện thuận lợi cho nhóm chúng em hoàn thành bài báo cáo này một cách tốt nhất.

Ngoài ra, nhóm chúng em cũng xin gửi lời cảm ơn sâu sắc đến các bạn học cùng lớp, những người đã đưa ra nhiều góp ý và nhiều nhận xét giá trị trong quá trình nhóm trình bày phần báo cáo của mình trên lớp giúp nhóm khắc phục và cải thiện những điểm hạn chế có trong báo cáo.

Hà Nội, ngày ... tháng ... năm 2024

Trưởng nhóm

Lý Trường Thành

Thành viên 1

Thành viên 2

Dương Bình Minh

Ngô Bình Dương

TÓM TẮT

Mạng nơ-ron sâu (*Deep Neural Networks* - **DNN**) mặc dù có hiệu suất cao nhưng thực tế lại cho thấy chúng dễ bị tổn thương bởi các mẫu đối kháng (*Adversarial Examples*) - là một loại đầu vào được sử dụng để đánh lừa DNN. Nhiều phương pháp tấn công đã được phát triển để tạo ra các AE, trong khi các phương pháp phòng thủ chỉ tập trung vào các loại tấn công cụ thể và không khái quát hoá.

Trong bài báo *Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng*, nhóm tác giả đã đưa ra một phương pháp gồm hai giai đoạn chính:

- **Bộ phát hiện (*detector*)**: Dựa trên thống kê cảnh tự nhiên (*Nature Scene Statistic* - **NSS**) để phát hiện AE thông qua các thay đổi trong tính năng thống kê.
- **Bộ khử nhiễu (*denoiser*)**: Sử dụng bộ lọc *Block Matching 3D* (**BM3D**) kết hợp với giá trị ngưỡng tối ưu từ mạng nơ-ron tích chập (*Convolutional Neural Network* - **CNN**) để đưa các mẫu trở về đa tạp dữ liệu (*data manifold*).

PHÂN CÔNG CÔNG VIỆC

STT	Người thực hiện	Công việc	Tỉ lệ tham gia (%)
1	Lý Trường Thành (Nhóm trưởng)	Làm demo, fix lỗi source code, làm slide phần thực nghiệm, viết báo cáo chương 3,4,5	40
2	Dương Bình Minh	Dịch bài báo, tìm hiểu các khái niệm chuyên môn, làm lại slide, thuyết trình, viết báo cáo chương 1,2 và chỉnh sửa khung báo cáo	40
3	Ngô Bình Dương	Làm slide và viết báo cáo	20

Bảng 1. Bảng phân công công việc

MỤC LỤC

Lời cam đoan	
Lời cảm ơn	
Tóm tắt	
Phân công công việc	
Mục lục	
Danh mục hình vẽ	
Danh mục bảng biểu	
CHƯƠNG 1. Giới thiệu chung	1
1.1. Đặt vấn đề	1
1.2. Giới thiệu bài báo	2
1.3. Giới thiệu tác giả	2
1.3.1. Wassim Hamidouche	2
1.3.2. Sid Ahmed Fezza	3
1.3.3. Anouar Kherchouche	3
CHƯƠNG 2. Phương pháp được đề xuất	4
2.1. Một số khái niệm	4
2.1.1. Mẫu đối kháng	4
2.1.2. Các loại tấn công đối kháng	4
2.1.3. Những phương pháp tấn công được tác giả sử dụng để đánh giá	4
2.1.4. Các phương pháp phòng thủ	5
2.1.5. Ký hiệu và độ đo được sử dụng trong bài báo	6
2.2. Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng	8
2.2.1. Bộ phát hiện	8
2.2.2. Bộ khử nhiễu	12
CHƯƠNG 3. Thực nghiệm	15
3.1. Thực nghiệm của tác giả	15
3.1.1. Bộ dữ liệu	15
3.1.2. Phương pháp tấn công	15

3.1.3. Quy trình huấn luyện	17
3.1.4. Kết quả và đánh giá	18
3.2. Thực nghiệm của nhóm	20
3.2.1. Tổng quan	20
3.2.2. Vấn đề	21
3.2.3. Xử lý vấn đề	21
3.2.4. Kết quả và đánh giá	23
CHƯƠNG 4. Kết luận	25
CHƯƠNG 5. Phụ lục	27
5.1. Ảnh phóng to thu nhỏ và ảnh gốc có cùng phân phối với ảnh gốc hay không?	27
5.2. Các ảnh cùng nhãn có cùng phân phối hay không?	27
Tài liệu tham khảo	29

DANH MỤC HÌNH VẼ

Hình 1	Ví dụ minh họa hình ảnh bị tấn công trở thành mẫu đối kháng làm mô hình DNN phân loại sai.	1
Hình 2	Mô tả tổng quan về quy trình làm việc của phương pháp phòng thủ. .	8
Hình 3	Luồng hoạt động của bộ phát hiện.	8
Hình 4	Minh họa mối quan hệ giữa NSS và nhiễu đối kháng.	10
Hình 5	Mô hình hoạt động của bộ lọc Block-Matching 3D.	12
Hình 6	Các kiến trúc CNN đề xuất được sử dụng để dự đoán các tham số λ_{3D} của BM3D cho các tập dữ liệu.	13
Hình 7	Hiệu suất của khối phòng thủ dưới cuộc tấn công black-box.	18
Hình 8	Hiệu suất của khối phòng thủ dưới cuộc tấn công gray-box.	18
Hình 9	Hiệu suất của khối phòng thủ dưới cuộc tấn công white-box.	18
Hình 10	Độ chính xác của bộ phân loại chống lại các cuộc tấn công.	19
Hình 11	Hiệu suất ROC của khối phát hiện chống lại tấn công white-box. . .	19
Hình 12	Các file cài đặt	20
Hình 13	Luồng hoạt động	21
Hình 14	Các bước chạy thử	21
Hình 15	Kết quả chạy bộ phát hiện	23
Hình 16	Kết quả chạy bộ khử nhiễu	24

DANH MỤC BẢNG BIỂU


Bảng 1	Bảng phân công công việc	
Bảng 2	Một số ký hiệu được sử dụng.	7
Bảng 3	Tỷ lệ thành công của các phương pháp tấn công và tỷ lệ FP (%) trên các tập dữ liệu	19

CHƯƠNG 1

GIỚI THIỆU CHUNG

1.1. Đặt vấn đề

Trong bối cảnh mạng nơ-ron sâu (DNN) ngày càng được ứng dụng rộng rãi trong nhiều lĩnh vực như nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên và lái xe tự động, sự xuất hiện của các mẫu đối kháng (AEs) đã trở thành một thách thức lớn. Những mẫu đối kháng không chỉ làm giảm hiệu suất hoạt động của DNN mà còn đặt ra nguy cơ về tính an toàn và bảo mật cho các hệ thống ứng dụng.



Hình 1. Ví dụ minh họa hình ảnh bị tấn công trở thành mẫu đối kháng làm mô hình DNN phân loại sai.

Lấy một ví dụ cụ thể, trong hình 1, một ảnh đầu vào được DNN phân loại chính xác là một biển báo 'STOP'. Khi các nhiễu được thêm vào các hình ảnh đầu vào khiến

cho mô hình phân loại sai thành biến báo '120km/h'. Điều này đặc biệt nguy hiểm và có thể gây ra nhiều hậu quả nghiêm trọng nhất là đối với những mô hình được ứng dụng trong xe tự lái. Do đó việc cải thiện tính bền vững của mô hình DNN là vô cùng quan trọng.

Việc hiểu và phân tích bài báo *Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng* giúp nhóm chúng em nắm rõ hơn về các kỹ thuật phòng thủ hiện đại trước mối đe dọa này.

1.2. Giới thiệu bài báo

Tên gốc: Detect and Defense Against Adversarial Examples in Deep Learning using Natural Scene Statistics and Adaptive Denoising.

Tên được dịch lại: Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng.

Nhóm tác giả: Anouar Kherchouche, Sid Ahmed Fezza, Wassim Hamidouche.

Ngày phát hành: 12/06/2021.

Công bố trên các tạp chí/hội thảo: NASA ADS, Google Scholar, Semantic Scholar

DOI: <https://doi.org/10.48550/arXiv.2107.05780>

1.3. Giới thiệu tác giả

1.3.1. Wassim Hamidouche

Ông là Phó giáo sư tại Viện Điện tử và Viễn thông Rennes thuộc phòng thí nghiệm CNRS, Viện Khoa học Ứng dụng Quốc gia Rennes, Rennes, Pháp. Và còn là Kỹ sư Nghiên cứu tại Trung tâm Nghiên cứu Canon, Rennes. Các mối quan tâm nghiên cứu hiện tại của ông bao gồm kiến trúc song song và thời gian thực cho các tiêu chuẩn mã hóa video mới, truyền đa phương tiện qua mạng không đồng nhất và bảo mật nội dung đa phương tiện.

Số lượng bài báo: 149.

Số lượng trích dẫn: 3101.

h-index: 30.

h10-index: 82.

1.3.2. Sid Ahmed Fezza

Ông hiện đang là phó giáo sư tại Viện viễn thông và công nghệ thông tin quốc gia, Oran, Algeria (National Higher School of Telecommunications and ICT). Ông là tác giả của một số ấn phẩm trên các tạp chí hàng đầu về xử lý ảnh và video. Nhận hai giải thưởng bài báo hay nhất trong top 10% tại ICIP 2014, giải thưởng bài báo của năm 2015 của Algeria.

Số lượng bài báo: 36.

Số lượng trích dẫn: 793.

h-index: 14.

h10-index: 17.

1.3.3. Anouar Kherchouche

Hiện đang là nghiên cứu sinh tiến sĩ trong lĩnh vực trí tuệ nhân tạo, công tác và làm việc tại trường đại học Poitiers (Pháp).

Số lượng bài báo: 7.

Số lượng trích dẫn: 70.

h-index: 4.

h10-index: 4.

CHƯƠNG 2

PHƯƠNG PHÁP ĐƯỢC ĐỀ XUẤT

2.1. Một số khái niệm

2.1.1. Mẫu đối kháng

Mẫu đối kháng là các đầu vào (ảnh, video, ...) đã được sửa đổi một cách tinh vi nhằm đánh lừa mô hình học máy, mặc dù là những thay đổi rất nhỏ và không thể quan sát bằng cách thông thường nhưng chúng có thể làm cho mô hình dự đoán sai với độ tin cậy cao.

2.1.2. Các loại tấn công đối kháng

- Tấn công white-box: Đây là loại tấn công mà kẻ tấn công có toàn quyền truy cập vào cấu trúc, tham số, quy trình huấn luyện thậm chí cả dữ liệu huấn luyện của mô hình mục tiêu.
- Tấn công black-box: Kẻ tấn công không có bất kì thông tin gì về cấu trúc mô hình, chỉ có thể quan sát đầu vào và đầu ra của mô hình.
- Tấn công gray-box: Có thể coi là một kiểu tấn công kết hợp một nửa của white-box, một nửa của black-box. Với loại tấn công này kẻ tấn công có thông tin về cấu trúc, tham số của mô hình nhưng lại không biết kĩ thuật phòng thủ nào được sử dụng.

2.1.3. Những phương pháp tấn công được tác giả sử dụng để đánh giá

- Tấn công theo phương pháp ký hiệu gradient nhanh (FGSM): Làm nhiễu hình ảnh đầu vào theo hướng gradient của hàm mất mát. Thực hiện cập nhật dọc theo các gradient theo một bước cập nhật, kẻ tấn công cần truy cập vào gradient của mô hình để tính toán hướng gây nhiễu.
- Tấn công giảm gradient dự kiến (PGD): Đây là phần mở rộng của FGSM. Nó thực hiện nhiều bản cập nhật gradient, tạo nhiều đối kháng theo khu vực lớn hơn, phức tạp hơn FGSM.
- Tấn công của Carlini và Wagner (CW): Cách tấn công này nhằm mục đích tìm nhiễu nhỏ nhất có thể gây ra phân loại sai. Xây dựng cuộc tấn công như việc giải

một bài toán tối ưu hoá, giảm thiểu biên độ nhiễu loạn trong khi tối đa hoá độ tin cậy phân loại sai.

2.1.4. Các phương pháp phòng thủ

- Huấn luyện đối kháng: Đây là phương pháp kết hợp các mẫu đối kháng vào dữ liệu huấn luyện nhằm nâng cao khả năng phân loại của mô hình. Tuy nhiên phương pháp này lại không khái quát hoá với nhiều loại tấn công khác nhau.
 - Đào tạo đối kháng với tăng cường dữ liệu: Phương pháp này tăng cường dữ liệu huấn luyện bằng các mẫu đối kháng được tạo ra từ nhiều kỹ thuật tấn công khác nhau. Mục tiêu là làm cho mô hình có khả năng thích ứng cao với nhiễu trong quá trình huấn luyện, giúp cải thiện khả năng dự đoán của mô hình trong quá trình dự đoán.
 - Huấn luyện với sinh mẫu đối kháng sáng tạo (Generative Adversarial Trainer): Kỹ thuật này dựa trên mạng sinh mẫu đối kháng (Generative Adversarial Networks - GAN) để cải thiện tính mạnh mẽ của mô hình trước các cuộc tấn công. GAN gồm hai phần: bộ tạo dữ liệu và bộ phân biệt dữ liệu. Trong quá trình huấn luyện, bộ tạo dữ liệu sinh ra các mẫu đối kháng, những mẫu này được đưa tới bộ phân biệt để phân loại các mẫu. Quá trình này làm mô hình phải học các tính năng mới và cải thiện khả năng phục hồi trước các cuộc tấn công.
- Tiền xử lý: Phương pháp này thực hiện xử lý các mẫu đầu vào trước khi phân loại nhằm giảm bớt tác động của các nhiễu đối kháng có trong mẫu. Một số ví dụ như:
 - Thay đổi kích thước và đệm ngẫu nhiên (Random resizing and padding - RRP): làm giảm nhiễu đối kháng bằng cách sử dụng các phép biến đổi ngẫu nhiên đối với đầu vào.
 - Sử dụng mô hình sinh: Các kỹ thuật như PixelDefend và Defense-GAN đào tạo các mô hình tạo trên những mẫu dữ liệu sạch để ước tính phân phối dữ liệu và chuyển đổi các mẫu đối kháng bằng cách tìm các hình ảnh lành tính có độ tương tự.
 - ME-Net: Phương pháp này tái tạo hình ảnh bằng việc sử dụng kỹ thuật ước tính ma trận khi loại bỏ ngẫu nhiên các điểm ảnh.

- Phát hiện mẫu đối kháng: Thay vì tập trung vào phân loại thì phương pháp này lại tập trung vào việc xác định xem đầu vào có phải là một mẫu đối kháng hay không. Một số ví dụ như:

- Kiểm định giả thuyết thống kê: Là phương pháp khai thác sự khác biệt về mặt thống kê giữa phân phối của mẫu đối kháng và mẫu sạch.
- Kiểm tra bất biến mạng nơ-ron: Kỹ thuật này tận dụng sự bất biến trong cấu trúc của DNN để phát hiện các mẫu đối kháng trong thời gian chạy.
- Phát hiện mẫu đối kháng có chọn lọc dựa trên tính năng: Là phương pháp kết hợp ước tính với các mô-đun phát hiện dựa trên ngưỡng tin cậy và phân tích tính năng sử dụng mã hoá tự động.

2.1.5. Ký hiệu và độ đo được sử dụng trong bài báo

2.1.5.1. Độ đo

- Hệ số chuẩn hoá độ tương phản (MSCN) là một độ đo được sử dụng để xác định các thuộc tính thống kê của hình ảnh tự nhiên, được tính cho từng điểm ảnh trong một hình ảnh và thể hiện sự khác biệt được chuẩn hoá giữa giá trị điểm ảnh và giá trị trung bình chia cho độ lệch chuẩn.
- Khoảng cách L_0 : Là đơn vị đo số lượng pixel khác nhau giữa hai hình ảnh.
- Khoảng cách Euclidean - L_2 : Là đơn vị đo khoảng cách đường thẳng giữa hai hình ảnh trong không gian điểm ảnh, khoảng cách này thường dùng để đánh giá mức độ nhiễu loạn.
- Khoảng cách Chebyshev - L_∞ : Là đơn vị đo sự khác biệt tối đa giữa các giá trị điểm ảnh tương ứng giữa hai ảnh.
- Độ đo tương đồng cấu trúc (SSIM): Đánh giá mức độ tương đồng giữa hai hình ảnh dựa trên độ sáng, độ tương phản và cấu trúc. Mục tiêu là duy trì mức độ tương đồng về cấu trúc sau quá trình khử nhiễu để duy trì phân loại chính xác.
- Tỷ lệ dương tính thực (TPR): Tỷ lệ các mẫu đối kháng được phát hiện chính xác trong tất cả các mẫu đối kháng thực tế.
- Tỷ lệ dương tính giả (FPR): Tỷ lệ các hình ảnh sạch được phân loại không chính xác.

- Đường cong ROC: Được sử dụng để biểu thị hiệu suất của bộ phát hiện ở các ngưỡng phát hiện khác nhau. Nó biểu diễn mối quan hệ giữa TPR và FPR.
- Diện tích dưới đường cong ROC (AUC): Là chỉ số tóm tắt hiệu suất chung của bộ phát hiện. Giá trị càng cao thì khả năng phát hiện mẫu đối kháng càng tốt.


2.1.5.2. Ký hiệu và định nghĩa

Ký hiệu	Định nghĩa
ξ	Không gian ảnh
I	Ảnh đầu vào
$H \times W \times C$	Chiều cao, chiều rộng và kênh của ảnh
x	Ảnh sạch
x'	Ảnh bị tấn công
$\tilde{x}$	Ảnh được khử nhiễu
c	Nhân lớp thực của một mẫu đầu vào x
$f_{\theta}(x)$	Đầu ra của mô hình phân loại f với tham số θ
$d(x, x')$	Chỉ số khoảng cách giữa x và x'
$\ \cdot\ _p$	Chuẩn L_p
∇_x	Đạo hàm theo x
L	Hàm mất mát
$\mathcal{D}$	Khối phát hiện
$\mathcal{S}$	Khối khử nhiễu
$\hat{I}$	Hệ số MSCN của ảnh I
β	Tham số hình dạng
σ^2	Phương sai của hàm mật độ xác suất
η	Giá trị trung bình của AGGD
τ_{3D}	Biến đổi tuyến tính 3D
λ_{3D}	Tham số ngưỡng của bộ lọc BM3D
$f_X(x)$	Hàm mật độ xác suất

Bảng 2. Một số ký hiệu được sử dụng.

2.2. Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng


Phương pháp được các tác giả đề xuất là một khung làm việc gồm 2 giai đoạn được mô tả như hình 2. Ta có thể thấy 2 thành phần chính đó là *bộ phát hiện* và *bộ khử nhiễu*.



Hình 2. Mô tả tổng quan về quy trình làm việc của phương pháp phòng thủ.

- *Bộ phát hiện* nhận ảnh đầu vào và nhận diện ảnh đó có phải là một mẫu đối kháng hay không. Nếu ảnh được xác định là "*sạch*" thì ảnh đó được chuyển tiếp tới bộ phân loại, ngược lại ảnh được đưa tới *bộ khử nhiễu*.
- *Bộ khử nhiễu* thực hiện nhiệm vụ giảm thiểu ảnh hưởng của nhiễu đối kháng đối có trong ảnh giúp bộ phân loại hoạt động chính xác hơn.

2.2.1. Bộ phát hiện



Hình 3. Luồng hoạt động của bộ phát hiện.

Hình 3 đã mô tả các giai đoạn chính của bộ phát hiện:

- Trích xuất các hệ số MSCN.
- Thực hiện mô hình hoá các đặc trưng theo phân phối Gauss tổng quát và Gauss tổng quát bất đối xứng.
- Tích hợp đặc trưng từ hai loại phân phối.
- Phân loại ảnh bằng mô hình SVM.

2.2.1.1. Trích xuất hệ số MSCN

Theo như nghiên cứu trong [55] tác giả đã giả định một hình ảnh sạch sở hữu những thuộc tính thống kê đều đặn nhất định. Những giá trị này bị thay đổi khi có nhiễu đối kháng được thêm vào trong ảnh, do đó, bằng cách mô tả những sai lệch này từ sự đều đặn của thống kê sử dụng NSS có thể xác định xem đầu vào có phải nhiễu hay không. Trong giai đoạn đầu tiên của luồng hoạt động, các tác giả thực hiện trích xuất các hệ số MSCN của hình ảnh, các hệ số được tính dựa trên công thức:

$$\hat{I}(i, j) = \frac{I(i, j) - \mu(i, j)}{\sigma(i, j) + c} \quad (2.1)$$


Với i và j là tọa độ điểm ảnh, và c là một hằng số nhỏ được thêm vào để tránh việc chia cho không. Giá trị trung bình cục bộ μ và độ lệch chuẩn cục bộ σ được tính bằng (2.2) và (2.3), tương ứng:

$$\mu(i, j) = \sum_{k=-3}^3 \sum_{l=-3}^3 \omega_{k,l} I_{k,l}(i, j) \quad (2.2)$$

$$\sigma(i, j) = \sqrt{\sum_{k=-3}^3 \sum_{l=-3}^3 \omega_{k,l} (I_{k,l}(i, j) - \mu(i, j))^2} \quad (2.3)$$

Với $\omega = \{\omega_{k,l} \mid k = -3, \dots, 3, l = -3, \dots, 3\}$ là một hàm trọng số Gauss đối xứng hình tròn 2D.

Và để chứng minh cho sự ảnh hưởng của nhiễu đối kháng với hệ số MSCN nhóm tác giả đã đánh giá trên ba cuộc tấn công white-box: FGSM, PGD và CW. Ta có thể thấy ở hình 4a, phía trên hình ảnh gốc với các phiên bản bị tấn công khác nhau tương ứng phía dưới là hệ số MSCN. Có thể thấy được rõ ràng tất cả các cuộc tấn công đều thành



Hình 4. Minh họa mối quan hệ giữa NSS và nhiễu đối kháng.

công đánh lừa mô hình DNN với độ tin cậy cao. Và ở hình 4b cho thấy thống kê của các hệ số MSCN của các hình ảnh, hình ảnh gốc thể hiện phân phối MSCN giống phân phối Gaussian trong khi đó hình ảnh nhiễu lại cho ra một phân phối với những khác biệt đáng kể. Kết quả này cho thấy mỗi mẫu bị tấn công đều có đặc trưng bởi phân phối riêng của nó và không phân phối MSCN giống Gaussian như ảnh sạch.

2.2.1.2. Mô hình hoá bằng phân phối GGD

Công thức phân phối GGD:

$$f_x(x; \beta, \sigma^2) = \frac{\beta}{2\alpha\Gamma(1/\beta)} e^{-\left(\frac{|x|}{\alpha}\right)^\beta} \quad (2.4)$$

Trong đó:

$$\alpha = \sigma \sqrt{\frac{\Gamma(1/\beta)}{\Gamma(3/\beta)}} \quad (2.5)$$

và $\Gamma(\cdot)$ là hàm gamma, được định nghĩa bởi:

$$\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt, \quad a > 0 \quad (2.6)$$

Giá trị của β điều khiển định dạng, và σ^2 là tham số điều khiển phương sai. Trong mô hình hoá bằng GGD đây là cặp giá trị cần quan tâm nhất.

2.2.1.3. Mô hình hoá bằng phân phối AGGD

Để tăng độ chính xác của bộ phát hiện, tác giả sử dụng phân phối AGGD để trích xuất các hệ số liên kề để mô hình hoá tích cặp của các hệ số MSCN lân cận, dọc theo 4 hướng:

- Ngang: $H(i, j) = \hat{I}(i, j) \cdot \hat{I}(i, j + 1)$
- Dọc: $V(i, j) = \hat{I}(i, j) \cdot \hat{I}(i + 1, j)$
- Chéo chính: $D_1(i, j) = \hat{I}(i, j) \cdot \hat{I}(i + 1, j + 1)$
- Chéo phụ: $D_2(i, j) = \hat{I}(i, j) \cdot \hat{I}(i + 1, j - 1)$

Cùng với đó là việc sử dụng phân phối AGGD:

$$f_X(x; v, \sigma_1^2, \sigma_r^2) = \begin{cases} \frac{v}{(\alpha_l + \alpha_r) \Gamma(\frac{1}{v})} e^{-\left(\frac{-x}{\alpha_l}\right)^v}, & x < 0, \\ \frac{v}{(\alpha_l + \alpha_r) \Gamma(\frac{1}{v})} e^{-\left(\frac{x}{\alpha_r}\right)^v}, & x \geq 0. \end{cases}$$

Trong đó:

$$\alpha_{\text{side}} = \sigma_{\text{side}} \sqrt{\frac{\Gamma(\frac{1}{v})}{\Gamma(\frac{3}{v})}}$$

với side có thể là r hoặc l , v đại diện cho tham số hình dạng, và σ_{side}^2 biểu thị các tham số phương sai bên trái hoặc phải.

Giá trị trung bình η được định nghĩa như sau:

$$\eta = (\alpha_r - \alpha_l) \frac{\Gamma(\frac{2}{v})}{\Gamma(\frac{1}{v})}.$$

2.2.1.4. Tích hợp đặc trưng

Từ hai phần trước: Mô hình hoá bằng GGD thu được hai tham số β và σ^2 , và AGGD đặc trưng bởi 4 đặc tính $(\eta, v, \sigma_l^2, \sigma_r^2)$, tổ hợp này tạo thành 16 đặc trưng.

Ghép nối hai tham số thu được từ GGD với 16 tham số từ AGGD thu được một hệ gồm 18 đặc trưng:

$$f = \begin{cases} (\beta, \sigma^2, \eta_H, v_H, \sigma_{l_H}^2, \sigma_{r_H}^2, \eta_V, v_V, \sigma_{l_V}^2, \sigma_{r_V}^2, \\ \eta_{D1}, v_{D1}, \sigma_{l_{D1}}^2, \sigma_{r_{D1}}^2, \eta_{D2}, v_{D2}, \sigma_{l_{D2}}^2, \sigma_{r_{D2}}^2) \end{cases}$$

Những đặc trưng này được sử dụng cho việc xác định ảnh đầu vào có phải mẫu đối kháng hay không ở mô hình SVM.

2.2.1.5. Phân loại ảnh bằng mô hình SVM

Bộ phân loại SVM được huấn luyện có giám sát bằng cách sử dụng tập dữ liệu bao gồm mẫu hình ảnh sạch và mẫu đối kháng.


Đầu vào: 18 đặc trưng được trích xuất.

Đầu ra: Hình ảnh được gán nhãn "clean" (mẫu sạch) hoặc "adversarial" (mẫu đối kháng).

Trong bộ mô hình SVM nhóm tác giả đã sử dụng hạt nhân Sigmoid, là hạt nhân phù hợp cho việc xử lý phân loại nhị phân phi tuyến tính, với bài báo là phân loại theo 2 trường hợp mẫu sạch và mẫu đối kháng.

2.2.2. Bộ khử nhiễu

Mục tiêu chính của bộ khử nhiễu là làm giảm mức độ nhiễu của một mẫu đối kháng và đưa mẫu đó trở lại đa tập dữ liệu ban đầu. Hay nói một cách khác, bộ khử nhiễu cố gắng tái tạo từ một mẫu đối kháng thành một mẫu mới thông qua các phép biến đổi làm giảm ảnh hưởng của nhiễu.



Hình 5. Mô hình hoạt động của bộ lọc Block-Matching 3D.

Trong bài báo, nhóm tác giả sử dụng bộ lọc BM3D để khử nhiễu ảnh. Đầu tiên bộ lọc BM3D tập hợp các mảnh 2D tương tự P của một hình ảnh trong một 3D-block được ký hiệu là $P(P)$. Mức độ tương đồng giữa hai mảnh được đo như sau:

$$P(P) = \{Q : (P, Q) \leq \tau\}$$

Trong đó là khoảng cách bậc hai chuẩn hóa và τ là một giá trị ngưỡng được thiết lập để kiểm tra xem hai mảnh có tương tự nhau hay không. Để tăng tốc quá trình, từ các mảnh

Q tương tự trong 3D-block $P(P)$, chỉ những mảnh N gần nhất với P được chọn để tạo thành nhóm 3D $\tilde{P}(P)$ bao gồm cả P .

Sau bước nhóm là một phép biến đổi tuyến tính τ_{3D} được áp dụng lên mỗi nhóm 3D, sau đó lại là một phép co lại. Cuối cùng một phép nghịch đảo của biến đổi đẳng cự được áp dụng để đưa ra ước tính của mỗi mảnh:


$$\tilde{P}(P) = \tau_{3D}^{-1} \left[\gamma \left(\tau_{3D} \left[\tilde{P}(P) \right] \right) \right]$$

Với γ là ngưỡng phụ thuộc vào λ_{3D} :

$$\gamma(x) = \begin{cases} 0 & \text{nếu } |x| \leq \lambda_{3D} \\ x & \text{trường hợp khác} \end{cases}$$

Những quy trình trên có thể được cải tiến ở bước thứ hai bằng cách sử dụng bộ lọc Wiener. Sự khác biệt của bộ lọc Wiener là so sánh các mảnh được lọc thay vì các mảnh gốc ở bước nhóm, và xử lý các nhóm 3D mới thay vì dùng phép biến đổi tuyến tính với ngưỡng. Chi tiết về quy trình lọc có trong [58].

Tuy nhiên để mở rộng cho cả hình ảnh màu nhóm tác giả thêm thành phần độ sáng Y và hai thành phần sắc độ U và V khi chuyển đổi từ hệ RGB sang không gian màu độ sáng - sắc độ. Sau khi xây dựng khối 3D trên cả ba kênh việc dự đoán tham số ngưỡng λ_{3D} là cần thiết. Do đó nhóm tác giả xây dựng mạng CNN được huấn luyện để tìm ra giá trị tối ưu cho mỗi kênh với từng tập dữ liệu khác nhau được minh hoạ trong hình 6.



Hình 6. Các kiến trúc CNN đề xuất được sử dụng để dự đoán các tham số λ_{3D} của BM3D cho các tập dữ liệu.

Ba mạng lưới CNN được huấn luyện theo phương pháp học có giám sát, việc huấn luyện nhằm mục đích giảm thiểu hàm mất mát giữa đầu ra và giá trị thực tế, là tập các mẫu đối kháng và các tham số khử nhiễu tối ưu. Các giá trị thực tế được xây dựng bằng cách sử dụng tấn công PGD ở các cường độ khác nhau.

Quá trình khử nhiễu có thể tạo ra một số mẫu được phân loại chính xác. Trong những mẫu này chỉ có một mẫu tối đa hoá chỉ số SSIM và được giữ lại trong giá trị thực tế.

CHƯƠNG 3

THỰC NGHIỆM

Trong chương này, chúng ta sẽ tìm hiểu về thực nghiệm của tác giả và triển khai cài đặt bộ phát hiện và khử nhiễu này.

3.1. Thực nghiệm của tác giả

3.1.1. Bộ dữ liệu

Tập dữ liệu được chia thành dữ liệu để huấn luyện mô hình (training), dữ liệu mới dùng để điều chỉnh chỉ số mô hình khi tiếp xúc với dữ liệu mới mà không tổng quát hóa dữ liệu mới dựa trên dữ liệu cũ (validation), dữ liệu mới dùng để kiểm tra (test).

Bộ dữ liệu được sử dụng trong huấn luyện và thực nghiệm là:

– Tập dữ liệu MNIST

- Đây là tập dữ liệu các ảnh số viết tay có giá trị từ 0 đến 9 bằng màu xám, kích thước 28x28.
- Tập dữ liệu này có 70.000 ảnh, trong đó: Training 50.000 ảnh, validation 10.000 ảnh, testing 10.000 ảnh.

– Tập dữ liệu CIFAR-10

- Đây là tập dữ liệu ảnh màu kích thước 32x32, có 10 lớp và 60.000 hình ảnh.
- Trong đó: Training 50.000 ảnh và testing 10.000 ảnh.

– Tập dữ liệu Tiny-ImageNet

- Đây là tập dữ liệu ảnh màu kích thước 64x64, với số lượng lớp hơn 200 lớp.
- Trong đó: Training 500 ảnh, validation 50 ảnh, testing 50 ảnh.

3.1.2. Phương pháp tấn công

Trong phần này, tác giả đã sử dụng một số phương pháp để tạo ra dữ liệu về mẫu đối kháng và sử dụng các phương pháp này để đánh giá hiệu suất của mô hình.

3.1.2.1. Fast Gradient Signed Method

Phương pháp tấn công FGSM sử dụng gradient của hàm mất mát để xác định hướng điều chỉnh cho ảnh đầu vào. Thay vì tối ưu hóa trọng số của mô hình, FGSM tối ưu hóa chính ảnh đầu vào để làm tăng hàm mất mát khiến cho mô hình dự đoán sai. FGSM tính toán gradient của hàm mất mát theo ảnh đầu vào và điều chỉnh ảnh theo hướng của gradient đó. Công thức tổng quát cho FGSM là:

$$\mathbf{x}' = \mathbf{x} + \epsilon \cdot \text{sign}(\nabla_{\mathbf{x}} L_{\theta}(\mathbf{x}, y))$$

- $\mathbf{x}'$ và $\mathbf{x}$ là hình ảnh mẫu đối kháng và hình ảnh ban đầu.
- ϵ là độ lớn của nhiễu.
- θ là tập các tham số đầu vào của mô hình và $\nabla_{\mathbf{x}} L$ tính đạo hàm bậc nhất của hàm mất mát L đối với đầu vào.
- $\text{sign}()$ là hàm vector có cùng hướng trả về giá trị dấu đầu vào, không quan tâm đến độ lớn của giá trị đầu vào.

3.1.2.2. Projected Gradient Descent

Phương pháp tấn công PGD sử dụng gradient của hàm mất mát để xác định hướng điều chỉnh. Ảnh đầu vào được cập nhật qua nhiều bước, mỗi bước sẽ điều chỉnh ảnh theo hướng của gradient, đồng thời đảm bảo rằng ảnh vẫn nằm trong khoảng cho phép. Phần cực đại tìm một mẫu đối kháng tối đa hoá mất mát. Phần cực tiểu nhằm mục đích giảm thiểu lượng đối kháng bị mất đi. Công thức cho PGD là:

$$\min_{\theta} \rho(\theta), \quad \text{where } \rho(\theta) = \mathbb{E}_{(x,y) \sim D} \left[\max_{\delta \in S} L_{\theta}(x + \delta, y) \right]$$

- Trong đó $\mathbb{E}_{(x,y) \sim D}$ biểu thị kỳ vọng theo phân phối D .
- $\mathbb{E}$ là hàm rủi ro, δ là độ lớn của nhiễu và S là tập hợp các nhiễu cho phép.
- $\max_{\delta \in S}$ biểu thị giá trị lớn nhất của hàm mất mát $L_{\theta}(x + \delta, y)$ với δ thuộc không gian S .

3.1.2.3. Carlini và Wagner

Phương pháp tấn công của Carlini và Wagner sử dụng ba phương pháp đo lường khoảng cách khác nhau: L_0 , L_2 và L_∞ . Nhằm vào việc tối thiểu của biến đổi δ và hàm mục tiêu $g(x')$, với $x' = x + \delta$ và $g(x') \leq 0$ nếu và chỉ nếu $f(x') = c$ và $f(x) \neq c$.

$$\min_{\delta} \|\delta\|_p + \lambda g(x + \delta),$$

- Trong đó x' và x là hình ảnh mẫu đối kháng và hình ảnh ban đầu.
- $x + \delta \in [0, 1]^n$, trong đó c là lớp mục tiêu và $\lambda > 0$ là một hằng số được tính toán theo phương pháp tìm kiếm nhị phân.

Với chuẩn L_2 có thể được biểu diễn như sau:

$$\min_{\omega} \frac{1}{2}(\tanh(\omega) + 1 - x)^2 + \lambda g\left(\frac{1}{2}(\tanh(\omega) + 1)\right),$$

- Với $\delta = \frac{1}{2}(\tanh(\omega) + 1) - x$ với điều kiện trong chuẩn L_2

3.1.3. Quy trình huấn luyện

Bộ phát hiện Dữ liệu huấn luyện là tập dữ liệu MNIST, 1000 mẫu sạch được chọn và các mẫu đối kháng sử dụng tấn công PGD. Tương tự với CIFAR và Tiny-ImageNet. Các đặc trưng thu được từ mỗi mẫu được cung cấp làm đầu vào cho bộ phân loại SVM.

Bộ khử nhiễu: Mô hình CNN riêng biệt được huấn luyện để ước tính các tham số cho bộ khử nhiễu. Mô hình huấn luyện:

- 10.000 mẫu được tạo ra bằng cách sử dụng tấn công PGD
- Tỷ lệ học 0.01
- Động lượng 0.9
- 64 epochs với batch-size là 128 cho tập dữ liệu MNIST và CIFAR-10
- 128 epochs với batch-size là 32 cho tập dữ liệu Tiny-ImageNet

3.1.4. Kết quả và đánh giá

Dataset	Method	FGSM	PGD				CW	
			7 steps	20 steps	40 steps	100 steps	$\kappa = 20$	$\kappa = 50$
MNIST	Madry [12]	96.8%	-	-	96.0%	95.7%	96.4%	97.0%
	Thermometer [57]	-	-	-	41.1%	-	-	-
	ME-Net [58]	93.2%	-	-	92.8%	92.2%	98.8%	98.7%
	Our method	97.6%	99.4%	99.4%	99.4%	99.4%	99.2%	98.9%
CIFAR-10	Madry [12]	67.0%	64.2%	-	-	-	78.7%	-
	Thermometer [57]	-	77.7%	-	-	-	-	-
	ME-Net [58]	92.2%	91.8%	91.8%	91.3%	-	93.6%	93.6%
	Our method	95.7%	98.3%	98.2%	98.2%	97.9%	93.8%	92.8%
Tiny-ImageNet	ME-Net [58]	67.1%	66.3%	60.0%	65.8%	-	67.6%	67.4%
	Our method	67.7%	68.8%	69.1%	69.1%	68.9%	68.3%	67.2%


Hình 7. Hiệu suất của khối phòng thủ dưới cuộc tấn công black-box.

Dataset	Method	FGSM	PGD				CW	
			7 steps	20 steps	40 steps	100 steps	$\kappa = 20$	$\kappa = 50$
MNIST	ME-Net [58]	-	-	96.2%	95.9%	95.3%	98.8%	98.7%
	Our method	97.4%	99.4%	99.3%	99.3%	99.3%	99.1%	98.5%
CIFAR-10	ME-Net [58]	85.1%	84.9%	84.0%	82.9%	-	84.0%	77.1%
	Our method	88.4%	95.0%	94.8%	94.8%	94.5%	83.7%	75.8%
Tiny-ImageNet	ME-Net [58]	66.5%	64.0%	62.6%	59.2%	-	58.3%	58.2%
	Our method	67.7%	69.0%	68.9%	68.9%	68.5%	61.2%	60.1%


Hình 8. Hiệu suất của khối phòng thủ dưới cuộc tấn công gray-box.

Dataset	Method	Attack steps				
		7	20	40	100	1000
MNIST	Madry [12]	-	-	93.2%	91.8%	91.6%
	ME-Net [58]	-	-	94.0%	91.8%	91.0%
	Our method	-	-	95.3%	94.9%	94.7%
CIFAR-10	Madry [12]	50.0%	47.1%	47.0%	46.9%	46.8%
	ME-Net [58]	74.1%	61.6%	57.4%	55.9%	55.1%
	Our method	71.2%	70.6%	70.3%	69.9%	69.6%
Tiny-ImageNet	Madry [12]	23.3%	22.4%	22.4%	22.3%	22.1%
	ME-Net [58]	38.8%	30.6%	29.4%	29.0%	28.5%
	Our method	36.0%	35.8%	35.7%	35.2%	34.8%

Hình 9. Hiệu suất của khối phòng thủ dưới cuộc tấn công white-box.



Hình 10. Độ chính xác của bộ phân loại chống lại các cuộc tấn công.



Hình 11. Hiệu suất ROC của khối phát hiện chống lại tấn công white-box.

Dataset	FGSM	PGD	CW	FP(%)
MNIST	100%	100%	100%	1.9%
CIFAR-10	100%	100%	100%	2.0%
Tiny-ImageNet	100%	100%	98%	2.3%

Bảng 3. Tỷ lệ thành công của các phương pháp tấn công và tỷ lệ FP (%) trên các tập dữ liệu

3.2. Thực nghiệm của nhóm

3.2.1. Tổng quan


Được cài đặt dựa trên source code có sẵn của bài báo.

Huấn luyện và chạy thử nghiệm mô hình với tập dữ liệu MNIST và phương pháp tấn công là PGD có độ nhiễu là: $0.03 \leq \epsilon \leq 0.7$ và tham số $\text{norm}=\text{np.inf}$ (L_∞ là giá trị lớn nhất trong các giá trị tuyệt đối của các thành phần của vector đó)

Các file cài đặt và luồng hoạt động:

 CIFAR-10_archi.py	trainh5 train_denoiser and fix import CIFAR10 TinyImageNet
 MNIST_model.py	steps_per_epoch define
 MSCN.py	calculate_mscn_coefficients error 1 dimen for 2 dimen
 PGD_attack.py	adv_img pgdAttack
 README.md	Update README.md
 Tiny_ImageNet_archi.py	trainh5 train_denoiser and fix import CIFAR10 TinyImageNet
 data_preparation_denoiser.py	data denoiser
 data_preparation_detection.py	done detector
 data_prepare.npz	data denoiser
 data_training.npz	done detector
 keras-auto-augment-cifar-10.rar	Add files via upload
 pngtree-the-cocky-dog-lay-quietly-on-the-law...	test
 svm_sigmoid_training.joblib	testDetector
 test.py	train_cnn.h5 and test
 testDenoiser.py	train_cnn.h5 and test
 testDetector.py	data prepare denoiser
 train.h5	trainh5 train_denoiser and fix import CIFAR10 TinyImageNet
 train_cnn.h5	train_cnn.h5 and test
 train_denoiser.py	train denoiser
 train_detector.py	testDetector

Hình 12. Các file cài đặt



Hình 13. Luồng hoạt động

3.2.2. Vấn đề

Không có phiên bản cài đặt trước hay dữ liệu chạy thử nghiệm. Thư viện cũ, sai hàm ở bài báo, các giá trị return không đúng,...

3.2.3. Xử lý vấn đề

Link github đã fix các lỗi cùng với mô hình và dữ liệu đã được huấn luyện:

Repository GitHub: <https://github.com/tthanh25/2DAE>

Hướng dẫn cài đặt: git clone <https://github.com/tthanh25/2DAE> => Cài đặt theo các bước.

Các thư viện cần thiết:

```
!pip install matplotlib cleverhans pandas numpy keras scipy Pillow scikit-image imageio joblib scikit-learn
!pip install tensorflow
!pip install bm3d
```

Phiên bản: TensorFlow version: 2.17.0 CleverHans version: 4.0.0bm3d version: 4.0.3

Trong quá trình cài đặt thư viện nếu báo lỗi thiếu thì các bạn import thêm nhé

Thứ tự chạy file:

1. MNIST_model.py
2. data_preparation_denoiser.py và data_preparation_detector.py
3. train_detector.py và train_denoiser.py
4. chạy file test như test.py / testDenoiser.py / testDetector.py

Hình 14. Các bước chạy thử

Cập nhật phiên bản mới nhất của các thư viện và các hàm:

TensorFlow version: 2.17.0

CleverHans version: 4.0.0

Ngoài ra còn các thư viện như bm3d, pandas, numpy, keras, imageio,...

Các thư viện keras cũ chuyển sang bản mới, ví dụ:

```
from keras.datasets import cifar10
```

Thay thành: `from tensorflow.keras.datasets import cifar10`

Các tham số trong huấn luyện các model:

```
lr=0.01 => learning_rate = 0.01
```

```
nb_epoch=64 => epochs=64
```

```
model.fit_generator() => model.fit()
```

...

Đầu vào và đầu ra của hình ảnh có số chiều và kích thước xác định sai, dẫn đến xung đột giữa các hàm. Do tập dữ liệu MNIST là ảnh xám, các ảnh ban đầu và ảnh nhiễu phải có dạng kích thước là (28,28,1) trong khi đó lại có kích thước là (1,28,28,1)

=> Phải chỉnh lại kích thước cho phù hợp với đầu vào và đầu ra: `np.reshape(img, (28, 28, 1))` và sử dụng `img.squeeze()`

Chỉnh lại kích thước các tham số và các kết quả trả về của các hàm trong việc tính toán MSCN như các hàm: `calculate_ggd_aggd`; `calculate_pair_product_coefficients`; `calculate_features` để có thể sử dụng cho đầu vào tiếp theo:

```
return [alpha, var[0]] => return [alpha, var]
```

```
return [alpha, mean[0], sigma_l[0] ** 2, sigma_r[0] ** 2] => return [alpha, mean, sigma_l ** 2, sigma_r ** 2]
```

```
return np.reshape(a,np.shape(img)[0]*np.shape(img)[1]*np.shape(img)[2])  
=> return a ...
```

Trong khối khởi nhiễu sử dụng hàm `bm3d_rgb` dành cho ảnh màu rgb trong khi sử dụng tập dữ liệu đầu vào là tập dữ liệu ảnh xám MNIST. Cụ thể trong hàm `extract_parameters` => dùng hàm `bm3d`

Tham số `v` và `t` trong cả 2 file `data_preparing_denoiser` và `data_preparing_detector` chưa được khai báo. Kết quả đầu ra của file `data_preparing_denoiser` là `data_prepare_final`

và `data_preparing_detector` là `data_training` chưa đúng với đầu vào của mô hình huấn luyện.


```
v = []
t_values = []
np.savez_compressed('data_training', X=v, Y=t_values)
np.savez_compressed('data_prepare_final', X=np.array(v), Y=np.array(t_values))
```

3.2.4. Kết quả và đánh giá

3.2.4.1. Bộ phát hiện

Nhóm em đã chạy thử trên 1000 bức ảnh và có kết quả là khối phát hiện có độ chính xác lên tới 100 % trên 1000 bức ảnh với độ nhiễu bất kì. Do việc nhận diện các điểm ảnh gây nhiễu bằng hệ số MSCN mang lại kết quả rất tốt. Nhưng hạn chế là nhóm chưa chạy thử trên các tập dữ liệu khác như CIFAR-10 và Tiny-ImageNet.

```
Image 0: Predicted: 1, Actual: 1
Image 0: Khong nhieu Predicted: 0, Actual: 0
Image 1: Predicted: 1, Actual: 1
Image 1: Khong nhieu Predicted: 0, Actual: 0
Image 2: Predicted: 1, Actual: 1
Image 2: Khong nhieu Predicted: 0, Actual: 0
Image 3: Predicted: 1, Actual: 1
Image 3: Khong nhieu Predicted: 0, Actual: 0
Image 4: Predicted: 1, Actual: 1
Image 4: Khong nhieu Predicted: 0, Actual: 0
Image 5: Predicted: 1, Actual: 1
Image 5: Khong nhieu Predicted: 0, Actual: 0
Image 6: Predicted: 1, Actual: 1
Image 6: Khong nhieu Predicted: 0, Actual: 0
Image 7: Predicted: 1, Actual: 1
Image 7: Khong nhieu Predicted: 0, Actual: 0
```




Hình 15. Kết quả chạy bộ phát hiện

3.2.4.2. Bộ khử nhiễu

Nhóm em đã chạy thử trên 200 bức ảnh và có kết quả là khử nhiễu chính xác khoảng 50%. Cụ thể hơn là các bức ảnh với độ nhiễu $\epsilon < 0.2$ có độ chính xác 100% và với $\epsilon \geq 0.2$ thì khử nhiễu không hiệu quả và nhận diện sai.

Lí do là với hệ số nhiễu $\epsilon > 0.1$ thì các vùng nhiễu có thể nhận thấy bằng mắt thường. Trong đó các ảnh nhiễu, mẫu đối kháng phải là những ảnh nhiễu khiến mô hình phân

loại sai mà mắt thường không thể phân biệt được nên việc khử nhiễu đối với ảnh quá nhiễu sẽ không có ý nghĩa.



Hình 16. Kết quả chạy bộ khử nhiễu

CHƯƠNG 4

KẾT LUẬN

Bài báo *Phát hiện và phòng thủ chống lại các mẫu đối kháng trong học sâu sử dụng thống kê cảnh tự nhiên và khử nhiễu thích ứng* đã giúp nhóm em có thêm cái nhìn về các kỹ thuật tấn công về xử lý ảnh và học máy. Đồng thời xây dựng bộ phòng thủ gồm bộ phát hiện và Bộ khử nhiễu nhằm bảo vệ các mô hình học sâu trước mối đe dọa từ các mẫu đối kháng. Qua đó, nhóm em có thể rút ra một số kết luận quan trọng như sau:

- **Tầm quan trọng của việc phát hiện mẫu đối kháng:** Việc phát hiện sớm các mẫu đối kháng là rất cần thiết để bảo vệ các hệ thống học máy. Phương pháp thống kê cảnh tự nhiên có thể giúp nhận diện các mẫu bất thường trong dữ liệu đầu vào.
- **Khử nhiễu thích ứng:** Kỹ thuật khử nhiễu thích ứng cho phép các mô hình học sâu cải thiện khả năng chống lại các cuộc tấn công đối kháng bằng cách điều chỉnh các tham số của mô hình dựa trên các đặc điểm của dữ liệu đầu vào. Không chỉ giúp tăng cường độ chính xác mà còn nâng cao tính ổn định của mô hình. Đồng thời giúp mô hình có thể sử dụng cho nhiều dạng dữ liệu đầu vào hơn.
- **Sự kết hợp giữa bộ phát hiện và bộ khử nhiễu:** Tạo ra một bộ phòng thủ có nhận diện và phòng thủ trước mẫu đối kháng tốt hơn.

Tuy nhiên, việc mở rộng dữ liệu đầu vào còn khó khăn khi mới được thử nghiệm trên tập dữ liệu nhỏ, Trên tập dữ liệu có kích thước ảnh lớn và có cấu trúc phức tạp thì việc phát hiện và khử nhiễu vẫn còn nhiều khó khăn.

Việc huấn luyện mô hình cũng gặp khó khăn do phải liên tục tạo ảnh nhiễu để làm đầu vào cho dữ liệu huấn luyện (Đối với tập dữ liệu MNIST phải tạo ra 10000 ảnh nhiễu để thêm ảnh gốc và ảnh nhiễu vào huấn luyện mô hình). Việc này đòi hỏi tốn rất nhiều tài nguyên, nhưng kết quả của bộ khử nhiễu là đưa ra một hệ số để khử nhiễu và hệ số khử nhiễu này cũng có giá trị gần giống nhau. Vì vậy kết quả của bộ khử nhiễu đối với tập dữ liệu có kích thước và cấu trúc chứa thông tin đơn giản như bộ dữ liệu số từ 1 đến 9 có thể hiệu quả nhưng đối với bộ dữ liệu có kích thước và cấu trúc thông tin phức tạp thì bộ khử nhiễu có thể làm mất vài chi tiết quan trọng nào đó.

Những kết luận này không chỉ giúp nhóm em hiểu rõ hơn về các kỹ thuật phòng thủ mà còn mở ra hướng đi mới cho các nghiên cứu tiếp theo trong lĩnh vực bảo mật học máy sau này.

CHƯƠNG 5

PHỤ LỤC

Đầu tiên ta cần làm rõ, việc nhận diện ảnh có nhiễu sẽ dựa vào hệ số MSCN. Hệ số MSCN cho ảnh gốc và ảnh nhiễu có sự khác biệt. Từ hệ số MSCN này ta sẽ mô hình hóa bằng 2 phân phối là GGD và AGGD.

Với GGD thì sẽ thu được β và σ^2 .

Với AGGD đặc trưng bởi 4 đặc tính $(\eta, v, \sigma_l^2, \sigma_r^2)$, tổ hợp này tạo thành 16 đặc trưng.

Ghép nối hai tham số thu được từ GGD với 16 tham số từ AGGD thu được một hệ gồm 18 đặc trưng:

$$f = \begin{cases} (\beta, \sigma^2, \eta_H, v_H, \sigma_{l_H}^2, \sigma_{r_H}^2, \eta_V, v_V, \sigma_{l_V}^2, \sigma_{r_V}^2, \\ \eta_{D1}, v_{D1}, \sigma_{l_{D1}}^2, \sigma_{r_{D1}}^2, \eta_{D2}, v_{D2}, \sigma_{l_{D2}}^2, \sigma_{r_{D2}}^2) \end{cases}$$

Sau đó các đặc trưng này sẽ xác định được giá trị đầu vào là có nhiễu hay không. Đây là đầu vào cho mô hình SVM sử dụng Sigmoid phân loại nhị phân phi tuyến tính theo 2 trường hợp là mẫu sạch và mẫu đối kháng.

5.1. Ảnh phóng to thu nhỏ và ảnh gốc có cùng phân phối với ảnh gốc hay không?

Trước tiên, ảnh to và ảnh nhỏ sẽ được đưa vào tính toán các tham số đặc trưng. Mô hình SVM sẽ dựa vào các tham số này và dự đoán đây là ảnh sạch hay không.

Hai ảnh này có phân phối GGD và AGGD khác nhau do chứa các giá trị điểm ảnh khác nhau. Dẫn đến các tham số đặc trưng trích xuất từ các phân phối cũng khác nhau, nhưng các tham số đặc trưng giữa 2 ảnh này có thể có tỉ lệ với nhau. Và mục đích cuối cùng là phân loại ảnh sẽ đều là không có nhiễu.

5.2. Các ảnh cùng nhãn có cùng phân phối hay không?

Cũng tương tự như trường hợp ảnh phóng to thu nhỏ và ảnh gốc. Do các điểm ảnh là khác nhau nên phân phối sẽ khác nhau. Đồng thời các tham số đặc trưng cũng sẽ có các giá trị khác nhau.

Tuy nhiên do cùng là một nhãn, cùng cấu trúc và nội dung thông tin bức ảnh nên các tham số đặc trưng và phân phối của chúng sẽ gần giống nhau. Tức là giữa các ảnh cùng

nhân sẽ có sự chênh lệch, biến động nhỏ giữa các phân phối và các tham số đặc trưng. Ví dụ giữa hai ảnh là số 1 với nhau, có tham số đặc trưng là β sẽ chênh lệch nhau 0.001 thì vẫn có sự khác nhau về phân phối và tham số đặc trưng nhưng sẽ đều nhận diện là ảnh không nhiễu.

Nếu các chênh lệch này lớn thì có thể ảnh này không cùng nhân hoặc là ảnh nhiễu.

Mô hình SVM được huấn luyện dựa trên các mẫu ảnh sạch và mẫu đối kháng, dựa trên 18 tham số đặc trưng đã làm tăng tỉ lệ dự đoán chính xác lên. Do có đầu vào càng chi tiết thì tỉ lệ dự đoán đúng sẽ càng tăng.

TÀI LIỆU THAM KHẢO

- [1] Deng, J., Dong, W., Socher, R., Li, L.J., Li, K., Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. In: 2009 IEEE conference on computer vision and pattern recognition, pp. 248–255. IEEE.
- [2] Lin, T.Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C.L. (2014). Microsoft coco: Common objects in context. In: European conference on computer vision, pp. 740–755. Springer.
- [3] Krizhevsky, A., Sutskever, I., Hinton, G.E. (2012). Imagenet classification with deep convolutional neural networks, pp. 1097–1105.
- [4] LeCun, Y., Bottou, L., Bengio, Y., Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE* 86(11), 2278–2324.
- [5] Andor, D., Alberti, C., Weiss, D., Severyn, A., Presta, A., Ganchev, K., Collins, M. (2016). Globally normalized transition-based neural networks. *arXiv preprint arXiv:1603.06042*.
- [6] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*.
- [7] Ren, S., He, K., Girshick, R., Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. In: *Advances in neural information processing systems*, pp. 91–99.
- [8] Hinton, G., Deng, L., Yu, D., Dahl, G.E., Mohamed, A.r., Jaitly, N., Senior, A., Vanhoucke, V., Nguyen, P., Sainath, T.N., et al. (2012). Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. *IEEE Signal processing magazine* 29(6), 82–97.
- [9] Moosavi-Dezfooli, S.M., Fawzi, A., Fawzi, O., Frossard, P. (2017). Universal adversarial perturbations, pp. 1765–1773.
- [10] Xie, C., Wu, Y., Maaten, L.v.d., Yuille, A.L., He, K. (2019). Feature denoising for improving adversarial robustness, pp. 501–509.
- [11] Carlini, N., Katz, G., Barrett, C., Dill, D.L. (2018). Groundtruth adversarial examples.
- [12] Kurakin, A., Goodfellow, I., Bengio, S. (2016). Adversarial machine learning at scale. *arXiv preprint arXiv:1611.01236*.

- [13] Lee, H., Han, S., Lee, J. (2017). Generative adversarial trainer: Defense to adversarial perturbations with GAN. arXiv preprint arXiv:1705.03387.
- [14] Carlini, N., Wagner, D. (2017). Towards evaluating the robustness of neural networks. IEEE Symposium on Security and Privacy (SP), Vol. 1, pp. 39–57.
- [15] Aldahdooh, A., Hamidouche, W., Fezza, S.A., D´eforges, O. (2021). Adversarial Example Detection for DNN Models: A Review, arXiv preprint arXiv:2105.00203.
- [16] Carlini, N., Wagner, D. (2017). Adversarial examples are not easily detected: Bypassing ten detection methods, pp. 3–14.
- [17] Xu, W., Evans, D., Qi, Y. (2017). Feature squeezing: Detecting adversarial examples in deep neural networks. arXiv preprint arXiv:1704.01155.
- [18] Hendrycks, D., Gimpel, K. (2016). Early methods for detecting adversarial images. arXiv preprint arXiv:1608.00530.
- [19] Li, X., Li, F. (2017). Adversarial examples detection in deep networks with convolutional filter statistics, pp. 5764–5772.
- [20] Ma, S., Liu, Y., Tao, G., Lee, W.C., Zhang, X. (2019). Nic: Detecting adversarial samples with neural network invariant checking.
- [21] Bhagoji, A.N., Cullina, D., Mittal, P. (2017). Dimensionality reduction as a defense against evasion attacks on machine learning classifiers. arXiv preprint arXiv:1704.02654.
- [22] Grosse, K., Manoharan, P., Papernot, N., Backes, M., McDaniel, P. (2017). On the (statistical) detection of adversarial examples. arXiv preprint arXiv:1702.06280.
- [23] Feinman, R., Curtin, R.R., Shintre, S., Gardner, A.B. (2017). Detecting adversarial samples from artifacts. arXiv preprint arXiv:1703.00410.
- [24] Ma, X., Li, B., Wang, Y., Erfani, S.M., Wijewickrema, S., Schoenebeck, G., Bailey, J., et al. (2018). Characterizing adversarial subspaces using local intrinsic dimensionality. arXiv preprint arXiv:1801.02613.
- [25] Lu, J., Issararon, T., Forsyth, D. (2017). Safetynet: Detecting and rejecting adversarial examples robustly, pp. 446–454.
- [26] Eniser, H.F., Christakis, M., Wüstholtz, V. (2020). Raid: Randomized adversarial-input detection for neural networks. arXiv preprint arXiv:200202776.
- [27] Sheikholeslami, F., Rezaabad, A.L., Kolter, J.Z. (2021). Provably robust classification of adversarial examples with detection. In: International Conference on Learning Representations.

- [28] Fezza, S.A., Bakhti, Y., Hamidouche, W., Deforges, O. (2019). Perceptual evaluation of adversarial attacks for CNN-based image classification. In: IEEE Eleventh International Conference on Quality of Multimedia Experience (QoMEX), pp. 1–6.
- [29] Wiyatno, R.R., Xu, A., Dia, O., de Berker, A. (2019). Adversarial examples in modern machine learning: A review. arXiv preprint arXiv:1911.05268.
- [30] Goodfellow, I., Shlens, J., Szegedy, C. (2014). Explaining and harnessing adversarial examples. arXiv preprint arXiv:1412.6572.
- [31] Madry, A., Makelov, A., Schmidt, L., Tsipras, D., Vladu, A. (2017). Towards deep learning models resistant to adversarial attacks. arXiv preprint arXiv:1706.06083.
- [32] Moosavi-Dezfooli, S., Fawzi, A., Frossard, P. (2015). Deepfool: a simple and accurate method to fool deep neural networks. arXiv preprint arXiv:1511.04599.
- [33] Szegedy, C., Zaremba, W., Sutskever, I., Bruna, J., Erhan, D., Goodfellow, I., Fergus, R. (2013). Intriguing properties of neural networks. arXiv preprint arXiv:1312.6199.
- [34] Liu, X., Hsieh, C.J. (2019). Rob-GAN: Generator, discriminator, and adversarial attacker, pp. 11234–11243.
- [35] Schmidt, L., Santurkar, S., Tsipras, D., Talwar, K., Madry, A. (2018). Adversarially robust generalization requires more data, pp. 5014–5026.
- [36] Xie, C., Wang, J., Zhang, Z., Ren, Z., Yuille, A.L. (2017). Mitigating adversarial effects through randomization. arXiv preprint arXiv:1711.01991.
- [37] Aldahdooh, A., Hamidouche, W., D’eforges, O. (2021). Revisiting Model’s Uncertainty and Confidences for Adversarial Example Detection. arXiv preprint arXiv:2103.05354v2.
- [38] Geifman, Y., El-Yaniv, R. (2019). SelectiveNet: A Deep Neural Network with an Integrated Reject Option. In: International Conference on Machine Learning.
- [39] Athalye, A., Carlini, N., Wagner, D. (2018). Obfuscated gradients give a false sense of security: Circumventing defenses to adversarial examples. arXiv preprint arXiv:1802.00420.
- [40] Gu, S., Rigazio, L. (2014). Towards deep neural network architectures robust to adversarial examples. arXiv preprint arXiv:1412.5068.
- [41] Bakhti, Y., Fezza, S.A., Hamidouche, W., D’eforges, O. (2019). DDSA: a defense against adversarial attacks using deep denoising sparse autoencoder. IEEE Access 7, 160397–160407.
- [42] Liu, X., Cheng, M., Zhang, H., Hsieh, C.J. (2018). Towards robust neural networks via random self-ensemble, pp. 369–385.

- [43] Lecuyer, M., Atlidakis, V., Geambasu, R., Hsu, D., Jana, S. (2019). Certified robustness to adversarial examples with differential privacy, pp. 656–672.
- [44] Dwork, C., Lei, J. (2009). Differential privacy and robust statistics, pp. 371–380.
- [45] Li, B., Chen, C., Wang, W., Carin, L. (2019). Certified adversarial robustness with additive noise, pp. 9464–9474.
- [46] Dhillon, G.S., Azizzadenesheli, K., Lipton, Z.C., Bernstein, J., Kossaifi, J., Khanna, A., Anandkumar, A. (2018). Stochastic activation pruning for robust adversarial defense. arXiv preprint arXiv:1803.01442.
- [47] Dziugaite, G.K., Ghahramani, Z., Roy, D.M. (2016). A study of the effect of JPG compression on adversarial images. arXiv preprint arXiv:1608.00853.
- [48] Athalye, A., Engstrom, L., Ilyas, A., Kwok, K. (2017). Synthesizing robust adversarial examples. arXiv preprint arXiv:1707.07397.
- [49] Meng, D., Chen, H. (2017). Magnet: a two-pronged defense against adversarial examples, pp. 135–147.
- [50] Zantedeschi, V., Nicolae, M.I., Rawat, A. (2017). Efficient defenses against adversarial attacks, pp. 39–49.
- [51] Samangouei, P., Kabkab, M., Chellappa, R. (2018). DefenseGAN: Protecting classifiers against adversarial attacks using generative models. arXiv preprint arXiv:1805.06605.
- [52] Buckman, J., Roy, A., Raffel, C., Goodfellow, I. (2018). Thermometer encoding: One hot way to resist adversarial examples.
- [53] Yang, Y., Zhang, G., Katabi, D., Xu, Z. (2019). Me-net: Towards effective adversarial robustness with matrix estimation. arXiv preprint arXiv:1905.11971.
- [54] Borkar, T., Heide, F., Karam, L. (2020). Defending against universal attacks through selective feature regeneration. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 709–719.
- [55] Mittal, A., Moorthy, A.K., Bovik, A.C. (2012). No-reference image quality assessment in the spatial domain. IEEE Transactions on Image Processing, vol. 21, no. 12, pp. 4695–4708.
- [56] Sharifi, K., Leon-Garcia, A. (1995). Estimation of shape parameter for generalized gaussian distributions in subband decompositions of video. IEEE Transactions on Circuits and Systems for Video Technology 5(1), 52–56.
- [57] Lasmar, N.E., Stitou, Y., Berthoumieu, Y. (2009). Multiscale skewed heavy tailed model for texture analysis, pp. 2281–2284.

- [58] Dabov, K., Foi, A., Katkovnik, V., Egiazarian, K. (2007). Image denoising by sparse 3-D transform-domain collaborative filtering. *IEEE Transactions on Image Processing* 16(8), 2080–2095.
- [59] Bashar, F., El-Sakka, M.R. (2016). BM3D image denoising using learning-based adaptive hard thresholding, pp. 206–216.
- [60] Lebrun, M. (2012). An analysis and implementation of the BM3D image denoising method. *Image Processing On Line* 2, 175–213.
- [61] Mukherjee, S., Kottayil, N.K., Sun, X., Cheng, I. (2019). CNN-based real-time parameter tuning for optimizing denoising filter performance, pp. 112–125.
- [62] Plotz, T., Roth, S. (2017). Benchmarking denoising algorithms with real photographs. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1586–1595.
- [63] Oord, A.v.d., Kalchbrenner, N., Kavukcuoglu, K. (2016). Pixel recurrent neural networks. *arXiv preprint arXiv:1601.06759*.
- [64] Cubuk, E.D., Zoph, B., Mane, D., Vasudevan, V., Le, Q.V. (2019). Autoaugment: Learning augmentation strategies from data, pp. 113–123.
- [65] Kurakin, A. (2018). Baseline resnet-v2-50, tiny imagenet.
https://github.com/tensorflow/models/tree/master/research/adversarial_logit_pairing.html
- [66] Hendrycks, D., Dietterich, T.G. (2018). Benchmarking neural network robustness to common corruptions and surface variations. *arXiv preprint arXiv:1807.01697*.
- [67] Song, Y., Kim, T., Nowozin, S., Ermon, S., Kushman, N. (2017). Pixeldefend: Leveraging generative models to understand and defend against adversarial examples. *arXiv preprint arXiv:1710.10766*.
- [68] Papernot, N., Goodfellow, I., Sheatsley, R., Feinman, R., McDaniel, P. (2016). CleverHans v1.0.0: an adversarial machine learning library. *arXiv preprint arXiv:1610.00768*.
- [69] Carlini, N., Athalye, A., Papernot, N., Brendel, W., Rauber, J., Tsipras, D., Goodfellow, I., Madry, A., Kurakin, A. (2019). On evaluating adversarial robustness. *arXiv preprint arXiv:1902.06705*.
- [70] Tramer, F., Carlini, N., Brendel, W., Madry, A. (2020). On adaptive attacks to adversarial example defenses. *arXiv preprint arXiv:2002.08347*.
- [71] Wang, Z., Bovik, A.C., Sheikh, H.R., Simoncelli, E.P. (2004). Image quality assessment: from error visibility to structural similarity. *IEEE Transactions on Image Processing* 13(4), 600–612.