

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO MÔN HỌC

Các vấn đề hiện đại trong Công nghệ thông tin

ĐỀ TÀI: ARES

An Automated Evaluation Framework for Retrieval-Augmented
Generation Systems

Giáo viên hướng dẫn: TS. Nguyễn Đức Anh

Danh sách sinh viên: Phạm Bá Danh - 21020289
Lại Đức Thắng - 21020404
Nguyễn Minh Tuấn - 21020395
Hà Sơn Tùng - 21020398

Hà Nội - 2024

Phân Chia Công Việc

Dự Án:
An Automated Evaluation Framework for Retrieval-Augmented Generation Systems

Nhóm: 1

Nhóm Trưởng: Nguyễn Minh Tuấn

Danh Sách Công Việc và Phân Chia

MSV	Thành viên	Công việc	Phân chia điểm
21020289	Phạm Bá Danh	Nghiên cứu tài liệu Thiết kế slide Viết báo cáo phần 1,2	25%
21020404	Lại Đức Thắng	Nghiên cứu tài liệu Thiết kế slide Viết báo cáo phần 5,6	25%
21020395	Nguyễn Minh Tuấn	Nghiên cứu tài liệu Thiết kế slide Tổng hợp báo cáo Trình bày	25%
21020398	Hà Sơn Tùng	Nghiên cứu tài liệu Thiết kế slide Viết báo cáo phần 3,4 Xây dựng, chạy thực nghiệm	25%

Ghi Chú

- Mọi thành viên cần hoàn thành công việc trước thời hạn.
- Báo cáo tiến độ công việc qua nhóm chat.

Mục lục

1	Giới thiệu	4
1	Bối cảnh và lý do nghiên cứu	4
2	Mục tiêu nghiên cứu	5
3	Phạm vi nghiên cứu	5
2	Tổng quan lý thuyết	7
1	Retrieval-Augmented Genemuration (RAG)	7
2	Khái niệm về ARES	7
3	Các framework đánh giá khác	8
3	Phương pháp và kiến trúc của ARES	9
1	Tổng quan về ARES	9
2	Chi tiết về ARES	10
2.1	Tạo bộ dữ liệu tổng hợp	10
2.2	Huấn luyện Các mô hình đánh giá	11
2.3	Xếp hạng các hệ thống RAG với khoảng tin cậy	12
4	Thực nghiệm	14
1	Mục tiêu	14
2	Giới thiệu dữ liệu	14
3	Các hệ thống, mô hình so sánh	15
4	Triển khai thực nghiệm	15
4.1	Hệ thống ARES	15
4.2	Phiên bản ARES của nhóm	16
4.3	Hệ thống RAGAS	17
4.4	Mô hình GPT-4o-mini	19
5	Kết quả thực nghiệm	20
5	Phân tích và Đánh giá	21
1	Metric đánh giá	21
1.1	Kendall's Tau	21
1.2	Accuracy	21
2	Ưu điểm của ARES	22
3	Hạn chế của ARES	23
4	So sánh với các framework khác	23
5	Câu hỏi phản biện	24
6	Kết luận	27
1	Tóm tắt nội dung	27
2	Ý nghĩa của nghiên cứu	28

Danh sách hình vẽ

3.1	Tổng quan về ARES	9
3.2	Ví dụ trong bộ dữ liệu tổng hợp của hệ thống ARES.	10
3.3	Prompt tạo câu hỏi của ARES	11
3.4	Prompt tạo câu trả lời của ARES	11
4.1	Code chạy hệ thống ARES đối với tiêu chí độ liên quan của câu trả lời. . .	15
4.2	Code chạy hệ thống ARES đối với tiêu chí độ liên quan của ngữ cảnh. . . .	16
4.3	Code huấn luyện mô hình của hệ thống ARES	16
4.4	Code chạy hệ thống RAGAS đối với tiêu chí độ liên quan của câu trả lời. .	17
4.5	Code chạy hệ thống RAGAS đối với tiêu chí độ liên quan của ngữ cảnh. . .	18
4.6	Code sử dụng gpt-4o-mini để đánh giá đối với tiêu chí về độ liên quan của câu trả lời.	19
4.7	Code sử dụng gpt-4o-mini để đánh giá đối với tiêu chí về độ liên quan của ngữ cảnh.	19
4.8	Biểu đồ so sánh độ chênh lệch giữa giữa dự đoán của các mô hình, hệ thống về chất lượng của bộ dữ liệu với giá trị thực tế chất lượng của bộ dữ liệu. Context_Diff , Ans_Diff là chênh lệch giữa dự đoán mô hình, hệ thống với chất lượng thực tế trên tiêu chí về độ liên quan ngữ cảnh và độ liên quan của câu trả lời.	20

Danh sách bảng

5.1	Bảng phân tích giữa số lượng nhân và hiệu suất của mô hình với độ đo Kendall's Tau.	22
5.2	Bảng đánh giá ARES và các hệ thống khác dựa trên 2 độ đo Accuracy và Kendall's Tau.	24

Chương 1

Giới thiệu

1 Bối cảnh và lý do nghiên cứu

Hiện nay, trong thời đại mà công nghệ thông tin ngày càng phát triển mạnh mẽ, các hệ thống giúp xử lý ngôn ngữ tự nhiên (NLP) đang ngày càng đóng một vai trò rất quan trọng trong việc cung cấp thông tin và hỗ trợ đưa ra quyết định một cách cực kỳ nhanh chóng. Một trong những phát triển đáng kể đến trong lĩnh vực này là sự phát triển của các hệ thống tạo văn bản dựa trên việc truy xuất các thông tin có sẵn đó hoặc được cho trước là Retrieval-Augmented Generation (RAG)[5]. RAG đã trở thành một phương pháp nổi bật trong các ứng dụng yêu cầu thông tin một cách chính xác, được cập nhật trong thời gian thực mang tính thời sự và phong phú. Nhờ vào khả năng truy xuất và tổng hợp thông tin từ các tài liệu hay các cơ sở dữ liệu lớn, RAG giúp cải thiện chất lượng và tính chính xác của câu trả lời được sinh ra bởi các mô hình ngôn ngữ, đặc biệt trong những ứng dụng yêu cầu tính chính xác cao như trả kiếm tra tính xác thực hay hỗ trợ khách hàng.

Tuy nhiên, sự phức tạp của các hệ thống RAG cũng mang lại rất nhiều thách thức, đặc biệt trong số đó chính là việc làm sao để đánh giá hiệu suất của chúng. Để đảm bảo rằng một hệ thống RAG có khả năng cung cấp thông tin chính xác, đầy đủ và liên quan, cần có các phương pháp đánh giá tin cậy và hiệu quả. Hiện tại, các phương pháp đánh giá truyền thống phần lớn dựa vào sự can thiệp của con người, yêu cầu người kiểm tra phải kiểm tra từng câu trả lời do hệ thống đưa ra dựa theo nhiều tiêu chí (ngữ cảnh, tính chính xác, ...). Quy trình này không những gây tốn kém chi phí mà còn lãng phí thời gian và dễ gây ra các sai lệch do sự khác biệt trong cách đánh giá của từng người, dẫn đến kết quả thiếu sự đồng nhất và tính khách quan.

Bên cạnh đó, khi mà các mô hình RAG ngày càng được áp dụng nhiều trong các lĩnh vực và ứng dụng khác nhau thì nhu cầu mở rộng các phương pháp đánh giá cho những hệ thống RAG mới ngày càng tăng. Điều này đặt ra yêu cầu phát triển các công cụ giúp đánh giá tự động không những có khả năng đánh giá chính xác các hệ thống RAG mà còn có thể sử dụng linh hoạt được ở trong nhiều ngữ cảnh và những loại dữ liệu khác nhau. Đây là lý do để thúc đẩy nhóm tác giả nghiên cứu phát triển ARES (**A**utomated **R**AG **E**valuation **S**ystem)[13] - một framework giúp đánh giá tự động cho các hệ thống RAG, nhằm cung cấp một giải pháp đánh giá hiệu quả, có thể đánh giá các hệ thống RAG trong nhiều ngữ cảnh khác nhau một cách linh hoạt, nhanh chóng và chính xác nhất.

2 Mục tiêu nghiên cứu

Nghiên cứu này nhằm mục tiêu phát triển và thử nghiệm ARES. Framework ARES hướng đến việc cung cấp một phương pháp đánh giá toàn diện, có khả năng đánh giá hiệu suất của các hệ thống RAG thông qua ba tiêu chí chính như sau:

- **Context Relevance - Mức độ liên quan của ngữ cảnh:** Đảm bảo rằng các thông tin được truy xuất để hỗ trợ cho mô hình ngôn ngữ sinh ra câu trả lời phù hợp với câu hỏi được cung cấp, tức là những thông tin được hệ thống RAG truy xuất để trả lời có khả năng bổ sung thông tin và bối cảnh quan trọng cho câu trả lời.
- **Answer Faithfulness - Tính trung thực của câu trả lời:** Đánh giá độ trung thực của câu trả lời dựa trên thông tin được truy xuất, đảm bảo rằng câu trả lời không chứa những thông tin "ảo giác" hoặc suy diễn.
- **Answer Relevance - Tính liên quan của câu trả lời:** Đánh giá xem câu trả lời có đáp ứng đầy đủ yêu cầu của câu hỏi và liên quan đến thông tin được truy xuất hay không.

Để thực hiện các mục tiêu trên, ARES được phát triển với phương pháp sử dụng dữ liệu đào tạo tổng hợp và mô hình ngôn ngữ lớn có kích thước nhỏ (lightweight LLM) nhằm tạo ra các đánh giá chính xác với chi phí thấp. ARES sử dụng một lượng nhỏ các dữ liệu được gán nhãn bởi con người để hiệu chỉnh các mô hình đánh giá, từ đó cải thiện độ tin cậy của các dự đoán và giảm thiểu sự phụ thuộc vào đánh giá thủ công. Điều này giúp ARES không chỉ giảm thiểu chi phí gán nhãn mà còn đảm bảo tính ổn định và nhất quán trong quá trình đánh giá, cho phép nó trở thành một công cụ hữu ích cho các nhà nghiên cứu và phát triển khi muốn so sánh và tối ưu hóa các hệ thống RAG một cách nhanh chóng.

3 Phạm vi nghiên cứu

Phạm vi nghiên cứu của đề tài tập trung vào việc phát triển và thử nghiệm Framework ARES trên các hệ thống RAG trong các tác vụ yêu cầu kiến thức chuyên sâu. Các tác vụ này bao gồm các bài toán chuẩn như KILT[12] và SuperGLUE[15], trong đó có các nhiệm vụ như trả lời câu hỏi (QA), kiểm tra tính đúng đắn của thông tin, và phân tích hội thoại. Các bộ dữ liệu này cung cấp một loạt các câu hỏi và ngữ cảnh phức tạp, đòi hỏi hệ thống RAG phải có khả năng phân tích và truy xuất thông tin đa chiều.

Cụ thể, nghiên cứu này sẽ thử nghiệm ARES trên nhiều hệ thống RAG khác nhau để đánh giá hiệu suất của nó trong việc xác định mức độ liên quan, tính chính xác và tính phù hợp của câu trả lời. Trong quá trình thử nghiệm, ARES sẽ được so sánh với các phương pháp đánh giá hiện có như RAGAS[7] và các mô hình ngôn ngữ lớn khác để xác định ưu điểm và hạn chế của ARES so với các phương pháp truyền thống. Bên cạnh đó, nghiên cứu sẽ kiểm tra khả năng của ARES trong các ngữ cảnh ứng dụng khác nhau, từ những tập dữ liệu chuẩn cho đến những tập dữ liệu mới với đặc điểm riêng biệt, nhằm đánh giá tính linh hoạt và độ tin cậy của framework này.

Nghiên cứu cũng bao gồm việc đánh giá hiệu suất của ARES khi được áp dụng trong các tình huống không có nhiều dữ liệu được gán nhãn, nhằm kiểm tra khả năng của hệ thống trong việc tạo ra các đánh giá chính xác dựa trên số lượng ít các dữ liệu được gán nhãn bởi con người. Điều này rất quan trọng khi áp dụng ARES trong các lĩnh vực cần tối ưu hóa chi phí hoặc trong các ứng dụng có ngữ cảnh đặc thù mà việc chú thích dữ liệu thủ công rất khó thực hiện. Kết quả nghiên cứu sẽ cung cấp một cái nhìn toàn diện về

hiệu suất và tính khả thi của ARES trong việc đánh giá tự động các hệ thống RAG, đóng góp vào việc phát triển các công cụ đánh giá hiện đại và ứng dụng rộng rãi trong lĩnh vực xử lý ngôn ngữ tự nhiên.

Bên cạnh đó, phạm vi nghiên cứu còn bao gồm việc kiểm tra khả năng của ARES trong việc sử dụng các mô hình ngôn ngữ khác nhau cho các tiêu chí đánh giá riêng biệt, chẳng hạn như sử dụng các mô hình ngôn ngữ lớn để đánh giá độ phù hợp của ngữ cảnh, và các mô hình nhẹ hơn để đánh giá tính chính xác của câu trả lời. Điều này giúp tối ưu hóa hiệu quả sử dụng tài nguyên, đồng thời giảm thiểu thời gian tính toán và tăng tính linh hoạt cho ARES khi áp dụng vào các ngữ cảnh và loại dữ liệu khác nhau.

Tóm lại, phạm vi của nghiên cứu này không chỉ là phát triển và thử nghiệm một framework để đánh giá các hệ thống RAG mà còn là đánh giá khả năng tương thích và độ chính xác của ARES trong các điều kiện đa dạng, các ứng dụng khác nhau. Kết quả của nghiên cứu sẽ góp phần phát triển các phương pháp đánh giá tự động trong lĩnh vực NLP, đồng thời cũng mở ra một cách thức, phương thức mới cho việc tối ưu hóa và ứng dụng các hệ thống RAG trong nhiều lĩnh vực khác nhau.

Chương 2

Tổng quan lý thuyết

1 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) là một phương pháp tiên tiến trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), kết hợp giữa các kỹ thuật truy xuất thông tin (retrieval) và tạo văn bản (generation) để tạo ra các câu trả lời hoặc văn bản có tính chính xác và tính liên quan cao. RAG gồm hai thành phần chính: một mô hình truy xuất (retriever) và một mô hình ngôn ngữ (language model) làm nhiệm vụ tạo văn bản.

Khi nhận một câu hỏi từ người dùng, hệ thống RAG sẽ thực hiện truy xuất các đoạn văn bản từ một kho tài liệu lớn để tìm ra những thông tin có liên quan nhất đến câu hỏi. Sau đó thì các đoạn văn bản được chọn sẽ được đưa vào mô hình ngôn ngữ để tạo ra câu trả lời hoặc nội dung văn bản dựa trên thông tin đã được truy xuất. Nhờ vào khả năng truy xuất thông tin từ nhiều nguồn, RAG được ứng dụng rộng rãi trong các tác vụ như trả lời câu hỏi, hỗ trợ khách hàng, kiểm tra tính đúng đắn của thông tin, và thậm chí là các trợ lý ảo.

Ưu điểm của RAG là nó có thể giảm thiểu hiện tượng "ảo tưởng" (hallucinations) thường gặp ở các mô hình ngôn ngữ truyền thống - khi mà mô hình có xu hướng tạo ra các thông tin không có căn cứ hay suy diễn. Nhờ vào việc sử dụng các thông tin truy xuất thực tế, RAG giúp cải thiện độ tin cậy và tính chính xác của câu trả lời, đặc biệt hữu ích trong các ứng dụng yêu cầu tính đúng đắn cao như y tế, pháp lý, và giáo dục. Tuy nhiên, RAG cũng đặt ra thách thức về đánh giá hiệu suất, vì các tiêu chí như mức độ liên quan, độ chính xác và tính phù hợp của câu trả lời khó có thể đánh giá chính xác nếu chỉ dựa vào phương pháp sử dụng con người để đánh giá một cách thủ công.

2 Khái niệm về ARES

ARES (Automated RAG Evaluation System) là một framework đánh giá tự động được phát triển nhằm giải quyết các thách thức trong việc đánh giá các hệ thống RAG. ARES được thiết kế nhằm thay thế quy trình đánh giá thủ công này bằng một hệ thống đánh giá tự động và nhất quán. Với ba tiêu chí chính gồm mức độ liên quan của ngữ cảnh, tính trung thực của câu trả lời, và tính liên quan của câu trả lời, ARES sử dụng các mô hình ngôn ngữ lớn để đánh giá có kích thước nhỏ (lightweight LLM judges) để phân tích và đánh giá hiệu suất của các hệ thống RAG. Đặc biệt, ARES sử dụng dữ liệu tổng hợp được sinh ra bởi các mô hình ngôn ngữ lớn để tinh chỉnh (huấn luyện) các mô hình đánh giá,

nhằm giảm thiểu khối lượng của việc gán nhãn thủ công nhưng vẫn đảm bảo tính chính xác cao trong quá trình đánh giá.

Một điểm nổi bật của ARES là phương pháp suy luận dựa trên dự đoán (prediction-powered inference - PPI[2]). Phương pháp này cho phép ARES tạo ra các khoảng tin cậy (confidence intervals) cho các đánh giá, giúp tăng tính chính xác của phương pháp dựa trên một lượng nhỏ các dữ liệu được gán nhãn. Điều này không chỉ giúp tiết kiệm tài nguyên mà còn đảm bảo rằng các đánh giá của ARES có tính chính xác cao hơn so với các phương pháp truyền thống.

3 Các framework đánh giá khác

Trong lĩnh vực đánh giá các hệ thống RAG, ngoài ARES, còn có một số phương pháp, ứng dụng hay framework đánh giá nổi bật khác như RAGAS và EXAM. Mỗi phương pháp đều có cách tiếp cận riêng để đánh giá hiệu suất của hệ thống RAG dựa trên các tiêu chí mà phương pháp ấy đề ra. Dưới đây là một số phương pháp khác đáng chú ý:

- **RAGAS**

RAGAS[7] là một framework đánh giá dựa trên các câu lệnh được thiết kế thủ công (heuristic prompts) để đánh giá độ chính xác và tính liên quan của câu trả lời. Tuy nhiên, RAGAS sử dụng một tập hợp các câu lệnh cố định, điều này làm hạn chế khả năng thích ứng của nó đối với các bối cảnh hoặc tập dữ liệu khác nhau. Mặc dù RAGAS là một công cụ tiện lợi để đánh giá nhanh các hệ thống tuy nhiên thì RAGAS không thể đảm bảo tính linh hoạt và độ chính xác cao trong các ngữ cảnh khác biệt và thường chỉ phù hợp cho các ứng dụng có yêu cầu đơn giản.

- **EXAM**

EXAM[14] là một framework được thiết kế để đánh giá hệ thống RAG dựa trên phương pháp kiểm tra (examination). Framework này mô phỏng một hệ thống kiểm tra để đánh giá khả năng trả lời của hệ thống RAG. EXAM yêu cầu RAG trả lời một tập hợp các câu hỏi với nhiều câu hỏi phụ liên quan, giúp kiểm tra mức độ hiểu biết và khả năng tổng hợp thông tin của hệ thống. Tuy nhiên, phương pháp này đòi hỏi một lượng lớn dữ liệu và công sức tạo ra bộ câu hỏi chi tiết, do đó khó áp dụng trong các ứng dụng thực tế có quy mô lớn.

- **GPT-Score và AutoCalibrate**

Một số framework mới gần đây như GPT-Score và AutoCalibrate[11] sử dụng các mô hình ngôn ngữ lớn để tự động đánh giá các câu trả lời được đưa ra bởi hệ thống RAG. GPT-Score sử dụng các mô hình GPT để đánh giá nhanh chất lượng câu trả lời dựa trên các câu hỏi và ngữ cảnh được cho trước. Mặt khác AutoCalibrate là một hệ thống đánh giá tự động với khả năng tự điều chỉnh dựa trên phản hồi của người dùng, giúp cải thiện độ chính xác của các đánh giá theo thời gian. Tuy nhiên, các phương pháp này chủ yếu dựa vào các mô hình ngôn ngữ lớn, đòi hỏi tài nguyên tính toán cao và không dễ mở rộng cho các hệ thống RAG có quy mô lớn hoặc cần hiệu quả về chi phí.

Tóm lại, các phương pháp đánh giá hiện nay đều có ưu điểm và hạn chế riêng, và ARES sinh ra như là một giải pháp linh hoạt và tiết kiệm tài nguyên nhờ vào phương pháp sử dụng dữ liệu tổng hợp và kết hợp với phương pháp suy luận dựa trên dự đoán. Nhờ đó, ARES có khả năng đánh giá các hệ thống RAG một cách chính xác, hiệu quả và phù hợp với nhiều ngữ cảnh và mục đích khác nhau, là một lựa chọn hữu ích cho các nhà nghiên cứu và phát triển trong lĩnh vực NLP.

Chương 3

Phương pháp và kiến trúc của ARES

ARES là hệ thống đánh giá tự động dành cho các hệ thống RAG, nhằm đánh giá chất lượng các câu trả lời tự động sinh ra từ các văn bản truy xuất. Hệ thống ARES tự động hóa quy trình đánh giá bằng cách tổng hợp dữ liệu và huấn luyện các mô hình đánh giá, giảm sự phụ thuộc vào các đánh giá thủ công tốn kém. Các thành phần chính của hệ thống bao gồm một bộ tổng hợp dữ liệu, các mô hình đánh giá được huấn luyện từ dữ liệu tổng hợp, và một cơ chế suy luận dựa trên dự đoán để tối ưu hiệu suất đánh giá.

1 Tổng quan về ARES



Hình 3.1: Tổng quan về ARES

Trong phần này, nhóm sẽ trình bày chi tiết cách tạo ra hệ thống ARES của tác giả để tạo ra các đánh giá tự động cho các mô hình RAG. Quy trình tạo ra hệ thống ARES trải qua 3 bước chính, bao gồm:

- **Tạo bộ dữ liệu tổng hợp:** Bước này sẽ trình bày cách tạo ra bộ dữ liệu đánh giá dùng để huấn luyện hệ thống đánh giá tự động.
- **Huấn luyện các mô hình đánh giá:** Dữ liệu được tạo ra ở bước trước sẽ được sử dụng để huấn luyện mô hình đánh giá.
- **Xếp hạng các hệ thống RAG với khoảng tin cậy:** Phương pháp Suy luận dựa trên dự đoán (Prediction-powered Inference - PPI[2]) được kết hợp với đầu ra của các mô hình để tạo ra được điểm số chính xác hơn.

Quy trình này yêu cầu đầu vào cần thiết là một bộ dữ liệu về các đoạn văn bản, một bộ dữ liệu đánh giá được tạo ra bởi con người, và 1 vài ví dụ về câu hỏi-câu trả lời mà

người dùng mong muốn.

2 Chi tiết về ARES

2.1 Tạo bộ dữ liệu tổng hợp

Bước này của bài báo trình bày cách tạo ra dữ liệu để huấn luyện mô hình đánh giá 3 tiêu chí quyết định chất lượng hệ thống RAG: mức độ liên quan của ngữ cảnh, tính trung thực và liên quan của câu trả lời. Ví dụ của bộ dữ liệu được mô tả trong hình 3.2. Để mô hình có thể đánh giá chính xác, bộ dữ liệu cần phải có cả ví dụ tốt và ví dụ không tốt về phản hồi của mô hình RAG trên cả 3 tiêu chí (được đánh nhãn bằng 1 (thỏa mãn) hoặc 0 (không thỏa mãn)). Mục này sẽ mô tả chi tiết về cách ARES tạo ra ví dụ tốt và không tốt đối với mỗi tiêu chí) mà không cần sự can thiệp của con người.

Query	Passage	Answer	Context Relevance	Answer Relevance
How can a ball that is not moving possess energy of position?	Mechanical energy is a combination of the energy of motion or position. This type of energy describes objects that are moving or could move. A moving ball can have energy from motion. An arrow can also have the energy of motion. Both are types of mechanical energy.	The ball holds mechanical energy	1	1

Hình 3.2: Ví dụ trong bộ dữ liệu tổng hợp của hệ thống ARES.

2.1.1 Ví dụ tốt

Định nghĩa. Là ví dụ đáp ứng được cả 3 tiêu chí về độ liên quan ngữ cảnh, độ chính xác và độ liên quan của câu trả lời.

Phương pháp. Để tạo ra ví dụ tốt, tác giả đã sử dụng mô hình ngôn ngữ lớn FLanT5 XXL[3] để sinh ra cặp câu hỏi - câu trả lời từ 1 tập đoạn văn bản mà người dùng cung cấp và ví dụ mà người dùng cung cấp. Cụ thể cách thực hiện bước này bao gồm:

- Tạo câu hỏi: Đầu tiên, tác giả tạo ra một tập các câu hỏi từ các đoạn văn bản với kỹ thuật few-shot prompting như hình 3.3.
- Lọc câu hỏi không tốt: Sau đó, để đảm bảo các câu hỏi được sinh ra từ mô hình có chất lượng cao, tác giả sử dụng 1 kỹ thuật lọc câu hỏi không tốt. Kỹ thuật này lọc những câu hỏi không tốt bằng cách thử nghiệm xem liệu câu hỏi được sinh ra có thể truy xuất được văn bản gốc (văn bản được dùng để sinh ra nó) hay không. Cụ thể, tác giả sử dụng kỹ thuật vector hóa văn bản và câu hỏi sử dụng FAISS IndexFlatL2[8] để tạo chỉ mục và mô hình text-embedding-ada-002 của OpenAI để vector hóa. Sau đó, các vector sẽ được tính điểm tương đồng sử dụng độ đo cosine. Điểm cosine này được coi là độ liên quan giữa câu hỏi và câu trả lời. Nếu văn bản truy xuất nằm trong top-k văn bản liên quan đến câu hỏi thì câu hỏi được coi là tốt. Trong bài báo, tác giả không nói giá trị của k là bao nhiêu.
- Tạo câu trả lời: Cuối cùng, câu trả lời được tạo ra từ cặp câu hỏi - đoạn văn bản sử dụng kỹ thuật few-shot prompting như hình 3.4 với FLanT5 XXL.

2.1.2 Ví dụ không tốt

Định nghĩa Là ví dụ đáp không đáp ứng được 1 trong 3 tiêu chí về độ liên quan ngữ cảnh, độ chính xác và độ liên quan của câu trả lời

- Example #1
Document: <few-shot example here>
Query: <few-shot example here>
- Example #2
Document: <few-shot example here>
Query: <few-shot example here>
- Example #3
Document: <few-shot example here>
Query: <few-shot example here>
- Example #4
Document: <in-domain passage>
Query:

Hình 3.3: Prompt tạo câu hỏi của ARES

- Example #1
Query: <few-shot example here>
Document: <few-shot example here>
Answer: <few-shot example here>
- Example #2
Query: <few-shot example here>
Document: <few-shot example here>
Answer: <few-shot example here>
- Example #3
Query: <few-shot example here>
Document: <few-shot example here>
Answer: <few-shot example here>
- Example #4
Query: <synthetic query here>
Document: <in-domain passage here>
Answer:

Hình 3.4: Prompt tạo câu trả lời của ARES

Phương pháp Để tạo ra các ví dụ tiêu cực cho mỗi tiêu chí, ARES sử dụng hai chiến lược mới, tạo ra cùng số lượng ví dụ tiêu cực với mỗi chiến lược:

- Tạo ví dụ tiêu cực yếu: Đối với các ví dụ tiêu cực về độ liên quan ngữ cảnh, đoạn văn bản trong bộ câu hỏi - đoạn văn bản - câu trả lời trong bộ dữ liệu ví dụ tích cực sẽ được thay bằng cách lấy ngẫu nhiên các đoạn văn không liên quan đến câu hỏi được tạo ra. Đối với các ví dụ tiêu cực về tính chính xác và độ liên quan của câu trả lời, chiến thuật tương tự được sử dụng bằng cách thay câu trả lời bằng các câu trả lời của đoạn văn bản khác.
- Tạo ví dụ tiêu cực mạnh: Đối với các ví dụ tiêu cực về độ liên quan ngữ cảnh, tác giả sử dụng chiến thuật tương tự với tạo ví dụ tiêu cực yếu, nhưng thay vì chọn ngẫu nhiên từ các đoạn văn bản không liên quan, tác giả lấy ngẫu nhiên từ tập các đoạn văn trong cùng 1 tài liệu với đoạn văn cần thay. Nếu đoạn văn bản độc lập (không nằm trong tài liệu nào), tác giả sẽ sử dụng BM25 để lấy ra 10 đoạn giống với đoạn văn bản cần thay nhất và lấy ngẫu nhiên từ chúng. Đối với các ví dụ tiêu cực về tính chính xác và độ liên quan của câu trả lời, tác giả tạo ra prompt để FLanT5 XXL "cố tình" tạo ra câu trả lời không tốt.

2.2 Huấn luyện Các mô hình đánh giá

Trong bước này, ARES huấn luyện ba mô hình đánh giá riêng biệt để kiểm tra 3 tiêu chí về độ liên quan ngữ cảnh, độ chính xác và độ liên quan của câu trả lời:

- **Mô hình đánh giá mức độ liên quan của ngữ cảnh:** Xác định liệu đoạn văn truy xuất có cung cấp đủ thông tin phù hợp để trả lời câu hỏi hay không.

- **Mô hình đánh giá tính trung thực của câu trả lời:** Đảm bảo rằng câu trả lời không chứa các thông tin ngoài lề hoặc "ảo tưởng", bám sát nội dung của đoạn văn và không vượt ra ngoài phạm vi thông tin truy xuất.
- **Mô hình đánh giá tính liên quan của câu trả lời:** Đánh giá xem câu trả lời có đáp ứng đủ yêu cầu của câu hỏi hay không, đảm bảo câu trả lời cung cấp thông tin chính xác và phù hợp với yêu cầu truy vấn.

Các mô hình này sử dụng DeBERTa-v3-Large[6] để làm mô hình cơ cho việc huấn luyện, bằng cách gắn 1 lớp phân loại nhị phân lên DeBERTa-v3-large, sử dụng các kỹ thuật lan truyền ngược (backpropagation) và học tương phản (contrastive learning) để tinh chỉnh các tham số mô hình. Kết quả cuối cùng là các mô hình đánh giá có thể phân loại tích cực (1) hoặc tiêu cực (0) cho mỗi tiêu chí dựa trên đầu vào câu hỏi - đoạn văn bản - câu trả lời.

2.3 Xếp hạng các hệ thống RAG với khoảng tin cậy

Đối với mỗi tiêu chí, ARES sẽ tạo ra 1 khoảng tin cậy bằng cách sử dụng phương pháp suy luận dựa trên dự đoán với đầu vào cần thiết là bộ dữ liệu ưu tiên xác nhận bởi con người, dự đoán trên dữ liệu chưa được gán nhãn. Chi tiết của phương pháp được mô tả ở mục 2.3.1. Sau khi có khoảng tin cậy cho mỗi tiêu chí, ARES sẽ lấy điểm chính giữa của các khoảng đó để làm điểm số cuối cùng cho mỗi tiêu chí. Điểm số đó sẽ được người dùng sử dụng để xếp hạng các hệ thống RAG.

2.3.1 Suy luận dựa trên dự đoán (Prediction-powered inference)

Suy luận dựa trên dự đoán - Prediction-powered inference (PPI)[2] là một phương pháp thống kê cung cấp các khoảng tin cậy chặt chẽ hơn trên một tập nhỏ các điểm dữ liệu đã được gán nhãn bằng cách tận dụng các dự đoán trên một tập dữ liệu không được gán nhãn lớn hơn nhiều. PPI có thể tận dụng cả các điểm dữ liệu đã được gán nhãn và dự đoán của các mô hình đánh giá trên các điểm dữ liệu chưa được gán nhãn để xây dựng các khoảng tin cậy cho hiệu suất của hệ thống RAG

Để làm điều này, PPI sử dụng các mô hình đánh giá để dự đoán điểm số trên dữ liệu đã được đánh giá điểm số bởi con người. Sau đó, PPI sẽ sử dụng điểm dự đoán và điểm thực tế (điểm được đánh giá bởi con người) để học 1 hàm chỉnh lưu được định nghĩa như một thước đo lỗi dự đoán của mô hình học máy. Công thức tổng quát của hàm chỉnh lưu là:

$$\Delta_{\theta} = E[g_{\theta}(X_i, Y_i) - g_{\theta}(X_i, f(X_i))] \quad (3.1)$$

Trong đó:

- g_{θ} là gradient của hàm mất mát ℓ_{θ} với tham số θ .
- X_i và Y_i là các đặc trưng và kết quả thực tế từ tập dữ liệu chuẩn.
- $f(X_i)$ là dự đoán của mô hình học máy cho X_i .

Mục đích của việc sử dụng hàm chỉnh lưu là nhằm xây dựng một tập hợp độ tin cậy về hiệu suất của mô hình, sử dụng mỗi dự đoán trong tập dữ liệu lớn hơn không được gán chú thích. Tập hợp độ tin cậy này sau đó có thể được sử dụng để tạo ra một khoảng tin cậy chặt chẽ hơn về hiệu suất của hệ thống RAG đối với mỗi tiêu chí so với việc chỉ sử dụng các đầu ra được gán chú thích từ hệ thống RAG được đánh giá. Bằng cách tăng cường tập

hợp xác nhận ưu tiên của con người với tập hợp điểm dữ liệu lớn hơn nhiều có dự đoán, PPI cho phép ước lượng sai số của mô hình đánh giá và tạo ra các giới hạn tin cậy cho tỷ lệ thành công và thất bại của hệ thống RAG.

Chương 4

Thực nghiệm

1 Mục tiêu

Mục tiêu của chương này là nhằm đánh giá khả năng hoạt động của hệ thống ARES thông qua link github [ARES](#) tác giả cung cấp so với các mô hình, hệ thống khác. Đồng thời, trong phần thực nghiệm, nhóm còn tự huấn luyện lại mô hình và chạy lại PPI để đánh giá tính tin cậy trong phương pháp của tác giả. Kết quả huấn luyện cho thấy mô hình nhóm huấn luyện lại cho kết quả tốt hơn so với mô hình của tác giả trên tiêu chí về độ liên quan ngữ cảnh.

2 Giới thiệu dữ liệu

Nhóm đã chạy thực nghiệm trên bộ dữ liệu Natural Question. Bộ dữ liệu Natural Questions (NQ)[10] là một tập dữ liệu trả lời câu hỏi. Mỗi ví dụ bao gồm một truy vấn google.com và một trang Wikipedia tương ứng. Mỗi trang Wikipedia có một đoạn văn (hoặc câu trả lời dài) được chú thích trên trang trả lời câu hỏi và một hoặc nhiều khoảng ngắn từ đoạn văn được chú thích có chứa câu trả lời thực tế. Tuy nhiên, bộ dữ liệu này không được sử dụng trực tiếp mà thông qua 3 bộ dữ liệu mà tác giả cung cấp, bao gồm:

- **nq_synthetic_queries.tsv**: Bộ dữ liệu tổng hợp được tác giả cung cấp để huấn luyện mô hình. Bộ dữ liệu này được tác giả tạo ra bằng phương pháp trong bài báo với ví dụ few-shot là dữ liệu trong dữ liệu NQ.
- **nq_unlabeled_output_500_Context_Relevance_Label.tsv**: Bộ dữ liệu bao gồm 500 ví dụ gồm câu hỏi-đoạn văn-câu trả lời và trường Context_Relevance_Label đánh giá xem liệu đoạn văn có liên quan đến câu hỏi hay không, 1 là "có", 0 là "không". Bộ dữ liệu này sẽ được sử dụng để so sánh ARES với các hệ thống, mô hình khác.
- **nq_unlabeled_output_500_Answer_Relevance_Label.tsv**: Bộ dữ liệu bao gồm 500 ví dụ gồm câu hỏi-đoạn văn-câu trả lời và trường Context_Answer_Label đánh giá xem liệu câu trả lời có liên quan đến câu hỏi và đoạn văn hay không, 1 là "có", 0 là "không". Bộ dữ liệu này sẽ được sử dụng để so sánh ARES với các hệ thống, mô hình khác.
- **nq_labeled_output.tsv**: Bộ dữ liệu tương tự với *nq_unlabeled_output_500_Context_Relevance_Label.tsv* nhưng được sử dụng giống như bộ dữ liệu đánh giá được tạo ra bởi con người để kết hợp với phương pháp Suy luận dựa trên dự đoán (PPI).

Hai bộ dữ liệu *nq_unlabeled_output_500_Answer_Relevance_Label.tsv* và *nq_unlabeled_output_500_Context_Relevance_Label.tsv* là dữ liệu được nhóm tách ra từ bộ dữ liệu *nq_unlabeled_output* của tác giả. Nhóm làm điều này là do giới hạn về tài nguyên khi phải chạy thử nghiệm trên các mô hình ngôn ngữ lớn phải trả phí.

3 Các hệ thống, mô hình so sánh

Trong thực nghiệm, nhóm sử dụng 3 hệ thống, mô hình để so sánh với hệ thống ARES, bao gồm:

- Hệ thống RAGAS (Retrieval Augmented Generation Assessment): một framework dùng để đánh giá tự động các hệ thống RAG.
- GPT-4o-mini: Trong bài báo, tác giả sử dụng tính năng này trong phần thực nghiệm với GPT3.5, một mô hình được cung cấp bởi OpenAI. Nhóm đã quyết định sử dụng GPT-4o-mini, một mô hình được đánh giá là có khả năng vượt trội hơn rất nhiều so với GPT3.5. Nhóm muốn so sánh xem liệu ARES có thể vượt trội hơn GPT-4o-mini trong việc đánh giá như tác giả đã chứng minh với GPT3.5 hay không.
- ARES của nhóm: Phiên bản ARES mà nhóm tự huấn luyện lại mô hình và tự chạy phương pháp suy luận dựa trên dự đoán mà không sử dụng code của tác giả.

4 Triển khai thực nghiệm

4.1 Hệ thống ARES

Nhóm tải code từ link github [ARES](#), sử dụng cho việc lấy dữ liệu và chạy hệ thống ARES. Việc này được thực hiện trong Google Colab với GPU T4 14GB RAM. Nhóm chạy code cho tiêu chí về mức độ liên quan ngữ cảnh (Context Relevance) và tính liên quan của câu trả lời (Answer Relevance) như trong hình 4.1, 4.2 của tác giả để có thể lấy được kết quả so sánh.

```
[ ] from ares import ARES

ppi_config = {
    "evaluation_datasets": ['/content/nq_unlabeled_output_500_Answer_Relevance_Label.tsv'],
    "few_shot_examples_filepath": "nq_few_shot_prompt_for_judge_scoring.tsv",
    "checkpoints": ['/content/drive/MyDrive/Answer_Relevance_Label_joint_trained_date_time.pt'],
    "labels": ["Answer_Relevance_Label"],
    "gold_label_paths": ["nq_labeled_output.tsv"],
    # "model_choice":
}

ares = ARES(ppi=ppi_config)
results = ares.evaluate_RAG()
print(results)
```

Hình 4.1: Code chạy hệ thống ARES đối với tiêu chí độ liên quan của câu trả lời.

```
[ ] from ares import ARES

ppi_config = {
    "evaluation_datasets": ["/content/nq_unlabeled_output_500_Context_Relevance_Label.tsv"],
    "few_shot_examples_filepath": "nq_few_shot_prompt_for_judge_scoring.tsv",
    "checkpoints": ["/content/drive/MyDrive/Context_Relevance_Label_joint_trained_date_time.pt"],
    "labels": ["Context_Relevance_Label"],
    "gold_label_paths": ["nq_labeled_output.tsv"],
    # "model_choice":
}

ares = ARES(ppi=ppi_config)
results = ares.evaluate_RAG()
print(results)
```

Hình 4.2: Code chạy hệ thống ARES đối với tiêu chí độ liên quan của ngữ cảnh.

4.2 Phiên bản ARES của nhóm

Tuy tác giả đã cung cấp checkpoint của mô hình và viết code chạy PPI, nhóm vẫn muốn tự huấn luyện lại mô hình và kết hợp nó với PPI để chứng minh được rằng phương pháp mà tác giả nêu ra là đáng tin cậy.

Trong quá trình huấn luyện mô hình, nhóm gặp phải 1 số khó khăn. Mặc dù ARES cung cấp tính năng huấn luyện mô hình như trong hình 4.3, nhóm gặp khó khăn trong việc sử dụng chức năng này của ARES do 1 T4 GPU là không đủ. Nhóm đã thực hiện việc chuyển code sang Kaggle để chạy với 2 T4 GPU nhưng lại gặp khó khăn bởi vì ARES không được thiết kế cho việc huấn luyện cho việc chạy trên nhiều GPU. Cuối cùng, nhóm quyết định sẽ tự huấn luyện lại mô hình sử dụng thư viện Transformers của Huggingface trên Kaggle và chạy PPI bằng cách tải code trên github [ppi_py](#) để chạy PPI. Quá trình huấn luyện và chạy PPI của nhóm có thể xem ở link <https://www.kaggle.com/code/htng177/cac-van-de-hien-dai-deberta-v3-large>

```
[ ] from ares import ARES

ues_idp_config = {
    "in_domain_prompts_dataset": "/content/nq_few_shot_prompt_for_judge_scoring.tsv",
    "unlabeled_evaluation_set": "/content/nq_unlabeled_output_500_Answer_Relevance_Label.tsv",
}

%cd /content/drive/MyDrive

# Training Classifier
classifier_config = {
    "training_dataset": ["/content/nq_synthetic_queries.tsv"],
    "validation_set": ["/content/nq_ratio_0.7.tsv"],
    "label_column": ["Context_Relevance_Label"],
    "num_epochs": 10,
    "patience_value": 3,
    "learning_rate": 5e-6,
    "assigned_batch_size": 1,
    "gradient_accumulation_multiplier": 16,
    "model_choice": "microsoft/deberta-v3-base",
    "validation_set_scoring": True,
}
```

Hình 4.3: Code huấn luyện mô hình của hệ thống ARES

4.3 Hệ thống RAGAS

Nhóm tải code từ link github [RAGAS](#), sử dụng cho việc lấy dữ liệu và chạy hệ thống RAGAS. Môi trường sử dụng và tiêu chí đánh giá được thực hiện giống như với hệ thống ARES ở mục 4.1. Code mà nhóm sử dụng được trình bày ở hình 4.4 và hình 4.5.

```
[ ] from datasets import Dataset
import pandas as pd
from ragas import evaluate
from ragas.metrics import answer_relevancy

def load_and_prepare_dataset(file_path):
    # Load the dataset from the TSV file
    dataset_df = pd.read_csv(file_path, delimiter='\t')

    dataset_df = dataset_df.dropna(subset=['Answer_Relevance_Label'])

    # Convert 'Context_Relevance_Label' to string if it is not already
    dataset_df['Answer_Relevance_Label'] = dataset_df['Answer_Relevance_Label'].astype(str)

    # Use 'Context_Relevance_Label' as 'ground_truth'
    prepared_data = {
        'question': dataset_df['Query'].tolist(),
        'contexts': [[doc] for doc in dataset_df['Document'].tolist()],
        'answer': dataset_df['Answer'].tolist(),
        'ground_truth': dataset_df['Answer_Relevance_Label'].tolist(),
    }

    # Convert to HuggingFace's Dataset format
    dataset = Dataset.from_dict(prepared_data)
    return dataset

file_path = "/content/nq_unlabeled_output_500_Answer_Relevance_Label.tsv"
prepared_dataset = load_and_prepare_dataset(file_path)

# Specify metrics
metrics = [
    answer_relevancy
]

evaluator_llm = LangchainLLMWrapper(ChatOpenAI(model="gpt-4o-mini-2024-07-18"))
# Evaluate
result = evaluate(prepared_dataset, metrics=metrics, llm=evaluator_llm)

print(result)
```

Hình 4.4: Code chạy hệ thống RAGAS đối với tiêu chí độ liên quan của câu trả lời.

```

from datasets import load_dataset, Dataset
from ragas import evaluate
from ragas.metrics import context_recall, context_precision
import pandas as pd
import os
from ragas.llms import LangchainLLMWrapper
from langchain_openai.chat_models import ChatOpenAI

def load_and_prepare_dataset(file_path):
    # Load the dataset from the TSV file
    dataset_df = pd.read_csv(file_path, delimiter='\t')

    # Remove rows where 'Context_Relevance_Label' has no values
    dataset_df = dataset_df.dropna(subset=['Context_Relevance_Label'])

    # Convert 'Context_Relevance_Label' to string if it is not already
    dataset_df['Context_Relevance_Label'] = dataset_df['Context_Relevance_Label'].astype(str)

    # Use 'Context_Relevance_Label' as 'ground_truth'
    prepared_data = {
        'question': dataset_df['Query'].tolist(),
        'contexts': [[doc] for doc in dataset_df['Document'].tolist()], # Contexts are expected to be list of lists
        'answer': dataset_df['Answer'].tolist(),
        'ground_truth': dataset_df['Context_Relevance_Label'].tolist(), # Using 'Context_Relevance_Label' as 'ground_truth'
    }

    # Convert to HuggingFace's Dataset format
    dataset = Dataset.from_dict(prepared_data)
    return dataset

# Load and prepare the dataset
file_path = "/content/nq_unlabeled_output_500_Context_Relevance_Label.tsv" # Update with the actual file path
prepared_dataset = load_and_prepare_dataset(file_path)

evaluator_llm = LangchainLLMWrapper(ChatOpenAI(model="gpt-4o-mini-2024-07-18"))
# Specify metrics
metrics = [
    context_precision,
    context_recall,
]

result = evaluate(prepared_dataset, metrics=metrics, llm=evaluator_llm) # Pass the initialized llm
print(result)

```

Hình 4.5: Code chạy hệ thống RAGAS đối với tiêu chí độ liên quan của ngữ cảnh.

4.4 Mô hình GPT-4o-mini

Hệ thống ARES cung cấp tính năng sử dụng mô hình ngôn ngữ lớn để đánh giá trên các tiêu chí của họ. Hình 4.6 và 4.7 là code nhóm sử dụng để thực hiện thực nghiệm.

```
[ ] from ares import ARES

ues_idp_config = {
    "in_domain_prompts_dataset": "nq_few_shot_prompt_for_judge_scoring.tsv",
    "unlabeled_evaluation_set": "/content/nq_unlabeled_output_500_Answer_Relevance_Label.tsv",
    "model_choice" : "gpt-4o-2024-11-20"
}

ares = ARES(ues_idp=ues_idp_config)
results = ares.ues_idp()
print(results)
```

Hình 4.6: Code sử dụng gpt-4o-mini để đánh giá đối với tiêu chí về độ liên quan của câu trả lời.


```
[ ] from ares import ARES

ues_idp_config = {
    "in_domain_prompts_dataset": "nq_few_shot_prompt_for_judge_scoring.tsv",
    "unlabeled_evaluation_set": "/content/nq_unlabeled_output_500_Context_Relevance_Label.tsv",
    "model_choice" : "gpt-4o-mini-2024-07-18"
}

ares = ARES(ues_idp=ues_idp_config)
results = ares.ues_idp()
print(results)
```

Hình 4.7: Code sử dụng gpt-4o-mini để đánh giá đối với tiêu chí về độ liên quan của ngữ cảnh.

5 Kết quả thực nghiệm



Hình 4.8: Biểu đồ so sánh độ chênh lệch giữa giữa dự đoán của các mô hình, hệ thống về chất lượng của bộ dữ liệu với giá trị thực tế chất lượng của bộ dữ liệu. **Context_Diff**, **Ans_Diff** là chênh lệch giữa dự đoán mô hình, hệ thống với chất lượng thực tế trên tiêu chí về độ liên quan ngữ cảnh và độ liên quan của câu trả lời.

Hình 4.8 là biểu đồ kết quả thực nghiệm của nhóm. Biểu đồ này thể hiện chênh lệch dự đoán chất lượng bộ dữ liệu của mô hình, hệ thống với chất lượng bộ dữ liệu đó trên thực tế. Nhóm không thể huấn luyện mô hình với tiêu chí về độ liên quan của câu trả lời bởi vì mặc dù đã để batchsize rất thấp nhưng vẫn bị gặp hiện tượng tràn RAM, nên nhóm chỉ thực hiện lại huấn luyện với tiêu chí độ liên quan ngữ cảnh.

Nhìn vào biểu đồ, nhóm thấy rằng sử dụng ARES với PPI luôn cho kết quả chính xác nhất, sau đó đến gpt-4o-mini và cuối cùng là ARES chỉ sử dụng LLM, RAGAS. Điều này cho thấy sự hiệu quả trong phương pháp của tác giả khi kết hợp các mô hình học máy với phương pháp Suy luận dựa trên dự đoán, khi nó có điểm số cao hơn rất nhiều kể cả khi so sánh với các mô hình ngôn ngữ lớn như gpt-4o-mini.

Đặc biệt, trong kết quả thực nghiệm, ARES do nhóm tự huấn luyện đạt độ chính xác cao hơn rất nhiều so với hệ thống ARES của tác giả. Điều này có thể do sự khác biệt trong việc huấn luyện mô hình của nhóm, bao gồm 2 lý do. Thứ nhất, nhóm sử dụng một lớp phân loại làm đầu ra cho mô hình khác với lớp phân loại của tác giả. Thứ hai, trong quá trình huấn luyện mô hình, nhóm nhận ra rằng mô hình chỉ học hiệu quả trong 2 epoch đầu và bắt đầu overfit từ epoch thứ 3, trong khi mô hình của tác giả được huấn luyện trong 3 epoch.

Chương 5

Phân tích và Đánh giá

1 Metric đánh giá

Trong phần này, nhóm sẽ đề cập đến những đơn vị đo lường mà tác giả sử dụng để đánh giá độ hiệu quả của hệ thống ARES.

1.1 Kendall's Tau

Kendall's Tau là một thước đo thống kê dùng để đánh giá mức độ tương quan giữa hai tập dữ liệu đã được xếp hạng theo thứ tự. Chỉ số này rất hữu ích để so sánh mức độ tương đồng giữa hai bộ sắp xếp thứ tự hoặc kiểm tra xem liệu hai tập dữ liệu đó có xu hướng xếp hạng theo cách giống nhau hay không.

Kendall's Tau sẽ tính toán số lượng các cặp dữ liệu có thứ tự giống nhau (cặp "đồng thuận") và các cặp dữ liệu có thứ tự khác nhau (cặp "bất đồng") giữa hai bộ xếp hạng. Công thức của Kendall's Tau dựa trên sự chênh lệch giữa số cặp đồng thuận và số cặp bất đồng.

Giá trị của Kendall's Tau nằm trong khoảng từ -1 đến 1, có ý nghĩa như sau:

- **1**: Hai bộ xếp hạng hoàn toàn đồng nhất với nhau (tương quan hoàn toàn dương).
- **-1**: Hai bộ xếp hạng hoàn toàn đối nghịch nhau (tương quan hoàn toàn âm).
- **0**: Không có sự tương quan giữa hai bộ xếp hạng, cho thấy hai biến không có mối quan hệ nào.

1.2 Accuracy

Khi xây dựng mô hình phân loại chúng ta sẽ muốn biết một cách khái quát tỷ lệ các trường hợp được dự báo đúng trên tổng số các trường hợp là bao nhiêu. Tỷ lệ đó được gọi là độ chính xác. Độ chính xác giúp ta đánh giá hiệu quả dự báo của mô hình trên một bộ dữ liệu. Độ chính xác càng cao thì mô hình của chúng ta càng chuẩn xác. Độ chính xác được tính theo công thức:

$$\text{Accuracy} = \frac{TP + TN}{\text{total sample}}$$

Trong đó:

- *TP* (True Positive): Số lượng ví dụ được dự đoán đúng là 1.
- *TN* (True Negative): Số lượng ví dụ được dự đoán đúng là 0.
- **Total sample**: Tổng số ví dụ trong bộ dữ liệu.

2 Ưu điểm của ARES

ARES mang lại nhiều ưu điểm tích cực trong việc đánh giá các hệ thống RAG. Nó có thể giúp người dùng tự động hóa quy trình đánh giá các hệ thống RAG mà không tốn nhiều chi phí và công sức. ARES chỉ yêu cầu sử dụng một lượng nhỏ dữ liệu được gán nhãn bởi con người nhưng vẫn cho hiệu quả cao trong việc đánh giá.

Bên cạnh đó, ARES cũng đánh giá khá toàn diện và chính xác bằng cách xác định 3 tiêu chí mức độ liên quan của ngữ cảnh, tính trung thực của câu trả lời, tính liên quan của câu trả lời. Đồng thời ở quá trình tạo bộ dữ liệu dùng cho việc huấn luyện các mô hình LLM đánh giá 3 tiêu chí trên, tác giả cũng đã sử dụng cả ví dụ đúng, ví dụ sai để phát hiện, ví dụ sai khó phát hiện kết và huấn luyện dựa trên mô hình cơ sở DeBERTa-v3-Large[6], một mô hình khá phổ biến huấn luyện trên 80GB dữ liệu và có khả năng tốt trên các nhiệm vụ về hiểu ngôn ngữ tự nhiên. Điều này giúp các mô hình LLM có sự đánh giá chính xác hơn cho các hệ thống RAG sau khi đã được huấn luyện. Sau khi có kết quả đánh giá từ các hệ thống LLM, ARES còn kết hợp với phương pháp PPI chỉ sử dụng rất ít dữ liệu được gán nhãn bởi con người nhưng lại giúp cho kết quả đánh giá được chính xác hơn rất nhiều.

PPI Labeled Count	NQ		MultiRC		ReCoRD	
	C.R.	A.R.	C.R.	A.R.	C.R.	A.R.
400	1.0	1.0	0.89	0.94	0.89	0.94
300	0.89	1.0	0.94	0.89	0.83	0.89
200	0.83	1.0	0.83	0.94	0.83	0.83
150	0.72	1.0	0.83	0.89	0.72	0.83
100	0.44	1.0	0.67	0.67	0.67	0.83
50	0.44	0.94	0.61	0.44	0.56	0.67
25	0.44	0.89	0.56	0.44	0.44	0.56

Bảng 5.1: Bảng phân tích giữa số lượng nhãn và hiệu suất của mô hình với độ đo Kendall's Tau.

Bảng [2] mô tả mức độ hiệu quả của ARES tương ứng với số lượng dữ liệu được gán nhãn bởi con người. Có thể thấy khi sử dụng ít hơn 150 dữ liệu được gán nhãn bởi con người thì hiệu suất của ARES khá thấp, nhưng khi sử dụng 150 dữ liệu trở lên thì hiệu quả khá cao vì thế tác giả có khuyến nghị nên sử dụng ít nhất 150 dữ liệu được gán nhãn.

ARES cũng thể hiện sự hoạt động tốt trên nhiều lĩnh vực điều này chứng minh qua việc tác giả đã tiến hành thử nghiệm ARES ở nhiều bộ dataset trên các lĩnh vực khác nhau nhưng vẫn cho kết quả rất tốt, lớn hơn rất nhiều so với các phương pháp khác.

3 Hạn chế của ARES

ARES tuy sở hữu nhiều ưu điểm vượt trội, nhưng cũng tồn tại một số nhược điểm cần xem xét khi áp dụng vào thực tế.

Đầu tiên, ARES sử dụng các mô hình lớn như FLAN-T5-XXL (11,3 tỷ tham số) hay DeBERTa-v3-Large (304 triệu tham số) nên sẽ yêu cầu phần cứng mạnh để vận hành hiệu quả đặc biệt là các GPU với bộ nhớ tối thiểu khoảng 32GB.

Tiếp theo đó, ARES mới chỉ được thử nghiệm và hoạt động tốt ở tiếng Anh. Tuy nhiên, các ngôn ngữ khác, đặc biệt là những ngôn ngữ ít tài nguyên hơn, có thể sẽ có hiệu suất thấp hơn nên điều này cũng cần phải nghiên cứu và phát triển thêm.

Ngoài ra, khi tìm hiểu sâu trên github của tác giả thì chúng em có nhận thấy tác giả cũng chưa có sự phân biệt rõ ràng giữa tính trung thực và tính liên quan của câu trả lời. Nhiều người cũng có cùng thắc mắc như chúng em và cũng có đặt câu hỏi trên github và tác giả có phản hồi là sẽ phát triển thêm trong tương lai tuy nhiên cho đến hiện tại chúng em vẫn chưa thấy có sự cập nhật nào trên github của tác giả.

ARES tuy đã giải quyết một vấn đề lớn cho các hệ thống RAG, tuy nhiên để hệ thống trở nên toàn diện hơn thì cần nghiên cứu và phát triển thêm rất nhiều và ta cũng nên cân nhắc về chi phí khi sử dụng thực tế.

4 So sánh với các framework khác

Trong bài báo tác giả có tiến hành thí nghiệm sử dụng hệ thống ARES, hệ thống RAGAS (phiên bản 0.0.18) và GPT-3.5 (gpt-3.5-turbo-16k) để đánh về độ phù hợp ngữ cảnh và mức độ liên quan câu trả lời trên các bộ dataset khác nhau.

Trong đó NQ[10], HotpotQA[16], MultiRC[9]: tập dữ liệu câu hỏi - câu trả lời, NQ là bộ dataset sử dụng một đoạn văn đơn lẻ để suy luận, HotpotQA là bộ dataset yêu cầu nhiều đoạn văn để suy luận, MultiRC là bộ dataset trả lời các câu hỏi trực tiếp thuộc nhiều lĩnh vực khác nhau (Tin tức, các bài viết về lịch sử/nhân chủng học, sách giáo khoa khoa học tiểu học, báo cáo về sự kiện 9/11, và tiểu thuyết), WoW[4] là bộ dataset đánh giá các tác nhân đối thoại bằng cách liên kết hội thoại của người dùng với các đoạn văn Wikipedia liên quan, trước khi chatbot tạo ra một phản hồi dạng đoạn văn, kết hợp kiến thức từ các đoạn văn đó, FEVER[1] là bộ dataset kiểm tra tính đúng sai của thông tin, xác định xem một đoạn văn có hỗ trợ hay bác bỏ một tuyên bố được đưa ra, và kết quả đầu ra mong đợi là "SUPPORTS" (HỖ TRỢ) hoặc "REFUTES" (BÁC BỎ), ReCoRD[17] là bộ dataset xác định thực thể còn thiếu trong một câu, chủ yếu dựa trên các bài báo tin tức từ CNN và Daily Mail.

Trong bảng 4, các chỉ số Kendall's Tau của hệ thống ARES là cao nhất so với các hệ thống khác trên hầu hết các bộ dữ liệu. Ở 5 dòng đầu tiên là đánh giá dựa trên chỉ số "Kendall's Tau" cho dữ liệu do con người đánh giá, hệ thống RAGAS, hệ thống GPT-3.5, ARES khi không sử dụng PPI và ARES khi sử dụng PPI. Có thể thấy kể cả khi ARES không sử dụng PPI thì vẫn đạt kết quả gần bằng hoặc tốt hơn nhiều so với các đối thủ của nó. Khi kết hợp với PPI thì nó có nhiều chỉ số đứng thứ nhất ở các bộ dataset khác nhau, đặc biệt ở các bộ NQ, WoW, MultiRC đã có chỉ số đạt 1.0 tức là đồng thuận tuyệt đối trong xếp hạng. Ở các bộ dataset khác thì tuy không xếp thứ nhất thì cũng xếp thứ 2.

Về độ chính xác (Accuracy), ARES đứng thứ nhất về độ chính xác (từ 79% trở lên) so

	NQ		HotpotQA		WoW		FEVER		MultiRC		ReCoRD	
	C.R.	A.R.	C.R.	A.R.	C.R.	A.R.	C.R.	A.R.	C.R.	A.R.	C.R.	A.R.
Kendall's Tau for												
Sampled Annotations	0.83	0.89	0.78	0.78	0.78	0.83	0.89	0.89	0.83	0.83	0.72	0.94
Kendall's Tau for												
RAGAS	0.89	0.89	0.94	0.89	0.94	0.94	0.72	0.61	0.83	0.94	0.89	0.44
Kendall's Tau for												
GPT-3.5 Judge	0.89	0.94	0.67	0.94	0.94	0.89	0.78	0.78	0.83	0.89	0.83	0.94
Kendall's Tau for												
ARES LLM Judge	0.89	1.0	0.89	0.94	0.94	1.0	0.83	0.72	0.94	0.83	0.78	0.83
Kendall's Tau for												
ARES	0.94	1.0	0.94	0.94	1.0	1.0	0.89	0.78	0.94	0.89	0.83	0.89
RAGAS Accuracy	31.4%	71.2%	17.2%	76.0%	36.4%	77.8%	23.7%	69.2%	16.1%	75.0%	15.0%	72.8%
GPT-3.5 Judge												
Accuracy	73.8%	95.5%	75.3%	71.6%	84.3%	85.2%	60.4%	59.6%	72.4%	60.3%	81.0%	65.8%
ARES Accuracy	79.3%	97.2%	92.3%	81.3%	85.7%	96.1%	88.4%	78.5%	85.8%	82.7%	67.8%	92.3%

Bảng 5.2: Bảng đánh giá ARES và các hệ thống khác dựa trên 2 độ đo Accuracy và Kendall's Tau.

với GPT-3.5 và RAGAS trên các bộ dữ liệu NQ, HotpotQA, WoW, FEVER, MultiRC. Với bộ dữ liệu ReCoRD, hệ thống ARES tốt hơn so với hệ thống RAGAS và chỉ thua GPT-3.5 trong tiêu chí về độ liên quan của ngữ cảnh.

Tóm lại, bảng 4 chứng tỏ sự vượt trội của ARES so với các framework tương tự như RAGAS hay các mô hình ngôn ngữ lớn có hàng trăm tỷ tham số như GPT-3.5 trên nhiều bộ dữ liệu thuộc các lĩnh vực và nhiệm vụ khác nhau.

5 Câu hỏi phản biện

Câu 1 Mô tả cách chạy mô hình và chất lượng thực nghiệm

Trả lời: Phần thực nghiệm nhóm có trình bày ở chương 4.

Câu 2 Thêm PPI ảnh hưởng đến dự án như thế nào. Khi train LLM thì nó tốt như thế nào ?

Trả lời: PPI không tham gia vào quá trình huấn luyện mô hình mà nó là một bước hậu xử lý. Nó giúp phân tích lỗi của mô hình và điều chỉnh kết quả. Như trong hình 4.8, ARES chỉ với LLM thông thường mặc dù cho kết quả khá tốt nhưng vẫn kém hơn các mô hình ngôn ngữ lớn như GPT-4o-mini. Nhưng khi kết hợp với PPI, nó giúp ARES đạt được kết quả tốt hơn rất nhiều, vượt qua cả hiệu suất của các mô hình ngôn ngữ lớn.

Câu 3 Nếu chạy 1 LLM khác thì nó có tốt hơn không ?

Trả lời: Với các nhiệm vụ cần khả năng hiểu ngôn ngữ để phân loại như trong trường hợp của hệ thống ARES, còn rất nhiều mô hình khác tốt hơn. Điều này có thể thấy thông qua một số benchmark đánh giá sự hiểu biết về ngôn ngữ như MultiNLI, GLUE, SuperGLUE ... Tuy nhiên, các mô hình này thường có hàng tỷ tham số, gây khó khăn trong việc huấn luyện cũng như triển khai trên máy người dùng. Trong khi đó các mô hình có tham số nhỏ hơn 1 tỷ như DeBERTa-V3-Large mặc dù có hiệu suất kém hơn 1 chút so

với các mô hình kia nhưng ưu điểm của nó là người dùng có thể dễ dàng sử dụng và huấn luyện nó với chi phí thấp. Chính vì vậy mà nhóm thấy sử dụng mô hình Deberta-V3-Large là 1 sự lựa chọn hợp lý, cân bằng giữa hiệu suất và chi phí.

Câu 4 PPI thường dùng giải quyết bài toán gì, nó giải quyết gì trong bài báo này ?

Trả lời: Trong bài báo về Suy luận dựa trên dự đoán (PPI), tác giả có sử dụng PPI trong nhiều nhiệm vụ như: ước lượng các đại lượng thống kê, kiểm định giả thuyết, bài toán với dữ liệu không đầy đủ và bị dịch chuyển và trong học máy như phân tích cấu trúc protein, phân loại thiên hà, gen, đánh giá mất rừng ...

Câu 5 Làm sao đánh giá thế nào là câu hỏi tốt khi sinh dữ liệu ?

Trả lời: Trong bài báo, để đảm bảo các câu hỏi được sinh ra từ mô hình có chất lượng cao, tác giả sử dụng 1 kỹ thuật lọc câu hỏi không tốt. Kỹ thuật này lọc những câu hỏi không tốt bằng cách thử nghiệm xem liệu câu hỏi được sinh ra có thể truy xuất được văn bản gốc (văn bản được dùng để sinh ra nó) hay không. Ví dụ, nếu nó truy xuất được văn bản gốc nằm trong top-5 văn bản liên quan thì nó là câu hỏi tốt. Ngược lại, nếu văn bản gốc nằm ngoài top-5 thì câu hỏi này là 1 câu hỏi không tốt.

Chi tiết hơn về cách truy xuất, tác giả sử dụng FAISS IndexFlatL2 để tạo chỉ mục và mô hình text-embedding-ada-002 của OpenAI để vector hóa.

Câu 6 Bài toán về chi phí khi dùng nhiều LLM ?

Trả lời: Khi nói về vấn đề chi phí để sinh dữ liệu, theo nhóm em thấy thì chi phí để sinh ra dữ liệu từ LLM đã ít hơn rất nhiều so với việc sử dụng con người. Với phương pháp tạo dữ liệu từ con người, sẽ có rất nhiều điều phải xem xét như chi phí cao, tìm người thực sự phù hợp với bài toán và thời gian. Ngược lại, khi sử dụng LLM, ta có thể tốn ít chi phí hơn cho việc tạo dữ liệu, thời gian để tạo ra dữ liệu cũng ít hơn so với con người và ta có thể prompt để LLM giải quyết bài toán theo 1 cách phù hợp nhất.

Tuy tốn nhiều tài nguyên khi sử dụng con người để tạo dữ liệu, phương pháp này sẽ cho kết quả chính xác. Một vấn đề khác cần xem xét là LLM cũng sẽ không đảm bảo được câu trả lời nó đưa ra là hoàn toàn chính xác, có thể ảnh hưởng đến chất lượng của bộ dữ liệu.

Câu 7 Tại sao cùng metric Kendall Tau để đánh giá và có metric nào tốt hơn không ?

Trả lời: Trong phần đánh giá, có 2 điều mà tác giả quan tâm là độ chính xác dự đoán và khả năng xếp hạng các mô hình RAG của ARES. Với độ chính xác dự đoán, tác giả sử dụng độ đo Accuracy. Còn với khả năng xếp hạng, có 2 metric khá phổ biến là độ tương quan Pearson và Kendall's Tau. Cả 2 metric này đều đánh giá các mối liên hệ thống kê dựa trên thứ hạng của dữ liệu. Dữ liệu xếp hạng được thực hiện trên các biến được sắp xếp riêng theo thứ tự và được đánh số, rất phù hợp cho đánh giá của tác giả mong muốn. Theo nhóm mình tìm hiểu thì lý do tác giả sử dụng Kendall's Tau thay vì Pearson bởi vì phân phối Tau của Kendall có các đặc tính thống kê tốt hơn.

Câu 8 Với lĩnh vực chuyên môn sâu thì ARES có áp dụng được không ?

Trả lời: Theo nhóm mình thấy thì ARES vẫn có thể áp dụng được cho nhiều nhiệm vụ và lĩnh vực khác nhau. Bằng chứng là khi đánh giá, ARES cho kết quả tốt trên rất nhiều bộ dữ liệu thuộc các lĩnh vực và nhiệm vụ khác nhau. Nhưng để ARES có thể đánh giá chính xác nhất, người dùng có thể sử dụng dữ liệu riêng của mình cho bước Suy luận dựa trên dự đoán (PPI).

Câu 9 Đánh giá trên 3 tiêu chí , có đánh đổi tiêu chí nào để tăng cường 2 tiêu chí còn lại không ?

Trả lời: Nhóm mình chưa hiểu ý của nhóm phản biên lắm nhưng theo mình trong bài báo tác giả đã tạo ra dữ liệu, huấn luyện mô hình tương ứng với từng tiêu chí nên không có việc đánh đổi 1 tiêu chí để tăng cường 2 tiêu chí còn lại.

Câu 10 Có cách nào để ước tính giới hạn số data được gán nhãn của con người cần cho ARES không ?

Trả lời: Trong bài báo, tác giả có làm 1 thực nghiệm để tìm ra số lượng dữ liệu được gán nhãn bởi con người cần để hệ thống ARES có thể hoạt động tốt [2]. Theo như trong thực nghiệm của tác giả thì người dùng cần từ 200 đến 400 ví dụ để ARES có thể hoạt động hiệu quả.

Câu 11 Chi phí thuê người đánh label có cao không ?

Trả lời: Trong bài báo, tác giả sử dụng dữ liệu có sẵn nên không mất chi phí.

Câu 12 ARES đánh giá retrieval hay generation?

Trả lời: ARES đánh giá cả 2 phần của mô hình RAG dựa trên 3 tiêu chí: độ liên quan về mặt ngữ cảnh, độ liên quan và độ chính xác của câu trả lời. Độ liên quan của ngữ cảnh đánh giá đoạn văn có liên quan đến câu hỏi không, đây chính là đánh giá cho phần retrieval. Độ liên quan và độ chính xác của câu trả lời chính là đánh giá cho phần generation.

Câu 13 Độ đo CR , AR so sánh dựa trên tiêu chí nào , độ đo nào ?

Trả lời: Với mỗi tiêu chí, tác giả sử dụng 2 độ đo là Accuracy và Kendall Tau.

Câu 14 Tạo dữ liệu trên LLM thì nó có ảnh hưởng bởi nhiều không , có ảnh hưởng đến mô hình không ?

Trả lời: Đầu tiên, nếu dữ liệu có nhiều thì chắc chắn sẽ ảnh hưởng đến việc huấn luyện mô hình vì mô hình sẽ coi các nhiều đây là đúng. Còn việc tạo dữ liệu trên LLM có tạo ra nhiều không thì có thể là có. Bởi vì các mô hình LLM hiện nay dù tốt đến đâu thì vẫn có khả năng đưa ra dự đoán sai, vậy nên việc có nhiều là không thể tránh khỏi. Trong bài, tác giả đã có cách để hạn chế sự ảnh hưởng của nhiễu bằng cách lọc các câu hỏi không tốt. (Chi tiết xem ở mục 2.1.1).

Câu 15 Tại sao phải làm để bước nhảy là 2.5% và cần phải làm sai các phần còn lại ?

Trả lời: Trong phần đánh giá, bước nhảy 2.5% này là lựa chọn của tác giả, ta có thể chọn 1 số khác. Đối với ý thứ hai, lý do tác giả làm sai phần còn lại bởi vì tác giả muốn tạo ra các hệ thống RAG giả để so sánh, đánh giá. Để tạo ra các hệ thống RAG giả này, tác giả có 1 bộ dữ liệu đã được gán nhãn và cố tình làm sai nó đi và coi dữ liệu sau khi làm sai như 1 hệ thống RAG giả. Các hệ thống RAG giả này khác nhau ở độ chính xác trên 3 tiêu chí mà bài báo đặt ra.

Câu 16 Giải thích kĩ phần PPI sử dụng data do con người label

Trả lời: Ý tưởng về phương pháp Suy luận dựa trên dự đoán (PPI) được trình bày trong mục 2.3.1.

Câu 17 Mô tả input output của hệ thống ARES.

Trả lời: Đầu vào của hệ thống ARES là 1 tập dữ liệu văn bản bao gồm 3 phần: câu hỏi - đoạn văn bản - câu trả lời. Tập dữ liệu này sẽ được đưa qua hệ thống ARES để đánh giá và trả về điểm số dự đoán trên 3 tiêu chí: độ liên quan của ngữ cảnh, độ liên quan của câu trả lời và độ chính xác của câu trả lời.

Chương 6

Kết luận

Ngày nay các hệ thống RAG đang ngày càng trở nên phổ biến đối với các hệ thống trong các tác vụ như tìm kiếm thông tin, trợ lý ảo, và nghiên cứu khoa học, Tuy nhiên hiện tại các phương pháp để đánh giá các hệ thống RAG dựa vào rất nhiều chú thích thủ công, chưa có tự động hóa và khó mở rộng sang các miền khác nhau. Những vấn đề này đã được giải quyết với ARES, một framework tự động hóa dựa trên mô hình ngôn ngữ lớn. ARES cung cấp một cách tiếp cận mới để đánh giá chất lượng câu trả lời của hệ thống RAG theo ba tiêu chí chính: tính phù hợp với ngữ cảnh, tính chính xác của câu trả lời và mức độ liên quan của câu trả lời.

1 Tóm tắt nội dung

Bài báo đã giới thiệu về ARES, một framework tự động hóa để đánh giá các hệ thống RAG (Retrieval-Augmented Generation) – những hệ thống kết hợp khả năng truy xuất thông tin và tạo văn bản nhằm trả lời truy vấn của người dùng. ARES tập trung vào việc đánh giá chất lượng của các câu trả lời thông qua ba tiêu chí chính: tính phù hợp với ngữ cảnh (context relevance), tính trung thực của câu trả lời (answer faithfulness), và mức độ liên quan của câu trả lời (answer relevance). Để thực hiện, ARES sử dụng các mô hình ngôn ngữ lớn (LLMs) được tinh chỉnh, như DeBERTa-v3-Large, để tự động phân tích và xếp hạng câu trả lời.

Điểm đặc biệt của ARES là khả năng ứng dụng phương pháp Suy luận dựa trên dự đoán (PPI) , kết hợp dữ liệu chú thích thủ công nhỏ và dữ liệu dự đoán, giúp giảm yêu cầu về dữ liệu chú thích lớn và tốn kém. Nhờ vậy, ARES đạt được độ chính xác cao trong việc đánh giá, ngay cả khi áp dụng trên các bộ dữ liệu thuộc miền khác nhau như KILT hay SuperGLUE. Điều này cho thấy ARES có thể hoạt động hiệu quả trên nhiều lĩnh vực và loại truy vấn khác nhau, chứng minh tính linh hoạt và khả năng ứng dụng rộng rãi của nó trên thực tế.

ARES không chỉ giảm chi phí và thời gian đánh giá mà còn mở ra tiềm năng phát triển các phương pháp đánh giá tự động mạnh mẽ hơn, giúp người dùng có thể kiểm tra độ tin cậy của các hệ thống RAG. Tuy nhiên, ARES vẫn tồn tại những yếu điểm và cần phải nghiên cứu và phải thiện thêm như việc phân biệt rõ ràng giữa tính trung thực và tính liên quan của câu trả lời, ứng dụng cho nhiều ngôn ngữ khác. Bên cạnh đó, ARES cũng không hỗ trợ tích hợp hệ thống RAG trực tiếp vào quá trình đánh giá, khiến cho việc sử dụng trở nên không thuận tiện.

2 Ý nghĩa của nghiên cứu

RAG (Retrieval-Augmented Generation) là mô hình học máy kết hợp khả năng truy xuất thông tin từ cơ sở dữ liệu với khả năng sinh văn bản để tạo ra các câu trả lời chính xác và phù hợp cho người dùng. RAG hoạt động bằng cách trước tiên truy xuất các thông tin liên quan từ một tập hợp dữ liệu lớn và sau đó sử dụng các thông tin này để tạo ra câu trả lời, giúp cải thiện độ chính xác và tính liên quan của thông tin đầu ra so với các mô hình sinh văn bản đơn thuần. Chính vì thế nên RAG được sử dụng làm nền tảng của nhiều ứng dụng AI hiện đại như tạo Chatbots và hệ thống hỗ trợ khách hàng, tạo nội dung tự động, tóm tắt văn bản, phân tích dữ liệu, ...

Trong bài báo , mô hình ARES đã giúp giảm sự phụ thuộc vào dữ liệu chú thích thủ công tốn kém thời gian và công sức. Thay vì dựa vào con người để đánh giá độ chính xác của từng câu trả lời, ARES sử dụng các mô hình ngôn ngữ lớn (LLMs) để tạo ra dữ liệu tổng hợp và huấn luyện các mô hình đánh giá tự động, giúp tăng tốc độ và hiệu quả đánh giá.

ARES còn tạo ra dữ liệu tổng hợp chất lượng cao bằng cách sử dụng các mô hình ngôn ngữ lớn, từ đó phát triển các ví dụ tích cực và tiêu cực, giúp cải thiện khả năng phân biệt của mô hình đánh giá. Hệ thống này cũng fine-tune ba mô hình đánh giá độc lập, mỗi mô hình tập trung vào một khía cạnh quan trọng của câu trả lời: tính phù hợp ngữ cảnh, tính trung thực và mức độ liên quan. Qua các thử nghiệm trên nhiều tập dữ liệu khác nhau, ARES đã chứng minh khả năng duy trì độ chính xác ngay cả khi đối mặt với sự thay đổi về lĩnh vực và nhiệm vụ ở trong dữ liệu, thể hiện tính linh hoạt và khả năng áp dụng rộng rãi.

ARES không chỉ cung cấp một framework tự động, mà còn giới thiệu phương pháp Suy luận dựa trên dự đoán (PPI), cho phép mô hình dự đoán chính xác dựa trên một tập dữ liệu được gán nhãn nhỏ, từ đó giảm thiểu sai số và tạo sự tin cậy cho hệ thống. Điều này giúp ARES duy trì độ chính xác cao trong đánh giá ngay cả khi đối mặt với sự thay đổi về truy vấn và dữ liệu, thể hiện tính linh hoạt và khả năng áp dụng rộng rãi trong các lĩnh vực khác nhau.

Tài liệu tham khảo

- [1] Mubashara Akhtar, Rami Aly, Christos Christodoulopoulos, Oana Cocarascu, Zhijiang Guo, Arpit Mittal, Michael Schlichtkrull, James Thorne, and Andreas Vlachos, editors. *Proceedings of the Sixth Fact Extraction and VERification Workshop (FEVER)*, Dubrovnik, Croatia, 2023. Association for Computational Linguistics.
- [2] Anastasios Angelopoulos et al. Prediction-powered inference. *arXiv preprint arXiv:2301.09633*, 2023.
- [3] Hyung Won Chung, Le Hou, Shayne Longpre, Barrett Zoph, Yi Tay, William Fedus, Eric Li, Xuezhi Wang, Mostafa Dehghani, Siddhartha Brahma, et al. Scaling instruction-finetuned language models. *arXiv preprint arXiv:2210.11416*, 2022.
- [4] Emily Dinan, Stephen Roller, Kurt Shuster, Angela Fan, Michael Auli, and Jason Weston. Wizard of wikipedia: Knowledge-powered conversational agents. *arXiv preprint arXiv:1811.01241*, 2018.
- [5] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Mingwei Chang. Retrieval augmented language model pre-training. In *Proceedings of the International Conference on Machine Learning*, pages 3929–3938. PMLR, 2020.
- [6] Pengcheng He, Jianfeng Gao, and Weizhu Chen. Debertav3: Improving deberta using electra-style pre-training with gradient-disentangled embedding sharing. *arXiv preprint arXiv:2111.09543*, 2021.
- [7] Jithin James and Shahul Es. Ragas: Evaluation framework for your retrieval augmented generation (rag) pipelines. 2023.
- [8] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547, 2019.
- [9] Daniel Khashabi, Snigdha Chaturvedi, Michael Roth, Shyam Upadhyay, and Dan Roth. Looking beyond the surface: A challenge set for reading comprehension over multiple sentences. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 252–262, 2018.
- [10] Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Jacob Devlin, Kenton Lee, et al. Natural questions: A benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 7:453–466, 2019.
- [11] Yuxuan Liu, Tianchi Yang, Shaohan Huang, Zihan Zhang, Haizhen Huang, Furu Wei, Weiwei Deng, Feng Sun, and Qi Zhang. Calibrating llm-based evaluator. *arXiv preprint arXiv:2309.13308*, 2023.

- [12] Fabio Petroni, Aleksandra Piktus, Angela Fan, Patrick Lewis, Majid Yazdani, Nicola De Cao, James Thorne, Yacine Jernite, Vladimir Karpukhin, Jean Maillard, Vassilis Plachouras, Tim Rocktäschel, and Sebastian Riedel. Kilt: A benchmark for knowledge intensive language tasks. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 2523–2544, Online, 2021. Association for Computational Linguistics.
- [13] Jon Saad-Falcon and Christopher Potts. Ares: An automated evaluation framework for retrieval-augmented generation systems. *arXiv preprint arXiv:2311.09476v2*, March 2024.
- [14] David P. Sander and Laura Dietz. Exam: How to evaluate retrieve-and-generate systems for users who do not (yet) know what they want. In *DESIRES*, pages 136–146, 2021.
- [15] Alex Wang, Yada Pruksachatkun, Nikita Nangia, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. Superglue: A stickier benchmark for general-purpose language understanding systems. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [16] Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. *arXiv preprint arXiv:1809.09600*, 2018.
- [17] Sheng Zhang, Xiaodong Liu, Jingjing Liu, Jianfeng Gao, Kevin Duh, and Benjamin Van Durme. Record: Bridging the gap between human and machine commonsense reading comprehension. *arXiv preprint arXiv:1810.12885*, 2018.